

INSTITUTO TECNOLÓGICO DE AERONÁUTICA



Luiz Filipe Martins Ramos
Bernardo Monteiro Rufino

Desenvolvimento de um classificador de postagens em rede social utilizando Processamento de Linguagem Natural

Trabalho de Graduação
2015

Computação

Número da CDU (tamanho 10)

Luiz Filipe Martins Ramos
Bernardo Monteiro Rufino

**Desenvolvimento de um classificador de postagens em rede social
utilizando Processamento de Linguagem Natural**

Orientador
Prof. Dr. Paulo André Lima de Castro

Engenharia de Computação

SÃO JOSÉ DOS CAMPOS
INSTITUTO TECNOLÓGICO DE AERONÁUTICA

2015

Dados Internacionais de Catalogação-na-Publicação (CIP)
Divisão de Informação e Documentação

Ramos, Luiz Filipe Martins
Rufino, Bernardo Monteiro

Desenvolvimento de um classificador de postagens em rede social utilizando Processamento de Linguagem Natural / Luiz Filipe Martins Ramos, Bernardo Monteiro Rufino

São José dos Campos, 2015

Número de folhas no formato 999f.

Trabalho de Graduação – Divisão de Ciência da Computação –

Instituto Tecnológico de Aeronáutica, 2015. Orientador: Prof. Dr. Paulo André Lima de Castro

1. Inteligência Artificial. 2. Processamento de Linguagem Natural. 3. Redes Bayesianas. I. Nome do segundo autor, se houver. II. Instituto Tecnológico de Aeronáutica. III. Desenvolvimento de um classificador de postagens em rede social utilizando Processamento de Linguagem Natural

REFERÊNCIA BIBLIOGRÁFICA

RAMOS, Luiz Filipe Martins; RUFINO, Bernardo Monteiro. Desenvolvimento de um classificador de postagens em rede social utilizando Processamento de Linguagem Natural. 2015. Total de folhas. Trabalho de Conclusão de Curso. (Graduação) – Instituto Tecnológico de Aeronáutica, São José dos Campos.

CESSÃO DE DIREITOS – (NEGRITO, TAMANHO 12)

NOME DO AUTOR: Luiz Filipe Martins Ramos; Bernardo Monteiro Rufino

TÍTULO DO TRABALHO: Desenvolvimento de um classificador de postagens em rede social utilizando Processamento de Linguagem Natural

TIPO DO TRABALHO/ANO: Graduação / 2015

É concedida ao Instituto Tecnológico de Aeronáutica permissão para reproduzir cópias deste trabalho de graduação e para emprestar ou vender cópias somente para propósitos acadêmicos e científicos. O autor reserva outros direitos de publicação e nenhuma parte desta monografia de graduação pode ser reproduzida sem a autorização do autor.

Luiz Filipe Martins Ramos
Pça Mal-do-Ar Eduardo Gomes, 50
12228-900 – São José dos Campos – SP

Bernardo Monteiro Rufino
Pça Mal-do-Ar Eduardo Gomes, 50
12228-900 – São José dos Campos - SP

**DESENVOLVIMENTO DE UM CLASSIFICADOR DE POSTAGENS EM REDE SOCIAL
UTILIZANDO PROCESSAMENTO DE LINGUAGEM NATURAL**

Essa publicação foi aceita como Relatório Final de Trabalho de Graduação

Luiz Filipe Martins Ramos
Autor

Bernardo Monteiro Rufino
Autor

Prof. Dr. Paulo André Lima de Castro (ITA)
Orientador

Prof. Dr. Carlos Henrique Costa Ribeiro (ITA)
Coordenador do Curso de Engenharia de Computação

São José dos Campos, _____ de _____ de _____

Agradecimentos

4.0141 There is a general rule by means of which the musician can obtain the symphony from the score, and which makes it possible to derive the symphony from the groove on the gramophone record, and, using the first rule, to derive the score again. That is what constitutes the inner similarity between these things which seem to be constructed in such entirely different ways. And that rule is the law of projection which projects the symphony into the language of musical notation. It is the rule for translating this language into the language of gramophone records.

Ludwig Wittgenstein. Tractatus Logico-Philosophicus.

Resumo

Abstract

Sumário

| | |
|--|-------|
| Agradecimentos | p. 6 |
| Resumo | p. 8 |
| Abstract | p. 9 |
| Lista de Figuras | p. 16 |
| Lista de Tabelas | p. 19 |
| Lista de Algoritmos | p. 20 |
| Lista de Abreviaturas | p. 22 |
| 1 Introdução | p. 23 |
| 1.1 Motivação | p. 23 |
| 1.2 Objetivos | p. 23 |
| 1.3 Organização do Texto | p. 24 |
| 2 Definição do Problema | p. 25 |
| 2.1 O Problema de Classificação | p. 25 |
| 2.1.1 Classificação Binária | p. 26 |
| 2.1.2 Classificação <i>Multi-Class</i> | p. 26 |
| 2.1.3 Classificação <i>Multi-Class / Multi-Label</i> | p. 26 |
| 2.2 Objeto de Estudo deste Trabalho | p. 27 |

| | |
|--|-------|
| 3 Fundamentação Teórica | p. 28 |
| 3.1 Definição formal | p. 28 |
| 3.2 Tipos de classificadores | p. 28 |
| 3.3 Redes Bayesianas | p. 29 |
| 3.3.1 Definição | p. 29 |
| 3.3.2 Regra de Bayes | p. 29 |
| 3.3.3 Naïve Bayes | p. 30 |
| 3.3.3.1 Problema a ser resolvido | p. 30 |
| 3.3.3.2 O que são Naïve Bayes | p. 31 |
| 3.3.3.3 Independência Condicional | p. 31 |
| 3.3.3.4 Inferência | p. 32 |
| 3.3.3.5 Classificação utilizando Naïve Bayes | p. 33 |
| 3.3.4 Modelagens para classificação de texto | p. 33 |
| 3.3.4.1 Representação por Bag-of-words | p. 33 |
| 3.3.4.2 Naïve Bayes de Bernoulli | p. 35 |
| 3.3.4.3 Multinomial Naïve Bayes | p. 36 |
| 3.3.4.4 Outras features | p. 39 |
| 3.3.4.5 Smoothing | p. 39 |
| 3.4 Weighted Naïve Bayes | p. 40 |
| 3.4.1 Entropy Weighted Naïve Bayes | p. 41 |
| 3.5 Métodos de avaliação de um classificador | p. 42 |
| 3.5.1 Classificador Binário | p. 43 |
| 3.5.1.1 Acurácia | p. 43 |
| 3.5.1.2 Precisão | p. 44 |
| 3.5.1.3 Abrangência (<i>Recall</i>) | p. 44 |
| 3.5.1.4 Fscore | p. 45 |

| | | |
|----------|---|-------|
| 3.5.2 | Classificador <i>Multi-Class</i> | p. 46 |
| 3.5.2.1 | Matriz de Confusão (<i>Confusion Matrix</i>) | p. 46 |
| 3.5.2.2 | Médias micro e macro (<i>Micro and Macro Averaging</i>) | p. 47 |
| 3.5.2.3 | Fscore | p. 48 |
| 3.5.2.4 | Acurácia | p. 48 |
| 3.5.2.5 | Medida Kappa | p. 49 |
| 4 | Metodologia | p. 51 |
| 4.1 | Plano de desenvolvimento | p. 51 |
| 4.2 | Aquisição de dados | p. 51 |
| 4.3 | Processamento do texto | p. 51 |
| 5 | Proposta de Classificador | p. 52 |
| 6 | Tecnologias Utilizadas | p. 53 |
| 7 | Validação - Experimentos, resultados e análise | p. 54 |
| 8 | Conclusões e Trabalhos Futuros | p. 55 |
| 9 | Instrumentos analisados | p. 56 |
| 9.1 | Características de interesse | p. 56 |
| 9.1.1 | Mecanismo de produção de som | p. 56 |
| 9.1.2 | Timbre | p. 57 |
| 9.1.3 | Tom | p. 57 |
| 9.1.4 | Popularidade | p. 57 |
| 9.2 | Instrumentos escolhidos | p. 57 |
| 9.3 | Flauta doce | p. 58 |
| 9.3.1 | Características | p. 58 |
| 9.3.2 | Análise espectral | p. 59 |

| | | |
|-----------|--|-------|
| 9.3.3 | Conclusões | p. 61 |
| 9.4 | <i>Tin Whistle</i> | p. 61 |
| 9.4.1 | Características | p. 61 |
| 9.4.2 | Análise espectral | p. 62 |
| 9.4.3 | Conclusões | p. 63 |
| 9.5 | Pífano | p. 63 |
| 9.5.1 | Características | p. 63 |
| 9.5.2 | Análise espectral | p. 64 |
| 9.5.3 | Conclusões | p. 65 |
| 9.6 | Flauta transversal ocidental | p. 65 |
| 9.6.1 | Características | p. 65 |
| 9.6.2 | Análise espectral | p. 66 |
| 9.6.3 | Conclusões | p. 67 |
| 9.7 | Flauta transversal chinesa (<i>dizi</i>) | p. 68 |
| 9.7.1 | Características | p. 68 |
| 9.7.2 | Análise espectral | p. 68 |
| 9.7.3 | Conclusões | p. 68 |
| 9.8 | Ocarina | p. 69 |
| 9.8.1 | Características | p. 69 |
| 9.8.2 | Análise espectral | p. 69 |
| 9.8.3 | Conclusões | p. 70 |
| 10 | Algoritmos de Otimização | p. 71 |
| 10.1 | Algoritmo Genético | p. 71 |
| | Cromossomo | p. 71 |
| | Função de <i>Fitness</i> | p. 71 |
| | Seleção | p. 72 |

| | |
|--|-------|
| Mutação | p. 72 |
| <i>Crossover</i> | p. 72 |
| Sobrevivência dos Mais Aptos | p. 72 |
| 10.2 Particle Swarm Optimization | p. 73 |
| 11 Tecnologias Utilizadas | p. 76 |
| 11.1 USARSim | p. 76 |
| 11.1.1 Nvidia PhysX | p. 76 |
| 11.1.2 UDK Editor | p. 78 |
| 11.1.3 UnrealScript | p. 78 |
| 11.1.4 Implementação de Robôs em USARSim | p. 80 |
| 11.1.5 Comunicação entre Agentes e USARSim | p. 80 |
| 11.2 Robonova-I | p. 81 |
| 12 Modelo de Simulação | p. 84 |
| 12.1 Modelos CAD | p. 84 |
| 12.2 Configuração no UDK Editor | p. 85 |
| 12.2.1 Implementação no USARSim | p. 85 |
| 13 Programa do Agente | p. 88 |
| 13.1 Comunicação | p. 89 |
| 13.2 Interface | p. 90 |
| 13.3 Controle | p. 91 |
| 14 Processo de Otimização | p. 92 |
| 14.1 Modelos de Caminhada | p. 92 |
| 14.2 Configuração dos Algoritmos de Otimização | p. 93 |
| 14.2.1 Configuração do Algoritmo Genético | p. 93 |

| | |
|--|--------|
| 14.2.2 Configuração do Particle Swarm Optimization | p. 94 |
| 14.3 Montagem do Experimento Simulado | p. 96 |
| 14.4 Resultados e Discussões | p. 98 |
| 15 Transferência para o Robô Real | p. 105 |
| 15.1 Desafios Envolvidos | p. 105 |
| 15.2 Processo de Transferência | p. 105 |
| 16 Validação com Outro Robô | p. 110 |
| 16.1 RoboCup 3D Soccer Simulation League | p. 110 |
| 16.2 Implementação | p. 112 |
| 16.3 Processo de Otimização | p. 113 |
| 17 Conclusões e Trabalhos Futuros | p. 116 |
| 17.1 Conclusão | p. 116 |
| 17.2 Trabalhos Futuros | p. 116 |
| Referências | p. 118 |

Lista de Figuras

| | | |
|----|--|-------|
| 1 | Esquema ilustrativo da função de um classificador | p. 25 |
| 2 | Exemplo de Redes Bayesiana | p. 30 |
| 3 | Exemplo de uma Naïve Bayes | p. 31 |
| 4 | Exemplo de documento em sua fiel representação sendo classificado. Fonte: (18) | p. 34 |
| 5 | Exemplo de documento com as palavras relevantes destacadas. Fonte: (18) | p. 34 |
| 6 | Exemplo de documento somente com as palavras relevantes. Fonte: (18) | p. 35 |
| 7 | Exemplo de documento com as palavras relevantes e seu número de ocorrências, onde a ordem não conta. Fonte: (18) | p. 35 |
| 8 | Entropia vs p , probabilidade de dar cara, num lançamento de moeda . | p. 42 |
| 9 | Exemplo de Matriz de Confusão para um classificador retirado de (6) . | p. 47 |
| 10 | Espectro para a nota C5 tocada em uma flauta doce Yamaha YRS-23Y obtido a partir da FFT em 1 segundo de gravação. | p. 59 |
| 11 | Espectro para um G5 (azul) e um G6 (verde) tocados em uma flauta doce Yamaha YRS-23Y obtido a partir da FFT em 1 segundo de gravação. | p. 60 |
| 12 | Espectro para a nota D5 tocada em um <i>whistle</i> Clarke SBDC obtido a partir da FFT em 1 segundo de gravação. | p. 62 |
| 13 | Espectro para um G5 (verde) e um G6 (azul) tocados em um <i>whistle</i> Clarke SBDC obtido a partir da FFT em 1 segundo de gravação. | p. 63 |
| 14 | Espectro para a nota C5 tocada em um pífano Yamaha YRF-21 obtido a partir da FFT em 1 segundo de gravação. | p. 64 |
| 15 | Espectro para a nota C4 tocada em uma flauta transversal Hallelu HFL-200 obtido a partir da FFT em 1 segundo de gravação. | p. 66 |

| | | |
|----|--|--------|
| 16 | Espectro para um G4 (verde) e um G6 (azul) tocados em uma flauta transversal Hallelu HFL-200C obtido a partir da FFT em 1 segundo de gravação. | p. 67 |
| 17 | Espectro para um A4 (azul) e um A5 (verde) tocados na ocarina escolhida, obtido a partir da FFT em 1 segundo de gravação. | p. 69 |
| 18 | Junta de revolução. | p. 77 |
| 19 | Diferenças entre modelos físicos gerados com K-DOF (os modelos físicos são apresentados em <i>wireframe</i>). | p. 79 |
| 20 | Robonova-I. Extraído de (28). | p. 81 |
| 21 | Juntas do Robonova-I. Extraído de (28). | p. 82 |
| 22 | Servomotores Hitec HSR-8498HB. Extraído de (28). | p. 82 |
| 23 | Detalhe das costas do Robonova-I mostrando a placa MR-C3204 instalada. Extraído de (28). | p. 83 |
| 24 | Modelo completo montado do Robonova-I. | p. 84 |
| 25 | Modelo completo explodido do Robonova-I. | p. 85 |
| 26 | Juntas implementadas no modelo de simulação. | p. 86 |
| 27 | Robonova-I simulado dentro do USARSim! (USARSim!). | p. 87 |
| 28 | Camadas do programa do agente. | p. 88 |
| 29 | ExampleMap. | p. 96 |
| 30 | Sistema de coordenadas no USARSim. | p. 97 |
| 31 | Resultados da otimização com Modelo Simples e AG! (AG!). | p. 99 |
| 32 | Resultados da otimização com Modelo com Movimento de Braços e AG! . p. 100 | |
| 33 | Resultados da otimização com Modelo Complexo e AG! | p. 100 |
| 34 | Resultados da otimização com Modelo Simples e PSO! (PSO!). | p. 101 |
| 35 | Resultados da otimização com Modelo com Movimento de Braços e PSO! .p. 101 | |
| 36 | Resultados da otimização com Modelo Complexo e PSO! | p. 102 |
| 37 | Sequência de imagens para ilustrar a caminhada aprendida com Modelo Simples e PSO! | p. 103 |

| | | |
|----|---|--------|
| 38 | Sequência de imagens para ilustrar a caminhada aprendida com Modelo com Movimento de Braços e PSO! | p. 104 |
| 39 | Sequência de imagens para ilustrar a caminhada aprendida com Modelo Complexo e PSO! | p. 104 |
| 40 | Sequência de imagens para ilustrar a caminhada final do Robonova real. A taxa de quadros usada para gravação foi de 30 quadros por segundo. | p. 108 |
| 41 | Ambiente do experimento de medida de velocidade do robô real. | p. 109 |
| 42 | Robô Nao simulado chutando uma bola no SimSpark! (SimSpark!). | p. 110 |
| 43 | Esquema das juntas do Nao simulado do SimSpark! | p. 111 |
| 44 | Resultados da otimização com PSO! realizada no ambiente da Soccer 3D! (Soccer 3D!). | p. 114 |
| 45 | Sequência de imagens para ilustrar a caminhada aprendida para o Nao simulado do SimSpark! . Há uma diferença de tempo de 0,1 segundo entre uma imagem e a posterior. | p. 115 |

Lista de Tabelas

| | | |
|----|--|--------|
| 1 | Resumo das medidas de performance para classificadores binários | p. 43 |
| 2 | Especificação dos servomotores Hitec HSR-8498HB. Extraído de (28). | p. 81 |
| 3 | Especificação da placa MR-C3024. Extraído de (7). | p. 83 |
| 4 | Peças implementadas como objetos do tipo “Part”. | p. 86 |
| 5 | Mapeamento das juntas dos modelos teóricos para as do Robonova (veja a Figura 26 para nomenclatura utilizada para as juntas do Robonova). | p. 93 |
| 6 | Limites para os valores das contantes dos modelos de caminhada. | p. 94 |
| 7 | Valores dos parâmetros usados nas execuções de AG! | p. 94 |
| 8 | Valores dos parâmetros usados nas execuções de PSO! | p. 96 |
| 9 | Limites para os valores das contantes dos modelos de caminhada. | p. 98 |
| 10 | Resultados dos Experimentos. | p. 99 |
| 11 | Limites para os valores das contantes dos modelos de caminhada. | p. 103 |
| 12 | Comparação entre diversas caminhadas para o Robonova-I. | p. 109 |
| 13 | Valores dos parâmetros da execução de PSO! para otimização dentro do domínio da Soccer 3D! . | p. 113 |
| 14 | Limites do espaço de busca para no caso da otimização realizada dentro da domínio da Soccer 3D! . | p. 113 |
| 15 | Parâmetros aprendidos para o Modelo Complexo executado no Nao simulado do SimSpark! . | p. 114 |
| 16 | Resultados de medidas de distâncias percorridas no sentido positivo do eixo X. Realizou-se 10 experimentos de 15 segundos para cada caminhada.p. | 115 |

Lista de Algoritmos

| | | |
|---|--|-------|
| 1 | Pseudocódigo do Algoritmo Genético. | p. 73 |
| 2 | Pseudocódigo do <i>Particle Swarm Optimization</i> | p. 75 |
| 3 | Subrotina que simula “choques” das partículas com os limites do espaço de busca. | p. 95 |

Lista de Listagens

Lista de Abreviaturas

NB Naïve Bayes

1 *Introdução*

1.1 Motivação

Um dos temas atualmente mais ativos na área de Ciência da Computação é o de Inteligência Artificial, sendo o Processamento de Linguagem Natural um dos seus principais tópicos. Hoje em dia vemos diversas aplicações dessa área na indústria como, por exemplo, os assistentes digitais Google Now, Siri (Apple) e Cortana (Microsoft), os quais, dado um processamento inicial do áudio, interpretam perguntas dos usuários, produzindo respostas satisfatórias.

Paralelamente a isto, observa-se um crescimento acelerado de redes sociais conectando usuários do mundo inteiro. Elas possuem uma abrangente variedade de assuntos, desde discussões sobre política até comentários sobre novelas. Muitas vezes os usuários não se interessam por uma boa parte das postagens e simplesmente as ignoram. As próprias redes sociais empregam grande esforço em ranquear seus conteúdos e apenas mostrar para seus usuários o que lhes interessa, entretanto não há hoje uma forma do próprio usuário informar à rede social seus interesses e a partir daí filtrar postagens não desejadas.

O Processamento de Linguagem Natural pode ser empregado para se analisar o conteúdo dos diversos textos postados, os categorizando em diferentes classes, o que permite a realização de uma filtragem dos conteúdos por parte do usuário.

1.2 Objetivos

Este trabalho tem, como objetivo, a criação de um classificador de textos baseado em Redes Bayesianas com aprendizado supervisionado. Este classificador será acoplado a uma rede social específica (o Facebook), através de um plugin para o navegador Google Chrome de modo a permitir que o usuário tenha contato apenas com postagens de assuntos de seu interesse.

1.3 Organização do Texto

Este texto foi organizado em capítulos de modo a proporcionar uma leitura simples, com uma progressão natural dos assuntos abordados. A estrutura escolhida foi a seguinte:

- **Capítulo 2:** Este capítulo irá definir o problema que será atacado ao longo do trabalho, clarificando os aspectos teóricos e práticos a serem considerados.
- **Capítulo 3:**
- **Capítulo 4:**
- **Capítulo 5:**

2 Definição do Problema

Antes de se abordarem as soluções propostas, é necessário entender com detalhes o problema que está sendo analisado.

2.1 O Problema de Classificação

Em aprendizado de máquina, o problema de classificação consiste na tarefa de atribuir a objetos uma ou mais das diversas categorias pré-definidas (37). Ou seja, dado um objeto, o classificador deve ser capaz de identificar em qual categoria tal objeto se encaixa melhor, como pode ser visualizado na Figura 1.

O problema de classificação em geral é o exemplo clássico de aprendizado de máquina supervisionado. A partir de um conjunto de exemplos previamente classificados por um supervisor experiente (em geral um ou mais humanos com conhecimento de domínio), o classificador é capaz de aprender e generalizar, podendo assim categorizar corretamente novos objetos encontrados.

Existem vários tipos diferentes de classificação baseados na quantidade de categorias pré-definidas bem como na quantidade de classes às quais cada objeto pode pertencer.



Figura 1: Esquema ilustrativo da função de um classificador

2.1.1 Classificação Binária

A classificação binária é o caso mais simples que pode ser estudado. Neste problema, há apenas duas classes diferentes e cada objeto pertence a exatamente uma delas.

Exemplos comuns que podem ser citados são a classificação de emails em spam ou não-spam, a classificação de tumores em benignos ou malignos, a determinação de quais produtos deverão ser descartados em uma linha de produção, a detecção de transações financeiras fraudulentas, etc.

2.1.2 Classificação *Multi-Class*

Quando há mais de duas classes possíveis, chama-se o problema de classificação *multi-class*. Neste caso, cada objeto deve pertencer a exatamente uma dentre as várias categorias pré-definidas. O classificador deve ser capaz de determinar qual é a categoria de cada objeto.

Vários exemplos de classificação podem ser considerados. Dadas imagens de frutas (que podem ser maçãs, peras, ou laranjas) determinar qual é o tipo de cada fruta. Ou então dadas imagens de telescópio de galaxias distantes, determinar o tipo da galaxia em questão (elíptica, espiral, etc).

2.1.3 Classificação *Multi-Class / Multi-Label*

Quando há várias classes possíveis (mais de duas) e cada objeto pode pertencer a mais de uma classe, chama-se o problema de *multi-class / multi-label*. Este é o mais difícil dos três problemas apresentados, uma vez que há diversas possíveis combinações de classes para cada objeto.

A classificação de textos é um clássico exemplo de classificação *multi-class / multi-label*, já que o texto pode pertencer a uma ou varias classes simultaneamente.

Para resolver o problema de classificação *multi-class / multi-label* podem ser utilizadas duas abordagens diferentes. Uma delas é a abordagem *one vs all* e a outra é a abordagem dos subconjuntos.

Na abordagem *one vs all*, para cada classe, realiza-se a classificação binária do objeto em *pertence* ou *não pertence* a esta classe. Desta forma, determina-se todas as classes às quais o dado objeto pertence. O problema desta abordagem é que pequenos erros que

façam com que o classificador de uma das classes não fique bom (dados ruins para uma classe por exemplo) torna o resultado inteiro ruim.

Na abordagem de subconjuntos, consideram-se todos os possíveis subconjuntos das classes (com 1, 2, 3, ..., L elementos, onde L é o total de classes) e escolhe-se o subconjunto desejado (utilizando um classificador multi-class). O grande problema desta abordagem é que há 2^{L-1} possíveis subconjuntos da classes (o que pode ser muito).

2.2 Objeto de Estudo deste Trabalho

Como foi visto, a classificação de textos é um problema do tipo *multi-class / multi-label*, entretanto seria necessária uma quantidade muito grande de dados para se obter resultados satisfatórios neste problema. Portanto, fez-se a simplificação de considerar o problema apenas *multi-class*, ou seja, cada texto só será classificado em um única classe.

3 Fundamentação Teórica

3.1 Definição formal

Utilizando a notação adotada por Dan Jurafsky e Christopher Manning em seu curso de Processamento de Linguagem Natural para Stanford (18), define-se o problema da classificação supervisionada de textos da seguinte forma.

Seja $C = \{c_1, c_2, \dots, c_J\}$ um conjunto fixo de classes, $D = \{d_1, d_2, \dots, d_n\}$ um conjunto de documentos, e $\mathcal{T} = \{(d_1, c_{d_1}), (d_2, c_{d_2}), \dots, (d_m, c_{d_m})\}$ um conjunto de treinamento (subconjunto de D) com m documentos classificados manualmente, o classificador consiste em uma função $\gamma : D \rightarrow C$ que relaciona um documento a uma classe, e um algoritmo de aprendizado de máquina supervisionado é um algoritmo que recebe como parâmetros C e \mathcal{T} e retorna γ .

3.2 Tipos de classificadores

Existem diversos tipos diferentes de classificadores que possuem resultados muito bons dependendo do problema analisado. Segue abaixo uma lista dos principais classificadores existentes.

- Árvores de Decisão
- Naïve Bayes
- Regressão Logística
- Support Vector Machines
- k-Nearest Neighbors
- Redes Neurais

- Dentre outros

A performance de todos estes métodos varia consideravelmente dependendo da aplicação. Estudos mostram que para bases de dados grandes o suficiente, ótimos resultados podem ser atingidos independentemente do método utilizado (17). Entretanto, para uma quantidade pequena de dados as Naïve Bayes apresentam resultados bons por serem classificadores de alto *bias* / baixa variância (9).

As NB possuem as vantagens de serem fáceis de se implementar, serem bem rápidas na hora da execução e mostrarem bons resultados práticos.

3.3 Redes Bayesianas

3.3.1 Definição

Em modelagem gráfica probabilística, Redes Bayesianas são grafos direcionados que representam relações de dependência condicionais entre diferentes variáveis aleatórias (22). A partir da visualização de uma Rede Bayesiana é possível utilizar a regra de Bayes para realizar inferências e descobrir a probabilidade de eventos, dadas algumas variáveis observadas. As arestas direcionadas representam as noções de causalidade entre as variáveis aleatórias e geram as dependências condicionais (TODO: causalidade?). Para cada nó do gráfico deve haver uma tabela de probabilidades condicionais para a variável em questão.

A Figura 2, retirada do curso de Modelagem Gráfica Probabilística da professora Daphne Koller de Stanford (19), ilustra um exemplo de uma Rede Bayesiana simples. Neste caso, pode-se ver que a nota do aluno é influenciada pela dificuldade da prova e pela sua inteligencia. Além disso a possibilidade do professor escrever uma carta de recomendação depende apenas da nota do aluno e o SAT do aluno depende apenas de sua inteligencia. Em cada nó do grafo há uma tabela de distribuições de probabilidades condicionais.

3.3.2 Regra de Bayes

Para realizar inferências nas redes Bayesianas utiliza-se a regra de Bayes, como definida a seguir.

Sejam A e B dois eventos com probabilidades de ocorrência $P(A)$ e $P(B)$ e sendo

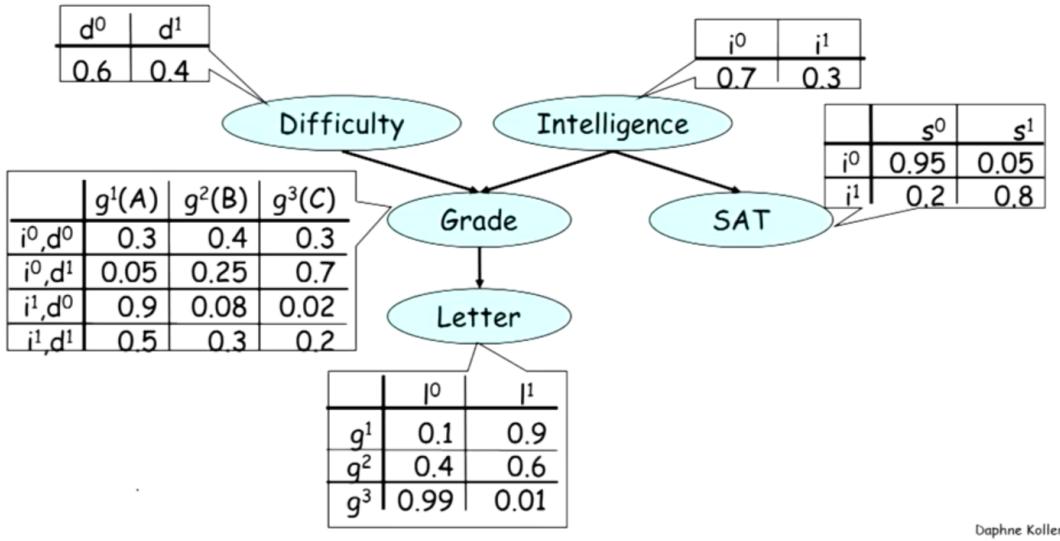


Figura 2: Exemplo de Redes Bayesiana

$P(A|B)$ e $P(B|A)$ as probabilidades condicionais de A dado B e de B dado A , respectivamente, tem-se que:

$$P(A|B) = \frac{P(A)P(B|A)}{P(B)}$$

Esse resultado parte da noção de probabilidade conjunta $P(A, B)$.

$$P(A, B) = P(A)P(B|A) = P(B)P(A|B) \rightarrow P(A|B) = \frac{P(A)P(B|A)}{P(B)}$$

No caso do exemplo da Figura 2, podemos calcular a probabilidade conjunta da rede da seguinte forma:

$$P(D, I, G, S, L) = P(D)P(I)P(G|I, D)P(S|I)P(L|G)$$

Onde $D = \text{Difficulty}$, $G = \text{Grade}$, $I = \text{Intelligence}$, $S = \text{SAT}$ e $L = \text{Letter}$.

3.3.3 Naïve Bayes

3.3.3.1 Problema a ser resolvido

Redes Bayesianas são ferramentas excelentes para modelar problemas complexos, entretanto elas possuem um grande problema prático. A realização de inferências em redes genéricas é um problema NP-Hard, conforme demonstrado por Cooper (10).

O que é realizado na prática é, ou realizar inferências aproximadas nas redes com algoritmos polinomiais, ou simplificar as redes a alguns tipos específicos mais simples.

3.3.3.2 O que são Naïve Bayes

As Naïve Bayes (Bayes "Ingênuas") são simplificações feitas na modelagem de um problema por redes Bayesianas de modo a tornar possível realizar a inferência de forma rápida. Elas assumem que as variáveis do problema são condicionalmente independentes (mesmo que na prática elas não sejam, o que explica o nome *ingênuas*).

A Figura 3 mostra um exemplo de uma NB comum. Ela possui uma variável *Classe* que interfere em uma série de outras varáveis $x_1, x_2, x_3, \dots, x_n$ (que serão chamadas a partir daqui de features). É importante notar que a estrutura da rede mostra que as features são condicionalmente independentes umas das outras e a *Classe* depende de cada uma das features individualmente. É fácil entender a grande vantagem desta abordagem. Cada tabela de probabilidades condicionais será pequena. Além disso a inferência da variável classe, dadas algumas das features será bem simples, como será mostrado nas próximas seções.

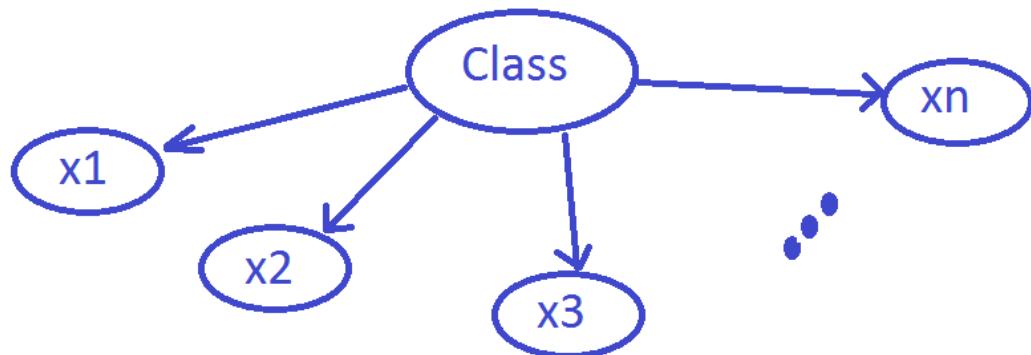


Figura 3: Exemplo de uma Naïve Bayes

Na prática o NB é um ótimo classificador de textos, pois, além de ser simples, traz resultados comparáveis a outros classificadores substancialmente mais complexos e lentos.

3.3.3.3 Independência Condisional

Antes de explicar a inferência em NB é importante entender o que significa o conceito de independência condicional.

Dados dois eventos A e B , dizemos que eles são independentes se a probabilidade de ocorrência de um deles não é influenciada pelo fato do outro ter ocorrido. Ou seja:

$$P(A|B) = P(A) \quad P(B|A) = P(B)$$

Esta propriedade é muito relevante na simplificação de expressões pois podemos usar o fato de que a probabilidade conjunta é igual ao produto das probabilidades individuais.

$$P(A, B) = P(A)P(B|A) = P(A)P(B)$$

3.3.3.4 Inferência

A regra de Bayes seguida pela propriedade de independência condicional pode ser utilizada para a realização de inferência em NB da seguinte forma.

Sejam $C = \{c_1, c_2, c_3, \dots, c_J\}$ um conjunto de classes e $x_1, x_2, x_3, \dots, x_n$ as features a serem analisadas. Como trata-se de NB, assume-se independência condicional das features. Deseja-se saber para cada i :

$$P(C = c_i|x_1, x_2, \dots, x_n)$$

Ou seja, deseja-se saber qual a probabilidade da classe possuir o valor c_i , dadas as features observadas.

Pela regra de Bayes temos:

$$P(C = c_i|x_1, x_2, \dots, x_n) = \frac{P(x_1, x_2, \dots, x_n|C = c_i)P(C = c_i)}{P(x_1, x_2, \dots, x_n)} \quad (3.1)$$

Como $x_1, x_2, x_3, \dots, x_n$ são condicionalmente independentes entre si, temos:

$$\begin{aligned} P(x_1, x_2, \dots, x_n|C = c_i) &= P(x_1, x_2, \dots, x_{n-1}|x_n, C = c_i)P(x_n|C = c_i) \\ &= P(x_1, x_2, \dots, x_{n-1}|C = c_i)P(x_n|C = c_i) \\ &= P(x_1, x_2, \dots, x_{n-2}|x_{n-1}, C = c_i)P(x_{n-1}|C = c_i)P(x_n|C = c_i) \\ &= P(x_1, x_2, \dots, x_{n-2}|C = c_i)P(x_{n-1}|C = c_i)P(x_n|C = c_i) \\ &= \dots = P(x_1|C = c_i)P(x_2|C = c_i)P(x_3|C = c_i)\dots P(x_n|C = c_i) \\ &= \prod_{j=1}^n P(x_j|C = c_i) \end{aligned} \quad (3.2)$$

Substituindo 3.2 em 3.1 temos:

$$P(C = c_i|x_1, x_2, \dots, x_n) = \frac{P(C = c_i)\prod_{j=1}^n P(x_j|C = c_i)}{P(x_1, x_2, \dots, x_n)} \quad (3.3)$$

3.3.3.5 Classificação utilizando Naïve Bayes

No problema de classificação temos um documento d que será representado pelas features x_1, x_2, \dots, x_n e deseja-se saber a qual classe $c \in C$ este documento pertence. Matematicamente, deseja-se saber a qual classe é mais provável que o documento pertença, isto é, a classe que maximiza $P(d|c)$.

$$\gamma(d) = \operatorname{argmax}_c(P(d|c)) = \operatorname{argmax}_c(P(x_1, x_2, \dots, x_n|c))$$

Pela equação 3.3, temos que:

$$\operatorname{argmax}_c(P(x_1, x_2, \dots, x_n|c)) = \operatorname{argmax}_c\left(\frac{P(C = c_i)(\prod_{j=1}^n P(x_j|C = c_i))}{P(x_1, x_2, \dots, x_n)}\right)$$

Como $P(x_1, x_2, \dots, x_n)$ não depende de c , pode-se eliminá-lo do denominador, chegando em:

$$\gamma(d) = \operatorname{argmax}_c(P(C = c_i)\left(\prod_{j=1}^n P(x_j|C = c_i)\right))$$

3.3.4 Modelagens para classificação de texto

Uma vez que já foi entendida a forma de classificar o texto, resta representá-lo por um conjunto de features adequada e adotar uma distribuição (parametrizada ou não) para suas probabilidades. A seguir é explicado o modelo de representação de documentos *Bag-of-words* e as modelagens *Naïve Bayes de Bernoulli* e *Multinomial Naïve Bayes*, onde a principal diferença é a distribuição das probabilidades.

3.3.4.1 Representação por Bag-of-words

Em classificação de texto uma das tarefas especialmente importante é a de representação de documento e seleção das features a serem consideradas. Diz-se especialmente importante pois, diferentemente de outras tarefas de classificação, a classificação textual apresenta dimensionalidade bastante elevada e a presença de muitas features irrelevantes (*noise*).

O modelo *Bag-of-words* é uma representação simplificada de um texto ou documento

em que o mesmo é figurativamente imaginado como uma sacola onde as palavras são colocadas, ignorando gramática ou ordem das palavras, mas mantendo a multiplicidade de cada uma.

Muito utilizado em classificação de texto (presente caso), *Bag-of-words* pode ser entendido como um mapa entre as palavras do texto e o número de ocorrências de cada uma.

Em alguns casos pode-se calcular a representação *Bag-of-words* de um documento levando-se em consideração todas as palavras do mesmo ou somente um subconjunto das mesmas. Nas figuras 4, 5, 6, 7 apresenta-se em sequência o método prático de reduzir um documento na sua representação simplificada *Bag-of-words* levando-se em consideração um subconjunto das palavras do mesmo.

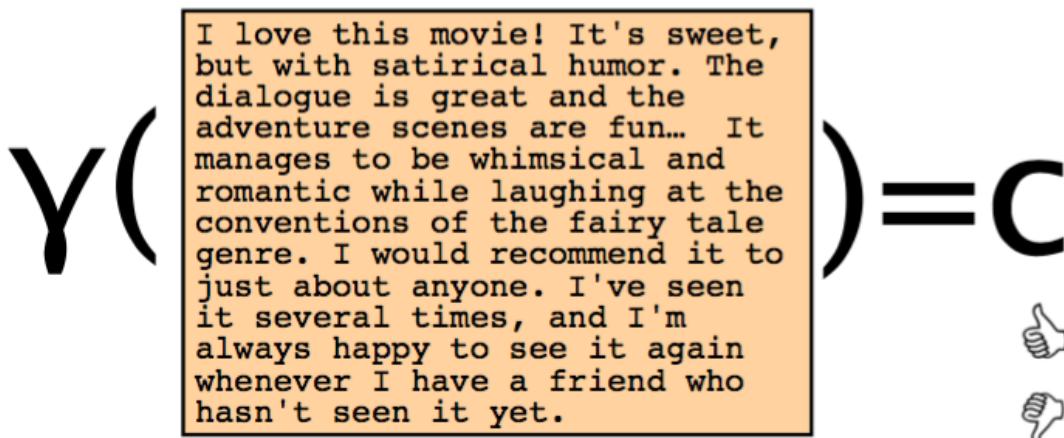


Figura 4: Exemplo de documento em sua fiel representação sendo classificado. Fonte: (18)

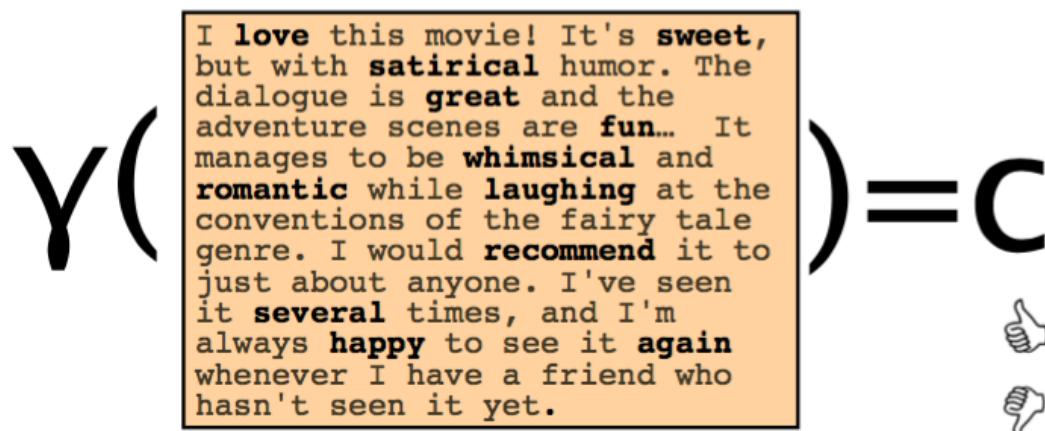


Figura 5: Exemplo de documento com as palavras relevantes destacadas. Fonte: (18)

Como pode-se perceber ao final da figura 7 gerou-se um mapa de palavra para número de




| |
|---|
| x love xxxxxxxxxxxxxxxx sweet |
| xxxxxxxx satirical xxxxxxxxx |
| xxxxxxxxxx great xxxxxxx |
| xxxxxxxxxxxxxx fun xxxx |
| xxxxxxxxxxx whimsical xxxx |
| romantic xxxx laughing |
| xxxxxxxxxxxxxxxxxxxxxxxxxxxxxx |
| xxxxxxxxxxxxxx recommend xxxx |
| xxxxxxxxxxxxxxxxxxxxxxxxxxxxxx |
| xx several xxxxxxxxxxxxxxxxx |
| xxxxx happy xxxxxxxxx again |
| xxxxxxxxxxxxxxxxxxxxxxxxxxxxxx |
| xxxxxxxxxxxxxxxxxxxxxxxxxxxxxx |

Figura 6: Exemplo de documento somente com as palavras relevantes. Fonte: (18)




| | |
|------------------|-----|
| great | 2 |
| love | 2 |
| recommend | 1 |
| laugh | 1 |
| happy | 1 |
| ... | ... |

Figura 7: Exemplo de documento com as palavras relevantes e seu número de ocorrências, onde a ordem não conta. Fonte: (18)

ocorrência das mesmas, onde a ordem não é considerada. Apesar de ignorar a ordem das palavras (e dependendo do pré-processamento outras informações como pontuação) é importante manter em mente que um humano facilmente classificaria artigos com taxa relativamente alta de acerto se fossem fornecidas algumas palavras-chave do texto fora de contexto e ordem. Pela sua simplicidade e eficiência para uso em classificação de texto, foi decidido utilizar a representação de documentos por Bag-of-words.

3.3.4.2 Naïve Bayes de Bernoulli

Na modelagem de Bernoulli, o documento é representado por um vetor de features onde cada coordenada indica se determinada palavra está presente ou não no documento, isto é, o documento é um vetor \mathbf{x} de tamanho $|V|$, onde V é o vocabulário, e $x_i \in \{0, 1\}$ indica se a palavra w_i está ou não presente no documento (caso apareça mais de uma vez

x_i permanece sendo 1). Assim:

$$\begin{aligned}
 P(\mathbf{X} = \mathbf{x}|c) &= \prod_{i=1}^{|V|} P(U_i = 1|c)^{x_i} P(U_i = 0|c)^{(1-x_i)} \\
 &= \prod_{i=1}^{|V|} P(U_i = 1|c)^{x_i} (1 - P(U_i = 1|c))^{(1-x_i)}
 \end{aligned} \tag{3.4}$$

Onde U_i é uma variável aleatória que indica se a palavra w_i está ou não presente num documento de classe c .

3.3.4.3 Multinomial Naïve Bayes

Nessa modelagem, o número de vezes em que uma determinada palavra aparece em um documento é levada em consideração. É bastante comum sua utilização em classificação de texto.

No Multinomial NB, também representa-se o texto por uma *Bag-of-words*. Utiliza-se a distribuição multinomial para modelar as probabilidades das features. Para derivar a expressão que representa $P(x_1, x_2, \dots, x_n|c)$ primeiro define-se o modelo de cada documento e o que representa seu conjunto de features.

Suponha que \mathbf{d} seja um documento que gere o vetor de features $\mathbf{x}(\mathbf{d}) = (x_1, x_2, \dots, x_{|V|})$, onde x_i representa a quantidade de vezes em que a palavra w_i ocorreu no documento \mathbf{d} . Note que dessa forma dois documentos cuja ordem das palavras mude possuirão o mesmo vetor de features, como esperado pela hipótese de "Bag of words". Um documento \mathbf{d} pode ser representado por um vetor de tamanho $|\mathbf{d}|$, o número de palavras do documento, onde cada coordenada é o índice da palavra do vocabulário que está naquela posição. Isto é, $\mathbf{d} = (d_1, d_2, \dots, d_{|\mathbf{d}|})$, onde $d_j \in \{1, 2, \dots, |V|\}$, o que significa que a palavra na j -ésima posição é w_{d_j} . Daí:

$$x_i = |\{d_j | j \in \{1, 2, \dots, |\mathbf{d}|\} \wedge d_j = i\}|$$

Por exemplo, um documento "w₆w₄w₅w₉w₆" é representado por $\mathbf{d} = (6, 4, 5, 9, 6)$ onde $|\mathbf{d}| = 5$. Supondo $|V| = 10$, esse documento gera um vetor de features $\mathbf{x}(\mathbf{d}) = (0, 0, 0, 1, 1, 2, 0, 0, 1, 0)$, observe que existem $\frac{5!}{2!}$ documentos que geram o mesmo vetor de

features, o que nada mais é que o número de permutações de \mathbf{d} .

De maneira genérica, para um vetor de features $\mathbf{x}^{(j)}$, seja $docs(\mathbf{x}^{(j)})$ o conjunto de documentos que o geram:

$$docs(\mathbf{x}^{(j)}) = \{\mathbf{d} | \mathbf{x}(\mathbf{d}) = \mathbf{x}^{(j)} = (x_1^{(j)}, x_2^{(j)}, \dots, x_{|V|}^{(j)})\}$$

Tem-se que:

$$|\mathbf{d}| = \sum_{i=1}^{|V|} x_i^{(j)} (\forall \mathbf{d} \in docs(\mathbf{x}^{(j)}))$$

E:

$$\begin{aligned} |docs(\mathbf{x}^{(j)})| &= \text{número de permutações de um } \mathbf{d} \in docs(\mathbf{x}^{(j)}) \\ &= \frac{|\mathbf{d}|!}{\prod_{i=1}^{|V|} x_i^{(j)}!} = \frac{(\sum_{i=1}^{|V|} x_i^{(j)})!}{\prod_{i=1}^{|V|} x_i^{(j)}!} \end{aligned}$$

Seja D_i a variável aleatória que representa a i -ésima palavra de um documento \mathbf{d} .

Assume-se que:

$$\begin{aligned} P(D_i = k | c) &= P(D_j = k | c) = P(D = k | c) \quad (3.5) \\ \forall i, j \in \{1, 2, \dots, |\mathbf{d}|\} \\ \forall k \in \{1, 2, \dots, |V|\} \end{aligned}$$

Em outras palavras, a distribuição de probabilidade de quais palavras aparecem no documento dado sua classe independe da posição da palavra. A essa hipótese dá-se o nome de *Independência Posicional*. Assim, podemos eliminar o subscrito e escrever D para representar essa distribuição.

Pela hipótese de *Independência Condicional* de NB, tem-se também que:

$$P(D_i | D_j, c) = P(D_i | c) \quad (3.6)$$

Logo, seja $\mathbf{d} = (d_1, d_2, \dots, d_N)$ um documento, por 3.6 e 3.5, vem:

$$P(\mathbf{D} = \mathbf{d}|c) = \prod_{j=1}^N P(D_j = d_j|c) = \prod_{j=1}^N P(D = d_j|c)$$

Levando-se em consideração $\mathbf{x}(\mathbf{d})$, tem-se:

$$\prod_{j=1}^N P(D = d_j|c) = \prod_{i=1}^{|V|} P(D = i|c)^{x_i}$$

Isto é, condensa-se probabilidades de palavras iguais com expoente > 1 , adiciona-se termos elevados a 0 para as palavras que não estão no documento e reordena-se na ordem em que as palavras aparecem no vocabulário. Assim:

$$P(\mathbf{D} = \mathbf{d}|c) = \prod_{i=1}^{|V|} P(D = i|c)^{x_i}$$

Note que $P(\mathbf{D} = \mathbf{d}|c)$ só depende de $\mathbf{x}(\mathbf{d})$, que é igual para todo documento $\in \text{docs}(\mathbf{x}(\mathbf{d}))$.

Finalmente:

$$\begin{aligned} P(\mathbf{X} = \mathbf{x}|c) &= \sum_{d \in \text{docs}(\mathbf{x})} P(\mathbf{D} = \mathbf{d}|c) \\ &= \sum_{d \in \text{docs}(\mathbf{x})} \prod_{i=1}^{|V|} P(D = i|c)^{x_i} \\ &= |\text{docs}(\mathbf{x})| \prod_{i=1}^{|V|} P(D = i|c)^{x_i} \\ &= \frac{(\sum_{i=1}^{|V|} x_i)!}{\prod_{i=1}^{|V|} x_i!} \prod_{i=1}^{|V|} P(D = i|c)^{x_i} \end{aligned} \tag{3.7}$$

Pode-se chegar a essa equação através da hipótese da distribuição multinomial. Nessa distribuição existem n tentativas independentes, cada uma gerando uma de k categorias distintas, cada categoria com uma chance distinta de sucesso. Considera-se cada tentativa a ocorrência de determinada palavra em uma posição do documento (que contém n palavras) dada sua classe c e cada categoria como sendo uma palavra do vocabulário, de tal forma que $k = |V|$.

Os parâmetros da distribuição são as probabilidades de cada categoria, ou palavra, $\mathbf{p} = (p_1, p_2, \dots, p_{|V|})$ de tal forma que $\sum_{i=1}^{|V|} p_i = 1$. Tem-se, então, que $p_j = P(D = j|c)$ ($\forall j \in 1, 2, \dots, |V|$). Diz-se então que o vetor $\mathbf{X} = (X_1, X_2, \dots, X_{|V|})$ segue uma distribuição multinomial com $\sum_{i=1}^{|V|} X_i = n$ e que:

$$\begin{aligned}
P(\mathbf{X} = \mathbf{x} | c) &= \frac{n!}{x_1! x_2! \dots x_3!} p_1^{x_1} p_2^{x_2} \dots p_{|V|}^{x_{|V|}} \\
&= \frac{(\sum_{i=1}^{|V|} x_i)!}{\prod_{i=1}^{|V|} x_i!} \prod_{i=1}^{|V|} p_i^{x_i} \\
&= \frac{(\sum_{i=1}^{|V|} x_i)!}{\prod_{i=1}^{|V|} x_i!} \prod_{i=1}^{|V|} P(D = i | c)^{x_i}
\end{aligned}$$

3.3.4.4 Outras features

É possível enriquecer o classificador utilizando outras features (que não sejam as próprias palavras do texto). Exemplos de features que podem ser utilizadas são: combinações de palavras, o tamanho do texto, quantidade de sinais de pontuação, quantidade de palavras com iniciais maiúsculas, etc.

Para o caso específico de postagens em redes sociais existem ainda outras features que podem ser incluídas. Pode-se considerar o autor da postagem, o momento em que ela foi publicada, a presença de fotos, vídeos ou links, etc.

3.3.4.5 Smoothing

Um dos problemas práticos encontrados por NB é a ocorrência de contagens nulas. O grande problema do 0 é que se ele for apenas um dos fatores da multiplicação o resultado inteiro será 0, inutilizando o método.

Isto não é algo incomum, principalmente se o conjunto de treinamento for pequeno. Basta ter uma palavra no conjunto de teste que nunca ocorreu em uma determinada classe no conjunto de treinamento.

Existem técnicas que são utilizadas para resolver este problema e elas são chamadas de Smoothing. Neste trabalho utilizou-se Laplace Smoothing, uma das mais comuns.

A técnica consiste em assumir que todas as features foram vistas pelo menos α vezes em cada uma das classes. Isso se traduz nas seguintes formulas, sendo L o número total de classes e V o numero total de features.

$$P(C = c_i) \simeq \frac{\#(c_i) + \alpha}{N + \alpha L}$$

e

$$P(x_j|C = c_i) \simeq \frac{\#(x_j \wedge c_i) + \alpha}{\#(c_i) + \alpha V}$$

No caso especial em que $\alpha = 1$, tem-se o *Add-One Smoothing*.

3.4 Weighted Naïve Bayes

Um dos problemas das NB é que muitas vezes nas aplicações reais não é possível assumir a independência condicional das features. Um modo inicial de relaxar essa hipótese de independência, é eliminar features com alta correlação, fazendo com que o subconjunto restante se encaixe melhor na hipótese de independência condicional. Isto é chamado de seleção de features.

Neste caso temos:

$$\gamma(d) = \operatorname{argmax}_c(P(C = c_i) \left(\prod_{j=1}^n P(x_j|C = c_i)^{I(j)} \right))$$

Onde:

$$I(j) \in \{0, 1\}$$

Existem bastantes features que são dependentes de outras, dessa forma quando coloca-se ambas no produtorio acaba-se prejudicando o resultado. Logo, colocar peso nas features é uma forma de amenizar a forte hipótese de independência das NB. Uma abordagem mais genérica, então, é ponderar cada feature de acordo com sua relevância. Ou seja:

$$\gamma(d) = \operatorname{argmax}_c(P(C = c_i) \prod_{j=1}^n P(x_j|C = c_i)^{w(j)})$$

Onde:

$$w(j) \in \mathbb{R}^+$$

Nota-se que a seleção de features é um caso específico da ponderação de features (onde $w(j)$ só pode ser 0 ou 1). Existem diversos algoritmos já desenvolvidos na literatura para seleção de features, muitos dos quais envolvem alguma busca no espaço das features com testes num grupo de dados dedicado e expansão do grupo de features somente se a nova

feature gerar uma melhoria na classificação nesse grupo de dados. Esses algoritmos são brevemente explorados em (41).

Tendo decidido realizar feature weighting, o grande problema passa a ser determinar os pesos $w(j)$ das features. Há diversos algoritmos que já foram propostos para realizar esta tarefa. Intuitivamente, quer-se um peso maior para features que possam ser decisivas no resultado final (ajudam a distinguir determinada classe).

Neste trabalho, estudou-se a utilização de um método baseado na Teoria da Informação, que além de ser comum na literatura ((20) e (41)), possui fundamentos teóricos bem embasados, onde o *Gain Ratio* de um atributo é utilizado como seu peso.

3.4.1 Entropy Weighted Naïve Bayes

Em Teoria da Informação, entropia é o valor esperado de informação contido em uma mensagem. Praticamente falando, a distribuição de probabilidade de eventos, junto com a quantidade de informação de cada evento, compõe uma variável aleatória cujo valor esperado é a quantidade média de informação, ou entropia, gerada por essa distribuição. Assim entropia H é:

$$H(X) = E[-\ln(P(X))]$$

Onde $-\ln(P(x))$ é considerado o conteúdo de informação de X . Para distribuições discretas:

$$H(X) = - \sum_i P(x_i) \log_b P(x_i) \quad (3.8)$$

Onde, geralmente, $b = 2$, de forma que a unidade de $H(X)$ é bits.

Entropia pode ser entendida como uma medida da incerteza de determinada variável. Considere uma moeda sendo jogada para o alto e uma probabilidade p de o resultado dar cara. Quanto mais próximo de $p = 0,5$ maior é a incerteza do resultado, logo maior será a entropia, e quanto mais longe de $p = 0,5$ menor é a entropia. A figura 8 ilustra isso.

Semelhante à entropia, define-se o conceito de Informação Mútua entre duas variáveis aleatórias, que mede sua dependência. Formalmente, a informação mútua entre duas variáveis discretas X e Y é:

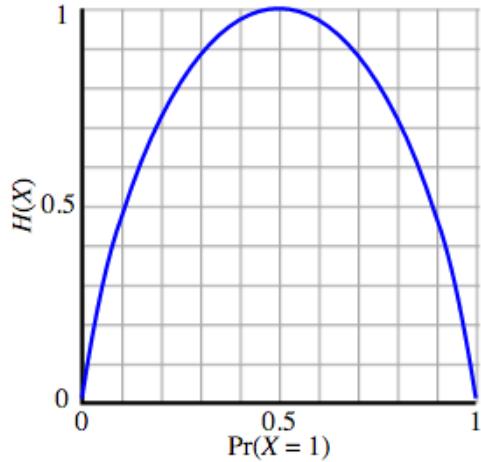


Figura 8: Entropia vs p , probabilidade de dar cara, num lançamento de moeda

$$MI(X, Y) = \sum_{y \in Y} \sum_{x \in X} P(X = x, Y = y) \log\left(\frac{P(X = x, Y = y)}{P(X = x)P(Y = y)}\right) \quad (3.9)$$

Intuitivamente, $MI(X, Y)$ mede o quanto de informação X e Y compartilham. Se, por exemplo, X e Y forem independentes tem-se $MI(X, Y) = 0$.

Em luz de 3.8 e 3.9 define-se Razão de Ganho *GR* (do inglês *Gain Ratio*) de uma feature X_i como sendo:

$$GR(i) = \frac{I(X_i, C)}{H(X_i)} = \frac{\sum_{c \in C} \sum_{x_1 \in X_1} P(x_1, c) \log\left(\frac{P(x_1, c)}{P(x_1)P(c)}\right)}{-\sum_{x_1} P(x_1) \log(P(x_1))} \quad (3.10)$$

Agora, resta-se somente normalizar as razões de ganho, de forma que o peso de cada feature é a sua razão de ganho dividida pela média de todas as razões de ganho.

$$w(j) = \frac{GR(j)}{\frac{1}{N} \sum_{i=1}^N GR(i)} \quad (3.11)$$

Onde N é o número de features.

3.5 Métodos de avaliação de um classificador

Uma vez desenvolvido o classificador é importante ser capaz de avaliá-lo a fim de determinar o quão bom ele é. A utilização de métricas numéricas para avaliar os classificadores é interessante pois permite a realização de comparações entre as diferentes versões

implementadas, tornando possível determinar se as modificações que foram feitas estão fazendo efeito.

Existem diversas métricas que podem ser utilizadas para avaliar classificadores, algumas delas serão analisadas nesta seção (36).

3.5.1 Classificador Binário

Primeiro serão explorados os métodos de avaliação da performance do classificador binário, que é o classificador mais simples.

A tabela 1 resume as diferentes medidas que podem ser utilizadas, onde tp é o verdadeiro positivo, tn é o verdadeiro negativo, fp é o falso positivo e fn é o falso negativo.

| Medida | Fórmula | Intuição |
|-------------|--|--|
| Acurácia | $\frac{tp+tn}{tp+fn+fp+tn}$ | Eficácia global do classificador |
| Precisão | $\frac{tp}{tp+fp}$ | Quantos dos objetos classificados como positivo são efetivamente positivos |
| Abrangência | $\frac{tp}{tp+fn}$ | Quantos dos objetos positivos foram classificados como positivos |
| Fscore | $\frac{(\beta^2+1)tp}{(\beta^2+1)tp+\beta^2fn+fp}$ | Uma média harmônica entre a precisão e a abrangência |

Tabela 1: Resumo das medidas de performance para classificadores binários

3.5.1.1 Acurácia

A acurácia mede a quantidade total de acertos (verdadeiro positivos ou verdadeiro negativos) em relação à quantidade total de objetos classificados.

$$acuracia = \frac{tp+tn}{tp+fn+fp+tn}$$

Esta é a medida de performance mais fácil de se entender, entretanto ela não é muito informativa, uma vez que dependendo da distribuição das classes, classificadores ruins podem ter alta acurácia.

Suponha, por exemplo, um classificador que classifica tumores em benignos ou malignos. Suponha também que 99.9% dos tumores sejam benignos. É possível criar um classificador que sempre responde que o tumor é benigno e ele teria uma acurácia de 99.9% (aparentemente muito boa). Entretanto este classificador falha miseravelmente na

sua tarefa principal (que é determinar quais tumores são malignos para que as devidas providencias sejam tomadas).

3.5.1.2 Precisão

A precisão é uma estatística que indica quantos dos objetos classificados como positivo são efetivamente positivos. Quando um classificador com alto precisão classifica um objeto como positivo, é muito provável que ele seja positivo (entretanto nada se sabe sobre quantos objetos positivos ele esta classificando como negativo).

$$precisao = \frac{tp}{tp+fp}$$

Um classificador que indica para uma pessoa se ela deve investir ou não em uma determinada ação deve ser muito preciso. Pois para o investidor o importante é que quando ele siga o conselho do classificador e invista, ele não perca dinheiro. Não importa tanto se havia várias outras ações que eram boas, mas que o classificador desprezou.

3.5.1.3 Abrangência (*Recall*)

A abrangência de um classificador indica quantos dos objetos positivos são efetivamente classificados como positivos. Um classificador com grande abrangência provavelmente irá detectar a maior parte dos objetos positivos (apesar de também poder detectar alguns negativos como sendo positivos).

$$abrangencia = \frac{tp}{tp+fn}$$

Um médico que classifica pintas na pele das pessoas entre malignas ou benignas (câncer de pele ou não) deve ter uma grande abrangência (sendo a classificação 'maligno' a classe positiva do classificador), mas a precisão não é tão importante. Isso ocorre pois se o médico deixar de classificar alguma pinta que era maligna como maligna, o paciente pode acabar evoluindo a doença e morrer (ou seja, todos que são efetivamente malignos devem ser classificados como malignos). A precisão não é tão importante pois se por ventura o médico classificar uma pinta benigna como maligna, o paciente vai remover a mesma e na biópsia será possível identificar que não era nada demais (o paciente só terá que passar inutilmente pelo procedimento cirúrgico de remoção de pintas, mas isso não é muito problemático).

Existe, normalmente uma relação inversa entre a precisão e a abrangência. Em geral quanto se aumenta a precisão se reduz a abrangência e vice-versa. Pode-se exemplificar

isto com o mesmo caso do médico que classifica pintas. Quando ele fica com dúvida se a pinta é benigna ou maligna, ele pode dizer que ela é maligna e pedir a remoção ou dizer que ela é benigna. Se na dúvida ele sempre disser que a pinta é maligna, ele estará aumentando a abrangência, mas diminuindo a precisão (pois haverá mais verdadeiros positivos e mais falso positivos). No limite, dizer que todas pintas são malignas dá abrangência máxima (100%). Se ele sempre disser que a pinta duvidosa é benigna, ele aumentará a precisão, mas diminuirá a abrangência (pois haverá mais falso negativos e menos falso positivos).

3.5.1.4 Fscore

Como pode ser visto, a abrangência e a precisão possuem comportamentos antagônicos. Normalmente é importante que o classificador tenha tanto uma precisão aceitável, quanto uma abrangência razoável. Então combinou-se a abrangência e a precisão em um único número, chamado de Fscore.

O caso mais simples do Fscore (chamado de F1score) é uma média harmônica entre a precisão e a abrangência.

$$F_1 = \frac{2}{\frac{1}{precisao} + \frac{1}{abrangencia}}$$

Ou seja:

$$F_1 = \frac{2 \cdot precisao \cdot abrangencia}{precisao + abrangencia}$$

Isto pode ser simplificado para:

$$F_1 = \frac{2tp}{2tp + fn + fp}$$

É interessante notar que se a precisão ou se a abrangência forem bem pequenas, o F1score será bem pequeno. Se ambas forem grandes, o F1score será algum valor entre as duas.

Como dependendo da aplicação, a precisão ou a abrangência podem ser mais importantes, há uma formulação genérica para o Fscore que utiliza o parâmetro β para determinar qual das duas métricas é mais importante.

$$F_\beta = \frac{(1+\beta^2) \cdot precisao \cdot abrangencia}{\beta^2 \cdot precisao + abrangencia}$$

É fácil provar que:

$$F_\beta = \frac{(\beta^2 + 1)tp}{(\beta^2 + 1)tp + \beta^2fn + fp}$$

Os dois valores de β mais comuns são 0.5 e 2. Nota-se que para β maior que 1 a

abrangência é considerada mais importante. Para β menor que 1 a precisão é considerada mais importante.

3.5.2 Classificador *Multi-Class*

As mesmas métricas definidas acima podem ser aplicadas para problemas *multi-class*, entretanto alguns problemas surgem. Por exemplo, as métricas seriam calculadas individualmente para cada classe (gerando vários números), o que tornaria a avaliação do classificador um processo complicado (vários números são mais difíceis de serem analisados do que apenas um único).

A tabela ?? resume as diferentes medidas utilizadas na avaliação de performance de um classificador *multi-class*.

3.5.2.1 Matriz de Confusão (*Confusion Matrix*)

Para facilitar a análise de problemas *multi-class*, criou-se a matriz de confusão. Ela consiste em uma matriz de números na qual as linhas representam as classificações realizadas pelo classificador e as colunas representam as classes originais das quais os objetos pertencem. A célula a_{ij} da matriz possui um número que indica quantas vezes o classificador classificou objetos de tipo j como i.

É fácil de notar que uma matriz de confusão de um classificador perfeito possui vários números positivos na diagonal principal e zero em todas as outras células. Nota-se que qualquer numero maior que zero em uma célula que não pertence a diagonal principal representa um erro. Com a matriz de confusão fica fácil de visualizar os erros mais comuns feitos pelo classificador.

A Figura 9 mostra uma matriz de confusão de um classificador que deve classificar expressões faciais.

A partir da matriz de confusão é fácil de determinar a precisão e a abrangência para cada classe i, conforme segue:

$$precisao(i) = \frac{a_{ii}}{\sum_{j=1}^L a_{ij}}$$

$$abrangencia(i) = \frac{a_{ii}}{\sum_{j=1}^L a_{ji}}$$

Ou seja, a precisão é um dos elementos da diagonal principal dividido pela soma de sua linha, enquanto que a abrangência é um dos elementos da diagonal principal dividido

| | Angry | bored | disgusted | Afraid | blissful | sad | neutral |
|------------------|--------------|--------------|------------------|---------------|-----------------|--------------|----------------|
| angry | 80.31 | 0.79 | 3.15 | 3.94 | 8.66 | 0 | 3.15 |
| bored | 0 | 66.67 | 6.17 | 2.47 | 0 | 7.41 | 17.28 |
| disgusted | 3.15 | 17.39 | 52.17 | 4.35 | 4.35 | 10.87 | 2.17 |
| afraid | 10.24 | 4.35 | 5.80 | 40.58 | 4.35 | 10.14 | 15.94 |
| blissful | 18.11 | 0 | 4.23 | 5.63 | 52.11 | 0 | 5.63 |
| sad | 0 | 11.29 | 0 | 1.61 | 0 | 82.26 | 4.85 |
| neutral | 2.36 | 17.71 | 5.06 | 7.59 | 0 | 2.53 | 63.29 |

Figura 9: Exemplo de Matriz de Confusão para um classificador retirado de (6)

pela sua coluna.

Apesar de ter números específicos é muito bom pra analisar o quanto bom um classificador é, é sempre importante observar a Matriz de Confusão pra detectar possíveis problemas e os lugares onde há erros mais comuns.

3.5.2.2 Médias micro e macro (*Micro and Macro Averaging*)

Conforme o descrito, pode-se calcular a precisão, a abrangência, o Fscore e a acurácia para cada classe individualmente. Entretanto seria interessante juntar todos estes dados em um único número. Para tal, faz-se uma média. Existem duas formas de realizar esta média, que são chamadas de micro e macro.

A média micro consiste em somar os numeradores e denominadores das fórmulas das métricas supracitadas separadamente (na prática isto é equivalente a realizar uma média ponderada nos denominadores). Seguem as fórmulas de precisão, abrangência e acurácia micro.

$$precisao_{\mu} = \frac{\sum_{i=1}^L tp_i}{\sum_{i=1}^L tp_i + fp_i}$$

$$abrangencia_{\mu} = \frac{\sum_{i=1}^L tp_i}{\sum_{i=1}^L tp_i + fn_i}$$

Com uma matemática simples da pra concluir que a precisão micro é numericamente igual à abrangência micro (basta notar que o numerador dos dois é igual e o denominador dos dois representa a soma de todos os elementos da matriz de confusão, um através da

soma das linhas e o outro através da soma das colunas).

A média macro consiste em somar os valores finais das métricas calculadas em cada classe e dividir pelo total de classes (uma média aritmética simples). Seguem as fórmulas de precisão e abrangência macro.

$$\text{precisao}_M = \frac{\sum_{i=1}^L \frac{tp_i}{tp_i + fp_i}}{L}$$

$$\text{abrangencia}_M = \frac{\sum_{i=1}^L \frac{tp_i}{tp_i + fn_i}}{L}$$

A intuição por trás dessas duas médias é que a média macro dá igual importância para todas as classes, enquanto que a média micro da mais importância para as classes mais comuns (no caso da abrangência) ou para as classes com mais objetos classificados nelas (no caso da precisão).

3.5.2.3 Fscore

Da mesma forma que foi definido o Fscore para o caso do classificador binário, é possível definir um Fscore macro e um Fscore micro (dependendo da utilização da precisão e abrangência macro ou micro).

$$F_{\beta\mu} = \frac{(1+\beta^2) \cdot \text{precisao}_{\mu} \cdot \text{abrangencia}_{\mu}}{\beta^2 \text{precisao}_{\mu} + \text{abrangencia}_{\mu}}$$

$$F_{\beta M} = \frac{(1+\beta^2) \cdot \text{precisao}_M \cdot \text{abrangencia}_M}{\beta^2 \text{precisao}_M + \text{abrangencia}_M}$$

Uma observação interessante é que, como a precisão micro e a abrangência micro são numericamente iguais, temos que o Fscore micro também terá este mesmo valor (independentemente de β). Para a média macro isto não acontece.

3.5.2.4 Acurácia

É possível encontrar na literatura duas definições diferentes de acurácia (8) (36).

Em uma das definições, a acurácia de um classificador *multi-class* é a média aritmética (média macro) das acurácias individuais de cada classe.

$$\text{accuracy} = \frac{\sum_{i=1}^L \frac{tp_i + tn_i}{tp_i + fn_i + fp_i + tn_i}}{L}$$

Na outra definição, a acurácia é a quantidade total de acertos (considerando todas as classes), dividida pela quantidade total de documentos.

$$\text{accuracy} = \frac{\sum_{i=1}^L tp_i}{N} \tag{3.12}$$

Considerando a matriz de confusão, temos que:

$$\text{accuracy} = \frac{\sum_{i=1}^L a_{ii}}{\sum_{i=1}^L \sum_{j=1}^L a_{ij}} = \frac{\sum_{i=1}^L a_{ii}}{N}$$

Neste trabalho será utilizada esta última definição por ser mais intuitiva e dar mais informação sobre a qualidade do classificador (observe que a primeira definição de acurácia tende a sempre resultar em valores altos para problemas com muitas classes, uma vez que a quantidade de verdadeiros negativos tende a ser alta para todas as classes).

Observa-se que a acurácia também é numericamente igual à abrangência e à precisão com média micro.

3.5.2.5 Medida Kappa

Como já foi discutido previamente, a acurácia é uma medida muito ruim pois é possível desenvolver classificadores com comportamento trivial que possuem uma boa acurácia. Para resolver este problema, utilizam-se outras estatísticas em vez da acurácia que possuem mais valor semântico e dão mais informações sobre a performance do classificador. Já foram explicadas outras medidas que possuem mais informações (abrangência, precisão e Fscore micros e macros) e a matriz de confusão que permite a visualização de problemas recorrentes no classificador. Entretanto, para o problema *multi-class* é comum utilizar uma outra métrica (chamada de Kappa) para avaliar a performance do classificador em questão.

A estatística Kappa é utilizada para comparar a Acurácia Observada com a Acurácia Esperada. Esta estatística é muito poderosa e permite a realização de comparações até mesmo entre classificadores diferentes (26). Ela utiliza a comparação em relação a um classificador aleatório de modo a tornar esta estatística mais confiável que uma simples acurácia.

A Acurácia Observada é a mesma acurácia que já foi definida previamente na equação 3.12. Ela representa a quantidade de objetos classificados corretamente em relação ao total.

Define-se como Acurácia Observada, a porcentagem esperada de acertos que um classificador aleatório teria se ele classificar os objetos com a mesma proporção entre as classes que o classificador original.

Para se deduzir a fórmula da Acurácia Esperada primeiro calcula-se a quantidade de vezes que o classificador original escolheu a classe c_i . É fácil de ver que ele escolheu esta

classe $tp_i + fp_i$ vezes. O valor esperado do número de acertos de um classificador aleatório que escolha a dada classe $tp_i + fp_i$ vezes é:

$$E[c_i] = (tp_i + fp_i) \frac{tp_i + fn_i}{N}$$

Isto ocorre pois $\frac{tp_i + fn_i}{N}$ é a probabilidade de que um objeto aleatório pertença à classe i . A quantidade esperada para o número de acertos em todas as classes é de:

$$E[c_1, c_2, \dots, c_L] = \sum_{i=1}^L (tp_i + fp_i) \frac{tp_i + fn_i}{N}$$

Como a Acurácia Esperada é a porcentagem de acertos desse classificador aleatório tem-se:

$$\text{acuracia_esperada} = \frac{E[c_1, c_2, \dots, c_L]}{N} = \frac{\sum_{i=1}^L (tp_i + fp_i)(tp_i + fn_i)}{N^2}$$

Em termos da matriz de confusão, a acurácia esperada é a somatória dos produtos entre cada linha com a sua respectiva coluna (linha 1 com coluna 1, linha 2 com coluna 2 e assim por diante) dividida pela quantidade total de elementos ao quadrado.

A definição de Acurácia Esperada é importante pois um classificador de Acurácia Observada 80% é muito mais impressionante se a Acurácia Esperada for de 1% do que se ela for 79%.

A estatística *Kappa* indica a porcentagem de melhoria que o classificador tem em relação à Acurácia Esperada (40). Um classificador com Acurácia Observada idêntica à Acurácia Esperada possui $Kappa = 0$, enquanto que um classificador com Acurácia Observada de 100% possui $Kappa = 1$. Valores intermediários do *Kappa* indicam a melhoria do classificador em relação ao aleatório. Desta forma, a fórmula para o *Kapp* é:

$$Kappa = \frac{\text{acuracia_observada} - \text{acuracia_esperada}}{1 - \text{acuracia_esperada}}$$

4 *Metodologia*

4.1 Plano de desenvolvimento

4.2 Aquisição de dados

4.3 Processamento do texto

5 *Proposta de Classificador*

*6 **Tecnologias Utilizadas***

7 Validação - Experimentos, resultados e análise

8 Conclusões e Trabalhos Futuros

9 Instrumentos analisados

Todo programa de computador é, essencialmente, um algoritmo que transforma um sinal de entrada em um sinal de saída, portanto, entender os sinais de entrada é fundamental para o desenvolvimento e a depuração de qualquer programa de computador.

No desenvolvimento deste trabalho diversos limites terão de ser impostos aos sinais sonoros de entrada. Serão estabelecidos limites, por exemplo à quantidade máxima de notas tocadas por segundo, à nota mais grave e mais alta, à intensidade mínima para um som ser considerado uma nota, etc. Entretanto, dada a multitude de instrumentos existente, é virtualmente impossível estabelecer limites para os exemplos dados que satisfaçam aos sinais gerados por todos os instrumentos.

Assim, embora o escopo deste trabalho seja a transcrição musical automática de instrumentos monofônicos temperados, independentemente da forma com que o som é gerado neles, as análises feitas a partir deste capítulo serão voltadas a um sub-conjunto específico de instrumentos. Espera-se que este sub-conjunto seja representativo o bastante para que o algoritmo final desenvolvido seja também aplicável a diversos outros instrumentos. Este capítulo apresenta os instrumentos escolhidos e justifica as escolhas.

9.1 Características de interesse

Ao escolher os instrumentos, algumas características desejadas foram levantadas, essas são apresentadas a seguir:

9.1.1 Mecanismo de produção de som

Deseja-se que os instrumentos analisados possuam mecanismos de produção de som simples e para os quais já existam modelos matemáticos confiáveis. Isso tornará possível embasar as decisões tomadas em modelos matemáticos que representam o mundo real, e não apenas em suposições feitas com base em teoria musical.

9.1.2 Timbre

O timbre é, talvez, a característica mais marcante de um instrumento, e pode variar muito mesmo entre instrumentos de uma mesma família. Por esses motivos, deseja-se que os instrumentos analisados possuam timbres consideravelmente distintos. Isso ajudará a elaborar algoritmos que funcionem em uma gama diversa de instrumentos.

9.1.3 Tom

Em um único instrumento, uma mesma nota pode ser tocada de diversas formas, ou tons, dependendo da sensação que o músico deseja transmitir. Por exemplo, uma nota pode ser suave ou agressiva; viva ou fria. É interessante que os instrumentos escolhidos sejam capazes de gerar uma vasta gama de tons, também para que os algoritmos elaborados sejam pouco específicos aos instrumentos escolhidos.

9.1.4 Popularidade

Para que os algoritmos desenvolvidos possuam aplicações reais, é interessante que eles funcionem bem para instrumentos populares, portanto faz sentido escolher instrumentos que sejam conhecidos e bastante utilizados.

9.2 Instrumentos escolhidos

Com base nas características levantadas, a classe dos instrumentos de sopro foi escolhida. Além de populares, a produção de som por esses instrumentos já é um processo bem conhecido e que pode ser aproximado por modelos majoritariamente lineares (13). Estes instrumentos também possuem timbres bastante característicos e distintos uns dos outros. Ainda, instrumentos como a flauta transversal permitem ao instrumentista realizar uma vasta gama de tonalidades dependendo de sua embocadura, controle de respiração, etc.

Dentro da classe dos instrumentos de sopro, os seguintes instrumentos foram selecionados:

1. Flauta doce
2. *Tin whistle*
3. Pífano

4. Flauta transversal ocidental
5. Flauta transversal chinesa (*dizi*)
6. Ocarina

Cada instrumento será apresentado partindo de uma breve descrição histórica, seguida de características de interesse para o trabalho e de uma análise espectral de algumas notas tocadas no instrumento. Nota-se que o espectro gerado por cada instrumento pode variar de acordo com a habilidade do instrumentista e com as técnicas que ele deseja executar (12). Entretanto, consideramos que essas variações são desprezíveis quando comparadas às causadas pelo uso de instrumentos diferentes e, portanto, podem ser desconsideradas nesse capítulo, cujo propósito é apenas comparar o espectro de diferentes instrumentos e discutir os resultados esperados para cada um.

9.3 Flauta doce

A flauta doce é um instrumento de origem medieval, sua popularidade em apresentações diminuiu consideravelmente com o surgimento de instrumentos voltados para orquestras. Hoje, por ser um instrumento relativamente simples e fácil de se tocar, a flauta doce é amplamente utilizada no ensino de música.

Neste trabalho, será utilizada uma flauta doce soprano germânica afinada em dó maior (modelo Yamaha YRS-23Y). Este modelo possui oito buracos, é feito de plástico e é amplamente utilizado por iniciantes. O termo "soprano" remete ao fato da nota mais grave produzida por esta flauta ser um C5, enquanto o termo "germânica" remete à forma com que os buracos na flauta devem ser utilizados para produzir notas específicas.

9.3.1 Características

A flauta doce utilizada é capaz de produzir 3 oitavas cromáticas¹ a partir do C5.

Uma característica que facilitará este trabalho é que a estrutura geométrica da flauta doce é totalmente controlada pelo fabricante (5). Seu bocal é feito de forma a direcionar o jato de ar produzido pelo flautista contra uma superfície afiada. Com isso, o flautista

¹A maioria dos instrumentos de sopro não possui um limite superior para as notas produzidas (13). Os limites apresentados aqui são os dados pelo fabricante do modelo utilizado, e refletem o que é pedido no repertório clássico.

não precisa se preocupar em direcionar o jato de ar gerado, e tem que apenas controlar a pressão exercida. O bocal da flauta doce também é projetado para facilitar o controle da pressão exercida e, como resultado, o flautista é capaz de produzir duas oitavas com modificações mínimas no jato de ar que produz, e sem ter de modificar sua geometria. Isso também significa que a tonalidade da flauta doce varia pouco, embora fatores como ressonância na cavidade oral do instrumentista ainda permitam a ele leves modificações no tom (5).

Por outro lado, a flauta doce não possui nenhum mecanismo para ajudar o flautista a pressionar os buracos em seu corpo. Assim, embora seja relativamente fácil produzir e alternar entre as notas da escala de dó maior, produzir uma escala cromática é uma tarefa difícil que requer muito controle do posicionamento dos dedos, sendo necessário encobrir certos buracos levemente, com um alto grau de precisão. Ainda, pode ser necessário alternar muitos dedos entre notas cromáticas, o que facilmente produz estados transientes desagradáveis em frases tocadas em *legato*.

9.3.2 Análise espectral

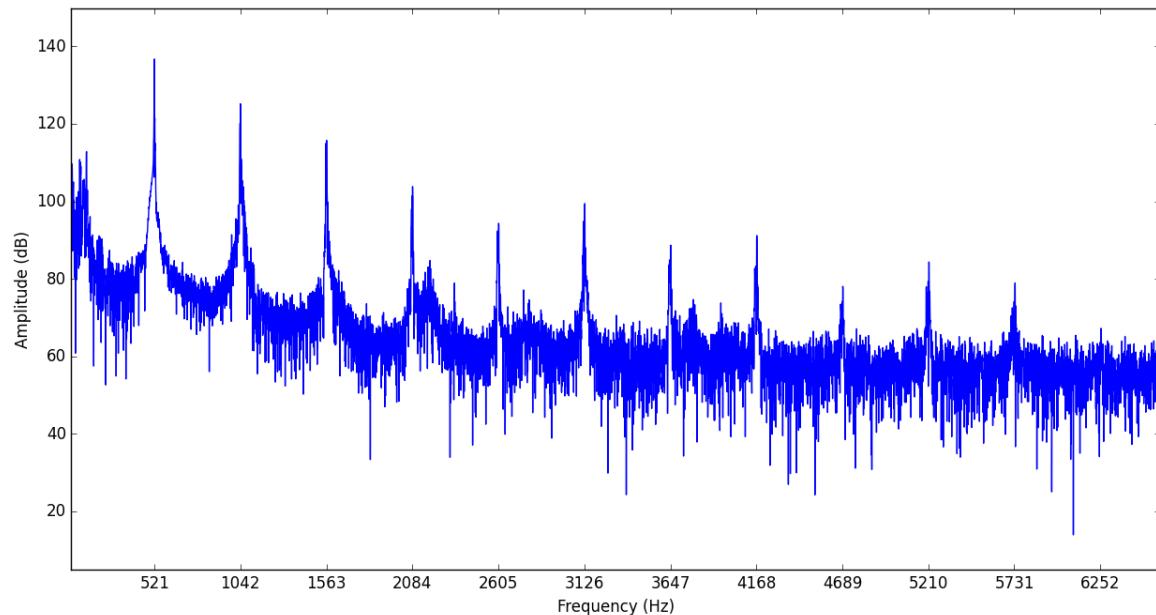


Figura 10: Espectro para a nota C5 tocada em uma flauta doce Yamaha YRS-23Y obtido a partir da FFT em 1 segundo de gravação.

A figura 10 mostra o espectro obtido em 1 segundo de gravação da nota mais grave produzida pela flauta doce (C5). Observa-se que na flauta doce o componente fundamental

é o mais acentuado, sendo seguido por quatro harmônicos cuja amplitude decai em cerca de 10dB/harmônico. A partir do quinto harmônico o comportamento deixa de seguir um padrão simples. Ainda, o máximo em 521Hz indica que a flauta doce utilizada está afinada com o A4 em cerca de 438Hz, o que sugere a afinação padrão de 440Hz com uma pequena margem de erro que pode ter sido causada, por exemplo, por diferenças de temperatura. Por fim, é interessante observar que os harmônicos da flauta doce seguem a série:

$$H_n = H_0(n + 1) \quad (9.1)$$

Sendo H_0 o harmônico fundamental. Outros instrumentos podem seguir a série:

$$H_n = H_0(2n + 1) \quad (9.2)$$

Uma explicação física para os instrumentos de sopro gerarem uma série ou a outra pode ser encontrada em (13).

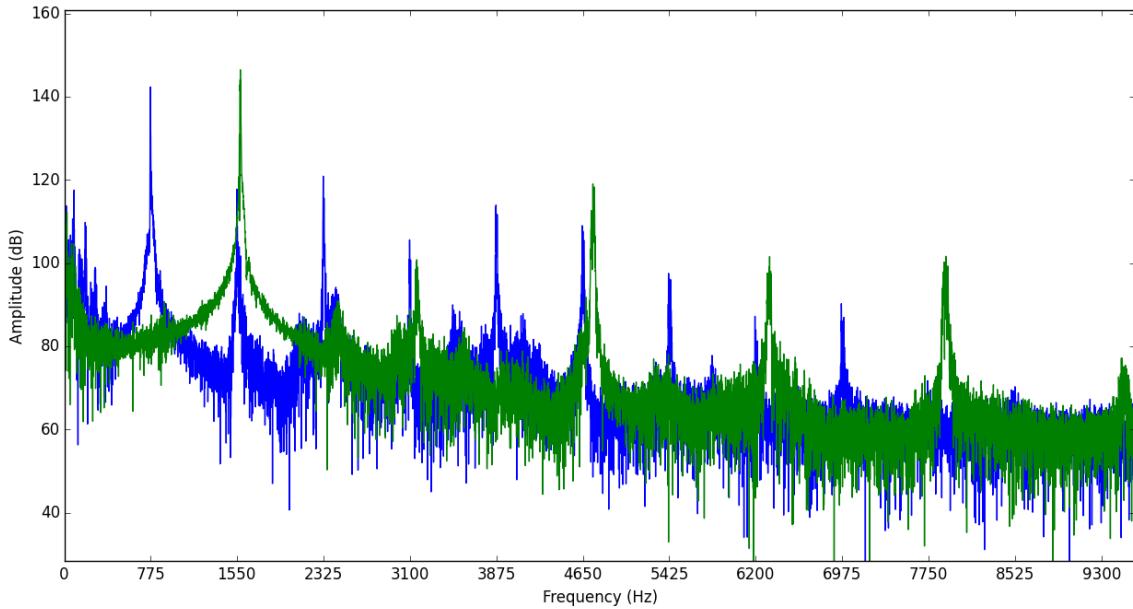


Figura 11: Espectro para um G5 (azul) e um G6 (verde) tocados em uma flauta doce Yamaha YRS-23Y obtido a partir da FFT em 1 segundo de gravação.

Já a figura 11 compara o espectro de um G5 e de um G6 uma oitava acima. É interessante observar que a amplitude relativa entre os harmônicos é bastante diferente da amplitude relativa para a nota C5 da figura 10, sendo o segundo harmônico mais intenso

que o primeiro. Apesar disso, tanto o G5 quanto o G6 possuem amplitudes relativas semelhantes entre si. Outro fator interessante é que os harmônicos produzidos não são posicionados exatamente nas mesmas frequências.

Por fim, observamos que a nota G6 tem uma leve tendência de gerar componentes posicionados nos harmônicos de um G5 que não são seus próprios harmônicos. Isso pode ser visto na frequência de (2325Hz), que é um múltiplo da frequência fundamental do G5 775Hz , mas não é um múltiplo do G6 (1550Hz). Isto dificultará a distinção dessas duas notas no algoritmo de detecção de frequência fundamental.

9.3.3 Conclusões

Espera-se que o programa desenvolvido nesse trabalho seja capaz de identificar muito bem músicas em dó maior tocadas nessa flauta, mas que encontre dificuldades em músicas cromáticas, especialmente se houver muitas frases em *legato*. Espera-se que essa dificuldade seja mais relacionada à erros cometidos pelo instrumentista do que de erros do algoritmo.

9.4 *Tin Whistle*

O *tin whistle* é um instrumento de sopro popular na música celta, seu corpo costuma ser feito de estanho, daí o nome. A música popular celta é conhecida por ritmos rápidos e frases com muitos ornamentos, e isso se reflete nas características do *whistle*.

Nesse trabalho será utilizado um *whistle* Clarke SBDC afinado em Ré maior, que possui 6 buracos.

9.4.1 Características

O *whistle* utilizado é capaz de produzir 2 oitavas nas escalas de Ré maior ou Sol maior, a partir de um D5.

O *whistle* é bastante semelhante à flauta doce, mas é um instrumento de confecção mais simples e seu bocal ajuda muito menos o instrumentista a controlar o jato de ar, sendo mais fácil gerar notas desafinadas ou desagradáveis. Por outro lado, os buracos no corpo do *whistle* são mais simples, e é muito fácil transitar entre as notas na escala para a qual ele foi afinado. Isso permite ao instrumentista tocar passagens muito rápidas e com

diversos ornamentos sem gerar muitos transientes desagradáveis.

9.4.2 Análise espectral

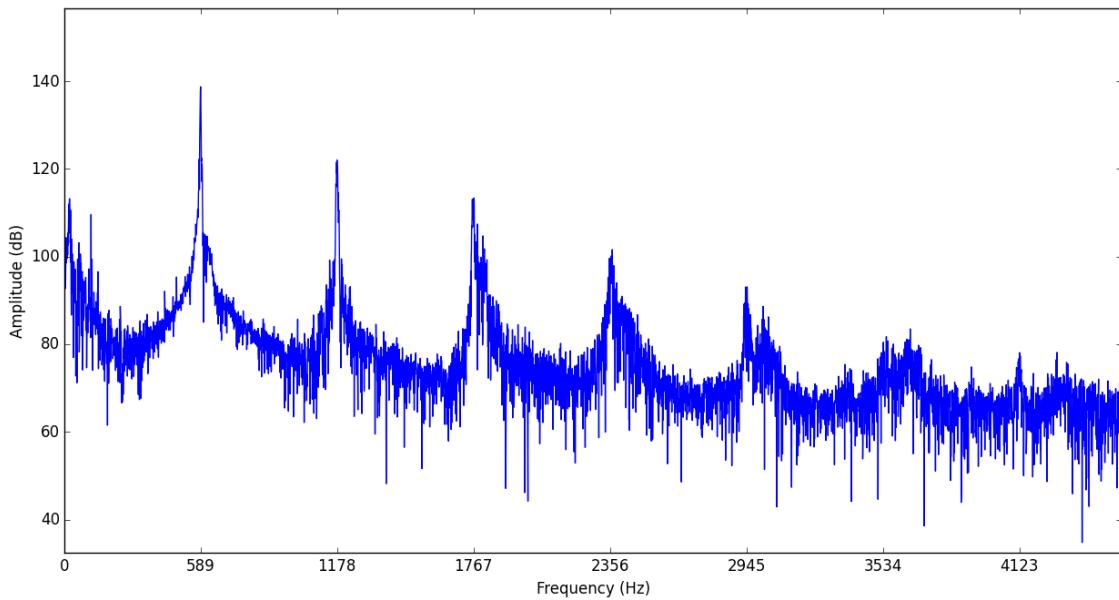


Figura 12: Espectro para a nota D5 tocada em um *whistle* Clarke SBDC obtido a partir da FFT em 1 segundo de gravação.

Na figura 12 podemos ver que, relativamente à flauta doce, o *whistle* gera menos harmônicos significativos. Além disso, os picos nas frequências dos harmônicos "vazam" mais para as frequências vizinhas. Isso pode ser atribuído ao bocal mais primitivo do *whistle*, que direciona menos o jato de ar produzido pelo instrumentista, fazendo com que parte da energia do jato seja desperdiçada e gere componentes indesejados.

Na figura 13 podemos comparar a nota G6 com a nota G5 no *whistle*. É interessante observar que na nota G6 os ruídos são muito mais intensos do que na G5, lembramos que no *whistle* é necessário aumentar consideravelmente a intensidade do jato de ar para trocar entre oitavas, como o bocal do *whistle* não faz nenhum ajuste no jato de ar, a maior intensidade causa um desperdício maior de energia, que se reflete no ruído.

Adicionalmente, nota-se que a nota G6 gera um componente harmônico na frequência fundamental da nota G5, mas com amplitude reduzida. Isso é esperado pois as duas notas possuem o mesmo dedilhado e, portanto, a forma geométrica do instrumento permite que esse componente seja formado. Esse detalhe pode causar erros na classificação correta da oitava de uma nota tocada.

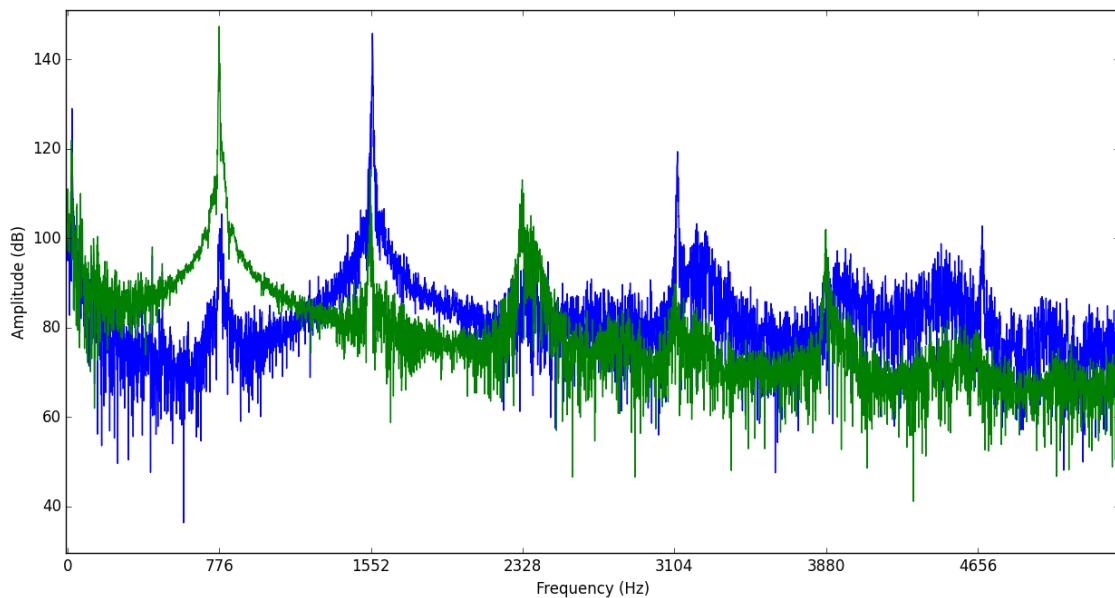


Figura 13: Espectro para um G5 (verde) e um G6 (azul) tocados em um *whistle* Clarke SBDC obtido a partir da FFT em 1 segundo de gravação.

9.4.3 Conclusões

Relativamente a flauta doce, espera-se que nos sinais provenientes do *whistle* seja mais fácil identificar passagens rápidas e com ornamentos, mas que para músicas lentas a precisão seja menor, devido a maior dificuldade em se controlar o jato de ar. Ainda, espera-se uma dificuldade adicional nas notas mais agudas, que possuem mais ruído e componentes nas mesmas frequências das notas correspondentes na oitava inferior.

9.5 Pífano

O pífano é uma flauta transversal pequena com timbre estridente. É um instrumento bastante simples, sendo desprovido de um bocal e, portanto, delegando o controle do jato de ar totalmente ao instrumentista.

Nesse trabalho será utilizado um pífano Yamaha YRF-21 afinado em Dó maior, que é feito de plástico e possui 9 buracos em seu corpo, sendo um destinado ao sopro.

9.5.1 Características

O pífano utilizado é capaz de produzir cromaticamente as notas entre C5 e E7.

O pífano escolhido é bastante semelhante à flauta doce, tanto em material quanto na posição dos dedilhados. A maior diferença é o fato do pífano ser desprovido de um bocal e de ser empunhado transversalmente. A ausência de um bocal permite ao instrumentista controlar sua embocadura de forma a variar muito o tom do instrumento. Assim, as dificuldades apresentadas para a flauta doce se mantém, sendo acrescentadas dificuldades em identificar precisamente as notas, que podem sofrer muitas variações de tom.

Nota-se, em especial, que a transição entre oitavas no pífano é muito mais difícil de se realizar do que nos instrumentos apresentados anteriormente. Tanto na flauta doce quanto no *whistle* essa transição pode ser feita usando um dedilhado levemente diferente e acelerando um pouco o jato de ar. Entretanto, como o pífano não possui um bocal para direcionar o jato de ar, o instrumentista precisa alterar consideravelmente a sua embocadura de forma a gerar um jato mais rápido que continua atingindo a superfície do instrumento no ângulo correto e com a largura adequada. Esse aspecto será analisado espectralmente a seguir.

9.5.2 Análise espectral

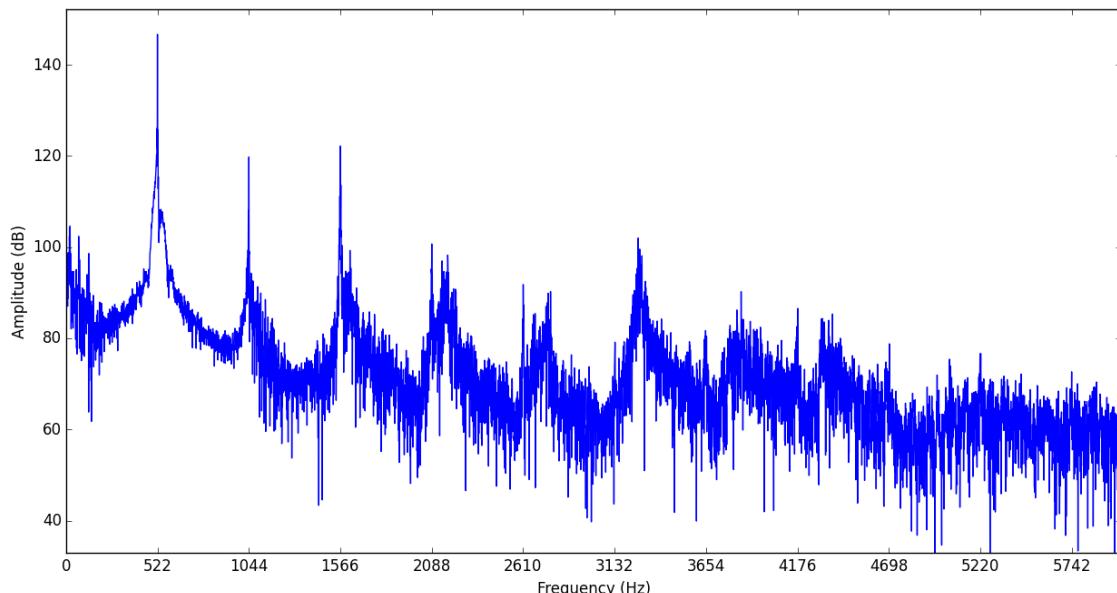


Figura 14: Espectro para a nota C5 tocada em um pífano Yamaha YRF-21 obtido a partir da FFT em 1 segundo de gravação.

Na figura 14 temos o espectro para um C5, a nota mais grave atingida pelo pífano. É possível reconhecer cerca de 8 harmônicos, sendo os 3 primeiros bem mais significativos.

Ainda, nota-se que os harmônicos a partir do terceiro são acompanhados de amplitudes consideráveis em suas redondezas, de forma semelhante ao que ocorre no *whistle*, e contrária à flauta doce.

9.5.3 Conclusões

Relativamente a flauta doce, espera-se que nos sinais provenientes do pífano seja mais difícil identificar precisamente a frequência fundamental das notas, e que ocorram erros relativos à oitava da nota tocada. Esses problemas se reduzem de acordo com a habilidade do instrumentista.

9.6 Flauta transversal ocidental

A flauta transversal ocidental é um dos instrumentos de sopro mais populares em orquestras. Foi feito a partir da modificação de flautas transversais medievais (semelhantes ao pífano). As principais melhorias introduzidas foram um corpo de metal, que é capaz de gerar notas muito mais altas e que podem ser carregadas sobre os demais instrumentos de uma orquestra, e um mecanismo de botões e molas que deixa os dedilhados muito mais confortáveis, pois os botões podem ser projetados para ocuparem posições confortáveis sem prejudicar a afinação do instrumento, além de facilitarem a tarefa de encobrir totalmente os buracos.

Nesse trabalho será utilizada uma flauta transversal afinada em Dó maior, modelo Hallelu HFL-200.

9.6.1 Características

A flauta transversal utilizada é capaz de produzir cromaticamente três oitavas a partir do C4.

Em relação aos instrumentos apresentados anteriormente, nota-se que a flauta transversal escolhida é capaz de produzir notas mais graves. Analisar essas notas será uma tarefa mais difícil, primeiro porque a diferença absoluta da frequência entre duas notas separadas por um semiton será menor e, segundo, porque a frequência menor aumenta o tempo em que o instrumento se encontra em estados transitórios (13).

Em relação à flauta doce e ao *whistle*, a ausência de um bocal dificulta a identificação

das notas tocadas, pois há uma variedade muito maior de tons que podem ser produzidos, assim como no pífano. Por outro lado, a construção mais cuidadosa do instrumento e os botões mecânicos ajudarão a produzir tons mais limpos do que no pífano, e facilitarão a identificação de notas em passagens rápidas e com *legatos*.

9.6.2 Análise espectral

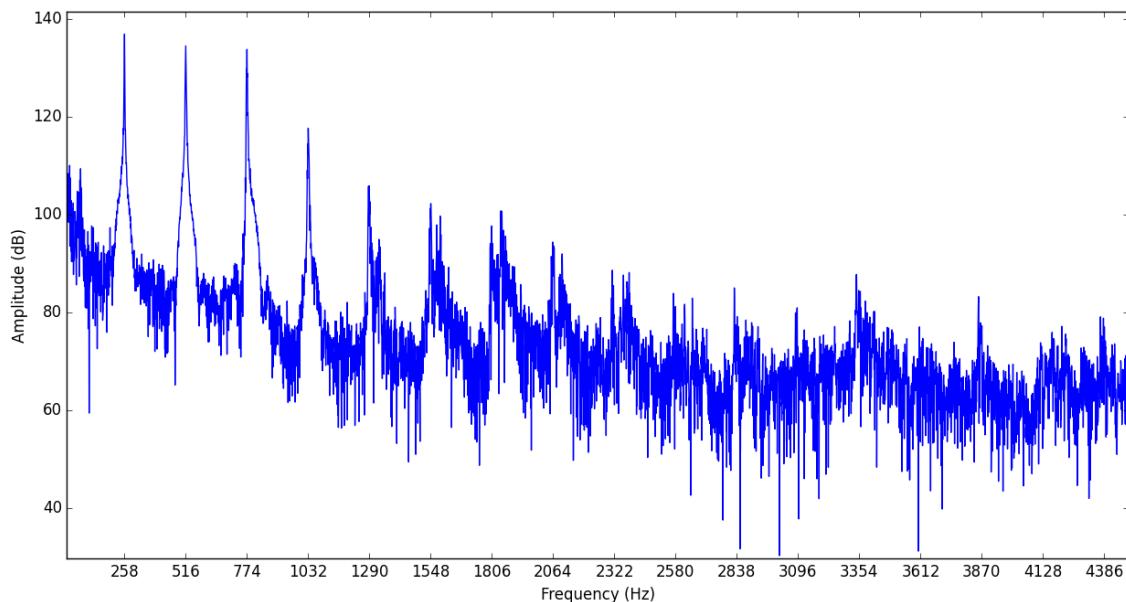


Figura 15: Espectro para a nota C4 tocada em uma flauta transversal Hallelu HFL-200 obtido a partir da FFT em 1 segundo de gravação.

Na figura 15 vemos o espectro para um C4, a nota mais grave produzível na flauta transversal. Já na figura 16 vemos as notas G4 e G6 na mesma flauta.

Primeiramente, observamos que na nota C4 os três primeiros harmônicos possuem amplitude bastante próxima. A nota C4 na flauta transversal é relativamente difícil de ser tocada, sendo necessário um controle bastante preciso do jato de ar produzido. Pequenos erros no jato podem transformar a nota em um C5, o que justifica a amplitude relativamente alta do segundo harmônico (que seria o fundamental para um C5). Além disso, os harmônicos mais altos não possuem picos tão bem definidos quanto os mais baixos, o que indica um som menos limpo do que o da flauta doce, por exemplo.

Comparando a figura 15 com a 16, podemos ver que a nota G4, apesar de estar na mesma oitava que a C4, não apresenta as dificuldades apresentadas anteriormente, possuindo um espectro parecido com os produzidos pela flauta doce, em que cada harmônico

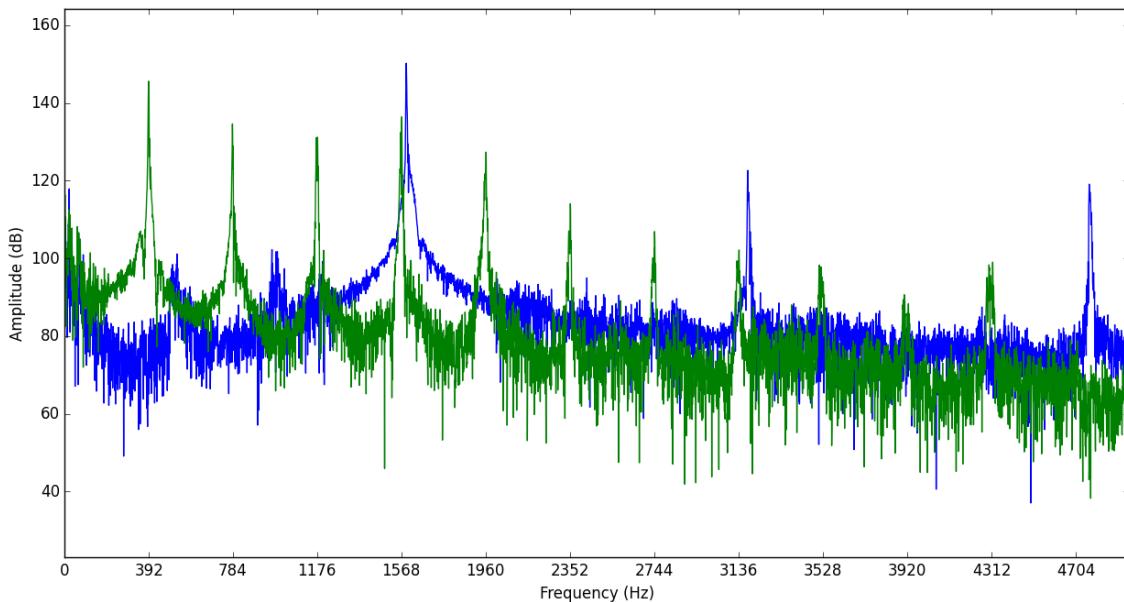


Figura 16: Espectro para um G4 (verde) e um G6 (azul) tocados em uma flauta transversal Hallelu HFL-200C obtido a partir da FFT em 1 segundo de gravação.

possui um pico bem definido no espectro.

Por fim, vemos que a nota G6, mesmo estando duas oitavas acima da nota G4, não apresenta um ruído significativamente maior e nem gera componentes sub-harmônicos significativos (dificuldades presentes, por exemplo, nas notas altas do *whistle*). Nota-se que a flauta transversal é um instrumento feito para ser ouvido sob uma orquestra e é, portanto, mais potente. A energia perdida no jato de ar produzido pelo flautista é menos significativa. Além disso, a ausência de um bocal permite ao flautista ajustar livremente a embocadura, de forma a aproveitar bem a energia do jato de ar e controlar os componentes sub-harmônicos.

9.6.3 Conclusões

Espera-se que a identificação das notas na flauta transversal seja mais fácil que nos demais instrumentos a partir da segunda oitava (C5-C7), desde que o flautista seja hábil o bastante para controlar sua embocadura corretamente. Na oitava inferior (C4-B4) podem haver mais erros devido à estados transitórios e à maior proximidade entre as frequências fundamentais. Por fim, espera-se ser mais fácil identificar passagens cromáticas na flauta transversal do que nos outros instrumentos, devido aos botões mecânicos que facilitam os dedilhados para notas acidentais.

9.7 Flauta transversal chinesa (*dizi*)

O *dizi*, comumente conhecido como flauta transversal chinesa, é um instrumento popular na china, sendo utilizado tanto em música popular quanto em óperas e orquestras chinesas. Costuma ser feito artesanalmente a partir de uma única peça de bambu, que é furada nas posições desejadas para os dedilhados.

Nesse trabalho será utilizado um *dizi* artesanal de baixa qualidade importado da china.

9.7.1 Características

O *dizi* utilizado é capaz de produzir um subconjunto específico de notas entre E5 e B7. Seu temperamento não gera notas separadas por semitons, o que dificultará muito a tarefa de classificá-las.

Em relação ao pífano, a produção artesanal do *dizi* faz com que as notas produzidas possuam várias imperfeições, tanto na afinação, pela posição dos buracos, quanto no tom, pela maior dificuldade em se encobrir totalmente os buracos. Ainda, o *dizi* escolhido possui 11 buracos em seu corpo, e seus dedilhados são pouco confortáveis, sendo difícil tocar passagens rápidas com precisão.

Por não ser muito adequado à música ocidental, ele será utilizado brevemente para testar os tons produzidos por instrumentos pouco comuns na música ocidental, e com afinações exóticas.

9.7.2 Análise espectral

9.7.3 Conclusões

Espera-se que a identificação correta das notas tocadas no *dizi* seja bastante difícil e que seja feita com sucesso apenas para músicas mais lentas, a menos que o instrumentista seja muito habilidoso. Ainda, espera-se que seja difícil obter as notas exatas devido à afinação não temperada do *dizi*.

9.8 Ocarina

A ocarina é um instrumento de sopro globular geralmente feito de cerâmica. É um dos instrumentos mais antigos conhecidos, e pode ter diversas formas.

Nesse trabalho será utilizada uma ocarina modelo ”TOTMC Legend of Zelda Ocarina of Time Triforce Link TOLO248” de 12 buracos afinada em Dó maior.

9.8.1 Características

A ocarina escolhida é capaz de produzir cromaticamente as notas no intervalo A4-F6.

O corpo globular da ocarina dificulta a criação de harmônicos, sendo a frequência fundamental muito mais intensa do que as mais altas. Entretanto, espera-se que a manufatura em cerâmica apresente mais imperfeições do que os instrumentos em plástico e metal, o que pode ser constatado, por exemplo, no formato irregular dos buracos. Também nota-se que os dedilhados na ocarina são pouco confortáveis, sendo muito fácil não encobrir corretamente alguns dos buracos.

9.8.2 Análise espectral

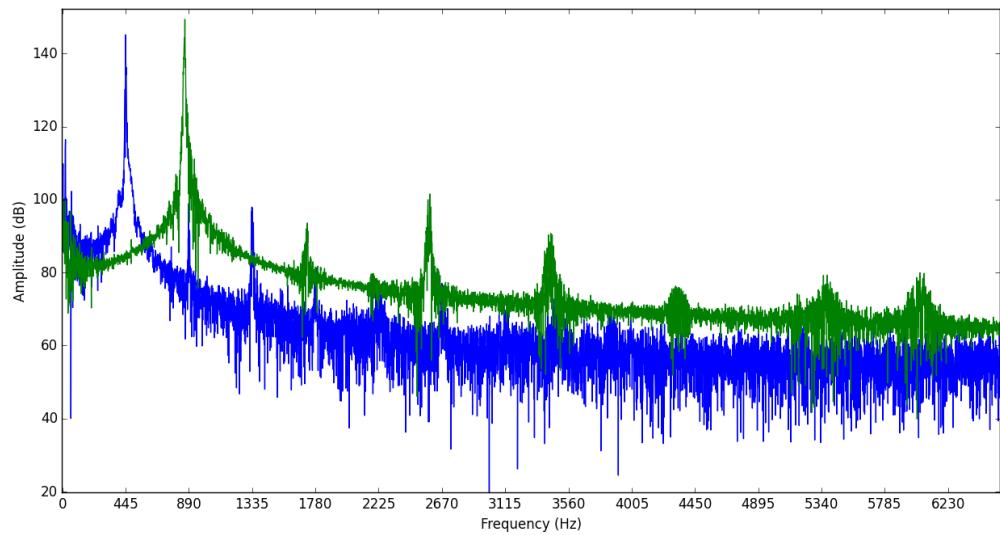


Figura 17: Espectro para um A4 (azul) e um A5 (verde) tocados na ocarina escolhida, obtido a partir da FFT em 1 segundo de gravação.

Na figura 17 comprovamos que apenas o harmônico fundamental é significativo na ocarina.

9.8.3 Conclusões

Como na ocarina apenas a frequência fundamental é considerável, espera-se que as notas identificadas estejam na oitava correta. Entretanto, pode haver erros na identificação de notas separadas por semitons, pois a decisão terá de ser tomada com a informação de um único harmônico.

10 Algoritmos de Otimização

10.1 Algoritmo Genético

Algoritmos Genéticos (**AG!**s) são inspirados na Teoria da Evolução de Darwin (16). Nestas técnicas, mantém-se uma população de soluções candidatas, chamadas cromossomos, que “evoluem” guiadas por uma medida de qualidade (função de *fitness*) através da aplicação de operações inspiradas pela evolução natural: seleção, mutação, *crossover* e sobrevivência dos mais aptos. Inicialmente, a população é composta por S_i (parâmetro do AG) cromossomos gerados aleatoriamente.

Existem diversas variantes de **AG!**. A seguir, explica-se os detalhes de **AG!** nas formas que são utilizadas com mais frequência. No final, apresenta-se também um pseudocódigo para **AG!**. Uma descrição mais geral de **AG!** pode ser encontrada em (30).

Cromossomo

Um cromossomo é um candidato à solução ótima. Cada parte do cromossomo é chamada gene. A boa codificação do problema em cromossomo é um fator fundamental para o sucesso do algoritmo. No caso do problema de otimizar um conjunto de parâmetros, a codificação em cromossomo óbvia é representar uma dada instância por um vetor, em que cada posição (gene) corresponde a um parâmetro específico.

Função de *Fitness*

É uma função que, dado um cromossomo, retorna um número real (*fitness*) que mede o quanto bom é este cromossomo para resolver o problema. Em geral, assume-se a convenção que quanto maior o *fitness*, melhor o cromossomo.

Seleção

A cada geração uma parte da população é escolhida para reprodução. Nesse processo, a probabilidade de um cromossomo ser escolhido é geralmente proporcional ao seu *fitness* (seleção por roleta). Outras formas de selecionar os que irão se reproduzir também são aplicadas. O número de quantos indivíduos R (parâmetro do **AG!**) são escolhidos para reprodução a cada geração é um parâmetro do **AG!**.

Mutação

Corresponde ao fator de caminhada aleatória do algoritmo. Dado um cromossomo, essa operação itera sobre cada gene e o troca por um valor aleatório (dentro do domínio do gene) com uma certa probabilidade de mutação p_m (parâmetro do **AG!**).

Crossover

Dados dois cromossomos escolhidos para se reproduzir, é interessante (assim como ocorre na Natureza) que, ao invés de se ter filhos como cópia idêntica dos pais, faça-se uma recombinação dos genes dos pais de modo a produzir cromossomos com características mistas. Assim, o *crossover* em um **AG!** segue um procedimento análogo ao *crossover* biológico: escolhe-se um ponto de quebra e cria-se um cromossomo filho tomando-se a parte do primeiro pai antes do ponto de quebra e a do segundo após esse ponto. Observe que esse processo pode ser generalizado para múltiplos pontos de quebra, embora comumente se utilize um único ponto.

Sobrevivência dos Mais Aptos

Como a cada iteração ocorre reprodução, a população tende a aumentar indefinidamente. Para evitar isso, assume-se um tamanho de população máximo S_m (parâmetro do **AG!**) e elimina-se os menos aptos (com menores valores de *fitness*) a cada geração. Outra forma de realizar esta operação envolve escolher probabilisticamente os sobreviventes com probabilidade de escolha dependente do valor de *fitness*.

Algoritmo 1: Pseudocódigo do Algoritmo Genético.

```

begin
    Populacao  $\leftarrow$  PopulacaoAleatoria( $S_i$ );
    Fitnesses  $\leftarrow$  CalcularFitnesses(Populacao);
    while critério de parada não satisfeito do
        Pais  $\leftarrow$  Selecao(Populacao, Fitnesses,  $R$ );
        Filhos  $\leftarrow$  Crossover(Pais);
        Populacao  $\leftarrow$  Populacao  $\cup$  Filhos;
        Populacao  $\leftarrow$  Mutacao(Populacao,  $p_m$ );
        Fitnesses  $\leftarrow$  CalcularFitnesses(Populacao);
        Populacao  $\leftarrow$  MaisAptos(Populacao, Fitnesses,  $S_m$ );
    end
end

```

10.2 Particle Swarm Optimization

PSO! é um algoritmo de otimização iterativo que busca uma candidata à solução ótima conforme uma medida de qualidade. O algoritmo trabalha com um espaço de busca em D dimensões limitado inferiormente por \mathbf{l} e superiormente por \mathbf{u} . Inicialmente, sorteia-se P “partículas” aleatoriamente tal que a posição \mathbf{x}_i e a velocidade \mathbf{v}_i de cada partícula p_i satisfazem as equações 10.1 e 10.2, respectivamente.

$$\mathbf{x}_i(d) \in [\mathbf{l}(d), \mathbf{u}(d)], d = 1, \dots, D \quad (10.1)$$

$$\mathbf{v}_i(d) \in [-|\mathbf{u}(d) - \mathbf{l}(d)|, |\mathbf{u}(d) - \mathbf{l}(d)|], d = 1, \dots, D \quad (10.2)$$

Assim, a cada iteração, cada posição de partícula é avaliada pela função de medida de qualidade $f : \mathbb{R}^D \rightarrow \mathbb{R}$ e atualiza-se \mathbf{b}_i , a melhor posição da partícula p_i até então, e \mathbf{g} , a melhor posição global de partícula até o momento, segundo f . A partir deste ponto, assume-se que o objetivo é maximizar $f(\mathbf{x})$. Note que isso não é limitação, pois se o objetivo é minimizar $f(\mathbf{x})$, basta executar o algoritmo com $g(\mathbf{x}) = -f(\mathbf{x})$. Por fim, atualiza-se a velocidade e a posição de cada partícula segundo as equações 10.3 e 10.4, respectivamente.

$$\mathbf{v}_i \leftarrow \omega \mathbf{v}_i + \varphi_p r_p (\mathbf{b}_i - \mathbf{x}_i) + \varphi_g r_g (\mathbf{g} - \mathbf{x}_i) \quad (10.3)$$

$$\mathbf{x}_i \leftarrow \mathbf{x}_i + \mathbf{v}_i \quad (10.4)$$

Em que ω , φ_p e φ_g são parâmetros do algoritmo, e r_p e r_g são número reais aleatórios entre 0 e 1. O método prossegue até que algum critério de parada seja atingido (número máximo de iterações, tempo máximo, limite de processamento, etc.). Um pseudocódigo para **PSO!** é apresentado no Algoritmo 2.

O **PSO!** tem vantagens por não impor requisitos sobre o problema a ser otimizado além do conhecimento do espaço de busca e de uma medida de desempenho. Entretanto, seu comportamento não é bem compreendido e não há garantia de convergência para solução ótima. Além disso, o método sofre de tendência a convergir para máximos locais.

Algoritmo 2: Pseudocódigo do *Particle Swarm Optimization*.

```

begin
    for  $i \leftarrow 1, \dots, P$  do
        for  $d \leftarrow 1, \dots, D$  do
             $\mathbf{x}_i(d) \leftarrow random(\mathbf{l}(d), \mathbf{u}(d));$ 
             $\Delta \leftarrow |\mathbf{u}(d) - \mathbf{l}(d)|;$ 
             $\mathbf{v}_i(d) \leftarrow random(-\Delta, \Delta);$ 
        end
         $\mathbf{b}_i \leftarrow \mathbf{x}_i;$ 
        if  $f(\mathbf{b}_i) > f(\mathbf{g})$  then
             $\mathbf{g} \leftarrow \mathbf{b}_i;$ 
        end
    end
    while critério de parada não satisfeito do
        for  $i \leftarrow 1, \dots, P$  do
            for  $d \leftarrow 1, \dots, D$  do
                 $r_p \leftarrow random(0, 1);$ 
                 $r_g \leftarrow random(0, 1);$ 
                 $\mathbf{v}_i(d) \leftarrow \omega \mathbf{v}_i(d) + \varphi_p r_p (\mathbf{b}_i(d) - \mathbf{x}_i(d)) + \varphi_g r_g (\mathbf{g}(d) - \mathbf{x}_i(d));$ 
            end
             $\mathbf{x}_i \leftarrow \mathbf{x}_i + \mathbf{v}_i;$ 
            if  $f(\mathbf{x}_i) > f(\mathbf{b}_i)$  then
                 $\mathbf{b}_i \leftarrow \mathbf{x}_i;$ 
                if  $f(\mathbf{b}_i) > f(\mathbf{g})$  then
                     $\mathbf{g} \leftarrow \mathbf{b}_i;$ 
                end
            end
        end
    end
end

```

11 *Tecnologias Utilizadas*

11.1 USARSim

USARSim! é um simulador de Robótica de alta fidelidade. A versão atual é baseada no **UDK!** (**UDK!**) (14), kit de desenvolvimento da *engine* de jogos Unreal. A Unreal usa como engine de Física a Nvidia PhysX (24), uma das mais avançadas *engines* de Física de tempo real. Com isso, é possível simular interações mecânicas, tais como colisão e atrito, com boa precisão. Inclusive, consegue-se modelar com boa fidelidade o comportamento de robôs humanóides com grande número de graus de liberdade, como demonstra (39).

O simulador já possui diversos modelos de robôs, sensores e atuadores. Além disso, a implementação de novos modelos é muito facilitada pelas ferramentas providas pelo **UDK!**, em especial uma ferramenta de edição chamada **UDK!** Editor e uma linguagem de *script* de alto nível denominada UnrealScript. A seguir, são apresentados os conceitos da **UDK!** e do **USARSim!** relevantes para o entendimento deste trabalho.

11.1.1 Nvidia PhysX

A simulação de Física da PhysX mantém uma cena em que os objetos são atualizados iterativamente, em que a cada iteração injeta-se um passo de simulação (no caso de tempo real, o intervalo de tempo desde a última atualização). Este comportamento discreto introduz erros de Física quando comparado ao que seria uma simulação contínua, logo deseja-se que o passo de simulação seja o menor possível para permitir uma maior fidelidade.

Em simulações em que a Física é crítica, como a simulação de um robô humanóide, a qualidade da simulação degrada muito com a redução da taxa de atualização da Física, como mostra (39). Observe que a simulação na Unreal ocorre em tempo real, o que torna o passo limitado pela capacidade de processamento disponível.

Uma cena de PhysX contém três importantes aspectos: *actors* (atores), *materials* (materiais) e *joints* (juntas). *Actors* definem objetos físicos capazes de interagir com o mundo e com outros objetos. *Actors* podem ser estáticos (fixos no mundo; geralmente usados para partes do cenário) ou corpos rígidos dinâmicos (usados para objetos móveis).

A cada *actor* pode estar associado um formato (modelo) físico. Note que este é desvinculado do modelo gráfico que é renderizado pela *engine* gráfica. Na realidade, para um dado objeto, em geral convém utilizar um modelo físico mais simples que o gráfico, pois cálculos de Física consomem bastante processamento; usar o modelo gráfico para Física é impraticável na maioria dos casos. Ademais, um *actor* também possui um tensor de inércia I_{body} e uma massa M localizada em seu centro de massa C_M .

Materials descrevem as propriedades de uma superfície (e.g. coeficiente de atrito) de um *actor*. Essas propriedades ditam o que ocorre quando dois *actors* colidem. *Joints* conectam dois corpos rígidos e limitam o movimento entre estes. PhysX possui diversos tipos de juntas (classificadas conforme as restrições aplicados aos corpos que unem). Neste trabalho, a única junta utilizada é a *revolute joint* (junta de revolução), que conecta dois corpos por um eixo como mostra a Figura 18.

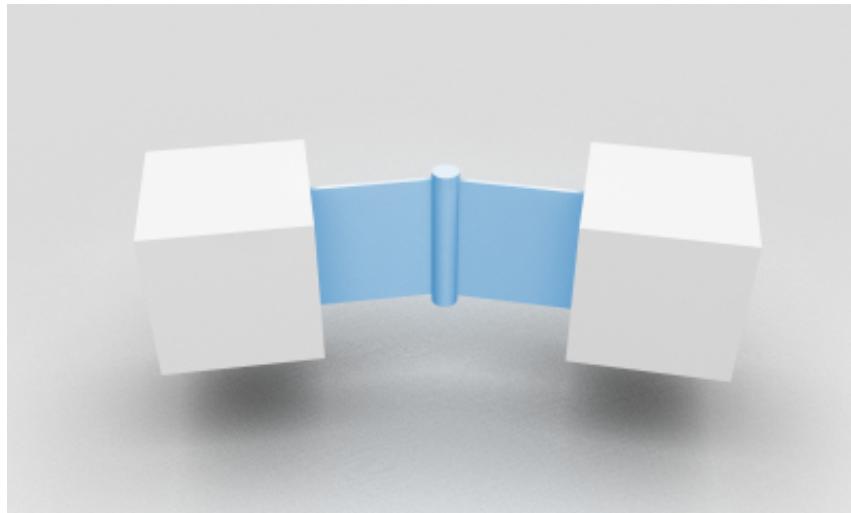


Figura 18: Junta de revolução.

Uma das tarefas mais importantes de uma engine Física é detectar quais colisões ocorrem em um dado momento eficientemente. Há dois desafios principais a serem superados nisso: detecção de colisão polígono por polígono (extremamente custosa) e dado n objetos presentes em uma cena, precisa-se, a princípio, testar colisão entre $\binom{n}{2}$ pares de objetos.

Para resolver o primeiro problema, a *engine* mantém uma caixa delimitadora (*bounding box*) para cada modelo físico. Essa caixa é formada pelos limites mínimos e máximos

do modelo em cada uma das coordenadas. Assim, para verificar se dois modelos colidem, o algoritmo verifica primeiro se as caixas delimitadoras se sobrepõem; se isso não ocorre, pode-se afirmar que os modelos certamente não colidem e evita-se o custoso teste polígono por polígono.

Para evitar testar colisão entre todos os pares de modelos de uma cena, PhysX divide o espaço em partições, de modo que há necessidade de verificar colisões apenas com outros objetos presente na mesma partição ou no máximo em partições vizinhas.

11.1.2 UDK Editor

O **UDK!** Editor é a ferramenta principal de edição do **UDK!**. Por ser uma ferramenta do UDK, ela é voltada à criação de jogos. Assim, possui diversas funcionalidades para este fim, como manipulação de modelos 3D, criação de cenários etc.

Para esse trabalho, a funcionalidade mais importante é a auto-geração de modelos físicos a partir de modelos gráficos 3D. Para isso, o editor provê diversos métodos. Um dos mais convenientes é o K-DOF. O algoritmo do K-DOF basicamente toma K planos alinhados com K eixos passando pelo centro da malha gráfica e aproxima esses planos o máximo possível da malha sem que ocorra intersecção com esta. Pode-se escolher K dentre as seguintes opções:

- 6: caixa alinhada com os eixos principais (X, Y e Z);
- 10: caixa com 4 arestas chanfradas – pode-se escolher dentre arestas alinhadas com os eixos X, Y ou Z;
- 18: caixa com todas as arestas chanfradas;
- 26: caixa com todas as arestas e cantos chanfrados.

A Figura 19 exibe as diferenças entre as opções de K-DOF para a peça do peito do Robonova.

11.1.3 UnrealScript

A UnrealScript é uma linguagem de *script* proprietária da *engine* Unreal. Foi projetada por Tim Sweeney especificamente para desenvolvimento de jogos. As principais características da UnrealScript são:

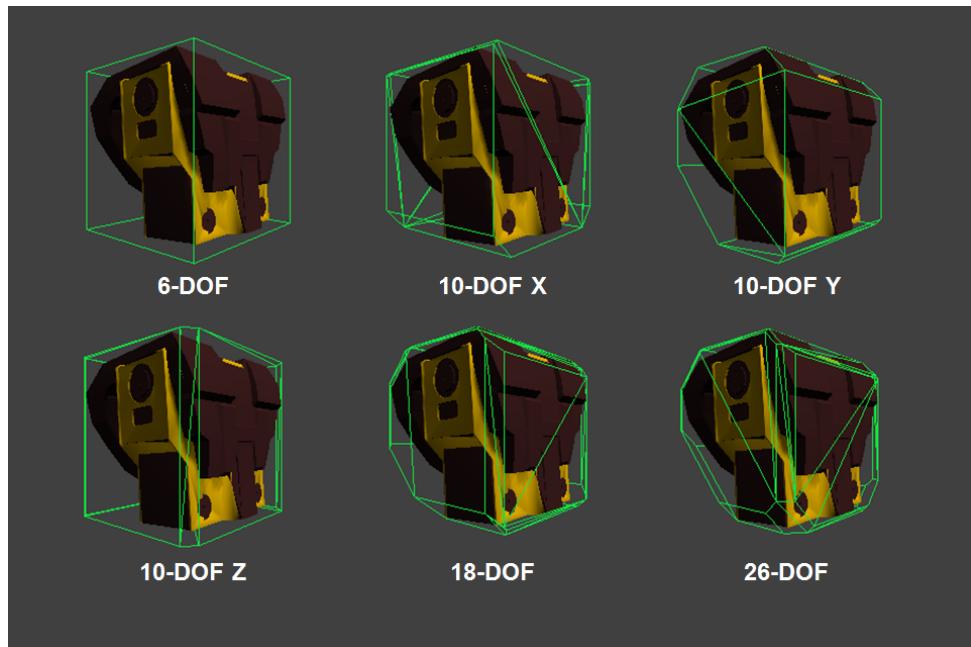


Figura 19: Diferenças entre modelos físicos gerados com K-DOF (os modelos físicos são apresentados em *wireframe*).

- Orientada a objetos;
- Não há suporte a herança múltipla, ou seja, uma classe só poder herdar de no máximo uma outra classe;
- Não existe o conceito de ponteiro. Trabalha-se com referências, assim como em Java;
- Programador não precisa se preocupar com desalocação de memória dinâmica, pois há um *garbage collector*;
- Forte detecção de erros durante tempo de compilação;
- Estilo de sintaxe similar a C/C++/Java;
- Suporte a sobrecarga de operadores;
- Não há suporte a sobrecarga de métodos;
- Suporte nativo a conceitos importantes para desenvolvimento de jogos: tempo, estados, eventos, propriedades, rede etc.

Como pode-se perceber pelas características listadas, muitas das decisões de projeto da UnrealScript foram inspiradas pela linguagem Java. Inclusive, Tim Sweeney experimentou

usar Java para a Unreal antes de decidir criar uma linguagem própria. Por fim, destaca-se que a UnrealScript é usada apenas para programar a parte de alto nível. O baixo nível, como as partes de renderização gráfica e de simulação de Física, que exigem mais desempenho, é programado em C++.

11.1.4 Implementação de Robôs em USARSim

A implementação de modelos novos de robôs em USARSim envolve basicamente os passos:

1. Construção de modelos **CAD!** que representam o robô;
2. Geração dos modelos físicos a partir dos modelos **CAD!**;
3. Programação do modelo do robô em UnrealScript;
4. Definição de partes extras, como sensores e atuadores.

11.1.5 Comunicação entre Agentes e USARSim

A comunicação entre agentes e o simulador é feita através de trocas de mensagens **TCP/IP!** seguindo protocolo próprio do **USARSim!**. Todas as mensagens trocadas contêm um tipo e uma lista de segmentos seguindo o formato “TIPO segmento1 segmento2...”, em que:

- TIPO: refere-se ao tipo da mensagem e deve ser escrito em letras maiúsculas. O protocolo define 5 tipos de mensagens: INIT, STA, SEN, DRIVE e CONF;
- Segmentos: são pares nome-valor escritos da forma “nome valor” que representam os dados da mensagem em si. Por exemplo, no caso do segmento “Orientation 0.0,0.0,0.0”, “Orientation” é o nome e “0.0,0.0,0.0” é o valor.

Note que o tipo e a lista de segmentos são separados por um espaço. Os segmentos são também separados entre si por um espaço. Dentro de um segmento, o nome e valor também são separados por um espaço, assim espaços dentro do nome ou do valor não são permitidos. Com isso, o segmento “Orientation 0.0, 0.0, 0.0” é inválido. Para indicar fim de mensagem, deve-se adicionar “\r\n” no final da cadeia de caracteres.

11.2 Robonova-I

O Robonova-I é um modelo de robô humanoíde de baixo custo desenvolvido pela empresa japonesa Hitec Robotics (28). A Figura 20 exibe o robô visto de costas e de frente. O Robonova-I é dotado de 16 graus de liberdade, distribuídos da seguinte forma: 3 em cada braço (2 no ombro e 1 no cotovelo) e 5 em cada perna (2 na coxa, 1 no joelho e 2 no pé). A Figura 21 mostra a disposição das juntas, assim como o eixo de rotação de cada uma.



Figura 20: Robonova-I. Extraído de (28).

Cada junta é implementada por um servomotor Hitec HSR-8498HB, apresentado na Figura 22. Tratam-se de servomotores especificamente desenvolvidos para o Robonova-I e são relativamente baratos, o que garante o baixo custo do robô. A Tabela 2 apresenta as principais características do HSR-8498HB.

| | |
|--------------------|-------------------------------------|
| Interface | Protocolo HMI! , PWM! |
| Voltagem | 6,0 V |
| Velocidade Máxima | 60° em 0,20 s @ 6,0 V |
| Torque | 10 kg·cm |
| Ângulo de Operação | Máximo de 180° |
| Peso | 55 g |
| Dimensão | 40 x 20 x 47 mm |

Tabela 2: Especificação dos servomotores Hitec HSR-8498HB. Extraído de (28).

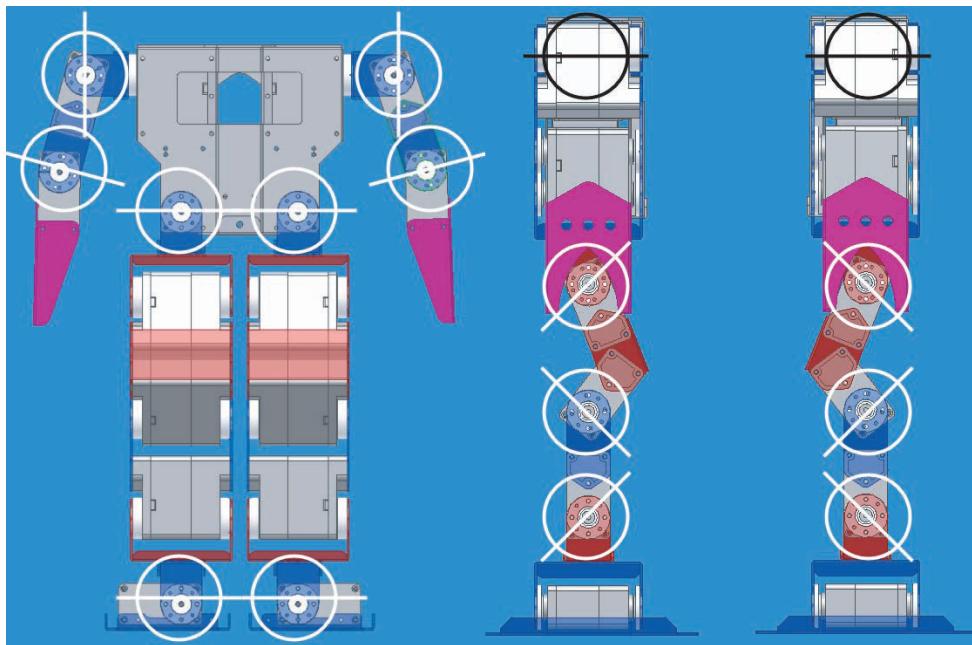


Figura 21: Juntas do Robonova-I. Extraído de (28).



Figura 22: Servomotores Hitec HSR-8498HB. Extraído de (28).

O único sensor que vem juntamente com o kit é um sensor infravermelho, que é instalado na cabeça do robô, para receber comandos de um controle remoto, que também faz parte do kit. Porém, o fabricante produzia alguns tipos de sensores compatíveis, como sensor de toque, girômetro e sensor de luz.

O controle do robô é feito por uma placa MR-C3024, que fica instalada nas costas do robô, conforme mostra a Figura 23. A CPU da placa é um Atmel ATMEGA128, o que é uma limitação caso se deseje ter um robô humanóide completamente autônomo. O ponto forte da MR-C3024 é ter uma capacidade de **E/S!** razoável, principalmente suporte a 24 **PWM!**s, o que é suficiente para controlar todos os 16 servomotores do kit e ainda permite a adição de mais 8. A Tabela 3 resume as características da MR-C3024.

A programação é feita com uma linguagem proprietária chamada RoboBASIC, especificamente criada para o Robonova-I. A linguagem tem a vantagem de possuir primitivas

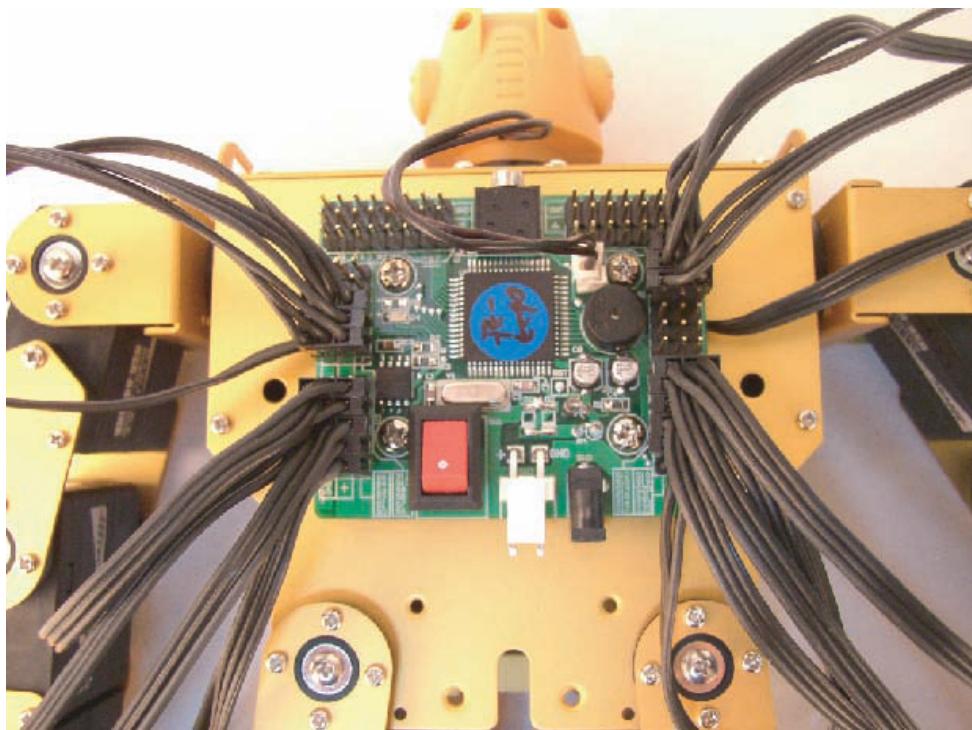


Figura 23: Detalhe das costas do Robonova-I mostrando a placa MR-C3204 instalada. Extraído de (28).

| | |
|---------------------|---------------------------|
| CPU | Atmel ATMEGA128 8bit RISC |
| Máx Servos | 24 |
| Conversores A/D | 8 |
| Memória de Programa | 32 Kbytes |
| Peso | 0,2 kg |
| Dimensão | 55 x 50 x 15 mm |

Tabela 3: Especificação da placa MR-C3024. Extraído de (7).

específicas para utilizar os recursos do Robonova-I e da MR-C3024. A programação feita é passada do PC para a MR-C3024 por comunicação serial RS-232 com uso de um cabo próprio. Outra opção de controle é mandar comandos via RS-232 para mover diretamente os servomotores seguindo protocolo próprio da MR-C3204 (1).

12 Modelo de Simulação

12.1 Modelos CAD

Os modelos **CAD!** foram confeccionados em um trabalho anterior (21). Os modelos foram construídos com uso do *software* Autodesk AutoCAD (3) a partir de medidas das peças de do Robonova-I real tomadas com um paquímetro. Cada peça foi feita como um modelo **CAD!** separado.

Em seguida, as peças foram importados no *software* Autodesk 3D Studio Max (2), onde materiais (gráficos) com padrões de cores simples foram criados e assinalados conforme as cores correspondentes no robô real. As Figuras 24 e 25 apresentam o modelo final montado e o explodido, respectivamente. Como pode-se verificar, teve-se o cuidado de confeccionar o modelo com boa precisão, para que se consiga um comportamento em simulação o mais fiel possível ao robô real.

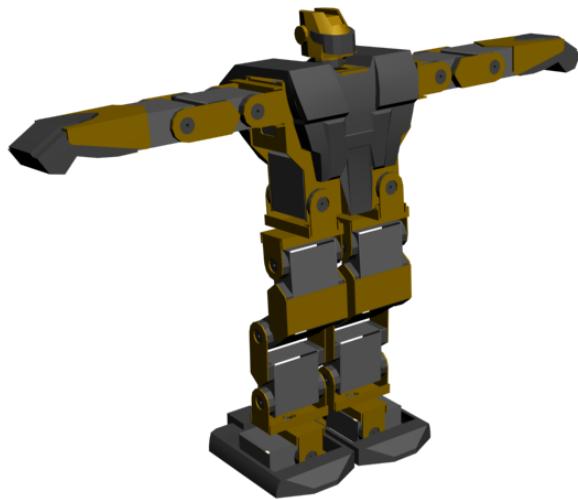


Figura 24: Modelo completo montado do Robonova-I.

Finalmente, cada modelo foi exportado como um arquivo FBX (4) separado, porque esse formato permite importação direta no **UDK!** Editor.

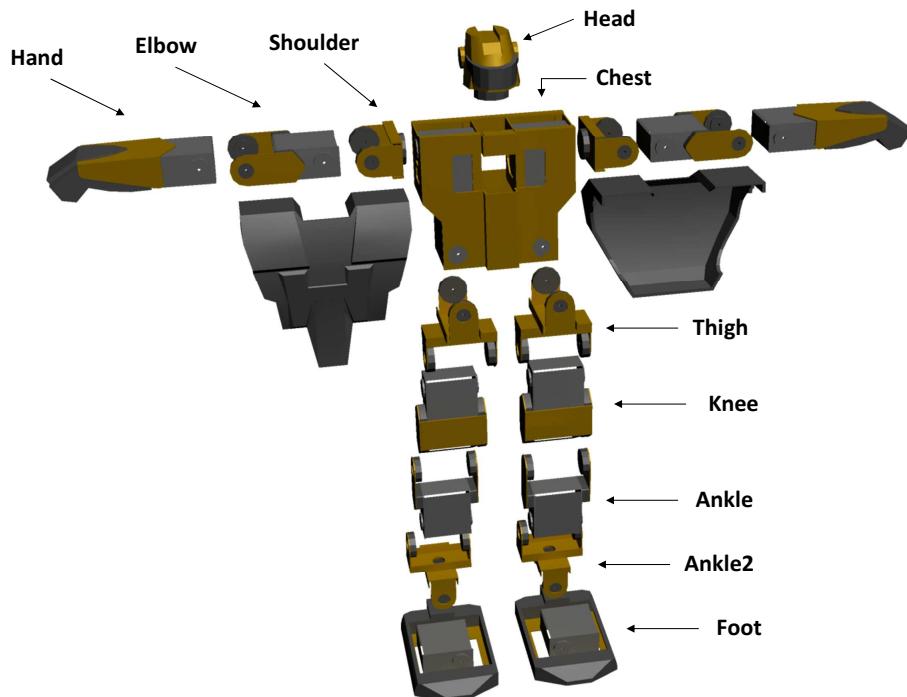


Figura 25: Modelo completo explodido do Robonova-I.

12.2 Configuração no UDK Editor

Para ter-se um modelo de simulação o mais fiel possível à realidade, optou-se pelo método *26-DOF simplified collision* para auto-gerar os modelos físicos a partir dos gráficos.

Embora os materiais já tivessem sido associados às peças anteriormente, foi necessário repetir esse processo dentro do **UDK!** Editor. Após a configuração de todos as peças, exportou-se o conjunto de peças como um pacote UPK (Unreal Package).

12.2.1 Implementação no USARSim

Para concluir a implementação do robô em **USARSim!**, faltava ainda criar a classe do robô em UnrealScript e configurar os sensores. A classe em UnrealScript do Robonova-I foi inspirada na implementação em **USARSim!** do robô Albebaran Nao (39).

As peças foram implementadas como objetos do tipo “Part”, que permite definir o modelo (gráfico e físico), massa e uma posição em relação à origem do robô (ou um deslocamento em relação a uma outra Part tomada como “pai”). A Tabela 4 apresenta todas as peças implementadas.

Em seguida, as juntas foram implementadas como juntas de revolução (objetos do

| Peca (Part) | Massa (g) |
|----------------|--------------|
| Head | 27 |
| Chest | 337 |
| LeftShoulder | 6 |
| LeftElbow | 65 |
| LeftHand | 65 |
| RightShoulder | 6 |
| RightElbow | 65 |
| RightHand | 65 |
| LeftThigh | 23 |
| LeftKnee | 135 |
| LeftAnkle | 44 |
| LeftAnkle2 | 23 |
| LeftFoot | 83 |
| RightThigh | 23 |
| RightKnee | 135 |
| RightAnkle | 44 |
| RightAnkle2 | 23 |
| RightFoot | 83 |

Tabela 4: Peças implementadas como objetos do tipo “Part”.

tipo “RevoluteJoint”). Um objeto do tipo RevoluteJoint une dois objetos do tipo Part por um eixo de rotação. A Figura 26 mostra os nomes dados às juntas implementadas.

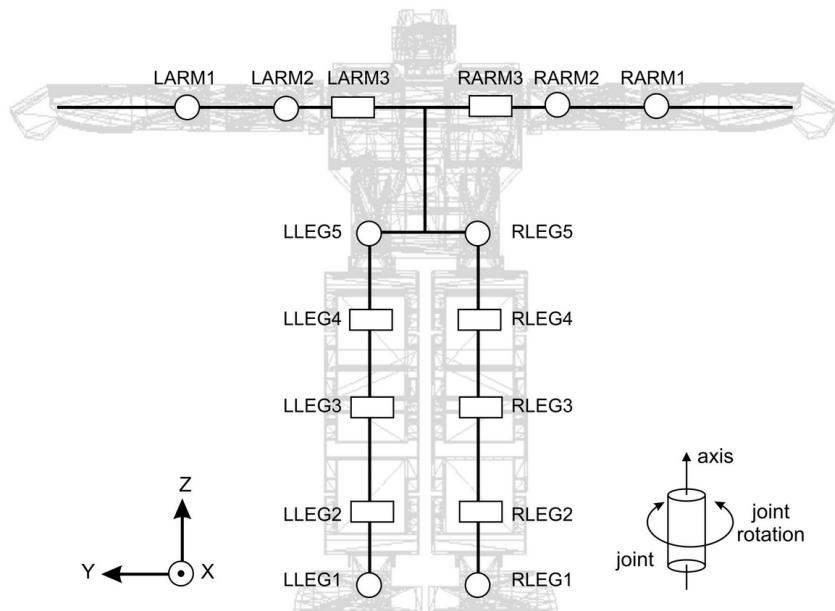


Figura 26: Juntas implementadas no modelo de simulação.

Devido a imprecisões dos modelos físicos, foi necessário desabilitar colisão entre peças adjacentes (considera-se que duas peças são adjacentes se são ligadas por uma junta). As

demais colisões foram mantidas ativas.

Para percepção, colocou-se uma câmera na cabeça e sensores de toque nos pés. O **USARSim!** já possui esses sensores implementados, logo foi necessário apenas configurá-los. Além disso, acoplou-se um sensor especial do **USARSim!** chamado “GroundTruth” no tronco do robô. Esse sensor provê posição e orientação globais livres de ruído. Embora essas informações sejam impossíveis de se obter em um robô real, elas são muito úteis em processos de Aprendizado ou Otimização.

A Figura 27 apresenta o Robonova-I dentro do **USARSim!**; os modelos físicos são mostrados em *wireframe* por linhas rosas. No canto superior esquerdo é mostrada a visualização a partir da câmera do robô.



Figura 27: Robonova-I simulado dentro do **USARSim!**.

13 Programa do Agente

O agente foi implementado em C++ usando a biblioteca Qt (23). Essas tecnologias foram escolhidas pois permitem implementação *cross-platform* e um alto desempenho em tempo de execução. Para permitir que boa parte do código fosse comum entre simulação e robô real, dividiu-se o programa do agente em três camadas (vide Figura 28):

- **Comunicação:** implementa a comunicação de baixo nível com sensores e atuadores. Interface e implementação são diferentes entre simulação e robô real;
- **Interface:** provê uma abstração para sensores e atuadores. Mesma interface na simulação e no robô real, mas implementações diferentes;
- **Controlador:** determina quais posições devem ser enviadas para as juntas do robô a cada momento. Interface e implementação iguais entre simulação e robô real.

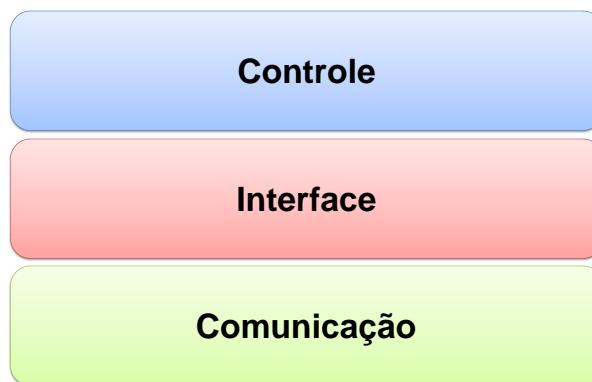


Figura 28: Camadas do programa do agente.

É importante observar que a camada de Interface provê uma abstração para a camada superior (Controle), de modo que, a princípio, pode-se usar o mesmo controlador para o robô simulado e para o real. Já as camadas de Comunicação e de Interface devem ser implementadas em cada plataforma.

Tal arquitetura é suficiente para os propósitos desse trabalho. Todavia, caso deseje-se que o robô realize tarefas mais complexas, como jogar futebol, as seguintes alterações são interessantes:

- Adição de um componente de **Modelo** à camada de Controle. Esse componente seria responsável por processar as percepções e gerar modelos mais elaborados sobre o mundo e sobre o agente, de modo a prover informações importantes, como posições globais do agente, de outros agentes e de objetos. Com isso, seria adequado passar a chamar essa nova camada de **Modelo e Controle**;
- Adição de uma camada de **Cognição**, que deveria ficar acima das demais. Tal camada trataria de, a partir dos modelos providos pelo componente de Modelo, determinar o melhor movimento (andar, girar o corpo, levantar-se etc.) a ser executado e notificar a camada de Controle disto.

A seguir, cada camada efetivamente implementada é detalhada. Nisso, deve-se destacar um fato: fazia parte do plano inicial utilizar o mesmo programa de agente no robô simulado e no real, tanto que a arquitetura explicada foi idealizada de modo a permitir isso. Entretanto, o único *hardware* de processamento disponibilizado foi a placa original do Robonova-I (MR-C3204) que é muito limitada e permite programação apenas em linguagem RoboBASIC. Com isso, implementou-se o programa de agente aqui descrito apenas na simulação.

Embora isto torne a separação do programa em camadas irrelevante para a proposta deste trabalho, esta arquitetura ainda é interessante para servir como base para futuros trabalhos em que se possua o *hardware* de processamento necessário.

13.1 Comunicação

A camada de comunicação implementa a comunicação direta de baixo nível com sensores e atuadores. Como essa comunicação difere muito entre robô simulado e real, é difícil estabelecer padrões para essa camada, portanto considerou-se interface e implementação diferentes entre as duas plataformas.

Para a simulação, essa camada deve consistir de um socket **TCP/IP!** para comunicação com o servidor e de um *parser* para transformar as mensagens brutas recebidas em uma estrutura mais fácil de lidar. Desse modo, a implementação é composta por duas classes:

- USARSocket: implementa um socket **TCP/IP!** para comunicação com o servidor do **USARSim!**. Faz a separação dos dados recebidos na comunicação em mensagens usando a indicação de fim de mensagem “\r\n”, como especificado no protocolo. A funcionalidade de socket propriamente dita é herdada de QTcpSocket, que a implementa de modo *cross-platform*;
- USARMessage: representa uma mensagem que segue o protocolo do USARSim. A classe possui dois construtores: um que faz o *parsing* de uma mensagem bruta recebida do servidor e a separada em seus constituintes (tipo e segmentos) e outro que recebe os constituintes e gera uma mensagem no protocolo esperado pelo servidor.

13.2 Interface

Esta camada trata as estruturas intermediárias recebidas da camada de Comunicação e provê uma abstração para sensores e atuadores independente de se o programa está sendo executado no robô simulado ou no real. Como a camada lida com estruturas da camada de Comunicação, a implementação tem de ser diferente entre as duas plataformas. Porém, como a intenção é prover uma abstração independente de plataforma para a camada de Controle, a interface deve ser a mesma entre robô simulado e real.

Para conseguir esse efeito, o mecanismo usado em Orientação a Objetos é criar classes abstratas para representar a interface e então criar classes concretas que herdam destas classes abstratas e que implementam as funcionalidades desejadas em cada caso. Portanto, criou-se as seguintes classes abstratas:

- RobotPerceptor: funciona como uma espécie de sensor especial que contém informações do corpo do robô, como nível da bateria e posições das juntas;
- Sensor: representa um sensor genérico. Sensores devem ser implementados através de especialização desta classe, com exceção do RobotPerceptor;
- Perception: provê uma interface única para toda a percepção;
- Action: representa uma ação genérica. Não inclui comandos para as juntas;
- ActionHandler: provê uma interface única para toda a atuação (incluindo as juntas).

No robô simulado, essa camada tem basicamente duas responsabilidades. No lado da percepção, deve interpretar as estruturas do tipo USARMessage da camada de Comunicação e atualizar o estado interno do agente. Em relação à atuação, deve receber

uma requisição para movimentação de junta e criar uma estrutura do tipo USARMessage que será passada para a camada de Comunicação. Para isso, as principais classes criadas foram:

- GroundTruth: implementa sensor GroundTruth. Sensor exclusivo do robô simulado;
- USARPerception: implementação concreta de Perception. Interpreta uma USAR-Message recebida da camada de Comunicação e atualiza o estado interno do robô;
- InitAction: inicia um modelo de robô na simulação;
- GetStartPosesAction: requisita ao servidor as localizações padrões em que o robô pode ser iniciado no mapa em questão;
- ReconnectAction: reconecta o agente ao simulador;
- USARActionHandler: implementação concreta de ActionHandler. Recebe ações (incluindo movimentação de junta), cria uma USARMessage correspondente e a envia para a camada de Comunicação.

13.3 Controle

O objetivo desta camada é implementar os movimentos do robô humanóide a partir do controle de suas juntas. Como a camada de Interface provê uma abstração para sensores e atuadores, o código desta camada pode ser o mesmo tanto no robô simulado quanto no simulado (considerando que o comportamento físico do robô simulado seja próximo o suficiente do real).

Dado o escopo do trabalho, implementou-se apenas um controlador para a caminhada do robô. Porém, a implementação feita já provê uma estrutura para implementações futuras de novos movimentos, como girar o corpo, levanta-se, chutar uma bola etc. As principais classes criadas foram:

- TFSGaitController: controlador para caminhada baseada em **SFT!** (**SFT!**);
- TFSGaitGenerator: classe abstrata que representa um gerador de caminhada baseada em **SFT!**. Dado o instante de tempo atual, gera as posições das juntas a partir das equações do modelo de caminhada.

14 Processo de Otimização

14.1 Modelos de Caminhada

Para verificar os efeitos da adição de movimento de braços e movimento no plano coronal, decidiu-se por implementar geradores para os 3 modelos propostos por Shafii (31, 32, 33), conforme explicitado no Capítulo ??.

Entretanto, após alguns testes, optou-se por modificar a função proposta por Shafii para os ombros. A modificação proposta envolve considerar que as amplitudes no sentido positivo e negativo podem ser diferentes para o movimento do braço, assim como é feito para a perna no sentido frente-trás. Desse modo, $\theta_o(t)$ passa a ser descrita pela equação (14.1).

$$\theta_o(t) = \begin{cases} -D_- \sin\left(\frac{2\pi t}{T}\right), & t \in \left[kT, \frac{T}{2} + kT\right), k \in \mathbb{Z} \\ -D_+ \sin\left(\frac{2\pi t}{T}\right), & t \in \left[\frac{T}{2} + kT, (k+1)T\right), k \in \mathbb{Z} \end{cases} \quad (14.1)$$

Note que essa modificação aumenta em 1 o número de constantes a serem determinadas para os modelos que possuem movimento de braços. Portanto, os modelos de caminhada implementados são os seguintes:

- Modelo Simples (MS): usa apenas as juntas na direção frente-trás das pernas;
- Modelo com Movimento de Braços (MB): além das juntas do “Modelo Simples”, utiliza as juntas do ombro (com trajetória para o ombro esquerdo definida pela equação (14.1));
- Modelo Complexo (MC): além das juntas do Modelo com “Movimento de Braços”, adiciona as juntas da coxa no sentido lateral (plano coronal).

| Junta nos Modelos Teóricos | Junta no Robonova |
|----------------------------|-------------------|
| Coxa Frente-trás Esquerda | LLEG4 |
| Joelho Esquerdo | LLEG3 |
| Pé Frente-trás Esquerdo | LLEG2 |
| Ombro Esquerdo | LARM3 |
| Coxa Lateral Esquerda | LLEG5 |
| Pé Lateral Esquerdo | LLEG1 |
| Coxa Frente-trás Direita | RLEG4 |
| Joelho Direito | RLEG3 |
| Pé Frente-trás Direito | RLEG2 |
| Ombro Direito | RARM3 |
| Coxa Lateral Direita | RLEG5 |
| Pé Lateral Direito | RLEG1 |

Tabela 5: Mapeamento das juntas dos modelos teóricos para as do Robonova (veja a Figura 26 para nomenclatura utilizada para as juntas do Robonova).

Observe que o Robonova possui os graus de liberdade necessários para implementar os 3 modelos. A Tabela 5 apresenta o mapeamento feito das juntas do modelo teórico para as do Robonova (veja a Figura 26 para nomenclatura utilizada para as juntas do Robonova).

14.2 Configuração dos Algoritmos de Otimização

Um algoritmo de Otimização fornece um *framework* para resolução de problemas de otimização, mas deve-se definir o que significa certos elemento do algoritmo para o problema em específico.

O problema de Otimização em questão envolve a determinação de constantes reais relacionada ao modelo de caminhada. É interessante definir um domínio para cada uma das constantes a fim de evitar valores sem sentido para o problema (que resultem em ângulos ou velocidades além do domínio de operação dos servomotores ou que certamente levem à queda do robô). Após testes manuais, determinou-se os limites para as constantes do modelo apresentados na Tabela 6 (as equações (??), (??), (14.1) e (??) apresentam detalhes sobre as constantes mencionadas).

14.2.1 Configuração do Algoritmo Genético

A seguir, são apresentados como os conceitos de **AG!** são definidos no problema em específico:

| Constante | Mínimo | Máximo |
|----------------|--------|--------|
| O_c | -1,5 | 0 |
| A | 0,01 | 1,0 |
| B | 0,01 | 1,0 |
| O_j | 0 | 2,0 |
| C | 0 | 1,0 |
| $\tau = t_2/T$ | 0,1 | 0,9 |
| T | 0,1 | 0,7 |
| D_+ | 0 | 0,6 |
| D_- | 0 | 0,6 |
| E | 0 | 0,5 |

Tabela 6: Limites para os valores das constantes dos modelos de caminhada.

- Cromossomo: a escolha mais óbvia para a definição de cromossomo é um vetor com as constantes, em que cada gene representa uma constante;
- Função de *fitness*: explicitada a seguir, na Seção 14.3;
- Mutação: altera um gene (no caso, uma das constantes) por um valor real aleatório dentro dos limites da Tabela 6.

Os demais conceitos de AG (seleção, *crossover* e sobrevivência dos mais aptos) saem naturalmente da definição de cromossomo.

Por fim, a Tabela 7 apresenta os valores dos parâmetros usados nas execuções de **AG!**.

| Parâmetro | Valor |
|-----------|-------|
| S_i | 20 |
| S_m | 20 |
| R | 10 |
| p_m | 0,05 |

Tabela 7: Valores dos parâmetros usados nas execuções de **AG!**.

14.2.2 Configuração do Particle Swarm Optimization

A escolha natural é considerar que cada partícula em um espaço n -dimensional, em que n é o número de constantes a serem determinadas. Assim, cada posição de partículas é um vetor de constantes. O espaço de busca é dado pelos limites da Tabela 6. Já a função de medida de qualidade é apresentada na Seção 14.3.

No **PSO!** pode ocorrer das partículas atingirem velocidades muito altas e saírem do espaço de busca. Para evitar esses problemas, fez-se modificações no **PSO!** apresentado na Seção 10.2. Primeiramente, logo após a atualização de velocidade de uma partícula, limita-se sua velocidade com uso da equação (14.2).

$$\mathbf{v}_i(d) \leftarrow \min(\mathbf{u}(d) - \mathbf{l}(d), \max(\mathbf{l}(d) - \mathbf{u}(d), \mathbf{v}_i(d))), d = 1, \dots, D \quad (14.2)$$

A outra modificação busca forçar as partículas a permanecerem sempre dentro do espaço de busca. Para tal, considera-se que as partículas sofrem “choques mecânicos inelásticos” ao tentarem cruzar os limites do espaço de busca. A partir desta inspiração da Mecânica, criou-se a subrotina apresentada no Algoritmo 3, que é executada logo após ser aplicada a limitação de velocidade. Note que o uso dessa subrotina introduz o parâmetro ε , ao qual deu-se a denominação de “coeficiente de restituição” para seguir a analogia mecânica.

Algoritmo 3: Subrotina que simula “choques” das partículas com os limites do espaço de busca.

```

begin
  for  $i \leftarrow 1, \dots, P$  do
    for  $d \leftarrow 1, \dots, D$  do
      if  $\mathbf{x}_i(d) > \mathbf{u}(d)$  then
         $\delta \leftarrow \mathbf{x}_i(d) - \mathbf{u}(d);$ 
         $\mathbf{x}_i(d) \leftarrow \varepsilon(\mathbf{u}(d) - \delta);$ 
         $\mathbf{v}_i(d) \leftarrow -\varepsilon\mathbf{v}_i(d);$ 
      end
      if  $\mathbf{x}_i(d) < \mathbf{l}(d)$  then
         $\delta \leftarrow \mathbf{l}(d) - \mathbf{x}_i(d);$ 
         $\mathbf{x}_i(d) \leftarrow \varepsilon(\mathbf{l}(d) + \delta);$ 
         $\mathbf{v}_i(d) \leftarrow -\varepsilon\mathbf{v}_i(d);$ 
      end
    end
  end
end

```

Por fim, a Tabela 8 apresenta os valores dos parâmetros usados nas execuções de **PSO!**.

| Parâmetro | Valor |
|---------------|-------|
| P | 20 |
| ω | 0,9 |
| φ_p | 0,6 |
| φ_g | 0,8 |
| ε | 0,7 |

Tabela 8: Valores dos parâmetros usados nas execuções de **PSO!**.

14.3 Montagem do Experimento Simulado

Para utilizar um algoritmo de Otimização para o “aprendizado” das melhores constantes para os modelos de caminhada, é necessário montar um experimento em que seja dado ao robô um período de tempo para tentar andar e depois seja aplicada uma métrica para avaliação do desempenho da caminhada com o dado conjunto de constantes.

O mapa do simulador escolhido para os experimentos foi o “ExampleMap” (vide Figura 29), porque possui uma grande área com terreno plano e sem presença de obstáculos. A localização escolhida para iniciar o robô no mapa foi a “RobotStart1”, que é onde o robô se encontra na Figura 29.

Como o robô inicia com as juntas em posições diferentes das posições neutras da caminhada (quando os senos valem zero), adicionou-se um tempo de preparação em que os ângulos das juntas são interpolados linearmente das posições iniciais para as neutras da caminhada. Experimentalmente, verificou-se que 1,5 segundo era adequado para esse tempo de ajuste.

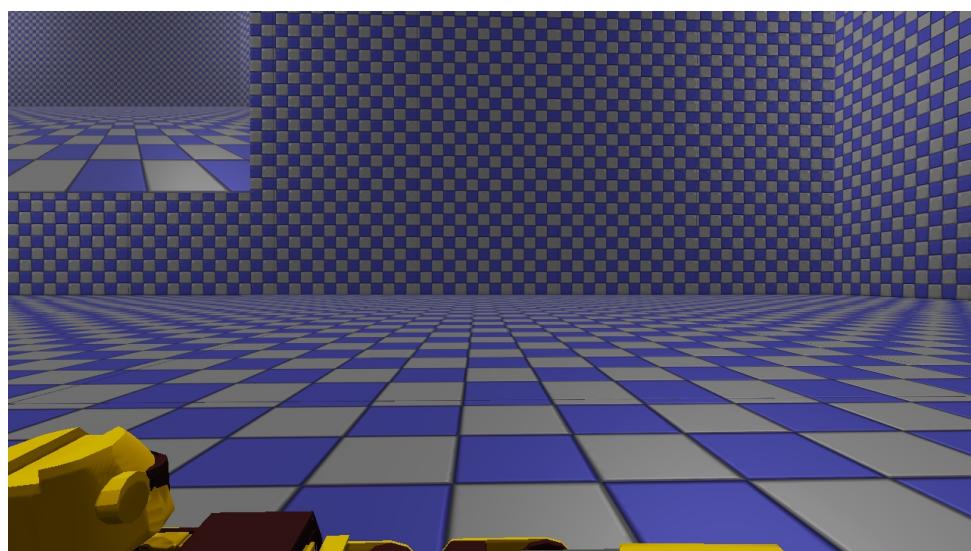


Figura 29: ExampleMap.

Depois, deixava-se o robô andar por 20 segundos, o que podia ser interrompido prematuramente caso o robô caísse. Considera-se queda se a orientação do robô passar de 0,6 radianos em relação aos eixos X ou Y (vide Figura 30). Por fim, media-se o desempenho do robô. Em resumo, cada experimento de simulação segue os passos:

1. Iniciar o Robonova na localização “RobotStart1”;
2. Esperar 1,5 segundo para preparação;
3. Esperar 20 segundos ou o robô cair, o que ocorrer primeiro;
4. Calcular desempenho com a equação (14.3).

$$D = (x - x_o) - |y - y_o| + 0,1 \times \Delta t - \sum P_i \quad (14.3)$$

Na equação (14.3), (x_o, y_o) e (x, y) são respectivamente as posições inicial e final do robô no plano do mapa; o sistema de coordenadas usado é o mostrado na Figura 30. Δt é a quantidade tempo (em segundos) que o robô permaneceu sem cair. $\sum P_i$ representa o somatório das possíveis punições (mostradas na Tabela 9). O objetivo das punições é tratar casos muito indesejados.

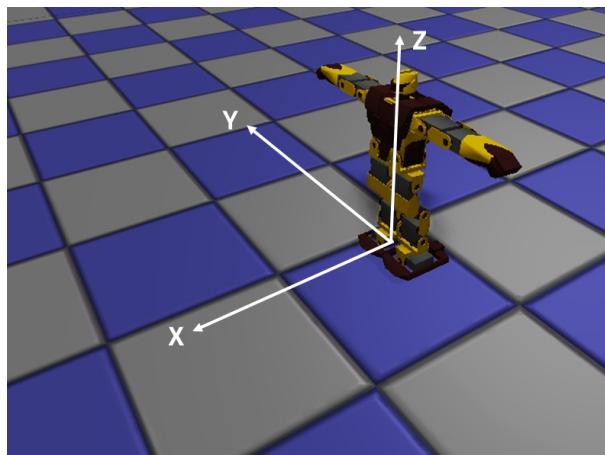


Figura 30: Sistema de coordenadas no USARSim.

Após algumas execuções dos experimentos simulados, verificou-se o seguinte:

- Percebeu-se que havia uma dificuldade grande do robô romper a transição brusca de quando ele estava parado para o primeiro passo. Ocorria com frequência de uma caminhada que se tornava bem instável quando o robô entrava em regime cair no primeiro passo;

| Punição | Significado | Valor |
|---------|---------------------------|-------|
| P_1 | Queda | 50 |
| P_2 | Posição inicial instável | 80 |
| P_3 | Praticamente não se moveu | 60 |

Tabela 9: Limites para os valores das contantes dos modelos de caminhada.

- Às vezes, ocorria de uma caminhada pouco estável, mas muito rápida, ter a sorte de se manter em pé durante os 20 segundos do teste e receber uma avaliação muito boa. Isto era problemático principalmente para o **PSO!**, que é fortemente guiado pelo melhor desempenho encontrado.

Para resolver estes dois problemas, implementou-se duas heurísticas propostas em (33):

- Ao invés de começar o movimento já com as amplitudes no máximo, no começo do movimento reduz-se todas as amplitudes dos movimentos por um fator que aumenta linearmente de 0 a 1. Após alguns testes, determinou-se que uma duração de 3 períodos (3 primeiros passos) era adequada para este tempo. Ou seja, o robô começa dando passos curtos e vai aumentando o tamanho do passo gradativamente até atingir o valor de regime;
- Ao invés de usar o desempenho de uma única execução do experimento para alimentar a otimização, passou-se a utilizar uma média de 3 execuções.

14.4 Resultados e Discussões

A Tabela 10 apresenta os resultados dos experimentos. Como **AG!** e **PSO!** envolvem aleatoriedade, o mais justo para comparação seria realizar diversas execuções de cada algoritmo para cada modelo de caminhada e tirar uma média. Entretanto, isso exigiria uma disponibilidade de poder de processamento bem superior à que o autor tinha disponível. Assim, cada linha da Tabela 10 se refere a uma única instância de execução. Apesar disso, acredita-se que os resultados apresentados permitem fazer as seguintes considerações qualitativas:

- A adição de movimento de braços provoca melhora na qualidade da caminhada (se os parâmetros estiverem ajustados corretamente);

- A adição de movimento no plano coronal provoca melhora ainda maior na qualidade da caminhada (novamente, se os parâmetros estiverem ajustados corretamente);
- Quanto mais parâmetros são adicionados ao modelo, mais difícil é a convergência dos algoritmos, como esperado.

| Algoritmo de Otimização | Modelo de Caminhada | Melhor Desempenho | Número de Testes |
|-------------------------|-------------------------|-------------------|------------------|
| AG | Simples | 6,16 | 1585 |
| AG | Com Movimento de Braços | 8,3 | 1678 |
| AG | Complexo | 5,77 | 1636 |
| PSO | Simples | 5,58 | 860 |
| PSO | Com Movimento de Braços | 7,2 | 1449 |
| PSO | Complexo | 7,99 | 1493 |

Tabela 10: Resultados dos Experimentos.

As Figuras 31, 32 e 33 apresentam como varia o melhor *fitness* até então pelo número de testes para experimentos com AG. As Figuras 34, 35 e 36 fazem o mesmo para o PSO. A Tabela 11 exibem os melhores conjuntos de parâmetros encontrados para cada caso.

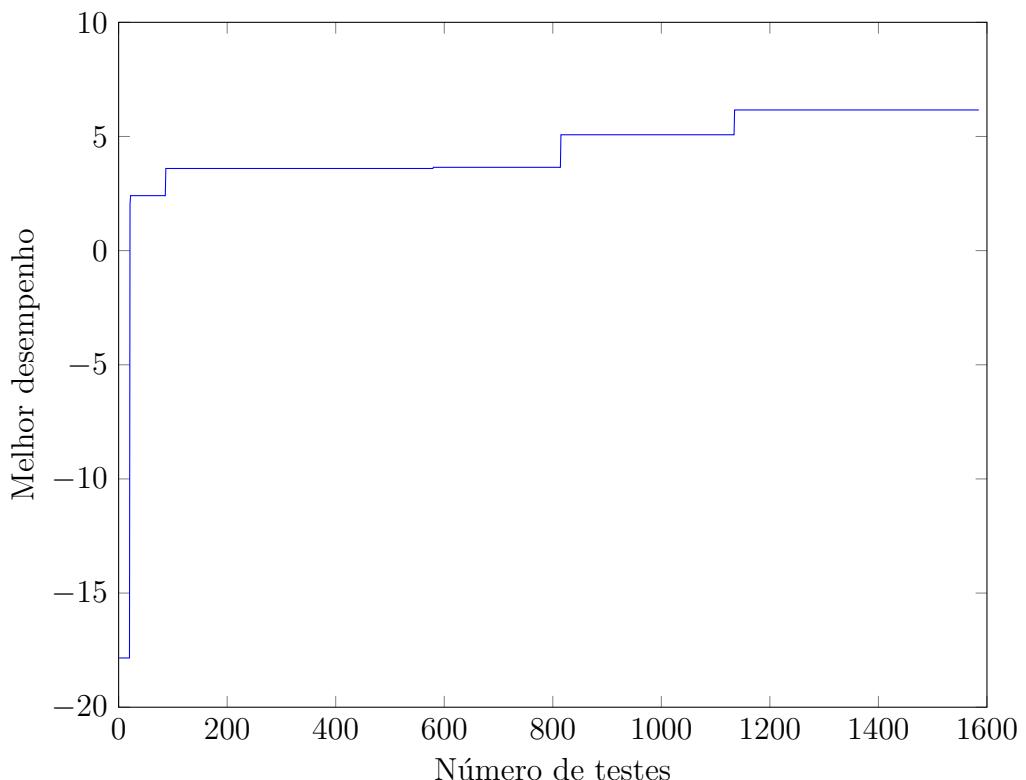


Figura 31: Resultados da otimização com Modelo Simples e **AG!**.

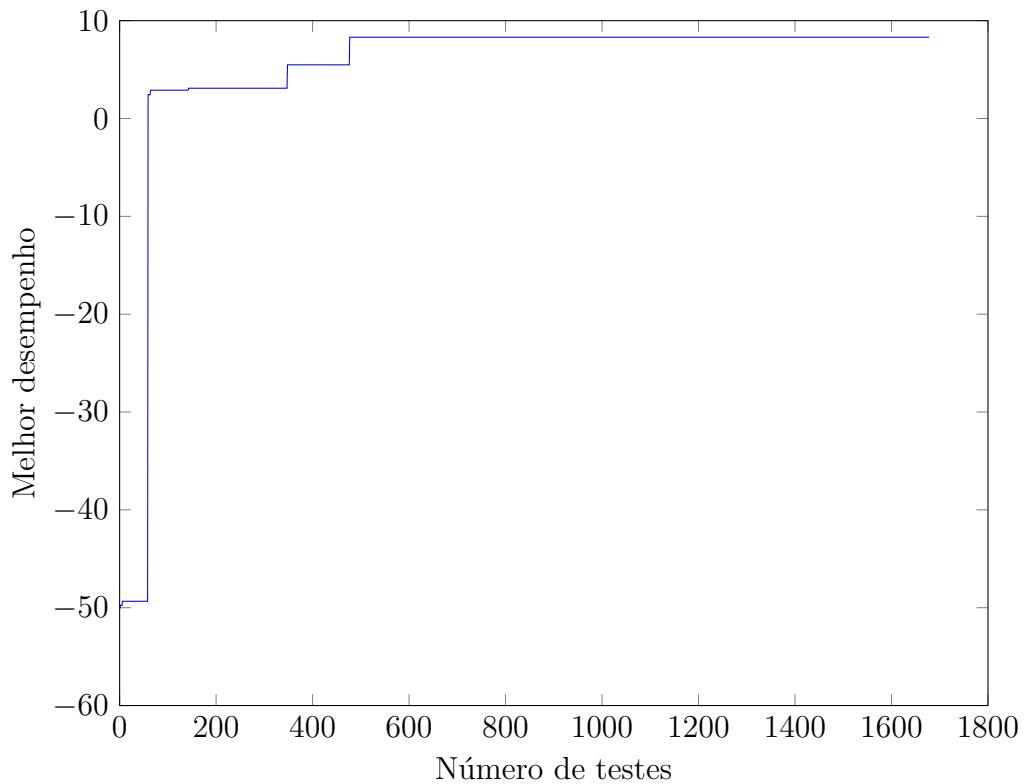


Figura 32: Resultados da otimização com Modelo com Movimento de Braços e **AG!**.

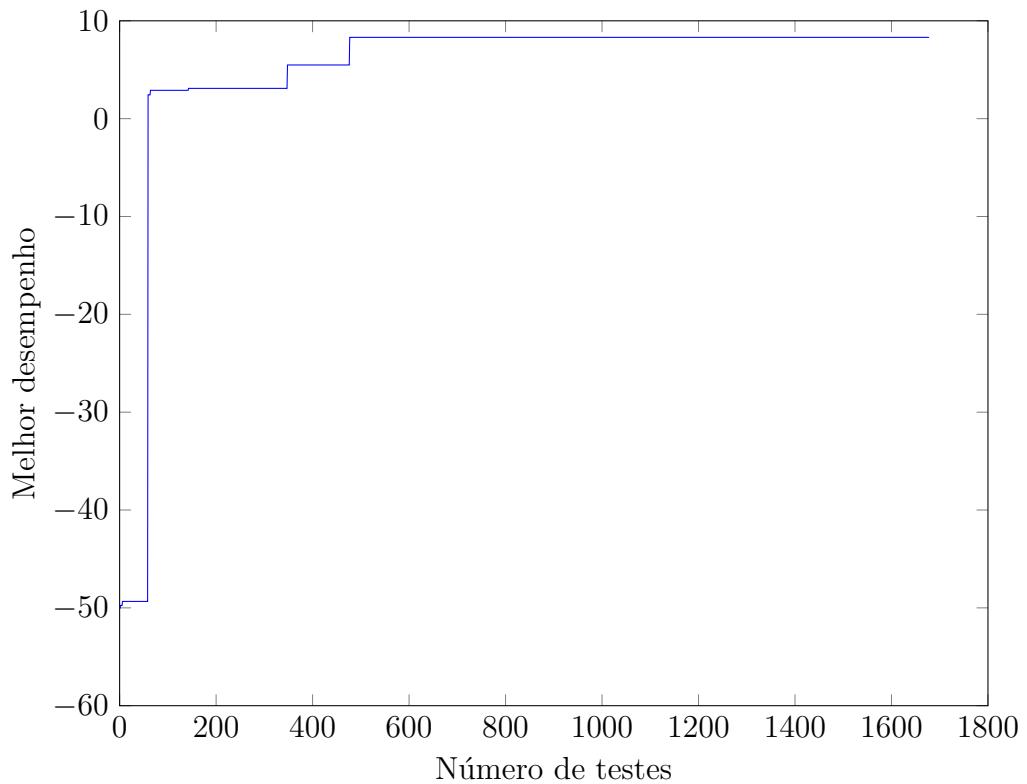


Figura 33: Resultados da otimização com Modelo Complexo e **AG!**.

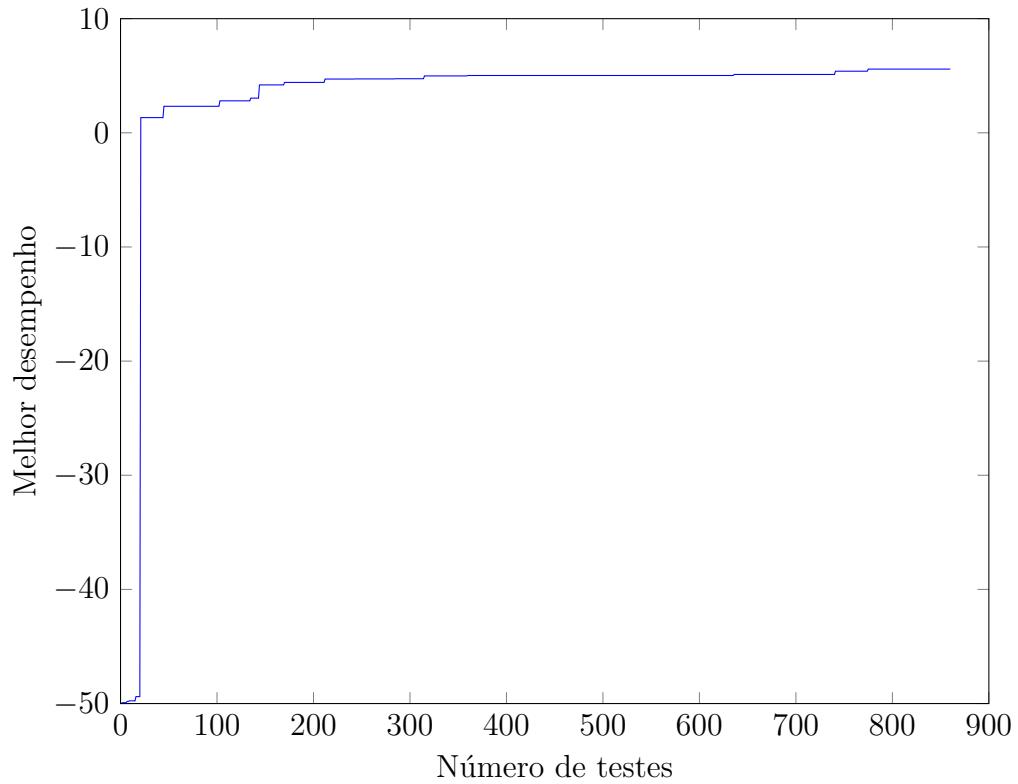


Figura 34: Resultados da otimização com Modelo Simples e **PSO!**.

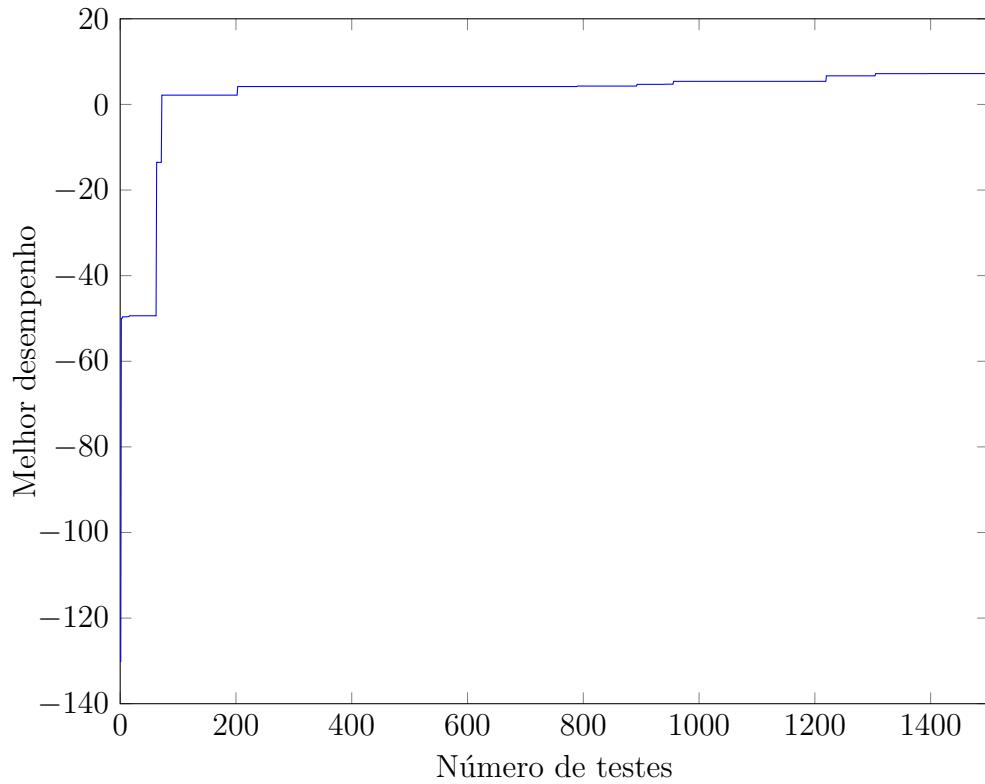


Figura 35: Resultados da otimização com Modelo com Movimento de Braços e **PSO!**.

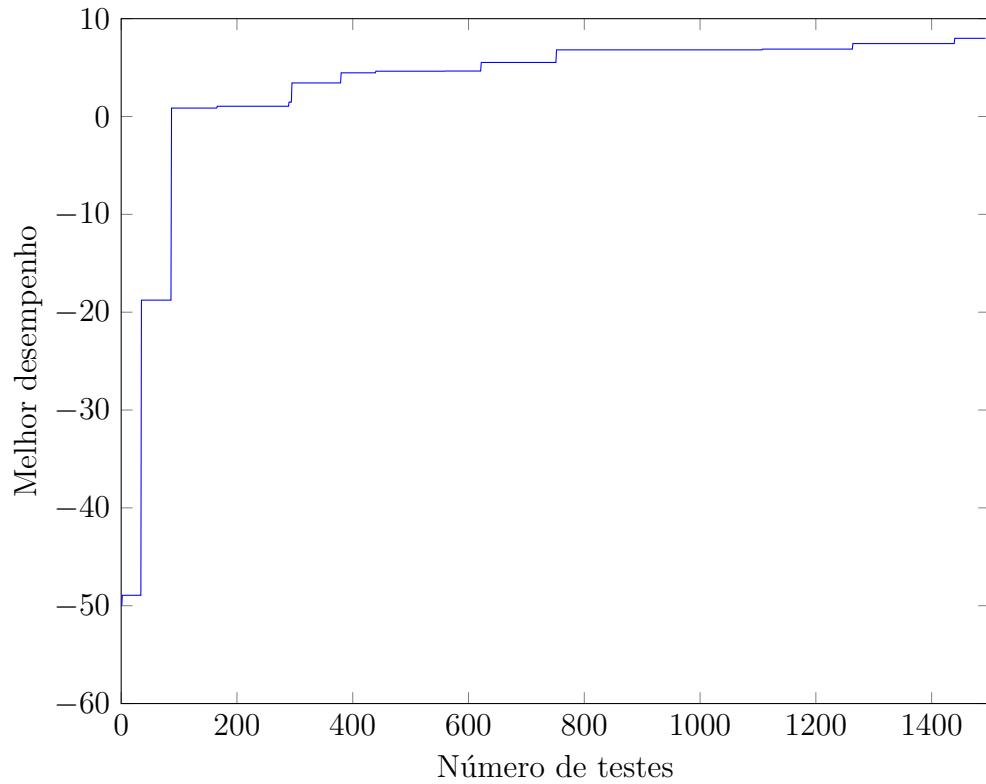


Figura 36: Resultados da otimização com Modelo Complexo e **PSO!**.

Por fim, as Figuras 37, 38 e 39 apresentam sequências de imagens para ilustrar a visualização das caminhadas aprendidas com **PSO!** para cada modelo. A taxa de quadros utilizada para a gravação foi de 15 quadros por segundo.

| Constante | MS+AG | MB+AG | MC+AG | MS+PSO | MB+PSO | MC+PSO |
|----------------|-------|-------|-------|--------|--------|--------|
| O_c | -0,69 | -1,2 | -0,96 | -0,64 | -0,66 | -0,87 |
| A | 0,23 | 0,33 | 0,37 | 0,27 | 0,5 | 0,51 |
| B | 0,43 | 0,37 | 0,68 | 0,35 | 0,56 | 0,7 |
| O_j | 0,98 | 1,6 | 0,99 | 0,85 | 0,83 | 1,23 |
| C | 0,4 | 0,51 | 0,76 | 0,3 | 0,6 | 0,46 |
| $\tau = t_2/T$ | 0,38 | 0,25 | 0,22 | 0,39 | 0,38 | 0,34 |
| T | 0,34 | 0,1 | 0,4 | 0,44 | 0,39 | 0,38 |
| D_+ | — | 0,58 | 0,58 | — | 0,17 | 0,54 |
| D_- | — | 0,14 | 0,55 | — | 0,57 | 0,39 |
| E | — | — | 0,04 | — | — | 0,05 |

Tabela 11: Limites para os valores das contantes dos modelos de caminhada.

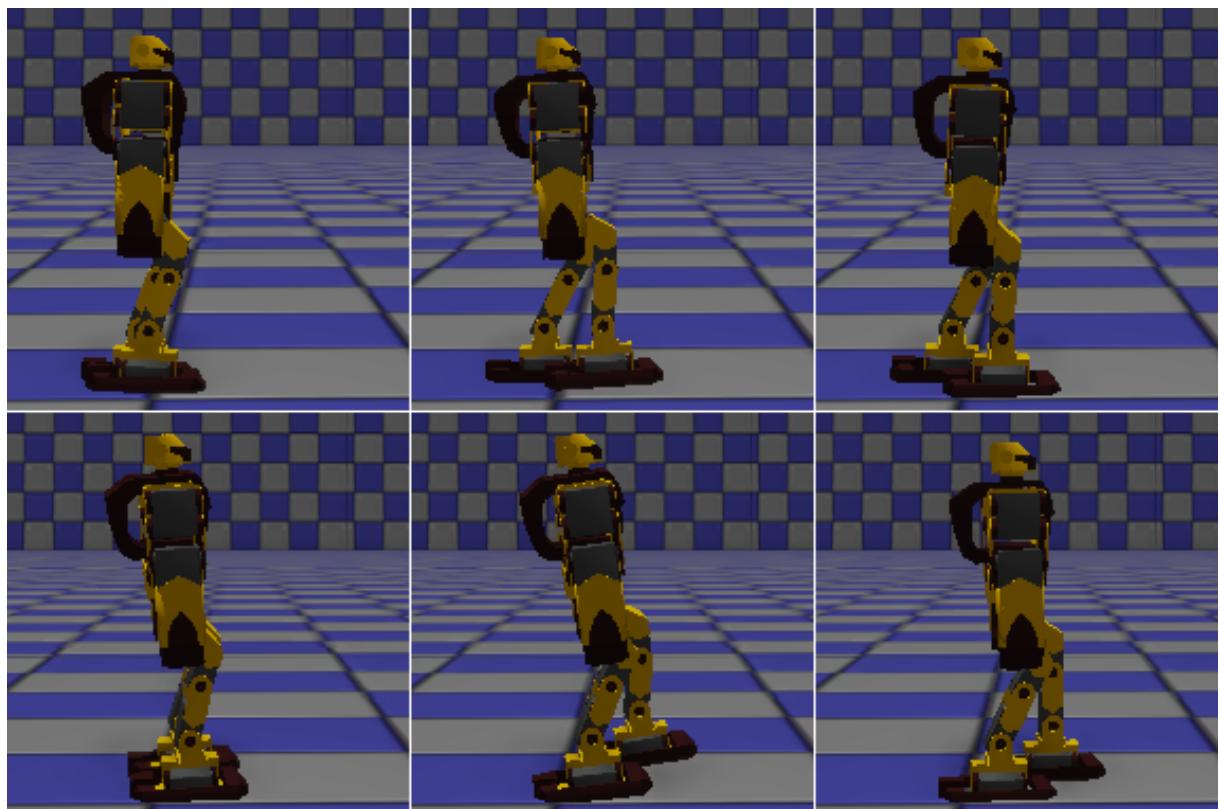


Figura 37: Sequência de imagens para ilustrar a caminhada aprendida com Modelo Simples e PSO!.

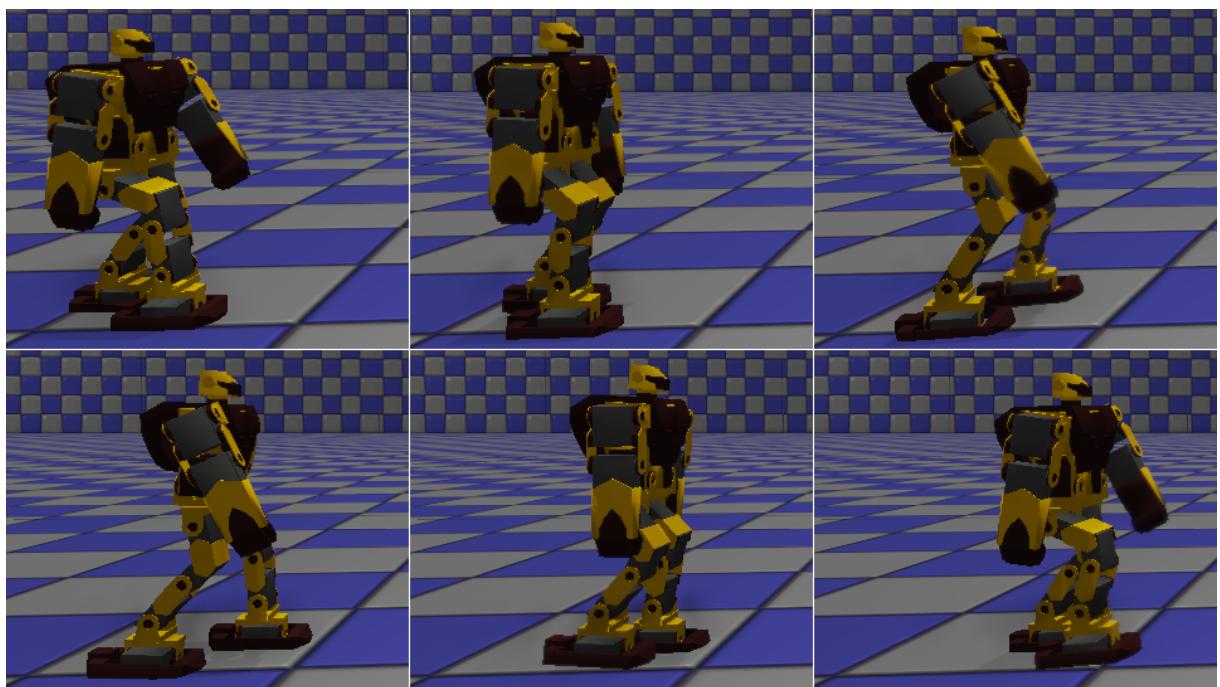


Figura 38: Sequência de imagens para ilustrar a caminhada aprendida com Modelo com Movimento de Braços e PSO!.

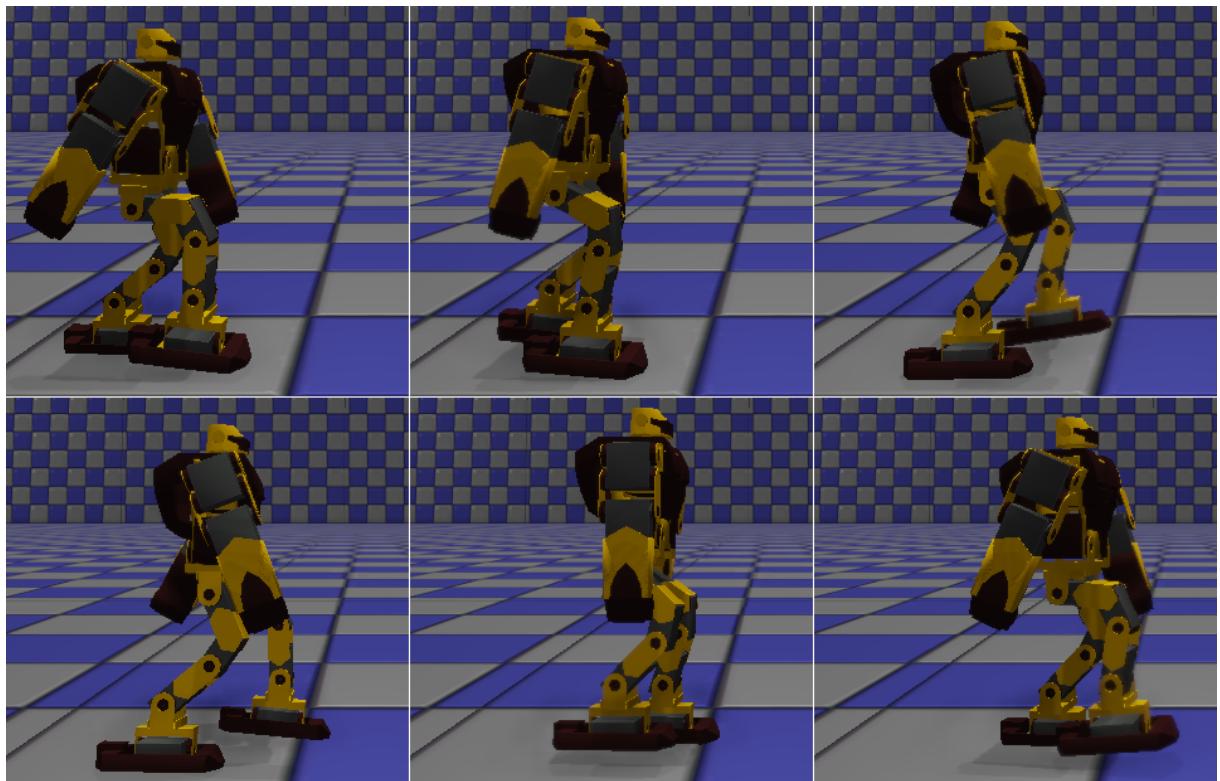


Figura 39: Sequência de imagens para ilustrar a caminhada aprendida com Modelo Complexo e PSO!.

15 Transferência para o Robô Real

15.1 Desafios Envoltos

Apesar do cuidado tomado em fazer um modelo físico o mais próximo possível do real e da PhysX ser uma das melhores *engines* de Física da atualidade, há diversas limitações na modelagem que não foram tratadas:

- Modelos físicos são aproximações dos modelos CAD;
- O coeficiente de atrito do solo usado para otimização no simulador não é necessariamente o mesmo que um solo em que o robô real caminhará;
- Embora sejam todos do mesmo modelo, os servomotores do robô real possuem pequenas diferenças de torque e velocidade devido a questões de construção;
- No robô real, existem folgas mecânicas que não são modeladas na simulação.

Locomoção humanóide é um problema complexo em que pequenas variações nas condições como as citadas acima podem tornar o comportamento muito diferente. Assim, espera-se que a caminhada com os parâmetros aprendidos em simulação não tenha um desempenho tão bom no robô real, mas que, após alguns ajustes manuais, obtenha-se uma boa solução para o problema.

15.2 Processo de Transferência

Como comentado na Seção ??, o plano inicial era utilizar o mesmo código C++ tanto em simulação quanto no robô real. Para isso, esperava-se substituir a placa original do Robonova (MR-C3024) por uma placa Gumstix (15). Esta placa roda uma versão embarcada do sistema operacional Linux, o que permitiria compilar e executar a maior parte do código do controlador construído para o robô simulado. Infelizmente, não foi

possível obter esse *hardware*. Desse modo, alterou-se o plano para programação na MR-C3024.

A programação para a MR-C3024 deve ser feita em RoboBASIC, conforme comentado na Seção 11.2. O recursos dessa linguagem são bem limitados e ela não possui suporte ao uso direto da função seno, que é necessária para a implementação das equações que descrevem as trajetórias angulares das juntas.

Portanto, decidiu-se criar um programa em linguagem C# que, a partir das equações do modelo de caminhada e um passo de tempo, gera código em RoboBASIC com os valores numéricos para as posições das juntas já calculados. O código gerado é formado basicamente por dois comandos da RoboBASIC: o MOVE, que envia novas posições para todos os servomotores, e DELAY, que bloqueia a execução por um tempo em milisegundos. A Listagem 15.1 mostra o código gerado para a caminhada com Modelo com Movimento de Braços.

Listagem 15.1: Código em RoboBASIC para a caminhada de Modelo com Movimento de Braços.

```
' 3 PASSOS INICIAIS

MOVE24 ,79,140,90, , ,100, , , , ,100, , , , , ,82,137,90, ,
DELAY 20
MOVE24 ,81,140,87, , ,101, , , , ,96, , , , , ,80,137,92, ,
DELAY 20
MOVE24 ,82,137,90, , ,100, , , , ,100, , , , , ,79,140,90, ,
DELAY 20
MOVE24 ,80,137,92, , ,96, , , , ,101, , , , , ,81,140,87, ,
DELAY 20
MOVE24 ,79,140,90, , ,100, , , , ,100, , , , , ,86,133,90, ,
DELAY 20
MOVE24 ,84,140,85, , ,102, , , , ,92, , , , , ,81,134,93, ,
DELAY 20
MOVE24 ,86,133,90, , ,100, , , , ,100, , , , , ,79,140,90, ,
DELAY 20
MOVE24 ,81,134,93, , ,92, , , , ,102, , , , , ,84,140,85, ,
DELAY 20
MOVE24 ,79,140,90, , ,100, , , , ,100, , , , , ,89,130,90, ,
DELAY 20
MOVE24 ,86,140,82, , ,103, , , , ,88, , , , , ,83,131,95, ,
```

```

DELAY 20
MOVE24 ,89,130,90, , ,100, , , , ,100, , , , , ,79,140,90, ,
DELAY 20
MOVE24 ,83,131,95, , ,88, , , , ,103, , , , , ,86,140,82, ,
DELAY 20

' MOVIMENTO PERIÓDICO

walk_loop:

MOVE24 ,79,140,90, , ,100, , , , ,100, , , , , ,89,130,90, ,
DELAY 20
MOVE24 ,89,140,80, , ,103, , , , ,84, , , , , ,84,127,97, ,
DELAY 20
MOVE24 ,92,127,90, , ,100, , , , ,100, , , , , ,79,140,90, ,
DELAY 20
MOVE24 ,84,127,97, , ,84, , , , ,103, , , , , ,89,140,80, ,
DELAY 20

GOTO walk_loop

```

Testes foram feitos para avaliar a velocidade de resposta do microcontrolador e dos servomotores na prática. Com os servomotores em velocidade máxima, determinou-se 20 milisegundos como um bom passo de tempo. Passos menores faziam os servomotores vibrarem excessivamente durante a operação.

Com isso, a primeira tentativa foi tentar a caminhada com “Modelo Simples” com os parâmetros aprendidos em simulação. A caminhada funcionou, mas o desempenho foi bem inferior ao da simulação: a caminhada ficou lenta, pouco estável (robô caia com frequência) e curvava excessivamente para a direita.

Através de alguns testes foi possível perceber que apenas a redução do período já melhorava a qualidade da caminhada. Empiricamente, chegou-se ao valor de 0,08 segundos como adequado para o período. A caminhada assim obtida mostrou-se bem estável, de modo que quedas se tornaram raras quando em solo plano.

Entretanto, ainda verificou-se que ela curvava muito. Atribui-se isso principalmente ao deslizamento no solo devido a uma amplitude muito grande dos passos. Desse modo, testes foram realizados reduzindo-se os valores das amplitudes de todas as juntas percen-

tualmente até encontrar um percentual de 60% de redução como adequado. A velocidade da caminhada assim obtida foi de 18,08 cm/s.

Então, implementou-se movimento de braços e verificou-se uma melhora de desempenho, com a velocidade passando a 21,49 cm/s. Também, a trajetória do robô passou a curvar menos.

A Tabela 12 resume as velocidades das caminhadas com os diferentes modelos. Para efeitos de comparação, mostra-se também as velocidades das caminhadas originais do kit Robonova e de uma versão melhorada disponível em (29). Observe que a caminhada final gerada nesse trabalho supera em velocidade todas as outras testadas. A Figura 40 apresenta uma sequência de imagens que ilustra a caminhada após todas as modificações feitas.



Figura 40: Sequência de imagens para ilustrar a caminhada final do Robonova real. A taxa de quadros usada para gravação foi de 30 quadros por segundo.

As medidas das velocidades das caminhadas foram feitas a partir de quanto o robô conseguia caminhar em 5 segundos. 10 testes foram feitos para cada tipo de caminhada. As medidas de distância foram feitas com uso de uma trena no chão e as de tempo com uso de um cronômetro digital. A Figura 41 mostra o ambiente do experimento montado.

| Caminhada | Média da Velocidade (cm/s) | Desvio Padrão da Velocidade (cm/s) | Número de Quedas (em 10 testes) |
|--------------------------------|----------------------------------|--|------------------------------------|
| Modelo Simples | 18,08 | 1,05 | 0 |
| Modelo com Movimento de Braços | 21,49 | 0,9 | 0 |
| Forward Walk (fabricante) | 2,7 | 0,25 | 0 |
| Fast Walk (fabricante) | 6,35 | 3,12 | 5 |
| New Fast Walk (29) | 19,2 | 1,3 | 0 |

Tabela 12: Comparação entre diversas caminhadas para o Robonova-I.



Figura 41: Ambiente do experimento de medida de velocidade do robô real.

16 Validação com Outro Robô

Para verificar a validade das técnicas utilizadas neste trabalho em outro modelo de robô, foi feito um procedimento análogo com o robô Nao simulado do domínio da RoboCup 3D Soccer Simulation League.

16.1 RoboCup 3D Soccer Simulation League

A **Soccer 3D!** é uma das categorias da competição RoboCup (11). Na **Soccer 3D!**, 22 agentes (11 em cada time) jogam futebol em um ambiente simulado, seguindo regras semelhantes às do futebol humano.

O simulador de Robótica utilizado é o **SimSpark!** (25). Esse simulador utiliza a **ODE! (ODE!)** (35) como sua *engine* de Física, que permite uma simulação precisa de interações mecânicas, como atrito e colisão. Isso permite modelar robôs humanóides complexos, como o Albebaran Nao (27), que possui 22 graus de liberdade. A Figura 42 mostra o robô Nao simulado dentro do **SimSpark!**.



Figura 42: Robô Nao simulado chutando uma bola no **SimSpark!**.

Diferentemente do USARSim, em que a simulação ocorre em tempo real, sendo o passo de tempo limitado pelo poder de processamento da máquina, a simulação no **SimSpark!**

ocorre a um passo fixo de 20 milisegundos. A comunicação entre agentes e servidor é por **TCP/IP!** (**TCP/IP!**) de acordo com um protocolo específico.

Um dos objetivos da competição é fomentar pesquisas em controle de humanóides, assim a atuação é feita a partir do envio de comandos de velocidade para as juntas. Note que a implementação de controle de posição para as juntas fica a cargo do agente. A Figura 43 apresenta um esquema das juntas do Nao simulado.

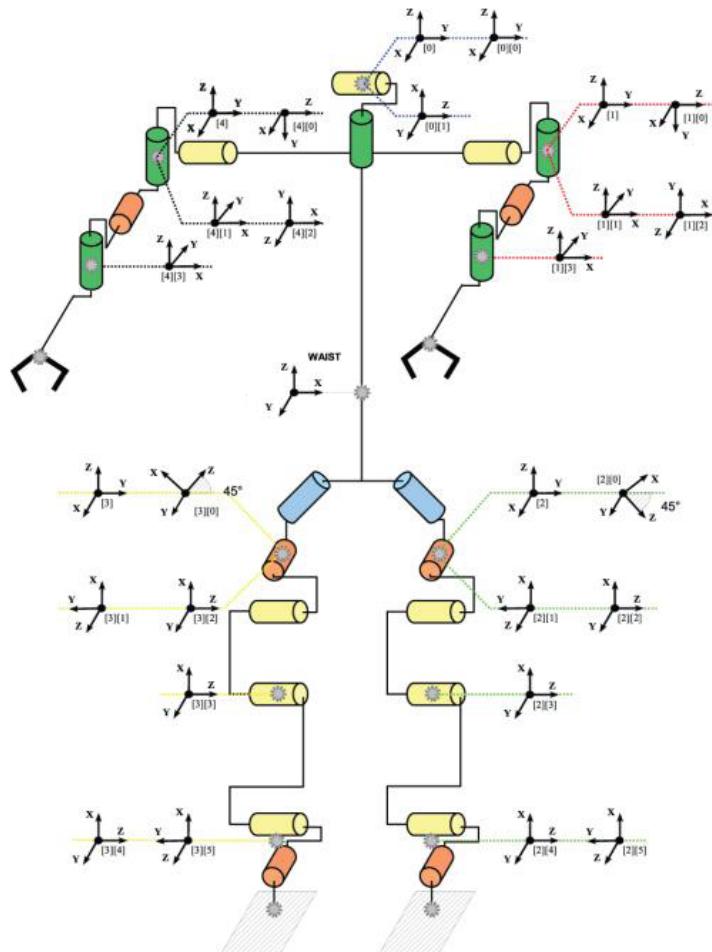


Figura 43: Esquema das juntas do Nao simulado do **SimSpark!**.

Já a visão é simplificada e não é necessário fazer processamento de imagem, pois o servidor envia medidas de distância e ângulo para cada objeto dentro do campo de visão do agente (que abrange 120° na horizontal). Outros sensores (acelerômetro, girômetro, sensores de pressão nos pés etc.) presentes no Nao real estão também presentes nessa versão simulada. Note que ruído é adicionado às medidas dos sensores para simular o que ocorre no caso de sensores reais. Ademais, para se comunicarem entre si, os agentes podem “falar” e “ouvir” mensagens limitadas a 20 bytes.

16.2 Implementação

Como trata-se de uma competição, a **Soccer 3D!** possui uma comunidade de tamanho razoável. Alguns times mais experientes liberam códigos de agentes base para servir de exemplo e facilitar a entrada de novos times.

Como o objetivo era apenas usar a **Soccer 3D!** para validação das técnicas utilizadas e não construir um novo programa de agente, optou-se pelo uso de um time base. Após a análise de alguns dos códigos providos em (34), escolheu-se o **magma-AF!** (**magma-AF!**), que é desenvolvido pelo time magmaOffenburg da Hochschule Offenburg University of Applied Sciences. O código do **magma-AF!** é escrito em Java com o uso de boas práticas de Engenharia de Software.

O **magma-AF!** é um agente funcional que joga futebol de modo autônomo com uma estratégia bem simples. Assim, várias das questões de baixo nível necessárias foram aproveitadas: comunicação com o servidor, controlador de posição, verificação de se o robô caiu etc.

Entretanto, no **SimSpark!**, o Nao não possui um sensor que dê a localização global do agente, assim como faz o GroundTruth do USARSim. Desse modo, o agente deve inferir sua posição a partir das medidas dos sensores que possui, principalmente da câmera. Considerando que o problema de Localização é um dos mais complexos da Robótica Móvel e que o **magma-AF!** usa um método muito simples de localização, as estimativas de posição feitas pelo agente certamente não seriam adequadas para o processo de treinamento.

A solução para isso foi implementar o que geralmente é chamado na liga de “treinador”. Esse treinador se conecta ao servidor como se fosse um monitor (um programa para visualização do jogo), logo recebe posições e orientações globais de todos os objetos. Com isso, pode-se obter a posição do agente desejado. O treinador implementado foi inspirado no código provido em (38). Para facilitar a troca de informações, optou-se por implementar o treinador no mesmo processo Java do agente, mas sendo executado em uma *thread* própria.

Depois disso, a caminhada com Modelo Complexo foi implementada conforme as estruturas providas pelo **magma-AF!**.

16.3 Processo de Otimização

O processo de otimização foi montado de modo semelhante ao explicado no Capítulo 14, inclusive a função de medida de qualidade utilizada foi a mesma. No caso, executou-se otimização apenas para o Modelo Complexo e com **PSO!**. Os parâmetros usados para o **PSO!** foram os apresentados na Tabela 13. Os limites para do espaço de busca são mostrados na Tabela 14.

| Parâmetro | Valor |
|---------------|-------|
| P | 50 |
| ω | 0,7 |
| φ_p | 0,5 |
| φ_g | 0,8 |
| ε | 0,8 |

Tabela 13: Valores dos parâmetros da execução de **PSO!** para otimização dentro do domínio da **Soccer 3D!**.

| Constante | Mínimo | Máximo |
|----------------|--------|--------|
| O_c | -1,0 | 0 |
| A | 0,01 | 1,0 |
| B | 0,01 | 1,0 |
| O_j | 0 | 1,5 |
| C | 0 | 1,5 |
| $\tau = t_2/T$ | 0,1 | 0,9 |
| T | 0,1 | 2,0 |
| D_+ | 0 | 1 |
| D_- | 0 | 1 |
| E | 0 | 0,5 |

Tabela 14: Limites do espaço de busca para no caso da otimização realizada dentro da domínio da **Soccer 3D!**.

A Figura 44 apresenta como o melhor desempenho até então varia com o número de testes. A Tabela 15 mostra os valores da melhor partícula encontrada, que foi avaliada com qualidade igual a 9,39. Por fim, a Figura 45 mostra uma sequência de imagens apresentando a caminhada aprendida.

Para avaliar o desempenho da caminhada aprendida, decidiu-se compará-la com a caminhada provida no **magma-AF!**. Assim, executou-se 10 experimentos simulados de 15 segundos para cada caminhada. Ao fim dos 15 segundos, a distância percorrida pelo robô no sentido positivo do eixo X era medida. A Tabela 16 resume os resultados obtidos.

| Constante | Valor |
|----------------|-------|
| O_c | -0,36 |
| A | 0,51 |
| B | 0,21 |
| O_j | 0,81 |
| C | 0,72 |
| $\tau = t_2/T$ | 0,36 |
| T | 0,27 |
| D_+ | 0,23 |
| D_- | 0,31 |
| E | 0,12 |

Tabela 15: Parâmetros aprendidos para o Modelo Complexo executado no Nao simulado do **SimSpark!**.

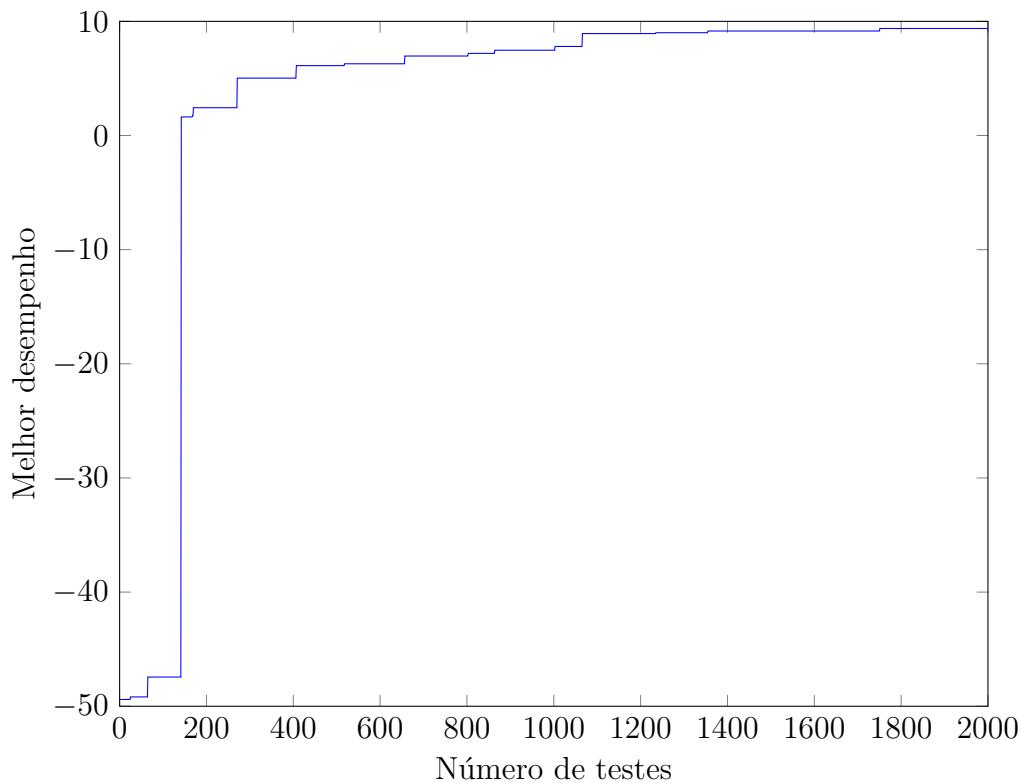


Figura 44: Resultados da otimização com **PSO!** realizada no ambiente da **Soccer 3D!**.

Observe que a caminhada aprendida é bem superior à do time base, sendo 89% mais rápida.

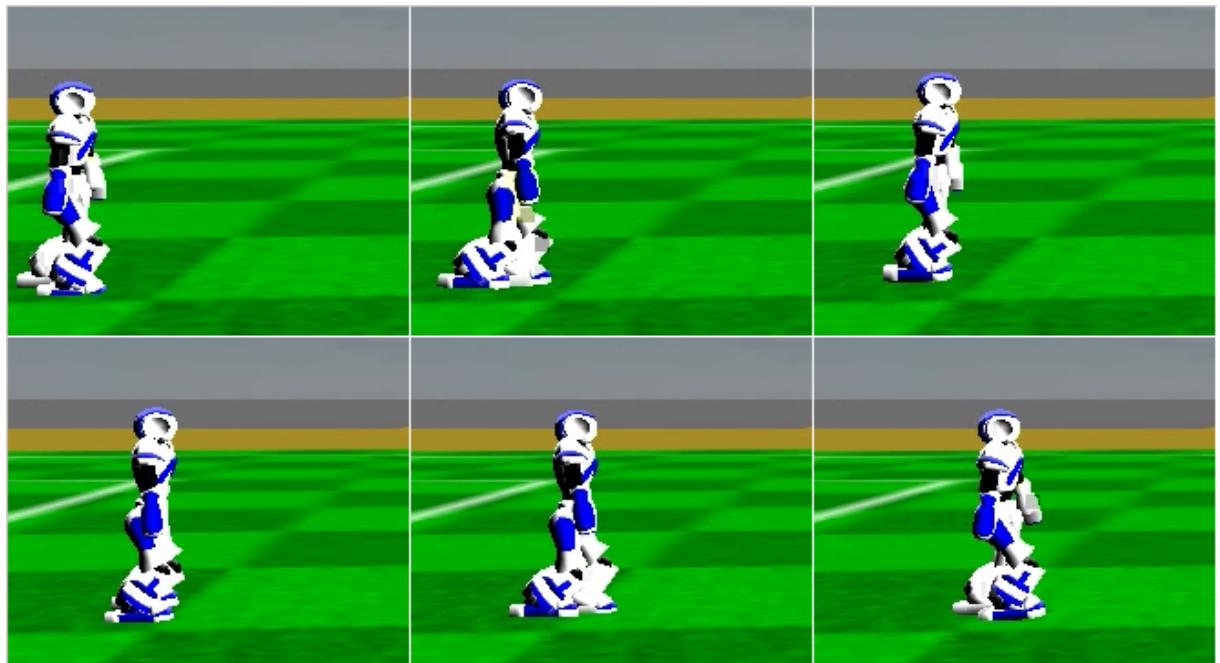


Figura 45: Sequência de imagens para ilustrar a caminhada aprendida para o Nao simulado do **SimSpark!**. Há uma diferença de tempo de 0,1 segundo entre uma imagem e a posterior.

| | Caminhada | Média | Desvio Padrão |
|-----------------|-----------|-------|---------------|
| Modelo Complexo | 7,41 | 0,55 | |
| magma-AF | 3,93 | 0,4 | |

Tabela 16: Resultados de medidas de distâncias percorridas no sentido positivo do eixo X. Realizou-se 10 experimentos de 15 segundos para cada caminhada.

17 Conclusões e Trabalhos Futuros

17.1 Conclusão

Nesse trabalho, caminhadas rápidas e estáveis foram confeccionadas para um robô Hitec Robonova-I. Para isso, usou-se um modelos parametrizados baseados em **SFT!** (**SFT!**) propostos em (32, 31, 33). Na abordagem seguida, parâmetros adequados para os modelos foram aprendidos com uso de 2 algoritmos de otimização: **AG!** (**AG!**) e **PSO!** (**PSO!**). Como aprendizado de locomoção diretamente no robô seria inconveniente e poderia provocar danos ao *hardware*, construiu-se um modelo do Robonova-I no **USARSim!** (**USARSim!**) e realizou-se o processo de aprendizado em simulação. Então, adaptou-se as caminhadas aprendidas para o robô real por ajustes manuais. Testes realizados com a melhor caminhada obtida mostraram que seu desempenho é bem superior à caminhada original do fabricante.

Posteriormente, uma validação adicional foi feita no domínio da **Soccer 3D!** (**Soccer 3D!**), que é uma categoria de futebol de robôs humanóides simulado da competição RoboCup. A **Soccer 3D!** é baseada no **SimSpark!** (**SimSpark!**) e atualmente usa um modelo simulado do robô Aldebaran Nao. Para evitar o desenvolvimento de uma interface com o **SimSpark!**, como foi feito no caso do **USARSim!**, utilizou-se o código base **magma-AF!** (**magma-AF!**). Assim, o processo de aprendizado foi executado e a melhor caminhada obtida se mostrou rápida e estável, inclusive superando significativamente o desempenho da caminhada provida no código base.

17.2 Trabalhos Futuros

Desde seu início, a intenção desse trabalho era criar uma estrutura para diversos outros trabalhos de pesquisa em robôs humanóides na instituição. Exatamente por isso, houve um cuidado especial em deixar os desenvolvimentos feitos bem documentados e em se fazer uma boa estrutura de programa de agente, embora essas questões não fossem tão

importantes dentro do escopo desse trabalho.

Em relação ao controle de humanóides especificamente, são propostas as seguintes frentes de trabalho futuro:

- Implementação de outros movimentos, como levantar-se, girar o corpo etc.;
- Idealização e execução de experimentos e métricas que avaliem o quanto o comportamento do robô simulado difere do real. A partir disso, seria interessante a realização de ajustes finos no modelo de simulação a fim de se obter um comportamento o mais próximo possível do robô real;
- Em otimização heurística, é difícil determinar de antemão qual o melhor método para um determinado problema. Assim, seria interessante tentar utilizar outros métodos além de **AG!** e **PSO!**;
- Estudo, desenvolvimento e implementação de novos modelos de caminhada. Em especial, caminhadas omnidirecionais, por serem mais flexíveis;
- Estudo, desenvolvimento e implementação de estratégias de balanço com base em sensores para “fechar a malha” da caminhada e torná-la mais estável e menos suscetível a pertubações como irregularidades no solo. Para isso, seria necessário antes a adição de sensores julgados interessantes, como acelerômetro, girômetro e sensores de pressão nos pés.

Em relação a outras linhas ligadas a humanóides, o autor tem interesse especial em continuar este trabalho em uma pós-graduação no sentido de construir robôs autônomos jogadores de futebol para a liga Humanoid KidSize da RoboCup, o que na realidade era objetivo implícito desde o início. Inclusive, um grupo de alunos de já está formado dentro da ITAndroids, grupo para competições de Robótica do ITA, para este projeto.

Referências

- 1 Hitec MR-C3024 to PC Protocol for RoboNova.
- 2 Autodesk. Autodesk 3D Studio Max. <http://usa.autodesk.com/3ds-max/>, 2012. [Online; acessado em 1 de novembro de 2012].
- 3 Autodesk. Autodesk Autocad. <http://usa.autodesk.com/autocad/>, 2012. [Online; acessado em 1 de novembro de 2012].
- 4 Autodesk. Autodesk FBX. <http://usa.autodesk.com/fbx/>, 2012. [Online; acessado em 1 de novembro de 2012].
- 5 R. Auvray, B. Fabre, and P.-Y. Lagrée. Harmonics generation in flute-like instruments. In *Proceedings of the International Symposium on Musical Acoustics*, pages 40–43, 2014.
- 6 Gianmario Bollano, Donato Ettorre, and Antonio Esiliato. Method and system to improve automated emotional recognition, January 31 2007. US Patent App. 12/449,298.
- 7 David Buckley. MR-C3024 ROBOT CONTROLLER.
- 8 Juan Carlos Fernández Caballero, Francisco José Martínez, César Hervás, and Pedro Antonio Gutiérrez. Sensitivity versus accuracy in multiclass problems using memetic pareto evolutionary neural networks. *Neural Networks, IEEE Transactions on*, 21(5):750–770, 2010.
- 9 Edwin Chen. What are the advantages of different classification algorithms? <https://www.quora.com/What-are-the-advantages-of-different-classification-algorithms>. [Online; acessado em 08 de novembro de 2015].
- 10 G. F. Cooper. In *The computational complexity of probabilistic inference using Bayesian belief networks*, 1990.
- 11 RoboCup Federation. RoboCup. <http://www.robocup.org/>, 2012. [Online; acessado em 25 de outubro de 2012].
- 12 N. H. Fletcher. Acoustical correlates of flute performance technique. *Journal of the Acoustical Society of America*, pages 233–237, 1975.
- 13 N. H. Fletcher. Air flow and sound generation in musical wind instruments. *Annual Review of Fluid Mechanics*, pages 123–146, 1979.
- 14 Epic Games. Unreal Development Kit. <http://www.unrealengine.com/udk/>, 2008–2012. [Online; acessado em 25 de outubro de 2012].

- 15 Gumstix. Gumstix. <http://www.gumstix.com/>, 2012. [Online; acessado em 25 de outubro de 2012].
- 16 J. H. Holland. *Adaptation in Natural and Artificial Systems*. The University of Michigan Press, 1975.
- 17 Dan Jurafsky and Christopher Manning. Practical Issues in Text Classification. <https://class.coursera.org/nlp/lecture>. [Online; acessado em 22 de setembro de 2015].
- 18 Dan Jurafsky and Christopher Manning. What is Text Classification? <https://class.coursera.org/nlp/lecture>. [Online; acessado em 20 de setembro de 2015].
- 19 Daphne Koller. Bayesian Network Fundamentals - Semantics And Factorization. <https://class.coursera.org/pgm/lecture>. [Online; acessado em 10 de outubro de 2015].
- 20 Chang-Hwan Lee, Fernando Gutierrez, and Dejing Dou. Calculating Feature Weights in Naive Bayes with Kullback-Leibler Measure. In *Data Mining (ICDM), 2011 IEEE International Conference on Data Mining*, pages 1146–1151. IEEE, 2011.
- 21 Jackson Paul Matsuura, Esther Luna Colombini, and Alexandre da Silva Simões. Desenvolvimento de Robô Humanóide Autônomo de Baixo Custo. In *Simpósio Brasileiro de Automação Inteligente (SBAI) 2007*, 2007.
- 22 P. Kevin Murphyk. A Brief Introduction to Graphical Models and Bayesian Networks. <http://www.cs.berkeley.edu/~murphyk/Bayes/bayes.html>, 1998. [Online; acessado em 04 de novembro de 2015].
- 23 Nokia. Qt. <http://qt.nokia.com/>, 2012. [Online; acessado em 28 de outubro de 2012].
- 24 Nvidia. Physx. <http://www.geforce.com/hardware/technology/physx>, 2012. [Online; acessado em 28 de outubro de 2012].
- 25 Oliver Obst and Markus Rollmann. SPARK - A Generic Simulator for Physical Multiagent Simulations. *Computer Systems Science and Engineering* 20, pages 347–356, 2005.
- 26 rbx. Kappa statistic in plain english. <http://stats.stackexchange.com/questions/82162/kappa-statistic-in-plain-english>, 2013. [Online; acessado em 10 de novembro de 2015].
- 27 Aldebaran Robotics. Nao H25: Humanoid Robot Platform. <http://www.aldebaran-robotics.com/en/Discover-NAO/nao-datasheet-h25.html>, 2012. [Online; acessado em 25 de outubro de 2012].
- 28 Hitec Robotics. Robonova-I English Instruction Manual.
- 29 Hitec Robotics. New source code with fast walk and fast turn. http://www.robonova.de/store/support/index.php?_m=downloads&_a=viewdownload&downloaditemid=93&nav=0,5,7, 2006.

- 30 Stuart Russell and Peter Norvig. *Artificial Intelligence: A Modern Approach*. Prentice Hall, 2009.
- 31 Nima Shafii, Siavash Aslani, Omid Mohamad Nezami, and Saeed Shiry. Evolution of Biped Walking Using Truncated Fourier Series and Particle Swarm Optimization. In *Baltes, J., Lagoudakis, M.G., Naruse, T.; Ghidary, S.S. (eds.) RoboCup 2009*, pages 344–354, 2010.
- 32 Nima Shafii, Ali Khorsandian, Abbas Abdolmaleki, and Bahram Jozi. An Optimized Gait Generator Based on Fourier Series Toward Fast and Robust Biped Locomotion Involving Arms Swing. In *Proceedings of the IEEE International Conference on Automation and Logistics*, 2009.
- 33 Nima Shafii, Luís Paulo Reis, and Nuno Lau. Biped Walking Using Coronal and Sagittal Movements Based on Truncated Fourier Series. In *RoboCup 2010: Robot Soccer World Cup XIV, Lecture Notes in Computer Science*, pages 324–335, 2010.
- 34 SimSpark. SimSpark Agents. <http://simspark.sourceforge.net/wiki/index.php/Agents>, 2012. [Online; acessado em 25 de outubro de 2012].
- 35 Russell Smith. Open Dynamics Engine. <http://www.ode.org/>, 2012. [Online; acessado em 25 de outubro de 2012].
- 36 Marina Sokolova and Guy Lapalme. A systematic analysis of performance measures for classification tasks. *Information Processing & Management*, 45(4):427–437, 2009.
- 37 Pang-Ning Tan, Michael Steinbach, and Vipin Kumar. Introduction to Data Mining. In *Introduction to Data Mining*, pages 145–146, 2006.
- 38 TinMan. TinMan. <http://code.google.com/p/tin-man/>, 2012. [Online; acessado em 25 de outubro de 2012].
- 39 Sander van Noort and Arnoud Visser. Validation of the dynamics of an humanoid robot in USARSim. In *Proceedings of the Performance Metrics for Intelligent Systems Workshop (PerMIS'12)*, March 2012.
- 40 Anthony J Viera, Joanne M Garrett, et al. Understanding interobserver agreement: the kappa statistic. *Fam Med*, 37(5):360–363, 2005.
- 41 Nayyar A Zaidi, Jesus Cerquides, Mark J Carman, and Geoffrey I Webb. Alleviating naive bayes attribute independence assumption by attribute weighting. *The Journal of Machine Learning Research*, 14(1):1947–1988, 2013.

FOLHA DE REGISTRO DO DOCUMENTO

| | | | |
|---|---------|--|--|
| 1. CLASSIFICAÇÃO/TIPO TC | 2. DATA | 3. REGISTRO N° | 4. N° DE PÁGINAS N PAGINAS |
| 5. TÍTULO E SUBTÍTULO: Desenvolvimento de um classificador de postagens em rede social utilizando Processamento de Linguagem Natural | | | |
| 6. AUTOR(ES): Luiz Filipe Martins Ramos Bernardo Monteiro Rufino | | | |
| 7. INSTITUIÇÃO(ES)/ÓRGÃO(S) INTERNO(S)/DIVISÃO(ES): Instituto Tecnológico de Aeronáutica - ITA | | | |
| 8. PALAVRAS-CHAVE SUGERIDAS PELO AUTOR: Inteligência Artificial, Processamento de Linguagem Natural, Redes Bayesianas | | | |
| 9. PALAVRAS-CHAVE RESULTANTES DE INDEXAÇÃO: Solicite preenchimento dos campos 2, 3 e 9 – envie este formulário para doc.pt@ita.br | | | |
| 10. APRESENTAÇÃO: | | <input checked="" type="checkbox"/> Nacional | <input type="checkbox"/> Internacional |
| ITA, São José dos Campos. Curso de Graduação em Engenharia de Computação. Orientador(es): Prof. Dr. Paulo André Lima de Castro. Publicado em 2015 | | | |
| 11. RESUMO: | | | |
| 12. GRAU DE SIGILO: <input checked="" type="checkbox"/> OSTENSIVO <input type="checkbox"/> RESERVADO <input type="checkbox"/> SECRETO | | | |