

INSTITUTO TECNOLÓGICO DE AERONÁUTICA



Luiz Filipe Martins Ramos
Bernardo Monteiro Rufino

Desenvolvimento de um classificador de postagens em rede social utilizando Processamento de Linguagem Natural

Trabalho de Graduação
2015

Computação

Número da CDU (tamanho 10)

Luiz Filipe Martins Ramos
Bernardo Monteiro Rufino

**Desenvolvimento de um classificador de postagens em rede social
utilizando Processamento de Linguagem Natural**

Orientador
Prof. Dr. Paulo André Lima de Castro

Engenharia de Computação

SÃO JOSÉ DOS CAMPOS
INSTITUTO TECNOLÓGICO DE AERONÁUTICA

2015

Dados Internacionais de Catalogação-na-Publicação (CIP)
Divisão de Informação e Documentação

Ramos, Luiz Filipe Martins
Rufino, Bernardo Monteiro

Desenvolvimento de um classificador de postagens em rede social utilizando Processamento de Linguagem Natural / Luiz Filipe Martins Ramos, Bernardo Monteiro Rufino

São José dos Campos, 2015

Número de folhas no formato 999f.

Trabalho de Graduação – Divisão de Ciência da Computação –

Instituto Tecnológico de Aeronáutica, 2015. Orientador: Prof. Dr. Paulo André Lima de Castro

1. Inteligência Artificial. 2. Processamento de Linguagem Natural. 3. Redes Bayesianas. I. Nome do segundo autor, se houver. II. Instituto Tecnológico de Aeronáutica. III. Desenvolvimento de um classificador de postagens em rede social utilizando Processamento de Linguagem Natural

REFERÊNCIA BIBLIOGRÁFICA

RAMOS, Luiz Filipe Martins; RUFINO, Bernardo Monteiro. Desenvolvimento de um classificador de postagens em rede social utilizando Processamento de Linguagem Natural. 2015. Total de folhas. Trabalho de Conclusão de Curso. (Graduação) – Instituto Tecnológico de Aeronáutica, São José dos Campos.

CESSÃO DE DIREITOS – (NEGRITO, TAMANHO 12)

NOME DO AUTOR: Luiz Filipe Martins Ramos; Bernardo Monteiro Rufino

TÍTULO DO TRABALHO: Desenvolvimento de um classificador de postagens em rede social utilizando Processamento de Linguagem Natural

TIPO DO TRABALHO/ANO: Graduação / 2015

É concedida ao Instituto Tecnológico de Aeronáutica permissão para reproduzir cópias deste trabalho de graduação e para emprestar ou vender cópias somente para propósitos acadêmicos e científicos. O autor reserva outros direitos de publicação e nenhuma parte desta monografia de graduação pode ser reproduzida sem a autorização do autor.

Luiz Filipe Martins Ramos
Pça Mal-do-Ar Eduardo Gomes, 50
12228-900 – São José dos Campos – SP

Bernardo Monteiro Rufino
Pça Mal-do-Ar Eduardo Gomes, 50
12228-900 – São José dos Campos - SP

**DESENVOLVIMENTO DE UM CLASSIFICADOR DE POSTAGENS EM REDE SOCIAL
UTILIZANDO PROCESSAMENTO DE LINGUAGEM NATURAL**

Essa publicação foi aceita como Relatório Final de Trabalho de Graduação

Luiz Filipe Martins Ramos
Autor

Bernardo Monteiro Rufino
Autor

Prof. Dr. Paulo André Lima de Castro (ITA)
Orientador

Prof. Dr. Carlos Henrique Costa Ribeiro (ITA)
Coordenador do Curso de Engenharia de Computação

São José dos Campos, _____ de _____ de _____

Agradecimentos

4.0141 There is a general rule by means of which the musician can obtain the symphony from the score, and which makes it possible to derive the symphony from the groove on the gramophone record, and, using the first rule, to derive the score again. That is what constitutes the inner similarity between these things which seem to be constructed in such entirely different ways. And that rule is the law of projection which projects the symphony into the language of musical notation. It is the rule for translating this language into the language of gramophone records.

Ludwig Wittgenstein. Tractatus Logico-Philosophicus.

Resumo

Abstract

Sumário

Agradecimentos	p. 6
Resumo	p. 8
Abstract	p. 9
Lista de Figuras	p. 17
Lista de Tabelas	p. 20
Lista de Algoritmos	p. 21
Lista de Abreviaturas	p. 23
1 Introdução	p. 24
1.1 Motivação	p. 24
1.2 Objetivos	p. 24
1.3 Organização do Texto	p. 25
2 Definição do Problema	p. 26
2.1 O Problema de Classificação	p. 26
2.1.1 Classificação Binária	p. 27
2.1.2 Classificação <i>Multi-Class</i>	p. 27
2.1.3 Classificação <i>Multi-Class / Multi-Label</i>	p. 27
2.2 Objeto de Estudo deste Trabalho	p. 28
3 Fundamentação Teórica	p. 29

3.1 Definição formal	p. 29
3.2 Tipos de classificadores	p. 29
3.3 Redes Bayesianas	p. 30
3.3.1 Definição	p. 30
3.3.2 Regra de Bayes	p. 30
3.3.3 Naïve Bayes	p. 31
3.3.3.1 Problema a ser resolvido	p. 31
3.3.3.2 O que são Naïve Bayes	p. 32
3.3.3.3 Independência Condicional	p. 32
3.3.3.4 Inferência	p. 33
3.3.3.5 Classificação utilizando Naïve Bayes	p. 34
3.3.3.6 Smoothing	p. 35
3.3.4 Modelagens para classificação de texto	p. 36
3.3.4.1 Naïve Bayes Binária	p. 36
3.3.4.2 Naïve Bayes de Bernoulli	p. 36
3.3.4.3 Multinomial Naïve Bayes	p. 36
3.3.4.4 Outras features	p. 36
3.4 Weighted Naïve Bayes	p. 36
3.5 Métodos de avaliação de um classificador	p. 37
3.5.1 Classificador Binário	p. 38
3.5.1.1 Acurácia	p. 38
3.5.1.2 Precisão	p. 39
3.5.1.3 Abrangência (<i>Recall</i>)	p. 39
3.5.1.4 Fscore	p. 40
3.5.2 Classificador <i>Multi-Class</i>	p. 41
3.5.2.1 Matriz de Confusão (<i>Confusion Matrix</i>)	p. 41

3.5.2.2 Médias micro e macro (<i>Micro and Macro Averaging</i>) . .	p. 42
3.5.2.3 Fscore	p. 43
3.5.2.4 Acurácia	p. 43
3.5.2.5 Medida Kappa	p. 44
4 Metodologia	p. 46
4.1 Plano de desenvolvimento	p. 46
4.1.1 Estudo basico sobre Processamento de Linguagem Natural . .	p. 46
4.1.2 Coleta de dados	p. 47
4.1.3 Pré-processamento dos textos e normalização	p. 47
4.1.4 Criação dos classificadores de Redes Bayesianas	p. 47
4.1.5 Estudo dos resultados obtidos no conjunto de validação para diferentes features e parâmetros	p. 48
4.1.6 Definição da arquitetura do classificador e sua implementação	p. 48
4.1.7 Desenvolvimento do plugin	p. 48
4.1.8 Testes de usabilidade	p. 48
4.2 Aquisição de dados	p. 48
4.2.1 Plugin de classificação de postagens	p. 49
4.2.1.1 Funcionamento de extensões do Chrome	p. 49
4.2.1.2 Manifesto da extensão	p. 50
4.2.1.3 Estrutura do DOM do Facebook	p. 51
4.2.1.4 UI desenvolvida	p. 53
4.2.1.5 Servidor	p. 54
4.2.1.6 Crawler	p. 56
4.3 Processamento do texto	p. 56
4.4 Tecnologias utilizadas	p. 57
5 Proposta de Classificador	p. 58

6 Validação - Experimentos, resultados e análise	p. 59
7 Conclusões e Trabalhos Futuros	p. 60
8 Instrumentos analisados	p. 61
8.1 Características de interesse	p. 61
8.1.1 Mecanismo de produção de som	p. 62
8.1.2 Timbre	p. 62
8.1.3 Tom	p. 62
8.1.4 Popularidade	p. 62
8.2 Instrumentos escolhidos	p. 62
8.3 Flauta doce	p. 63
8.3.1 Características	p. 64
8.3.2 Análise espectral	p. 64
8.3.3 Conclusões	p. 66
8.4 <i>Tin Whistle</i>	p. 67
8.4.1 Características	p. 67
8.4.2 Análise espectral	p. 67
8.4.3 Conclusões	p. 69
8.5 Pífano	p. 69
8.5.1 Características	p. 69
8.5.2 Análise espectral	p. 70
8.5.3 Conclusões	p. 70
8.6 Flauta transversal ocidental	p. 71
8.6.1 Características	p. 71
8.6.2 Análise espectral	p. 72
8.6.3 Conclusões	p. 73

8.7 Flauta transversal chinesa (<i>dizi</i>)	p. 74
8.7.1 Características	p. 74
8.7.2 Análise espectral	p. 74
8.7.3 Conclusões	p. 74
8.8 Ocarina	p. 75
8.8.1 Características	p. 75
8.8.2 Análise espectral	p. 75
8.8.3 Conclusões	p. 76
9 Algoritmos de Otimização	p. 77
9.1 Algoritmo Genético	p. 77
Cromossomo	p. 77
Função de <i>Fitness</i>	p. 77
Seleção	p. 78
Mutação	p. 78
Crossover	p. 78
Sobrevivência dos Mais Aptos	p. 78
9.2 Particle Swarm Optimization	p. 79
10Tecnologias Utilizadas	p. 82
10.1 USARSim	p. 82
10.1.1 Nvidia PhysX	p. 82
10.1.2 UDK Editor	p. 84
10.1.3 UnrealScript	p. 85
10.1.4 Implementação de Robôs em USARSim	p. 86
10.1.5 Comunicação entre Agentes e USARSim	p. 86
10.2 Robonova-I	p. 87

11 Modelo de Simulação	p. 91
11.1 Modelos CAD	p. 91
11.2 Configuração no UDK Editor	p. 92
11.2.1 Implementação no USARSim	p. 92
12 Programa do Agente	p. 95
12.1 Comunicação	p. 96
12.2 Interface	p. 97
12.3 Controle	p. 98
13 Processo de Otimização	p. 100
13.1 Modelos de Caminhada	p. 100
13.2 Configuração dos Algoritmos de Otimização	p. 101
13.2.1 Configuração do Algoritmo Genético	p. 102
13.2.2 Configuração do Particle Swarm Optimization	p. 103
13.3 Montagem do Experimento Simulado	p. 104
13.4 Resultados e Discussões	p. 107
14 Transferência para o Robô Real	p. 114
14.1 Desafios Envolvidos	p. 114
14.2 Processo de Transferência	p. 114
15 Validação com Outro Robô	p. 119
15.1 RoboCup 3D Soccer Simulation League	p. 119
15.2 Implementação	p. 121
15.3 Processo de Otimização	p. 122
16 Conclusões e Trabalhos Futuros	p. 125
16.1 Conclusão	p. 125

16.2 Trabalhos Futuros p.126

Referências p.127

Lista de Figuras

1	Esquema ilustrativo da função de um classificador	p. 26
2	Exemplo de Redes Bayesianas	p. 31
3	Exemplo de uma Naïve Bayes	p. 32
4	Exemplo de Matriz de Confusão para um classificador retirado de (6) p. 42	
5	Exemplo de HTML do Facebook, com algumas classes aleatórias e algumas de nome legível	p. 52
6	Exemplo ilustrativo da estrutura básica da árvore de DOM do Facebookp. 53	
7	Exemplo em uma postagem do cabeçalho contendo as possíveis classesp. 54	
8	Exemplo da UI de uma postagem classificada pelo usuário	p. 55
9	Barra de opções para modificar a escolha do assunto na extensão do Chrome	p. 56
10	Espectro para a nota C5 tocada em uma flauta doce Yamaha YRS-23Y obtido a partir da FFT em 1 segundo de gravação.	p. 65
11	Espectro para um G5 (azul) e um G6 (verde) tocados em uma flauta doce Yamaha YRS-23Y obtido a partir da FFT em 1 segundo de gravação.	p. 66
12	Espectro para a nota D5 tocada em um <i>whistle</i> Clarke SBDC obtido a partir da FFT em 1 segundo de gravação.	p. 68
13	Espectro para um G5 (verde) e um G6 (azul) tocados em um <i>whistle</i> Clarke SBDC obtido a partir da FFT em 1 segundo de gravação.	p. 68
14	Espectro para a nota C5 tocada em um pífano Yamaha YRF-21 obtido a partir da FFT em 1 segundo de gravação.	p. 70
15	Espectro para a nota C4 tocada em uma flauta transversal Hallelu HFL-200 obtido a partir da FFT em 1 segundo de gravação.	p. 72

16	Espectro para um G4 (verde) e um G6 (azul) tocados em uma flauta transversal Hallelu HFL-200C obtido a partir da FFT em 1 segundo de gravação.	p. 72
17	Espectro para um A4 (azul) e um A5 (verde) tocados na ocarina es- colhida, obtido a partir da FFT em 1 segundo de gravação.	p. 75
18	Junta de revolução.	p. 83
19	Diferenças entre modelos físicos gerados com K-DOF (os modelos físicos são apresentados em <i>wireframe</i>).	p. 85
20	Robonova-I. Extraído de (29).	p. 87
21	Juntas do Robonova-I. Extraído de (29).	p. 88
22	Servomotores Hitec HSR-8498HB. Extraído de (29).	p. 88
23	Detalhe das costas do Robonova-I mostrando a placa MR-C3204 ins- talada. Extraído de (29).	p. 89
24	Modelo completo montado do Robonova-I.	p. 91
25	Modelo completo explodido do Robonova-I.	p. 92
26	Juntas implementadas no modelo de simulação.	p. 94
27	Robonova-I simulado dentro do USARSim! (USARSim!).	p. 94
28	Camadas do programa do agente.	p. 95
29	ExampleMap.	p. 105
30	Sistema de coordenadas no USARSim.	p. 106
31	Resultados da otimização com Modelo Simples e AG! (AG!).	p. 109
32	Resultados da otimização com Modelo com Movimento de Braços e AG!	p. 109
33	Resultados da otimização com Modelo Complexo e AG!	p. 110
34	Resultados da otimização com Modelo Simples e PSO! (PSO!).	p. 110
35	Resultados da otimização com Modelo com Movimento de Braços e PSO!	p. 111
36	Resultados da otimização com Modelo Complexo e PSO!	p. 111

- 37 Sequência de imagens para ilustrar a caminhada aprendida com Modelo Simples e **PSO!**. p.112
- 38 Sequência de imagens para ilustrar a caminhada aprendida com Modelo com Movimento de Braços e **PSO!**. p.113
- 39 Sequência de imagens para ilustrar a caminhada aprendida com Modelo Complexo e **PSO!**. p.113
- 40 Sequência de imagens para ilustrar a caminhada final do Robonova real. A taxa de quadros usada para gravação foi de 30 quadros por segundo. p.117
- 41 Ambiente do experimento de medida de velocidade do robô real. . . . p.118
- 42 Robô Nao simulado chutando uma bola no **SimSpark!** (**SimSpark!**). p.119
- 43 Esquema das juntas do Nao simulado do **SimSpark!**. p.120
- 44 Resultados da otimização com **PSO!** realizada no ambiente da **Soccer 3D!** (**Soccer 3D!**). p.123
- 45 Sequência de imagens para ilustrar a caminhada aprendida para o Nao simulado do **SimSpark!**. Há uma diferença de tempo de 0,1 segundo entre uma imagem e a posterior. p.124

Lista de Tabelas

1	Resumo das medidas de performance para classificadores binários . .	p.38
2	Especificação dos servomotores Hitec HSR-8498HB. Extraído de (29). p.	88
3	Especificação da placa MR-C3024. Extraído de (7).	p.89
4	Peças implementadas como objetos do tipo “Part”.	p.93
5	Mapeamento das juntas dos modelos teóricos para as do Robonova (veja a Figura 26 para nomenclatura utilizada para as juntas do Ro- bonova).	p.101
6	Limites para os valores das contantes dos modelos de caminhada. . .	p.102
7	Valores dos parâmetros usados nas execuções de AG!	p.102
8	Valores dos parâmetros usados nas execuções de PSO!	p.104
9	Limites para os valores das contantes dos modelos de caminhada. . .	p.106
10	Resultados dos Experimentos.	p.108
11	Limites para os valores das contantes dos modelos de caminhada. . .	p.108
12	Comparação entre diversas caminhadas para o Robonova-I.	p.118
13	Valores dos parâmetros da execução de PSO! para otimização dentro do domínio da Soccer 3D!	p.122
14	Limites do espaço de busca para no caso da otimização realizada dentro da domínio da Soccer 3D!	p.122
15	Parâmetros aprendidos para o Modelo Complexo executado no Nao simulado do SimSpark!	p.123
16	Resultados de medidas de distâncias percorridas no sentido positivo do eixo X. Realizou-se 10 experimentos de 15 segundos para cada caminhada.	p.124

Lista de Algoritmos

- | | | |
|---|--|--------|
| 1 | Pseudocódigo do Algoritmo Genético. | p. 79 |
| 2 | Pseudocódigo do <i>Particle Swarm Optimization</i> | p. 81 |
| 3 | Subrotina que simula “choques” das partículas com os limites do espaço de busca. | p. 104 |

Lista de Listagens

Lista de Abreviaturas

NB Naïve Bayes

1 *Introdução*

1.1 Motivação

Um dos temas atualmente mais ativos na área de Ciência da Computação é o de Inteligência Artificial, sendo o Processamento de Linguagem Natural um dos seus principais tópicos. Hoje em dia vemos diversas aplicações dessa área na indústria como, por exemplo, os assistentes digitais Google Now, Siri (Apple) e Cortana (Microsoft), os quais, dado um processamento inicial do áudio, interpretam perguntas dos usuários, produzindo respostas satisfatórias.

Paralelamente a isto, observa-se um crescimento acelerado de redes sociais conectando usuários do mundo inteiro. Elas possuem uma abrangente variedade de assuntos, desde discussões sobre política até comentários sobre novelas. Muitas vezes os usuários não se interessam por uma boa parte das postagens e simplesmente as ignoram. As próprias redes sociais empregam grande esforço em ranquear seus conteúdos e apenas mostrar para seus usuários o que lhes interessa, entretanto não há hoje uma forma do próprio usuário informar à rede social seus interesses e a partir daí filtrar postagens não desejadas.

O Processamento de Linguagem Natural pode ser empregado para se analisar o conteúdo dos diversos textos postados, os categorizando em diferentes classes, o que permite a realização de uma filtragem dos conteúdos por parte do usuário.

1.2 Objetivos

Este trabalho tem, como objetivo, a criação de um classificador de textos baseado em Redes Bayesianas com aprendizado supervisionado. Este classificador será acoplado a uma rede social específica (o Facebook), através de um plugin para o navegador Google Chrome de modo a permitir que o usuário tenha contato apenas

com postagens de assuntos de seu interesse.

1.3 Organização do Texto

Este texto foi organizado em capítulos de modo a proporcionar uma leitura simples, com uma progressão natural dos assuntos abordados. A estrutura escolhida foi a seguinte:

- **Capítulo 2:** Este capítulo irá definir o problema que será atacado ao longo do trabalho, clarificando os aspectos teóricos e práticos a serem considerados.
- **Capítulo 3:**
- **Capítulo 4:**
- **Capítulo 5:**

2 Definição do Problema

Antes de se abordarem as soluções propostas, é necessário entender com detalhes o problema que está sendo analisado.

2.1 O Problema de Classificação

Em aprendizado de máquina, o problema de classificação consiste na tarefa de atribuir a objetos uma ou mais das diversas categorias pré-definidas (38). Ou seja, dado um objeto, o classificador deve ser capaz de identificar em qual categoria tal objeto se encaixa melhor, como pode ser visualizado na Figura 1.

O problema de classificação em geral é o exemplo clássico de aprendizado de máquina supervisionado. A partir de um conjunto de exemplos previamente classificados por um supervisor experiente (em geral um ou mais humanos com conhecimento de domínio), o classificador é capaz de aprender e generalizar, podendo assim categorizar corretamente novos objetos encontrados.

Existem vários tipos diferentes de classificação baseados na quantidade de categorias pré-definidas assim como na quantidade de classes as quais cada objeto pode pertencer.



Figura 1: Esquema ilustrativo da função de um classificador

2.1.1 Classificação Binária

A classificação binária é o caso mais simples que pode ser estudado. Neste problema, há apenas duas classes diferentes e cada objeto pertence a exatamente uma delas.

Exemplos comuns que podem ser citados são a classificação de emails em spam ou não-spam, a classificação de tumores em benignos ou malignos, a determinação quais produtos deverão ser descartados em uma linha de produção, a detecção de transações financeiras fraudulentas, etc.

2.1.2 Classificação Multi-Class

Quando há mais de duas classes possíveis, chama-se o problema de classificação *multi-class*. Neste caso, cada objeto deve pertencer a exatamente uma dentre as várias categorias pré definidas. O classificador deve ser capaz de determinar qual é a categoria de cada objeto.

Vários exemplos de classificação podem ser considerados. Dadas imagens de frutas (que podem ser maçãs, peras, ou laranjas) determinar qual é o tipo de cada fruta. Ou então dadas imagens de telescópio de galaxias distantes, determinar o tipo da galaxia em questão (elíptica, espiral, etc).

2.1.3 Classificação Multi-Class / Multi-Label

Quando há várias classes possíveis (mais de duas) e cada objeto pode pertencer a mais de uma classe, chama-se o problema de *multi-class / multi-label*. Este é o mais difícil dos três problemas apresentados, uma vez que há diversas possíveis combinações de classes para cada objeto.

A classificação de textos é um exemplo clássico de classificação *multi-class / multi-label*, uma vez que o texto pode pertencer a uma ou varias classes simultaneamente.

Para resolver o problema de classificação *multi-class / multi-label* podem ser utilizadas duas abordagens diferentes. Uma delas é a abordagem *one vs all* e a outra é a abordagem dos subconjuntos.

Na abordagem *one vs all*, para cada classe, realiza-se a classificação binaria do

objeto em *pertence* ou *não pertence* a esta classe. Desta forma determina-se todas as classes às quais o dado objeto pertence. O problema desta abordagem é que pequenos erros que façam com que o classificador de uma das classes não fique bom (dados ruins para uma classe por exemplo) torna o resultado inteiro ruim.

Na abordagem de subconjuntos, consideram-se todos os possíveis subconjuntos das classes (com 1, 2, 3, ..., L elementos, onde L é o total de classes) e escolhe-se o subconjunto desejado (utilizando um classificador multi-class). O grande problema desta abordagem é que ha 2^{L-1} possíveis subconjuntos da classes (o que pode ser muito).

2.2 Objeto de Estudo deste Trabalho

Como foi visto, a classificação de textos é um problema do tipo *multi-class / multi-label*, entretanto seria necessária uma quantidade muito grande de dados para se obter resultados satisfatórios neste problema. Portanto, fez-se a simplificação de considerar o problema apenas *multi-class*, ou seja, cada texto só será classificado em um única classe.

3 Fundamentação Teórica

3.1 Definição formal

Utilizando a notação adotada por Dan Jurafsky e Christopher Manning em seu curso de Processamento de Linguagem Natural para Stanford (19), define-se o problema da classificação supervisionada de textos da seguinte forma.

Seja $C = \{c_1, c_2, \dots, c_J\}$ um conjunto fixo de classes, $D = \{d_1, d_2, \dots, d_n\}$ um conjunto de documentos, e $\mathcal{T} = \{(d_1, c_{d_1}), (d_2, c_{d_2}), \dots, (d_m, c_{d_m})\}$ um conjunto de treinamento (subconjunto de D) com m documentos classificados manualmente, o classificador consiste em uma função $\gamma : D \rightarrow C$ que relaciona um documento a uma classe, e um algoritmo de aprendizado de máquina supervisionado é um algoritmo que recebe como parâmetros C e \mathcal{T} e retorna γ .

3.2 Tipos de classificadores

Existem diversos tipos diferentes de classificadores que possuem resultados muito bons dependendo do problema analisado. Segue abaixo uma lista dos principais classificadores existentes.

- Árvores de Decisão
- Naïve Bayes
- Regressão Logística
- Support Vector Machines
- k-Nearest Neighbors
- Redes Neurais

- Dentre outros

A performance de todos estes métodos varia consideravelmente dependendo da aplicação. Estudos mostram que para bases de dados grandes o suficiente, ótimos resultados podem ser atingidos independentemente do método utilizado (18). Entretanto, para uma quantidade pequena de dados as Naïve Bayes apresentam resultados bons por serem classificadores de alto *bias* / baixa variância (9).

As NB possuem as vantagens de serem fáceis de se implementar, serem bem rápidas na hora da execução e mostrarem bons resultados práticos.

3.3 Redes Bayesianas

3.3.1 Definição

Em modelagem gráfica probabilística, Redes Bayesianas são grafos direcionados que representam relações de dependência condicionais entre diferentes variáveis aleatórias (23). A partir da visualização de uma Rede Bayesiana é possível utilizar a regra de Bayes para realizar inferências e descobrir a probabilidade de eventos, dadas algumas variáveis observadas. As arestas direcionadas representam as noções de causalidade entre as variáveis aleatórias e geram as dependências condicionais. Para cada nó do gráfico deve haver uma tabela de probabilidades condicionais para a variável em questão.

A Figura 2, retirada do curso de Modelagem Gráfica Probabilística da professora Daphne Koller de Stanford (20), ilustra um exemplo de uma Rede Bayesiana simples. Neste caso, pode-se ver que a nota do aluno é influenciada pela dificuldade da prova e pela sua inteligencia. Além disso a possibilidade do professor escrever uma carta de recomendação depende apenas da nota do aluno e o SAT do aluno depende apenas de sua inteligencia. Em cada nó do grafo há uma tabela de distribuições de probabilidades condicionais.

3.3.2 Regra de Bayes

Para realizar inferências nas redes Bayesianas utiliza-se a regra de Bayes, como definida a seguir.

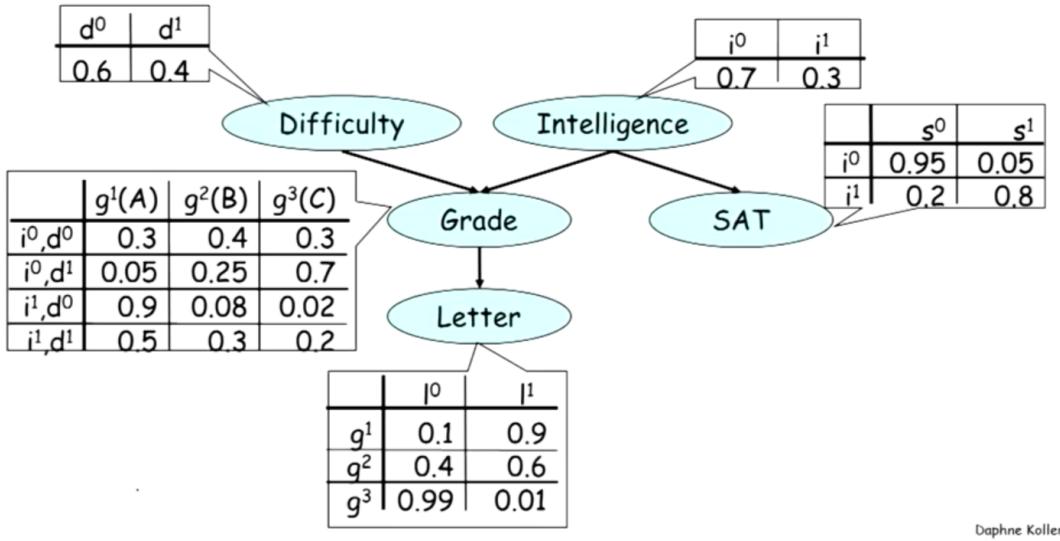


Figura 2: Exemplo de Redes Bayesianas

Sejam A e B dois eventos com probabilidades de ocorrência $P(A)$ e $P(B)$ e sendo $P(A|B)$ e $P(B|A)$ as probabilidades condicionais de A dado B e de B dado A , respectivamente, tem-se que:

$$P(A|B) = \frac{P(A)P(B|A)}{P(B)}$$

Esse resultado parte da noção probabilidade conjunta $P(A, B)$.

$$P(A, B) = P(A)P(B|A) = P(B)P(A|B) \rightarrow P(A|B) = \frac{P(A)P(B|A)}{P(B)}$$

No caso do exemplo da Figura 2, podemos calcular a probabilidade conjunta da rede da seguinte forma:

$$P(D, I, G, S, L) = P(D)P(I)P(G|I, D)P(S|I)P(L|G)$$

Onde $D = \text{Difficulty}$, $G = \text{Grade}$, $I = \text{Intelligence}$, $S = \text{SAT}$ e $L = \text{Letter}$.

3.3.3 Naïve Bayes

3.3.3.1 Problema a ser resolvido

Redes Bayesianas são ferramentas excelentes para modelar problemas complexos, entretanto elas possuem um grande problema prático. A realização de inferências em redes genéricas é um problema NP-Hard, conforme demonstrado por Cooper (10).

O que é realizado na prática é, ou realizar inferências aproximadas nas redes com algoritmos polinomiais, ou simplificar as redes a alguns tipos específicos mais

simples.

3.3.3.2 O que são Naïve Bayes

As Naïve Bayes (bayes ingênuas) são simplificações feitas na modelagem de um problema por redes Bayesianas de modo a tornar possível realizar a inferência de forma rápida. Elas assumem que as variáveis do problema são condicionalmente independentes (mesmo que na prática elas não sejam, o que explica o nome *ingênuas*).

A Figura 3 mostra um exemplo de uma NB comum. Ela possui uma variável *Classe* que depende de um série de outras varáveis $x_1, x_2, x_3, \dots, x_n$ (que serão chamadas a partir daqui de features). É importante notar que a estrutura da rede mostra que as features são condicionalmente independentes umas das outras e a *Classe* depende de cada uma das features individualmente. É fácil entender a grande vantagem desta abordagem. Cada tabela de probabilidades condicionais será pequena. Além disso a inferência da variável classe, dadas algumas das features será bem simples, como será mostrado nas próximas seções.

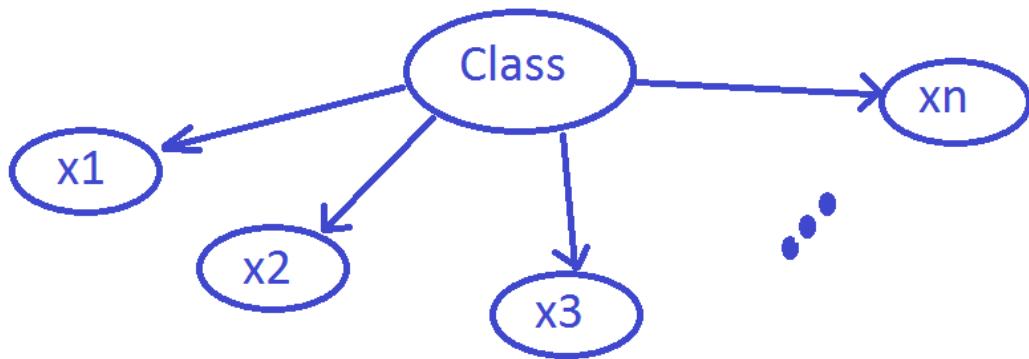


Figura 3: Exemplo de uma Naïve Bayes

Na prática o NB é um ótimo classificador de textos, pois, além de ser simples, traz resultados comparáveis a outros classificadores substancialmente mais complexos e lentos.

3.3.3.3 Independência Condicional

Antes de explicar a inferência em NB é importante entender o que significa o conceito de independência condicional.

Dados dois eventos A e B , dizemos que eles são independentes se a probabilidade de ocorrência de um deles não é influenciada pelo fato do outro ter ocorrido. Ou seja:

$$P(A|B) = P(A) \quad P(B|A) = P(B)$$

Esta propriedade é muito relevante na simplificação de expressões pois podemos usar o fato de que a probabilidade conjunta é igual ao produto das probabilidades individuais.

$$P(A, B) = P(A)P(B|A) = P(A)P(B)$$

3.3.3.4 Inferência

A regra de Bayes seguida pela propriedade de independência condicional pode ser utilizada para a realização de inferência em NB da seguinte forma.

Sejam $C = \{c_1, c_2, c_3, \dots, c_J\}$ um conjunto de classes e $x_1, x_2, x_3, \dots, x_n$ as features a serem analisadas. Como trata-se de NB, assume-se independência condicional das features. Deseja-se saber para cada i :

$$P(C = c_i|x_1, x_2, \dots, x_n)$$

Ou seja, deseja-se saber qual a probabilidade da classe possuir o valor c_i , dadas as features observadas.

Pela regra de Bayes temos:

$$P(C = c_i|x_1, x_2, \dots, x_n) = \frac{P(x_1, x_2, \dots, x_n|C = c_i)P(C = c_i)}{P(x_1, x_2, \dots, x_n)} \quad (3.1)$$

Como $x_1, x_2, x_3, \dots, x_n$ são condicionalmente independentes entre si, temos:

$$\begin{aligned}
P(x_1, x_2, \dots, x_n | C = c_i) &= P(x_1, x_2, \dots, x_{n-1} | x_n, C = c_i) P(x_n | C = c_i) \\
&= P(x_1, x_2, \dots, x_{n-1} | C = c_i) P(x_n | C = c_i) \\
&= P(x_1, x_2, \dots, x_{n-2} | x_{n-1}, C = c_i) P(x_{n-1} | C = c_i) P(x_n | C = c_i) \\
&= P(x_1, x_2, \dots, x_{n-2} | C = c_i) P(x_{n-1} | C = c_i) P(x_n | C = c_i) \\
&= \dots = P(x_1 | C = c_i) P(x_2 | C = c_i) P(x_3 | C = c_i) \dots P(x_n | C = c_i) \\
&= \prod_{j=1}^n P(x_j | C = c_i)
\end{aligned} \tag{3.2}$$

Substituindo 3.2 em 3.1 temos:

$$P(C = c_i | x_1, x_2, \dots, x_n) = \frac{P(C = c_i)(\prod_{j=1}^n P(x_j | C = c_i))}{P(x_1, x_2, \dots, x_n)} \tag{3.3}$$

3.3.3.5 Classificação utilizando Naïve Bayes

No problema de classificação temos um documento d que será representado pelas features x_1, x_2, \dots, x_n e deseja-se saber de qual classe $c \in C$ este documento pertence.

Matematicamente, deseja-se saber de qual classe é mais provável que o documento pertença. Isto é, a classe que maximiza $P(d|c)$.

$$\gamma(d) = \operatorname{argmax}_c(P(d|c)) = \operatorname{argmax}_c(P(x_1, x_2, \dots, x_n | c))$$

Pela equação 3.3, temos que:

$$\operatorname{argmax}_c(P(x_1, x_2, \dots, x_n | c)) = \operatorname{argmax}_c\left(\frac{P(C=c_i)(\prod_{j=1}^n P(x_j | C=c_i))}{P(x_1, x_2, \dots, x_n)}\right)$$

Como $P(x_1, x_2, \dots, x_n)$ não depende de c , pode-se cortá-lo do denominador, chegando em:

$$\gamma(d) = \operatorname{argmax}_c(P(C = c_i)(\prod_{j=1}^n P(x_j | C = c_i)))$$

Agora, para descobrir a classe do documento, basta calcular $P(C = c_i)$ e $P(x_k | C = c_i)$ e ambas estas probabilidades são fáceis de serem estimadas (se tivermos um conjunto de treino suficientemente grande).

Assumindo que as features sejam binárias, isto é, ou estão presentes no docu-

mento, ou não estão. Seja $\#(x)$ um operador que indica quantas vezes a feature x aparece no conjunto de treinamento e $\#(c)$ quantos documentos do conjunto de treinamento possuem a classe c . Além disso, seja $\#(x \wedge c)$ a quantidade de vezes que a feature x aparece num documento de classe c e seja N o total de documentos do conjunto de treinamento. É fácil ver que:

$$P(C = c_i) \simeq \frac{\#(c_i)}{N}$$

e

$$P(x_j | C = c_i) \simeq \frac{\#(x_j \wedge c_i)}{\#(c_i)}$$

Ou seja, o problema de classificação se tornou basicamente um problema de contagem.

3.3.3.6 Smoothing

Um dos problemas práticos encontrados por NB é a ocorrência de contagens nulas. O grande problema do 0 é que se ele for apenas um dos fatores da multiplicação o resultado inteiro será 0, inutilizando o método.

Isto não é algo incomum, principalmente se o conjunto de treinamento for pequeno. Basta ter uma palavra no conjunto de teste que nunca ocorreu em uma determinada classe no conjunto de treinamento.

Existem técnicas que são utilizadas para resolver este problema e elas são chamadas de Smoothing. Neste trabalho utilizou-se uma das mais comuns: o Laplace Smoothing.

O Laplace consiste em assumir que todas as features foram vistas pelo menos α vezes em cada uma das classes. Isso se traduz nas seguintes formulas, sendo L o número total de classes e V o numero total de features.

$$P(C = c_i) \simeq \frac{\#(c_i) + \alpha}{N + \alpha L}$$

e

$$P(x_j | C = c_i) \simeq \frac{\#(x_j \wedge c_i) + \alpha}{\#(c_i) + \alpha V}$$

No caso especial em que $\alpha = 1$, tem-se o *Add-One Smoothing*.

3.3.4 Modelagens para classificação de texto

Uma vez que já foi entendida a forma de classificar o texto, resta apenas representá-lo por um conjunto de features.

3.3.4.1 Naïve Bayes Binária

Uma forma comum de representar um texto em features é considerá-lo como um conjunto de palavras. Assume-se que cada palavra é uma feature que pode estar presente ou não no documento. Nesta representação a ordem das palavras não é importante.

Esta representação não leva em consideração a frequência com a qual cada palavra aparece no texto. A fórmula para calcular a classe mais provável é aquela que foi desenvolvida acima.

3.3.4.2 Naïve Bayes de Bernoulli

3.3.4.3 Multinomial Naïve Bayes

É interessante levar em consideração a frequência da ocorrência das palavras uma vez que esta pode trazer informação relevante sobre a classe.

3.3.4.4 Outras features

É possível enriquecer o classificador utilizando outras features (que não sejam as próprias palavras do texto). Exemplos de features que podem ser utilizadas são: combinações de palavras, o tamanho do texto, quantidade de sinais de pontuação, quantidade de palavras com iniciais maiúsculas, etc.

Para o caso específico de postagens em redes sociais existem ainda outras features que podem ser incluídas. Pode-se considerar o autor da postagem, o momento em que ela foi publicada, a presença de fotos, vídeos ou links, etc.

3.4 Weighted Naïve Bayes

Um dos problemas das NB é que muitas vezes nas aplicações reais não é possível assumir a independência condicional das features. Muitas vezes uma das

features tem um peso maior que as outras, por exemplo.

Um modo inicial de relaxar essa hipótese de independência, é eliminar features com alta correlação, fazendo com que o subconjunto restante se encaixe melhor na hipótese de independência condicional. Isto é chamado de seleção de features.

Neste caso temos:

$$\gamma(d) = \operatorname{argmax}_c(P(C = c_i)(\prod_{j=1}^n P(x_j|C = c_i)^{I(j)})$$

Onde:

$$I(j) \in \{0, 1\}$$

Uma abordagem mais genérica é ponderar cada feature de acordo com sua relevância. Ou seja:

$$\gamma(d) = \operatorname{argmax}_c(P(C = c_i)(\prod_{j=1}^n P(x_j|C = c_i)^{w(j)})$$

Onde:

$$w(j) \in \mathbb{R}^+$$

Nota-se que a seleção de features é um caso específico da ponderação de features (onde $w(j)$ só pode ser 0 ou 1).

Agora o grande problema passa a ser determinar os pesos $w(j)$ das features. Há diversos algoritmos que já foram propostos para realizar esta tarefa.

Neste trabalho, estudou-se a utilização de um método baseado na Teoria da Informação, que além de ser comum na literatura, possui fundamentos teóricos bem embasados (21).

3.5 Métodos de avaliação de um classificador

Uma vez desenvolvido o classificador é importante ser capaz de avaliá-lo a fim de determinar o quanto bom ele é. A utilização de métricas numéricas para avaliar os classificadores é interessante pois permite a realização de comparações entre as diferentes versões implementadas, tornando possível determinar se as modificações que foram feitas estão fazendo efeito.

Existem diversas métricas que podem ser utilizadas para avaliar classificadores, algumas delas serão analisadas nesta seção (37).

3.5.1 Classificador Binário

Primeiro serão explorados os métodos de avaliação da performance do classificador binário, que é o classificador mais simples.

A tabela 1 resume as diferentes medidas que podem ser utilizadas, onde tp é o verdadeiro positivo, tn é o verdadeiro negativo, fp é o falso positivo e fn é o falso negativo.

Medida	Fórmula	Intuição
Acurácia	$\frac{tp+tn}{tp+fn+fp+tn}$	Eficácia global do classificador
Precisão	$\frac{tp}{tp+fp}$	Quantos dos objetos classificados como positivo são efetivamente positivos
Abrangência	$\frac{tp}{tp+fn}$	Quantos dos objetos positivos foram classificados como positivos
Fscore	$\frac{(\beta^2+1)tp}{(\beta^2+1)tp+\beta^2fn+fp}$	Uma média harmônica entre a precisão e a abrangência

Tabela 1: Resumo das medidas de performance para classificadores binários

3.5.1.1 Acurácia

A acurácia mede a quantidade total de acertos (verdadeiro positivos ou verdadeiro negativos) em relação à quantidade total de objetos classificados.

$$acuracia = \frac{tp+tn}{tp+fn+fp+tn}$$

Esta é a medida de performance mais fácil de se entender, entretanto ela não é muito informativa, uma vez que dependendo da distribuição das classes, classificadores ruins podem ter alta acurácia.

Suponha, por exemplo, um classificador que classifica tumores em benignos ou malignos. Suponha também que 99.9% dos tumores sejam benignos. É possível criar um classificador que sempre responde que o tumor é benigno e ele teria uma acurácia de 99.9% (aparentemente muito boa). Entretanto este classificador falha miseravelmente na sua tarefa principal (que é determinar quais tumores são malignos para que as devidas providências sejam tomadas).

3.5.1.2 Precisão

A precisão é uma estatística que indica quantos dos objetos classificados como positivo são efetivamente positivos. Quando um classificador com alto precisão classifica um objeto como positivo, é muito provável que ele seja positivo (entretanto nada se sabe sobre quantos objetos positivos ele esta classificando como negativo).

$$precisao = \frac{tp}{tp+fp}$$

Um classificador que indica para uma pessoa se ela deve investir ou não em uma determinada ação deve ser muito preciso. Pois para o investidor o importante é que quando ele siga o conselho do classificador e invista, ele não perca dinheiro. Não importa tanto se havia várias outras ações que eram boas, mas que o classificador desprezou.

3.5.1.3 Abrangência (Recall)

A abrangência de um classificador indica quantos dos objetos positivos são efetivamente classificados como positivos. Um classificador com grande abrangência provavelmente irá detectar a maior parte dos objetos positivos (apesar de também poder detectar alguns negativos como sendo positivos).

$$abrangencia = \frac{tp}{tp+fn}$$

Um médico que classifica pintas na pele das pessoas entre malignas ou benignas (câncer de pele ou não) deve ter uma grande abrangência (sendo a classificação 'maligno' a classe positiva do classificador), mas a precisão não é tão importante. Isso ocorre pois se o médico deixar de classificar alguma pinta que era maligna como maligna, o paciente pode acabar evoluindo a doença e morrer (ou seja, todos que são efetivamente malignos devem ser classificados como malignos). A precisão não é tão importante pois se por ventura o médico classificar uma pinta benigna como maligna, o paciente vai remover a mesma e na biópsia será possível identificar que não era nada demais (o paciente só terá que passar inutilmente pelo procedimento cirúrgico de remoção de pintas, mas isso não é muito problemático).

Existe, normalmente uma relação inversa entre a precisão e a abrangência. Em geral quanto se aumenta a precisão se reduz a abrangência e vice-versa. Pode-se exemplificar isto com o mesmo caso do médico que classifica pintas. Quando ele

fica com dúvida se a pinta é benigna ou maligna, ele pode dizer que ela é maligna e pedir a remoção ou dizer que ela é benigna. Se na dúvida ele sempre disser que a pinta é maligna, ele estará aumentando a abrangência, mas diminuindo a precisão (pois haverá mais verdadeiros positivos e mais falso positivos). No limite, dizer que todas pintas são malignas dá abrangência máxima (100%). Se ele sempre disser que a pinta duvidosa é benigna, ele aumentará a precisão, mas diminuirá a abrangência (pois haverá mais falso negativos e menos falso positivos).

3.5.1.4 Fscore

Como pode ser visto, a abrangência e a precisão possuem comportamentos antagônicos. Normalmente é importante que o classificador tenha tanto uma precisão aceitável quanto uma abrangência razoável. Então combinou-se a abrangência e a precisão em um único número, chamado de Fscore.

O caso mais simples do Fscore (chamado de F1score) é uma média harmônica entre a precisão e a abrangência.

$$F_1 = \frac{2}{\frac{1}{precisao} + \frac{1}{abrangencia}}$$

Ou seja:

$$F_1 = \frac{2 \cdot precisao \cdot abrangencia}{precisao + abrangencia}$$

Isto pode ser simplificado para:

$$F_1 = \frac{2tp}{2tp + fn + fp}$$

É interessante notar que se a precisão ou se a abrangência forem bem pequenas, o F1score será bem pequeno. Se ambas forem grandes, o F1score será algum valor entre as duas.

Como dependendo da aplicação, a precisão ou a abrangência podem ser mais importantes, há uma formulação genérica para o Fscore que utiliza o parâmetro β para determinar qual das duas métricas é mais importante.

$$F_\beta = \frac{(1+\beta^2) \cdot precisao \cdot abrangencia}{\beta^2 \cdot precisao + abrangencia}$$

É fácil provar que:

$$F_\beta = \frac{(\beta^2+1)tp}{(\beta^2+1)tp + \beta^2fn + fp}$$

Os dois valores de β mais comuns são 0.5 e 2. Nota-se que para β maior que

α a abrangência é considerada mais importante. Para β menor que 1 a precisão é considerada mais importante.

3.5.2 Classificador *Multi-Class*

As mesmas métricas definidas acima podem ser aplicadas para problemas *multi-class*, entretanto alguns problemas surgem. Por exemplo, as métricas seriam calculadas individualmente para cada classe (gerando vários números), o que tornaria a avaliação do classificador um processo complicado (vários números são mais difíceis de serem analisados do que apenas um único).

A tabela ?? resume as diferentes medidas utilizadas na avaliação de performance de um classificador *multi-class*.

3.5.2.1 Matriz de Confusão (*Confusion Matrix*)

Para facilitar a análise de problemas *multi-class*, criou-se a matriz de confusão. Ela consiste em uma matriz de números na qual as linhas representam as classificações realizadas pelo classificador e as colunas representam as classes originais das quais os objetos pertencem. A célula a_{ij} da matriz possui um número que indica quantas vezes o classificador classificou objetos de tipo j como i.

É fácil de notar que uma matriz de confusão de um classificador perfeito possui vários números positivos na diagonal principal e zero em todas as outras células. Nota-se que qualquer numero maior que zero em uma célula que não pertence a diagonal principal representa um erro. Com a matriz de confusão fica fácil de visualizar os erros mais comuns feitos pelo classificador.

A Figura 4 mostra uma matriz de confusão de um classificador que deve classificar expressões faciais.

A partir da matriz de confusão é fácil de determinar a precisão e a abrangência para cada classe i, conforme segue:

$$\text{precisao}(i) = \frac{a_{ii}}{\sum_{j=1}^L a_{ij}}$$

$$\text{abrangencia}(i) = \frac{a_{ii}}{\sum_{j=1}^L a_{ji}}$$

Ou seja, a precisão é um dos elementos da diagonal principal dividido pela soma de sua linha, enquanto que a abrangência é um dos elementos da diagonal principal

	Angry	bored	disgusted	Afraid	blissful	sad	neutral
angry	80.31	0.79	3.15	3.94	8.66	0	3.15
bored	0	66.67	6.17	2.47	0	7.41	17.28
disgusted	3.15	17.39	52.17	4.35	4.35	10.87	2.17
afraid	10.24	4.35	5.80	40.58	4.35	10.14	15.94
blissful	18.11	0	4.23	5.63	52.11	0	5.63
sad	0	11.29	0	1.61	0	82.26	4.85
neutral	2.36	17.71	5.06	7.59	0	2.53	63.29

Figura 4: Exemplo de Matriz de Confusão para um classificador retirado de (6)

dividido pela sua coluna.

Apesar de ter números específicos é muito bom pra analisar o quanto bom um classificador é, é sempre importante observar a Matriz de Confusão pra detectar possíveis problemas e os lugares onde há erros mais comuns.

3.5.2.2 Médias micro e macro (*Micro and Macro Averaging*)

Conforme o descrito, pode-se calcular a precisão, a abrangência, o Fscore e a acurácia para cada classe individualmente. Entretanto seria interessante juntar todos estes dados em um único número. Para tal, faz-se uma média. Existem duas formas de realizar esta média, que são chamadas de micro e macro.

A média micro consiste em somar os numeradores e denominadores das fórmulas das métricas supracitadas separadamente (na prática isto é equivalente a realizar uma média ponderada nos denominadores). Seguem as fórmulas de precisão, abrangência e acurácia micro.

$$precisao_{\mu} = \frac{\sum_{i=1}^L tp_i}{\sum_{i=1}^L tp_i + fp_i}$$

$$abrangencia_{\mu} = \frac{\sum_{i=1}^L tp_i}{\sum_{i=1}^L tp_i + fn_i}$$

Com uma matemática simples da pra concluir que a precisão micro é numericamente igual à abrangência micro (basta notar que o numerador dos dois é igual

e o numerador dos dois representa a soma de todos os elementos da matriz de confusão, um através da soma das linhas e o outro através da soma das colunas).

A média macro consiste em somar os valores finais das métricas calculadas em cada classe e dividir pelo total de classes (uma média aritmética simples). Seguem as fórmulas de precisão e abrangência macro.

$$\text{precisao}_M = \frac{\sum_{i=1}^L \frac{tp_i}{tp_i + fp_i}}{L}$$

$$\text{abrangencia}_M = \frac{\sum_{i=1}^L \frac{tp_i}{tp_i + fn_i}}{L}$$

A intuição por trás dessas duas médias é que a média macro dá igual importância para todas as classes, enquanto que a média micro da mais importância para as classes mais comuns (no caso da abrangência) ou para as classes com mais objetos classificados nelas (no caso da precisão).

3.5.2.3 Fscore

Da mesma forma que foi definido o Fscore para o caso do classificador binário, é possível definir um Fscore macro e um Fscore micro (dependendo da utilização da precisão e abrangência macro ou micro).

$$F_{\beta\mu} = \frac{(1+\beta^2) \cdot \text{precisao}_{\mu} \cdot \text{abrangencia}_{\mu}}{\beta^2 \text{precisao}_{\mu} + \text{abrangencia}_{\mu}}$$

$$F_{\beta M} = \frac{(1+\beta^2) \cdot \text{precisao}_M \cdot \text{abrangencia}_M}{\beta^2 \text{precisao}_M + \text{abrangencia}_M}$$

Uma observação interessante é que, como a precisão micro e a abrangência micro são numericamente iguais, temos que o Fscore micro também terá este mesmo valor (independentemente de β). Para a média macro isto não acontece.

3.5.2.4 Acurácia

É possível encontrar na literatura duas definições diferentes de acurácia (8) (37).

Em uma das definições, a acurácia de um classificador *multi-class* é a média aritmética (média macro) das acurácias individuais de cada classe.

$$\text{accuracy} = \frac{\sum_{i=1}^L \frac{tp_i + tn_i}{tp_i + fn_i + fp_i + tn_i}}{L}$$

Na outra definição, a acurácia é a quantidade total de acertos (considerando todas as classes), dividida pela quantidade total de documentos.

$$\text{accuracy} = \frac{\sum_{i=1}^L tp_i}{N} \quad (3.4)$$

Considerando a matriz de confusão, temos que:

$$\text{accuracy} = \frac{\sum_{i=1}^L a_{ii}}{\sum_{i=1}^L \sum_{j=1}^L a_{ij}} = \frac{\sum_{i=1}^L a_{ii}}{N}$$

Neste trabalho será utilizada esta última definição por ser mais intuitiva e dar mais informação sobre a qualidade do classificador (observe que a primeira definição de acurácia tende a sempre resultar em valores altos para problemas com muitas classes, uma vez que a quantidade de verdadeiros negativos tende a ser alta para todas as classes).

Observa-se que a acurácia também é numericamente igual à abrangência e à precisão com média micro.

3.5.2.5 Medida Kappa

Como já foi discutido previamente, a acurácia é uma medida muito ruim pois é possível desenvolver classificadores com comportamento trivial que possuem uma boa acurácia. Para resolver este problema, utilizam-se outras estatísticas em vez da acurácia que possuem mais valor semântico e dão mais informações sobre a performance do classificador. Já foram explicadas outras medidas que possuem mais informações (abrangência, precisão e Fscore micros e macros) e a matriz de confusão que permite a visualização de problemas recorrentes no classificador. Entretanto, para o problema *multi-class* é comum utilizar uma outra métrica (chamada de Kappa) para avaliar a performance do classificador em questão.

A estatística Kappa é utilizada para comparar a Acurácia Observada com a Acurácia Esperada. Esta estatística é muito poderosa e permite a realização de comparações até mesmo entre classificadores diferentes (27). Ela utiliza a comparação em relação a um classificador aleatório de modo a tornar esta estatística mais confiável que uma simples acurácia.

A Acurácia Observada é a mesma acurácia que já foi definida previamente na equação 3.4. Ela representa a quantidade de objetos classificados corretamente em relação ao total.

Define-se como Acurácia Observada, a porcentagem esperada de acertos que um classificador aleatório teria se ele classificar os objetos com a mesma proporção

entre as classes que o classificador original.

Para se deduzir a fórmula da Acurácia Esperada primeiro calcula-se a quantidade de vezes que o classificador original escolheu a classe c_i . É fácil de ver que ele escolheu esta classe $tp_i + fp_i$ vezes. O valor esperado do número de acertos de um classificador aleatório que escolha a dada classe $tp_i + fp_i$ vezes é:

$$E[c_i] = (tp_i + fp_i) \frac{tp_i + fn_i}{N}$$

Isto ocorre pois $\frac{tp_i + fn_i}{N}$ é a probabilidade de que um objeto aleatório pertença à classe i . A quantidade esperada para o número de acertos em todas as classes é de:

$$E[c_1, c_2, \dots, c_L] = \sum_{i=1}^L (tp_i + fp_i) \frac{tp_i + fn_i}{N}$$

Como a Acurácia Esperada é a porcentagem de acertos desse classificador aleatório tem-se:

$$\text{acuracia_esperada} = \frac{E[c_1, c_2, \dots, c_L]}{N} = \frac{\sum_{i=1}^L (tp_i + fp_i)(tp_i + fn_i)}{N^2}$$

Em termos da matriz de confusão, a acurácia esperada é a somatória dos produtos entre cada linha com a sua respectiva coluna (linha 1 com coluna 1, linha 2 com coluna 2 e assim por diante) dividida pela quantidade total de elementos ao quadrado.

A definição de Acurácia Esperada é importante pois um classificador de Acurácia Observada 80% é muito mais impressionante se a Acurácia Esperada for de 1% do que se ela for 79%.

A estatística $Kappa$ indica a porcentagem de melhoria que o classificador tem em relação à Acurácia Esperada (41). Um classificador com Acurácia Observada idêntica à Acurácia Esperada possui $Kappa = 0$, enquanto que um classificador com Acurácia Observada de 100% possui $Kappa = 1$. Valores intermediários do $Kappa$ indicam a melhoria do classificador em relação ao aleatório. Desta forma, a fórmula para o $Kappa$ é:

$$Kappa = \frac{\text{acuracia_observada} - \text{acuracia_esperada}}{1 - \text{acuracia_esperada}}$$

4 **Metodologia**

4.1 **Plano de desenvolvimento**

Dividiu-se o desenvolvimento do projeto em diversas etapas.

4.1.1 **Estudo basico sobre Processamento de Linguagem Natural**

Inicialmente realizou-se um estudo aprofundado sobre o assunto do projeto para aproveitar o conhecimento já desenvolvido ao longo dos anos pela comunidade científica e garantir que as melhores tecnologias e técnicas fossem adotadas. O plano de estudos adotado foi:

- (a) Expressões regulares
- (b) Processamento de texto
- (c) Normalização
- (d) Tokenização das strings
- (e) Modelagem linguística e simplificação de N-gramas
- (f) Classificação de texto
- (g) Naïve Bayes
- (h) Métricas de performance (Precisão, Abrangência, Acurácia, etc)
- (i) Melhorias para Naïve Bayes

4.1.2 Coleta de dados

Como trata-se de um projeto de Inteligência Artificial, é essencial que se obtenha uma base de dados grande o suficiente para que o sistema desenvolvido seja capaz de realizar as generalizações necessárias para um bom funcionamento sem que haja overfit.

Esta base de dados consiste em um conjunto de postagens (variável X) e o assunto da mesma (variável Y).

Foram propostas duas formas possíveis de aquisição de dados.

- Uma delas foi desenvolver um plugin que colete as postagens e pergunte o assunto para o usuário. A utilização deste plugin por várias pessoas permitiu a aquisição de uma base de dados considerável.
- Paralelamente desenvolveram-se crawlers para vasculhar sites que contenham artigos e textos sobre cada assunto que se deseja classificar. É importante ter a capacidade de classificar artigos de sites genéricos, pois muitas das postagens em rede social possuem links para tais sites.

4.1.3 Pré-processamento dos textos e normalização

Como trata-se de linguagem natural e ainda por cima coloquial, para atingir um bom resultado com o classificador é essencial que haja um bom pré-processamento do texto corrigindo palavras erradas, frases mal-construídas, normalizando termos parecidos, etc.

4.1.4 Criação dos classificadores de Redes Bayesianas

Foram criados classificadores de NB e suas performances foram avaliadas contra um conjunto de validação. Os métodos mais efetivos foram selecionados, combinando os classificadores de postagens e de artigos e ajustando seus parâmetros para obter um bom resultado final.

4.1.5 Estudo dos resultados obtidos no conjunto de validação para diferentes features e parâmetros

Foi realizado um estudo detalhado dos resultados obtidos pelos classificadores para diferentes features, parâmetros e técnicas de classificação (NB e NB com pesos). A avaliação final da rede foi realizada em um conjunto de teste separado.

4.1.6 Definição da arquitetura do classificador e sua implementação

Definiu-se onde a rede seria treinada e armazenada (nas máquinas cliente vs em um servidor centralizado). Considerou-se também a possibilidade da rede ser dinâmica (ou seja, se a interação com o usuário fazer com que a rede aprenda online com as novas informações).

4.1.7 Desenvolvimento do plugin

Por fim desenvolveu-se o plugin para o Google Chrome, com uma interface gráfica amigável para o usuário para que ele entenda de forma fácil como filtrar as postagens em seu feed de notícias.

4.1.8 Testes de usabilidade

Por fim foram realizados testes de usabilidade com colegas de turma baseados nas heurísticas de Nielsen.

4.2 Aquisição de dados

Como já foi dito, foram desenvolvidas duas formas diferente de realizar a aquisição de dados. Uma delas consiste numa extensão para o Google Chrome que possibilita o usuário classificar cada postagens à qual ele se depara no Facebook, enviando os dados e a classificação da mesma para o banco de dados. A outra forma de aquisição de dados é o desenvolvimento de um crawler que faz o download diversos artigos online.

4.2.1 Plugin de classificação de postagens

4.2.1.1 Funcionamento de extensões do Chrome

Extensões são softwares que melhoram as funcionalidades de um navegador. O Google Chrome disponibiliza um Framework de desenvolvimento de extensões com muitas capacidades (15).

A extensão consiste em um conjuntos de arquivos zipados que incluem HTML, Javascript, CSS, imagens, etc. O Javascript de uma extensão pode ser dividido em 3 partes diferentes: código de extensão (*extension code*), scripts de conteúdo (*content scripts*) e scripts injetados (*injected scripts*). Estes três modos foram descritos abaixo.

- **Código de extensão:** Trata-se do código injetado diretamente no browser, tendo portanto acesso a todas as funcionalidades da API do Chrome, como tabs de background, pop-ups do navegador (aqueles pequenos ícones das extensões que ficam no canto superior direito do chrome), etc.
- **Scripts de conteúdo:** Trata-se de um código que é executado quando uma determinada página é carregada pelo usuário. Este script possui um escopo entre o do código de extensão e o do script injetado. Os scripts de conteúdo têm acesso à algumas das funcionalidades da API do Chrome e ao mesmo tempo pode acessar e modificar o DOM da página. Por estar em um escopo diferente ao escopo do javascript da própria página ele não tem acesso às funções e objetos definidos no mesmo. Por outro lado, ele não possui diversas das restrições de segurança que scripts injetados possuem. O script de conteúdo pode, por exemplo, executar cross-origin requests (ou seja, acessar servidores de outra origem).
- **Scripts injetados:** Scripts injetados são, como o nome diz, pedaços de código javascript que são injetados numa determinada página, executando em seu escopo. Desta forma eles tem acesso à todas as funções e variáveis definidas pelo javascript original da página. Também podem modificar como eles quiserem estas variáveis e o próprio DOM.

No caso da aplicação deste trabalho, é necessário ser capaz de mandar os dados das postagens com suas classificações para um servidor central (que obviamente

não é do próprio Facebook), logo scripts injetados não são uma boa solução (uma vez que o javascript do Facebook impede a execução de cross-origin requests). Ou seja, a extensão foi desenvolvida predominantemente com scripts de conteúdo.

Uma observação importante é que scripts de conteúdo ainda possuem algumas restrições de segurança ao fazer requests para outros domínios. Se o site principal for https, o script de conteúdo só poderá realizar requests para outros servidores por https também. Para tal, o servidor desenvolvido neste trabalho deve ser capaz de responder requests https.

4.2.1.2 Manifesto da extensão

As extensões do Chrome possuem um arquivo de configuração chamado de manifesto. Este arquivo encontra-se no formato de JSON.

Listagem 4.1: Manifesto da extensão do Chrome para coleta de dados

```

1  {
2      "manifest_version": 2,
3      "name": "Demeter",
4      "version": "1.0.0",
5      "description": "Collect data from facebook to use in NLP studies.
6          This plugin has academic purposes.",
7
8      "icons": {
9          "128" : "icon_128.png",
10         "180" : "icon_180.png"
11     },
12
13     "content_scripts": [
14         "matches": [ "https://*.facebook.com/*" ],
15         "js": [
16             "jquery-1.11.3.min.js",
17             "poo_utilities.js",
18             "facebook_tree.js",
19             "demeter_dom.js",
20             "story_classification.js",
21             "contentscript.js"
22         ]
23     }
24 }
```

```

21   ],
22   "css": [ "demeter.css" ]
23 },
24
25 "permissions": [ "tabs", "https://*.facebook.com/*", "https://
26   demeter-1075.appspot.com/*" ],
27
28 "web_accessible_resources": [
29   "contentscript.js",
30   "jquery-1.11.3.min.js",
31   "poo_utilities.js",
32   "facebook_tree.js",
33   "story_classification.js",
34   "demeter_dom.js",
35   "demeter.css",
36   "three-dots.png"
37 ]

```

O código 4.1 ilustra o manifesto da extensão desenvolvida. Ele identifica o nome da extensão (Demeter), a sua versão, os ícones utilizados, os scripts de conteúdo e as permissões (acessar o facebook e o servidor desenvolvido).

Note que além dos códigos desenvolvidos, utilizou-se a biblioteca do JQuery para facilitar a manipulação do DOM.

4.2.1.3 Estrutura do DOM do Facebook

Para injetar um pedaço de HTML no meio do Feed de notícias do Facebook, é importante entender a sua estrutura, básica.

Este projeto foi feito assumindo que o Facebook não iria realizar grandes mudanças em seu design e em sua estrutura básica de HTML em um curto prazo. Caso houvesse tal modificação, a extensão desenvolvida iria parar de funcionar, sendo necessário realizar algumas adaptações para que ela fosse consertada. Todo código foi desenvolvido de forma modularizada de modo a tentar diminuir as dificuldades de adaptação caso este evento infeliz ocorresse. Todavia, desde o

começo até o final do desenvolvimento do projeto isto não aconteceu.

O HTML do Facebook passa por um processo de ofuscação e compressão antes de ser enviado para as máquinas cliente. Essa ofuscação troca as classes e ids dos elementos por nomes aleatórios e curtos. Então um elemento HTML que originalmente tinha uma classe ‘facebook_feed’, por exemplo, passará a ter a classe ‘_u_s8v4’. Este processo atrapalha um pouco no desenvolvimento de uma extensão que se acople ao site do Facebook (pois esses ids e classes são aleatórios e podem mudar). Entretanto, por algum motivo (provavelmente se trata de um código antigo), algumas classes e ids continuam com nomes legíveis. Considerou-se que estes nomes legíveis são mais estáveis e portanto, baseou-se a extensão desenvolvida em elementos HTML que possuíam estes nomes.

```

▼ <div class="4-u2 mbm _5v3q _4-u8" id="u_jsonp_2_2">
  ▼ <div class="_3ccb" data-gt='{"type": "click2canvas", "fbsource": 703, "ref": "nf_generic"}' id="u_jsonp_2_3">
    <div></div>
    ▼ <div class="userContentWrapper _5pcr" role="article" aria-label="Story">
      ▶ <div class="_1dwg">...</div>
      ▶ <div>...</div>
      </div>
    </div>
  </div>
</div>

```

Figura 5: Exemplo de HTML do Facebook, com algumas classes aleatórias e algumas de nome legível

A Figura 5 ilustra o que foi explicado no parágrafo anterior. Algumas das classes são strings aleatórias('_5pcr', '_3ccb', '_1dwg', etc), enquanto que algumas possuem valores legíveis ('userContentWrapper').

Observando estes elementos nomeados, chegou-se à seguinte estrutura simplificada para o DOM do Facebook. Todo o conteúdo do site, exceto a barra azul superior e o chat que fica ao lado direito, se encontra dentro de um div chamado de mainContainer. Dentro deste mainContainer há um div chamado de feed_stream, que possui todas as postagens do feed de notícias. O feed_stream contém um ou mais substreams. Cada substream é um conjunto de postagens. Quando o usuário desce a página até a parte inferior, um novo substream é criado com as novas postagens. Cada substream possui uma ou mais postagens que são representadas por divs chamados de userContentWrapper. É possível que userContentWrapper's contenham outros userContentWrapper's (por exemplo quando uma pessoa compartilha a postagem de outra pessoa). A Figura 6 mostra um exemplo de uma árvore de DOM simplificada para o Facebook.

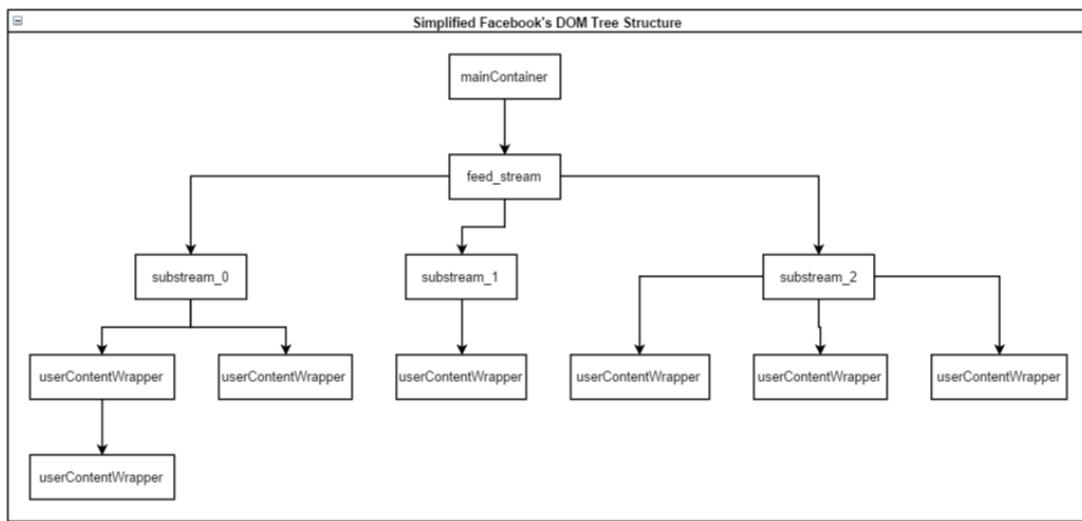


Figura 6: Exemplo ilustrativo da estrutura básica da árvore de DOM do Facebook

4.2.1.4 UI desenvolvida

A extensão desenvolvida utiliza a API de javascript JQuery para injetar um pedaço de HTML logo acima do userContentWrapper, de modo a colocar um cabeçalho no topo de cada postagem com as classes pré definidas. O usuário deverá agir como um supervisor para o classificador indicando qual o assunto da postagem em questão. A Figura 7 ilustra o cabeçalho em uma postagem.

Uma vez que o usuário clique na classe à qual a postagem pertence, o cabeçalho passa a conter apenas o nome da classe escolhida e uma barra opções a direita que pode ser expandida, conforme a Figura 8

A barra de opções possui duas possíveis ações: ‘Mudar Assunto’ ou ‘Adicionar Assunto’. Se o usuário clicar na primeira opção ele poderá escolher um novo assunto para a postagem. Se o usuário clicar na segunda opção ele poderá adicionar um novo assunto para a postagem (que então possuirá duas classes). A Figura 9 ilustra a barra de opções.

Observe que apesar de na hora de realizar a classificação foi feita a simplificação de que o problema se trata apenas de *multi-class* (não *multi-class / multi-label*), na hora da coleta de dados é possível classificar uma única postagem em vários assuntos diferentes. Isto foi feito primordialmente por dois motivos. Primeiramente, é interessante já possuir uma base de dados com postagens com classificações múltiplas para se poder estudar o classificador *multi-class / multi-label* em trabalhos futuros. Além disto, vários usuários diferentes podem classificar as postagens de

Assunto: Política / Economia Propaganda Filme Humor Celebridade
 Esporte Curiosidades Pessoal Turismo Ciencia / Tecnologia Minorias
 Educacao Noticias Bebes / Animais Medicina

Caio Dottori liked this.

 **Carol Valle via Não Salvo** [Add Friend](#)
 20 hrs · 

Em um relacionamento sério com o relatório de projeto



 [Share](#)

Caio Dottori and 19 others like this.

1 share

Figura 7: Exemplo em uma postagem do cabeçalho contendo as possíveis classes

forma distinta (não concordam entre si). Neste caso, o servidor guarda a contagem de classificações para cada classe e é considerado que a postagem pertence à classe mais frequente (empates são quebrados manualmente).

4.2.1.5 Servidor

Sempre que um usuário seleciona uma classe para uma determinada postagem, é realizada uma requisição POST para o servidor do Demeter (nome do projeto), contendo as informações relevantes. O servidor salva estas informações em um

Ciencia / Tecnologia

O Globo
6 hrs ·

Você perde o 3G mas não perde o rumo. <http://glo.bo/1PmlUrz>
#JornalOGlobo

Google Maps lança versão off-line

Foto: Google Maps
BLOGS.OGLOBO.GLOBO.COM | BY CARLOS ALBERTO TEIXEIRA

6.1k Likes 177 Comments 363 Shares

Like Comment Share

Figura 8: Exemplo da UI de uma postagem classificada pelo usuário banco de dados.

O banco de dados contem postagens indexadas por sua url (que é um valor único para cada postagem) e é associado a um conjunto de classes e frequências. Por exemplo, se um post foi classificado 5 vezes como Política e 2 como educação, essa informação ficará registrada no banco de dados.

É importante notar que não é apenas o texto da postagem que é salva no banco de dados. Também armazena-se o usuário que realizou criou a postagem, o momento em que ela foi publicada (timestamp), a presença de fotos ou vídeos, a existência de informações sobre o local de onde o usuário postou, etc. Essas informa-



Figura 9: Barra de opções para modificar a escolha do assunto na extensão do Chrome

ções podem ser relevantes na hora de se criar features para a NB.

4.2.1.6 Crawler

4.3 Processamento do texto

Um bom pré processamento do texto é essencial para um bom resultado de classificação. Isso é especificamente válido em um ambiente como uma rede social, onde muitas vezes há abreviações, interjeições, utilização de linguagem informal, etc.

O processamento realizado neste trabalho inclui as seguintes etapas:

- **Remover caracteres unicode:** Acentos, cedilhas, tremas e outros caracteres unicode são substituídos pelo equivalente em ASCII.
- **Remover letras maiúscula:** Todas as letras maiúsculas são mudadas para minúscula.
- **Remoção números:** Quando há um número no texto, seu valor exato não importa muito para o classificador. O que importa é a sua presença. O mesmo vale para datas, porcentagens, urls, valores de dinheiro e datas. No caso, os números são substituídos por '{number}', as datas por '{date}' e assim por diante.
- **Remover a pontuação:** Toda a pontuação é removida.

- **Encontrar risadas:** Todas as ocorrências de risadas (que puderam ser identificadas com algumas heurísticas simples) são substituídas por 'laughter'
- **Remover letras duplas:** Em redes sociais é muito comum o usuário repetir a mesma letras diversas vezes para enfatizar a palavra. Por exemplo: 'Que FOOOOOOOOOFO!'. Isto atrapalharia o classificador. Por isso letras repetidas são removidas. Note que, apesar de ser permitido no português 'r' e 's' duplos, removê-los não atrapalhará muito o classificador.
- **Filtrar palavras comuns e que não agregam muito valor ao classificador:** Palavras comuns do português como artigos, preposições, etc são desconsideradas.

4.4 Tecnologias utilizadas

5 *Proposta de Classificador*

6 *Validação - Experimentos, resultados e análise*

7 ***Conclusões e Trabalhos Futuros***

8 *Instrumentos analisados*

Todo programa de computador é, essencialmente, um algoritmo que transforma um sinal de entrada em um sinal de saída, portanto, entender os sinais de entrada é fundamental para o desenvolvimento e a depuração de qualquer programa de computador.

No desenvolvimento deste trabalho diversos limites terão de ser impostos aos sinais sonoros de entrada. Serão estabelecidos limites, por exemplo à quantidade máxima de notas tocadas por segundo, à nota mais grave e mais alta, à intensidade mínima para um som ser considerado uma nota, etc. Entretanto, dada a multíitude de instrumentos existentes, é virtualmente impossível estabelecer limites para os exemplos dados que satisfaçam aos sinais gerados por todos os instrumentos.

Assim, embora o escopo deste trabalho seja a transcrição musical automática de instrumentos monofônicos temperados, independentemente da forma com que o som é gerado neles, as análises feitas a partir deste capítulo serão voltadas a um sub-conjunto específico de instrumentos. Espera-se que este sub-conjunto seja representativo o bastante para que o algoritmo final desenvolvido seja também aplicável a diversos outros instrumentos. Este capítulo apresenta os instrumentos escolhidos e justifica as escolhas.

8.1 Características de interesse

Ao escolher os instrumentos, algumas características desejadas foram levantadas, essas são apresentadas a seguir:

8.1.1 Mecânismo de produção de som

Deseja-se que os instrumentos analisados possuam mecanismos de produção de som simples e para os quais já existam modelos matemáticos confiáveis. Isso tornará possível embasar as decisões tomadas em modelos matemáticos que representam o mundo real, e não apenas em suposições feitas com base em teoria musical.

8.1.2 Timbre

O timbre é, talvez, a característica mais marcante de um instrumento, e pode variar muito mesmo entre instrumentos de uma mesma família. Por esses motivos, deseja-se que os instrumentos analisados possuam timbres consideravelmente distintos. Isso ajudará a elaborar algoritmos que funcionem em uma gama diversa de instrumentos.

8.1.3 Tom

Em um único instrumento, uma mesma nota pode ser tocada de diversas formas, ou tons, dependendo da sensação que o músico deseja transmitir. Por exemplo, uma nota pode ser suave ou agressiva; viva ou fria. É interessante que os instrumentos escolhidos sejam capazes de gerar uma vasta gama de tons, também para que os algoritmos elaborados sejam pouco específicos aos instrumentos escolhidos.

8.1.4 Popularidade

Para que os algoritmos desenvolvidos possuam aplicações reais, é interessante que eles funcionem bem para instrumentos populares, portanto faz sentido escolher instrumentos que sejam conhecidos e bastante utilizados.

8.2 Instrumentos escolhidos

Com base nas características levantadas, a classe dos instrumentos de sopro foi escolhida. Além de populares, a produção de som por esses instrumentos já é um processo bem conhecido e que pode ser aproximado por modelos majoritariamente

lineares (13). Estes instrumentos também possuem timbres bastante característicos e distintos uns dos outros. Ainda, instrumentos como a flauta transversal permitem ao instrumentista realizar uma vasta gama de tonalidades dependendo de sua enbocadura, controle de respiração, etc.

Dentro da classe dos instrumentos de sopro, os seguintes instrumentos foram selecionados:

1. Flauta doce
2. *Tin whistle*
3. Pífano
4. Flauta transversal ocidental
5. Flauta transversal chinesa (*dizi*)
6. Ocarina

Cada instrumento será apresentado partindo de uma breve descrição histórica, seguida de características de interesse para o trabalho e de uma análise espectral de algumas notas tocadas no instrumento. Nota-se que o espectro gerado por cada instrumento pode variar de acordo com a habilidade do instrumentista e com as técnicas que ele deseja executar (12). Entretanto, consideramos que essas variações são desprezíveis quando comparadas às causadas pelo uso de instrumentos diferentes e, portanto, podem ser desconsideradas nesse capítulo, cujo propósito é apenas comparar o espectro de diferentes instrumentos e discutir os resultados esperados para cada um.

8.3 Flauta doce

A flauta doce é um instrumento de origem medieval, sua popularidade em apresentações diminuiu consideravelmente com o surgimento de instrumentos voltados para orquestras. Hoje, por ser um instrumento relativamente simples e fácil de se tocar, a flauta doce é amplamente utilizada no ensino de música.

Neste trabalho, será utilizada uma flauta doce soprano germânica afinada em dó maior (modelo Yamaha YRS-23Y). Este modelo possui oito buracos, é feito de

plástico e é amplamente utilizado por iniciantes. O termo "soprano" remete ao fato da nota mais grave produzida por esta flauta ser um C5, enquanto o termo "germânica" remete à forma com que os buracos na flauta devem ser utilizados para produzir notas específicas.

8.3.1 Características

A flauta doce utilizada é capaz de produzir 3 oitavas cromáticas¹ a partir do C5.

Uma característica que facilitará este trabalho é que a estrutura geométrica da flauta doce é totalmente controlada pelo fabricante (5). Seu bocal é feito de forma a direcionar o jato de ar produzido pelo flautista contra uma superfície afiada. Com isso, o flautista não precisa se preocupar em direcionar o jato de ar gerado, e tem que apenas controlar a pressão exercida. O bocal da flauta doce também é projetado para facilitar o controle da pressão exercida e, como resultado, o flautista é capaz de produzir duas oitavas com modificações mínimas no jato de ar que produz, e sem ter de modificar sua geometria. Isso também significa que a tonalidade da flauta doce varia pouco, embora fatores como ressonância na cavidade oral do instrumentista ainda permitam a ele leves modificações no tom (5).

Por outro lado, a flauta doce não possui nenhum mecanismo para ajudar o flautista a pressionar os buracos em seu corpo. Assim, embora seja relativamente fácil produzir e alternar entre as notas da escala de dó maior, produzir uma escala cromática é uma tarefa difícil que requer muito controle do posicionamento dos dedos, sendo necessário encobrir certos buracos levemente, com um alto grau de precisão. Ainda, pode ser necessário alternar muitos dedos entre notas cromáticas, o que facilmente produz estados transitórios desagradáveis em frases tocadas em *legato*.

8.3.2 Análise espectral

A figura 10 mostra o espectro obtido em 1 segundo de gravação da nota mais grave produzida pela flauta doce (C5). Observa-se que na flauta doce o componente fundamental é o mais acentuado, sendo seguido por quatro harmônicos cuja amplitude decai em cerca de 10dB/harmônico. A partir do quinto harmônico o comportamento deixa de seguir um padrão simples. Ainda, o máximo em 521Hz indica

¹A maioria dos instrumentos de sopro não possui um limite superior para as notas produzidas (13). Os limites apresentados aqui são os dados pelo fabricante do modelo utilizado, e refletem o que é pedido no repertório clássico.

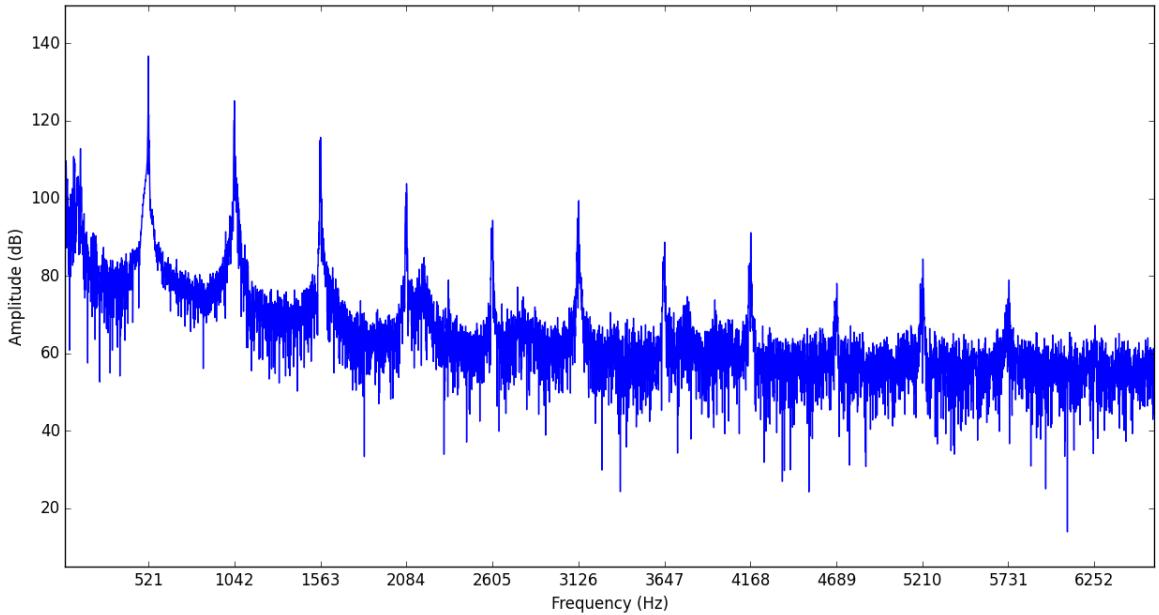


Figura 10: Espectro para a nota C5 tocada em uma flauta doce Yamaha YRS-23Y obtido a partir da FFT em 1 segundo de gravação.

que a flauta doce utilizada está afinada com o A4 em cerca de 438Hz , o que sugere a afinação padrão de 440Hz com uma pequena margem de erro que pode ter sido causada, por exemplo, por diferenças de temperatura. Por fim, é interessante observar que os harmônicos da flauta doce seguem a série:

$$H_n = H_0(n + 1) \quad (8.1)$$

Sendo H_0 o harmônico fundamental. Outros instrumentos podem seguir a série:

$$H_n = H_0(2n + 1) \quad (8.2)$$

Uma explicação física para os instrumentos de sopro gerarem uma série ou a outra pode ser encontrada em (13).

Já a figura 11 compara o espectro de um G5 e de um G6 uma oitava acima. É interessante observar que a amplitude relativa entre os harmônicos é bastante diferente da amplitude relativa para a nota C5 da figura 10, sendo o segundo harmônico mais intenso que o primeiro. Apesar disso, tanto o G5 quanto o G6 possuem amplitudes relativas semelhantes entre si. Outro fator interessante é que os harmônicos

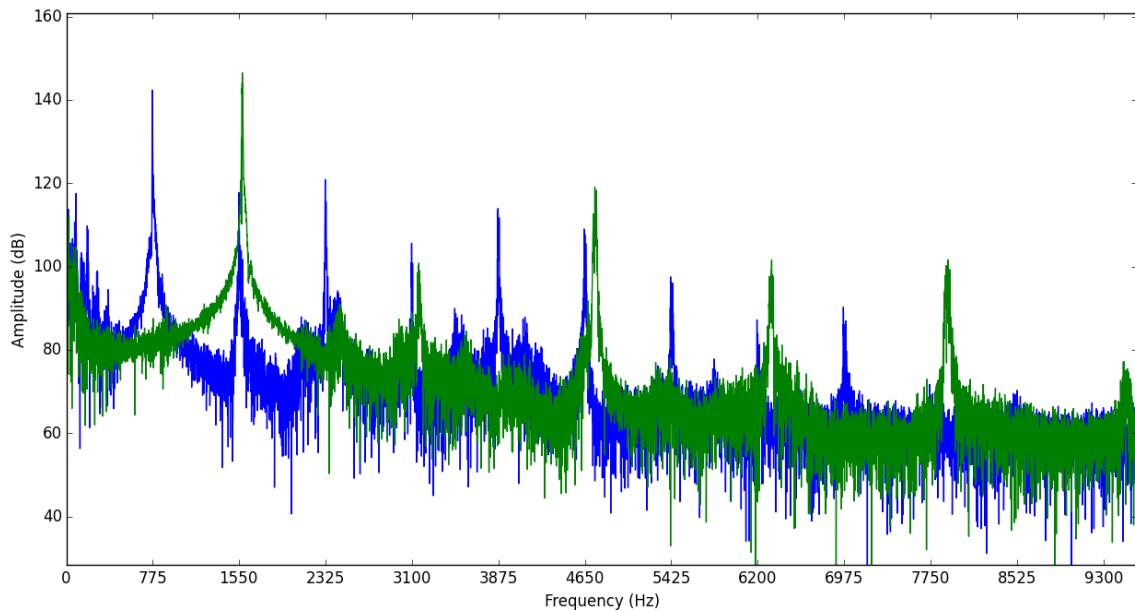


Figura 11: Espectro para um G5 (azul) e um G6 (verde) tocados em uma flauta doce Yamaha YRS-23Y obtido a partir da FFT em 1 segundo de gravação.

produzidos não são posicionados exatamente nas mesmas frequências.

Por fim, observamos que a nota G6 tem uma leve tendência de gerar componentes posicionados nos harmônicos de um G5 que não são seus próprios harmônicos. Isso pode ser visto na frequência de (2325Hz) , que é um múltiplo da frequência fundamental do G5 775Hz , mas não é um múltiplo do G6 (1550Hz) . Isto dificultará a distinção dessas duas notas no algoritmo de detecção de frequência fundamental.

8.3.3 Conclusões

Espera-se que o programa desenvolvido nesse trabalho seja capaz de identificar muito bem músicas em dó maior tocadas nessa flauta, mas que encontre dificuldades em músicas cromáticas, especialmente se houver muitas frases em *legato*. Espera-se que essa dificuldade seja mais relacionada à erros cometidos pelo instrumentista do que de erros do algoritmo.

8.4 *Tin Whistle*

O *tin whistle* é um instrumento de sopro popular na música celta, seu corpo costuma ser feito de estanho, daí o nome. A música popular celta é conhecida por ritmos rápidos e frases com muitos ornamentos, e isso se reflete nas características do *whistle*.

Nesse trabalho será utilizado um *whistle* Clarke SBDC afinado em Ré maior, que possui 6 buracos.

8.4.1 Características

O *whistle* utilizado é capaz de produzir 2 oitavas nas escalas de Ré maior ou Sol maior, a partir de um D5.

O *whistle* é bastante semelhante à flauta doce, mas é um instrumento de confecção mais simples e seu bocal ajuda muito menos o instrumentista a controlar o jato de ar, sendo mais fácil gerar notas desafinadas ou desagradáveis. Por outro lado, os buracos no corpo do *whistle* são mais simples, e é muito fácil transitar entre as notas na escala para a qual ele foi afinado. Isso permite ao instrumentista tocar passagens muito rápidas e com diversos ornamentos sem gerar muitos transientes desagradáveis.

8.4.2 Análise espectral

Na figura 12 podemos ver que, relativamente à flauta doce, o *whistle* gera menos harmônicos significativos. Além disso, os picos nas frequências dos harmônicos "vazam" mais para as frequências vizinhas. Isso pode ser atribuído ao bocal mais primitivo do *whistle*, que direciona menos o jato de ar produzido pelo instrumentista, fazendo com que parte da energia do jato seja desperdiçada e gere componentes indesejados.

Na figura 13 podemos comparar a nota G6 com a nota G5 no *whistle*. É interessante observar que na nota G6 os ruídos são muito mais intensos do que na G5, lembramos que no *whistle* é necessário aumentar consideravelmente a intensidade do jato de ar para trocar entre oitavas, como o bocal do *whistle* não faz nenhum ajuste no jato de ar, a maior intensidade causa um desperdício maior de energia,

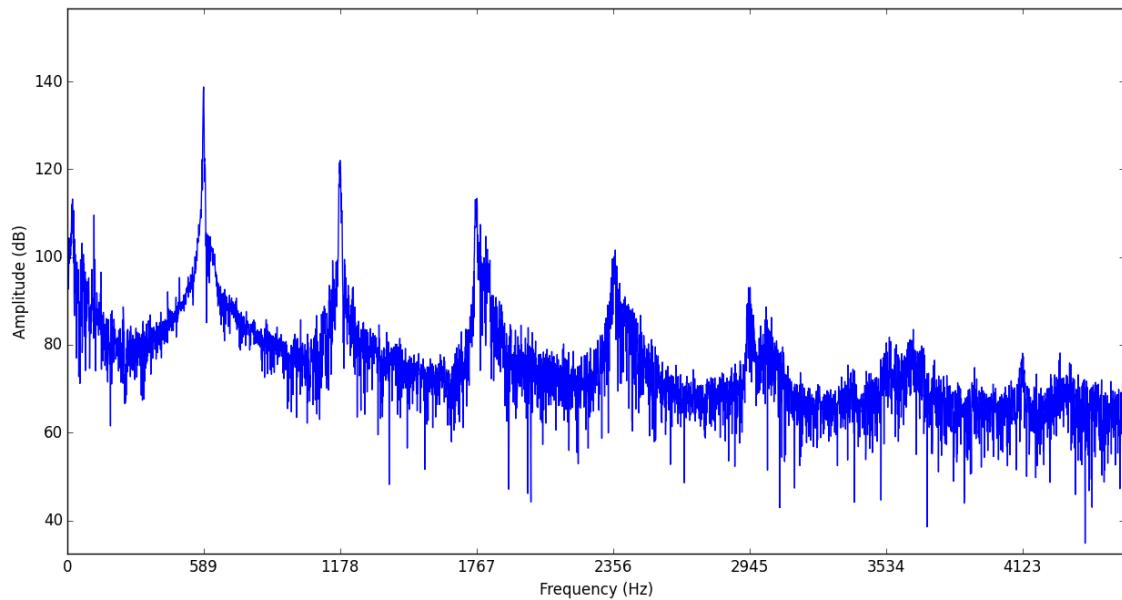


Figura 12: Espectro para a nota D5 tocada em um *whistle* Clarke SBDC obtido a partir da FFT em 1 segundo de gravação.

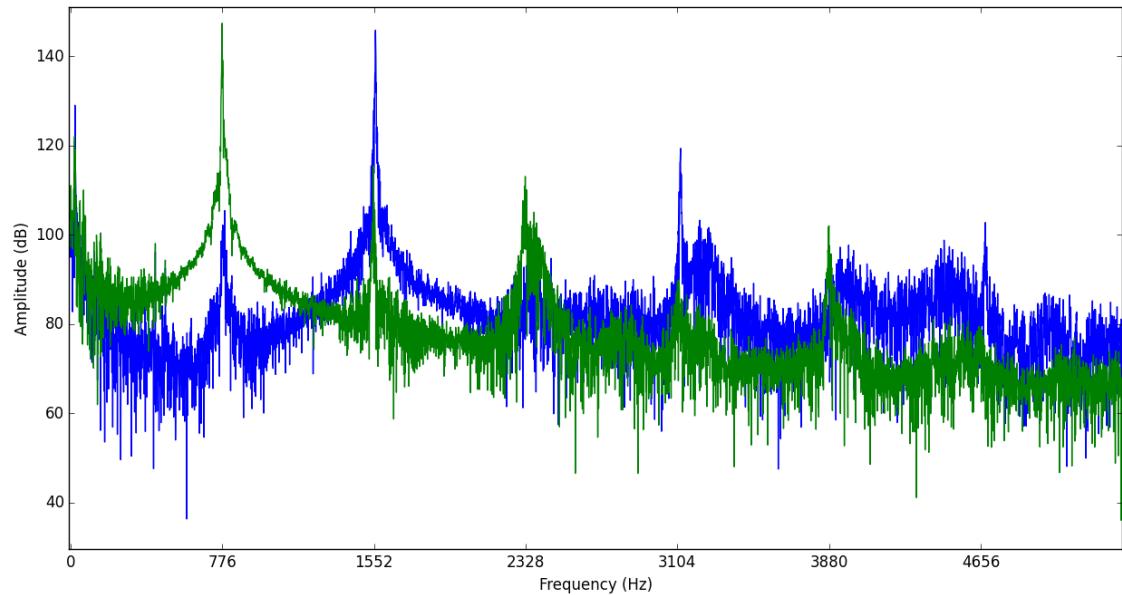


Figura 13: Espectro para um G5 (verde) e um G6 (azul) tocados em um *whistle* Clarke SBDC obtido a partir da FFT em 1 segundo de gravação.

que se reflete no ruído.

Adicionalmente, nota-se que a nota G6 gera um componente harmônico na frequência fundamental da nota G5, mas com amplitude reduzida. Isso é esperado

pois as duas notas possuem o mesmo dedilhado e, portanto, a forma geométrica do instrumento permite que esse componente seja formado. Esse detalhe pode causar erros na classificação correta da oitava de uma nota tocada.

8.4.3 Conclusões

Relativamente a flauta doce, espera-se que nos sinais provenientes do *whistle* seja mais fácil identificar passagens rápidas e com ornamentos, mas que para músicas lentas a precisão seja menor, devido a maior dificuldade em se controlar o jato de ar. Ainda, espera-se uma dificuldade adicional nas notas mais agudas, que possuem mais ruído e componentes nas mesmas frequências das notas correspondentes na oitava inferior.

8.5 Pífano

O pífano é uma flauta transversal pequena com timbre estridente. É um instrumento bastante simples, sendo desprovido de um bocal e, portanto, delegando o controle do jato de ar totalmente ao instrumentista.

Nesse trabalho será utilizado um pífano Yamaha YRF-21 afinado em Dó maior, que é feito de plástico e possui 9 buracos em seu corpo, sendo um destinado ao sopro.

8.5.1 Características

O pífano utilizado é capaz de produzir cromaticamente as notas entre C5 e E7.

O pífano escolhido é bastante semelhante à flauta doce, tanto em material quanto na posição dos dedilhados. A maior diferença é o fato do pífano ser desprovido de um bocal e de ser empunhado transversalmente. A ausência de um bocal permite ao instrumentista controlar sua embocadura de forma a variar muito o tom do instrumento. Assim, as dificuldades apresentadas para a flauta doce se mantém, sendo acrescentadas dificuldades em identificar precisamente as notas, que podem sofrer muitas variações de tom.

Nota-se, em especial, que a transição entre oitavas no pífano é muito mais difícil de se realizar do que nos instrumentos apresentados anteriormente. Tanto na

flauta doce quando no *whistle* essa transição pode ser feita usando um dedilhado levemente diferente e acelerando um pouco o jato de ar. Entretanto, como o pífano não possui um bocal para direcionar o jato de ar, o instrumentista precisa alterar consideravelmente a sua embocadura de forma a gerar um jato mais rápido que continua atingindo a superfície do instrumento no ângulo correto e com a largura adequada. Esse aspecto será analisado espectralmente a seguir.

8.5.2 Análise espectral

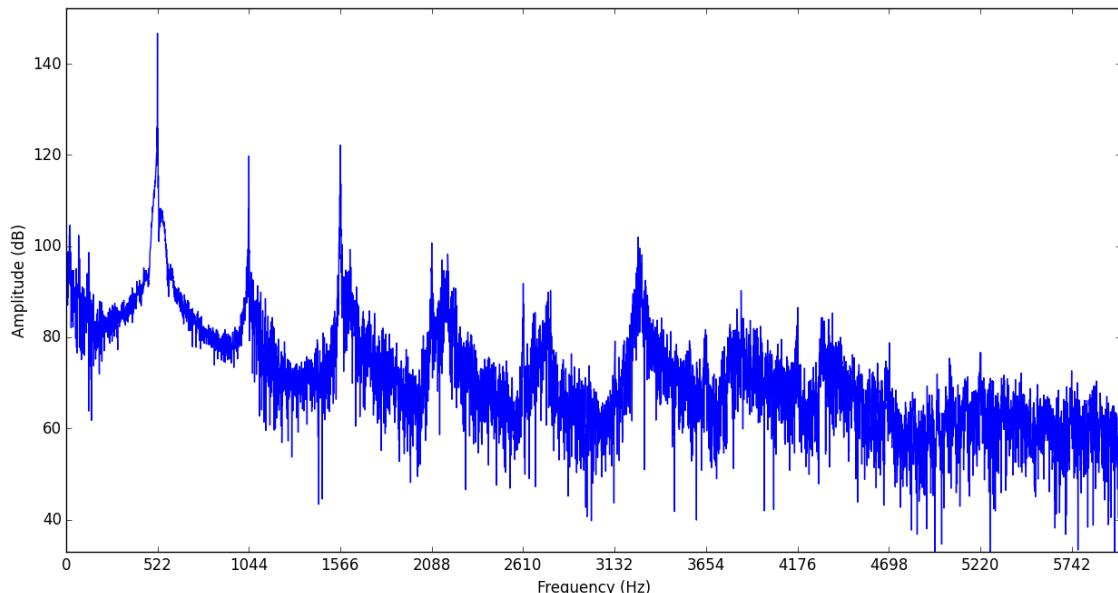


Figura 14: Espectro para a nota C5 tocada em um pífano Yamaha YRF-21 obtido a partir da FFT em 1 segundo de gravação.

Na figura 14 temos o espectro para um C5, a nota mais grave atingida pelo pífano. É possível reconhecer cerca de 8 harmônicos, sendo os 3 primeiros bem mais significativos. Ainda, nota-se que os harmônicos a partir do terceiro são acompanhados de amplitudes consideráveis em suas redondezas, de forma semelhante ao que ocorre no *whistle*, e contrária à flauta doce.

8.5.3 Conclusões

Relativamente a flauta doce, espera-se que nos sinais provenientes do pífano seja mais difícil identificar precisamente a frequência fundamental das notas, e que

ocorram erros relativos à oitava da nota tocada. Esses problemas se reduzem de acordo com a habilidade do instrumentista.

8.6 Flauta transversal ocidental

A flauta transversal ocidental é um dos instrumentos de sopro mais populares em orquestras. Foi feito a partir da modificação de flautas transversais medievais (semelhantes ao pífano). As principais melhorias introduzidas foram um corpo de metal, que é capaz de gerar notas muito mais altas e que podem ser carregadas sobre os demais instrumentos de uma orquestra, e um mecanismo de botões e molas que deixa os dedilhados muito mais confortáveis, pois os botões podem ser projetados para ocuparem posições confortáveis sem prejudicar a afinação do instrumento, além de facilitarem a tarefa de encobrir totalmente os buracos.

Nesse trabalho será utilizada uma flauta transversal afinada em Dó maior, modelo Hallelu HFL-200.

8.6.1 Características

A flauta transversal utilizada é capaz de produzir cromaticamente três oitavas a partir do C4.

Em relação aos instrumentos apresentados anteriormente, nota-se que a flauta transversal escolhida é capaz de produzir notas mais graves. Analisar essas notas será uma tarefa mais difícil, primeiro porque a diferença absoluta da frequência entre duas notas separadas por um semitom será menor e, segundo, porque a frequência menor aumenta o tempo em que o instrumento se encontra em estados transitórios (13).

Em relação à flauta doce e ao *whistle*, a ausência de um bocal dificulta a identificação das notas tocadas, pois há uma variedade muito maior de tons que podem ser produzidos, assim como no pífano. Por outro lado, a construção mais cuidadosa do instrumento e os botões mecânicos ajudarão a produzir tons mais limpos do que no pífano, e facilitarão a identificação de notas em passagens rápidas e com legatos.

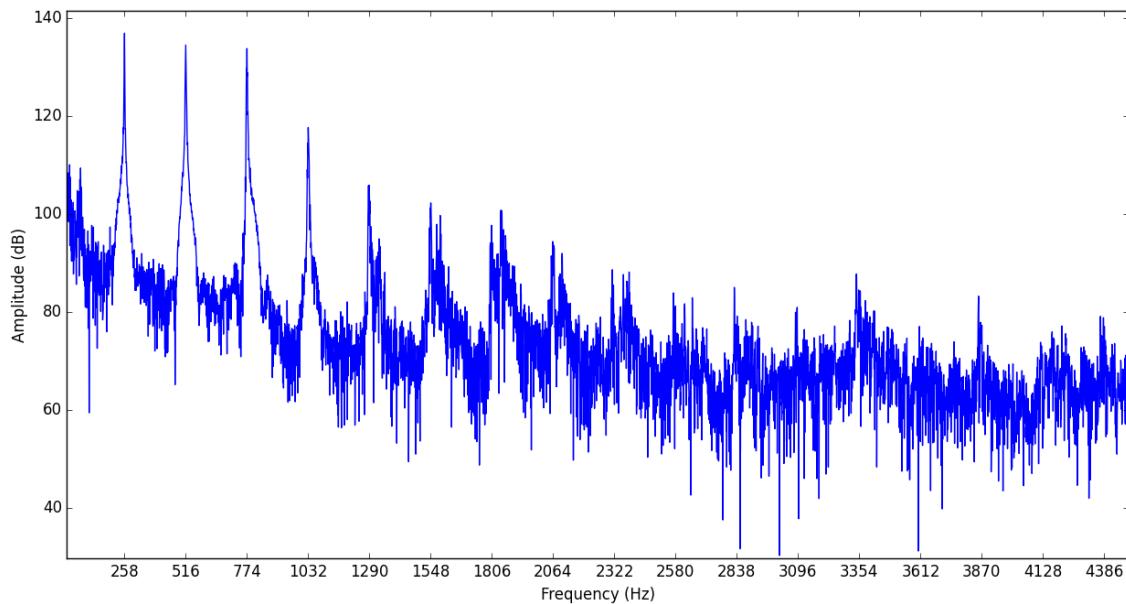


Figura 15: Espectro para a nota C4 tocada em uma flauta transversal Hallelu HFL-200 obtido a partir da FFT em 1 segundo de gravação.

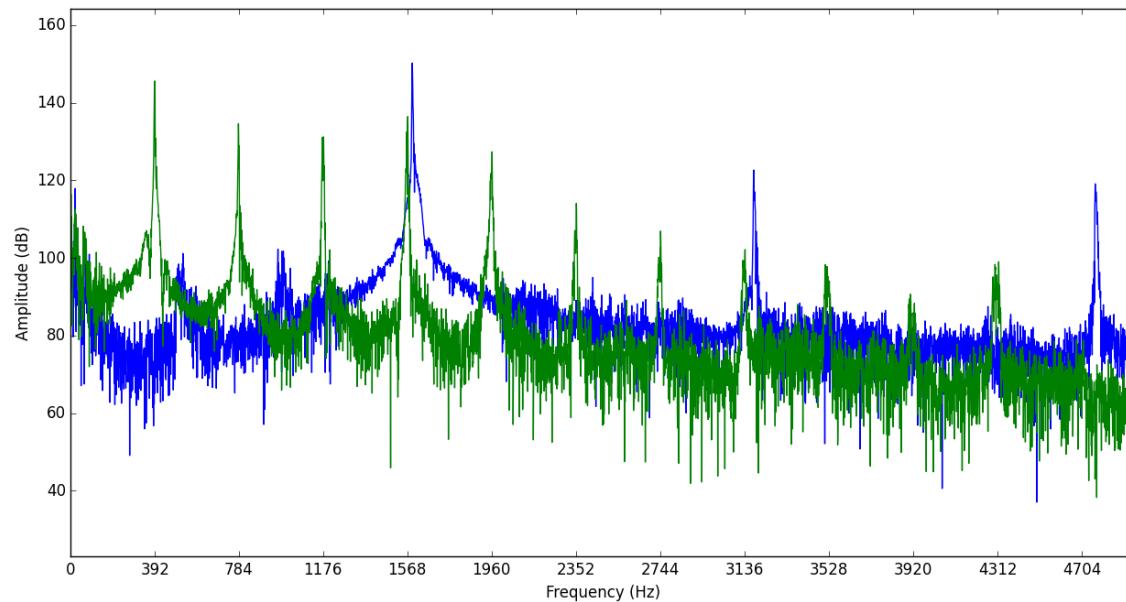


Figura 16: Espectro para um G4 (verde) e um G6 (azul) tocados em uma flauta transversal Hallelu HFL-200C obtido a partir da FFT em 1 segundo de gravação.

8.6.2 Análise espectral

Na figura 15 vemos o espectro para um C4, a nota mais grave produzível na flauta transversal. Já na figura 16 vemos as notas G4 e G6 na mesma flauta.

Primeiramente, observamos que na nota C4 os três primeiros harmônicos possuem amplitude bastante próxima. A nota C4 na flauta transversal é relativamente difícil de ser tocada, sendo necessário um controle bastante preciso do jato de ar produzido. Pequenos erros no jato podem transformar a nota em um C5, o que justifica a amplitude relativamente alta do segundo harmônico (que seria o fundamental para um C5). Além disso, os harmônicos mais altos não possuem picos tão bem definidos quanto os mais baixos, o que indica um som menos limpo do que o da flauta doce, por exemplo.

Comparando a figura 15 com a 16, podemos ver que a nota G4, apesar de estar na mesma oitava que a C4, não apresenta as dificuldades apresentadas anteriormente, possuindo um espectro parecido com os produzidos pela flauta doce, em que cada harmônico possui um pico bem definido no espectro.

Por fim, vemos que a nota G6, mesmo estando duas oitavas acima da nota G4, não apresenta um ruído significativamente maior e nem gera componentes sub-harmônicos significativos (dificuldades presentes, por exemplo, nas notas altas do *whistle*). Nota-se que a flauta transversal é um instrumento feito para ser ouvido sob uma orquestra e é, portanto, mais potente. A energia perdida no jato de ar produzido pelo flautista é menos significativa. Além disso, a ausência de um bocal permite ao flautista ajustar livremente a embocadura, de forma a aproveitar bem a energia do jato de ar e controlar os componentes sub-harmônicos.

8.6.3 Conclusões

Espera-se que a identificação das notas na flauta transversal seja mais fácil que nos demais instrumentos a partir da segunda oitava (C5-C7), desde que o flautista seja hábil o bastante para controlar sua embocadura corretamente. Na oitava inferior (C4-B4) podem haver mais erros devido à estados transitórios e à maior proximidade entre as frequências fundamentais. Por fim, espera-se ser mais fácil identificar passagens cromáticas na flauta transversal do que nos outros instrumentos, devido aos botões mecânicos que facilitam os dedilhados para notas acidentais.

8.7 Flauta transversal chinesa (*dizi*)

O *dizi*, comumente conhecido como flauta transversal chinesa, é um instrumento popular na china, sendo utilizado tanto em música popular quanto em óperas e orquestras chinesas. Costuma ser feito artesanalmente a partir de uma única peça de bambu, que é furada nas posições desejadas para os dedilhados.

Nesse trabalho será utilizado um *dizi* artesanal de baixa qualidade importado da china.

8.7.1 Características

O *dizi* utilizado é capaz de produzir um subconjunto específico de notas entre E5 e B7. Seu temperamento não gera notas separadas por semitons, o que dificultará muito a tarefa de classificá-las.

Em relação ao pífano, a produção artesanal do *dizi* faz com que as notas produzidas possuam várias imperfeições, tanto na afinação, pela posição dos buracos, quanto no tom, pela maior dificuldade em se encobrir totalmente os buracos. Ainda, o *dizi* escolhido possui 11 buracos em seu corpo, e seus dedilhados são pouco confortáveis, sendo difícil tocar passagens rápidas com precisão.

Por não ser muito adequado à música ocidental, ele será utilizado brevemente para testar os tons produzidos por instrumentos pouco comuns na música ocidental, e com afinações exóticas.

8.7.2 Análise espectral

8.7.3 Conclusões

Espera-se que a identificação correta das notas tocadas no *dizi* seja bastante difícil e que seja feita com sucesso apenas para músicas mais lentas, a menos que o instrumentista seja muito habilidoso. Ainda, espera-se que seja difícil obter as notas exatas devido à afinação não temperada do *dizi*.

8.8 Ocarina

A ocarina é um instrumento de sopro globular geralmente feito de cerâmica. É um dos instrumentos mais antigos conhecidos, e pode ter diversas formas.

Nesse trabalho será utilizada uma ocarina modelo "TOTMC Legend of Zelda Ocarina of Time Triforce Link TOLO248" de 12 buracos afinada em Dó maior.

8.8.1 Características

A ocarina escolhida é capaz de produzir cromaticamente as notas no intervalo A4-F6.

O corpo globular da ocarina dificulta a criação de harmônicos, sendo a frequência fundamental muito mais intensa do que as mais altas. Entretanto, espera-se que a manufatura em cerâmica apresente mais imperfeições do que os instrumentos em plástico e metal, o que pode ser constatado, por exemplo, no formato irregular dos buracos. Também nota-se que os dedilhados na ocarina são pouco confortáveis, sendo muito fácil não encobrir corretamente alguns dos buracos.

8.8.2 Análise espectral

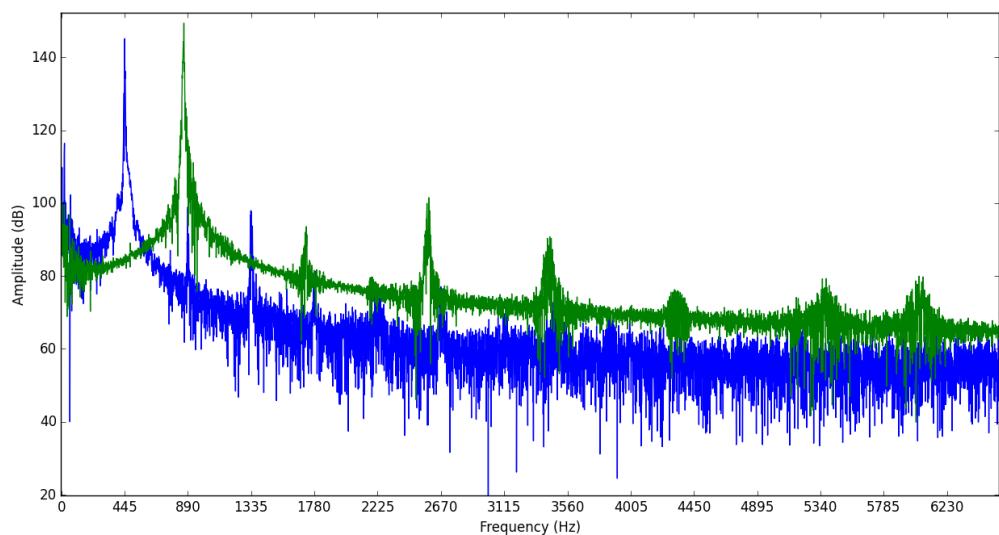


Figura 17: Espectro para um A4 (azul) e um A5 (verde) tocados na ocarina escolhida, obtido a partir da FFT em 1 segundo de gravação.

Na figura 17 comprovamos que apenas o harmônico fundamental é significativo na ocarina.

8.8.3 Conclusões

Como na ocarina apenas a frequência fundamental é considerável, espera-se que as notas identificadas estejam na oitava correta. Entretanto, pode haver erros na identificação de notas separadas por semitonos, pois a decisão terá de ser tomada com a informação de um único harmônico.

9 Algoritmos de Otimização

9.1 Algoritmo Genético

Algoritmos Genéticos (**AG!**s) são inspirados na Teoria da Evolução de Darwin (17). Nestas técnicas, mantém-se uma população de soluções candidatas, chamadas cromossomos, que “evoluem” guiadas por uma medida de qualidade (função de *fitness*) através da aplicação de operações inspiradas pela evolução natural: seleção, mutação, crossover e sobrevivência dos mais aptos. Inicialmente, a população é composta por S_i (parâmetro do AG) cromossomos gerados aleatoriamente.

Existem diversas variantes de **AG!**. A seguir, explica-se os detalhes de **AG!** nas formas que são utilizadas com mais frequência. No final, apresenta-se também um pseudocódigo para **AG!**. Uma descrição mais geral de **AG!** pode ser encontrada em (31).

Cromossomo

Um cromossomo é um candidato à solução ótima. Cada parte do cromossomo é chamada gene. A boa codificação do problema em cromossomo é um fator fundamental para o sucesso do algoritmo. No caso do problema de otimizar um conjunto de parâmetros, a codificação em cromossomo óbvia é representar uma dada instância por um vetor, em que cada posição (gene) corresponde a um parâmetro específico.

Função de *Fitness*

É uma função que, dado um cromossomo, retorna um número real (*fitness*) que mede o quanto bom é este cromossomo para resolver o problema. Em geral, assume-se a convenção que quanto maior o *fitness*, melhor o cromossomo.

Seleção

A cada geração uma parte da população é escolhida para reprodução. Nesse processo, a probabilidade de um cromossomo ser escolhido é geralmente proporcional ao seu *fitness* (seleção por roleta). Outras formas de selecionar os que irão se reproduzir também são aplicadas. O número de quantos indivíduos R (parâmetro do **AG!**) são escolhidos para reprodução a cada geração é um parâmetro do **AG!**.

Mutação

Corresponde ao fator de caminhada aleatória do algoritmo. Dado um cromossomo, essa operação itera sobre cada gene e o troca por um valor aleatório (dentro do domínio do gene) com uma certa probabilidade de mutação p_m (parâmetro do **AG!**).

Crossover

Dados dois cromossomos escolhidos para se reproduzir, é interessante (assim como ocorre na Natureza) que, ao invés de se ter filhos como cópia idêntica dos pais, faça-se uma recombinação dos genes dos pais de modo a produzir cromossomos com características mistas. Assim, o *crossover* em um **AG!** segue um procedimento análogo ao *crossover* biológico: escolhe-se um ponto de quebra e cria-se um cromossomo filho tomando-se a parte do primeiro pai antes do ponto de quebra e a do segundo após esse ponto. Observe que esse processo pode ser generalizado para múltiplos pontos de quebra, embora comumente se utilize um único ponto.

Sobrevivência dos Mais Aptos

Como a cada iteração ocorre reprodução, a população tende a aumentar indefinidamente. Para evitar isso, assume-se um tamanho de população máximo S_m (parâmetro do **AG!**) e elimina-se os menos aptos (com menores valores de *fitness*) a cada geração. Outra forma de realizar esta operação envolve escolher probabilisticamente os sobreviventes com probabilidade de escolha dependente do valor de *fitness*.

Algoritmo 1: Pseudocódigo do Algoritmo Genético.

```

begin
  Populacao  $\leftarrow$  PopulacaoAleatoria( $S_i$ );
  Fitnesses  $\leftarrow$  CalcularFitnesses(Populacao);
  while critério de parada não satisfeito do
    Pais  $\leftarrow$  Selecao(Populacao, Fitnesses,  $R$ );
    Filhos  $\leftarrow$  Crossover(Pais);
    Populacao  $\leftarrow$  Populacao  $\cup$  Filhos;
    Populacao  $\leftarrow$  Mutacao(Populacao,  $p_m$ );
    Fitnesses  $\leftarrow$  CalcularFitnesses(Populacao);
    Populacao  $\leftarrow$  MaisAptos(Populacao, Fitnesses,  $S_m$ );
  end
end
  
```

9.2 Particle Swarm Optimization

PSO! é um algoritmo de otimização iterativo que busca uma candidata à solução ótima conforme uma medida de qualidade. O algoritmo trabalha com um espaço de busca em D dimensões limitado inferiormente por \mathbf{l} e superiormente por \mathbf{u} . Inicialmente, sorteia-se P “partículas” aleatoriamente tal que a posição \mathbf{x}_i e a velocidade \mathbf{v}_i de cada partícula p_i satisfazem as equações 9.1 e 9.2, respectivamente.

$$\mathbf{x}_i(d) \in [\mathbf{l}(d), \mathbf{u}(d)], d = 1, \dots, D \quad (9.1)$$

$$\mathbf{v}_i(d) \in [-|\mathbf{u}(d) - \mathbf{l}(d)|, |\mathbf{u}(d) - \mathbf{l}(d)|], d = 1, \dots, D \quad (9.2)$$

Assim, a cada iteração, cada posição de partícula é avaliada pela função de medida de qualidade $f : \mathbb{R}^D \rightarrow \mathbb{R}$ e atualiza-se \mathbf{b}_i , a melhor posição da partícula p_i até então, e \mathbf{g} , a melhor posição global de partícula até o momento, segundo f . A partir deste ponto, assume-se que o objetivo é maximizar $f(\mathbf{x})$. Note que isso não é limitação, pois se o objetivo é minimizar $f(\mathbf{x})$, basta executar o algoritmo com $g(\mathbf{x}) = -f(\mathbf{x})$. Por fim, atualiza-se a velocidade e a posição de cada partícula segundo as equações 9.3 e 9.4, respectivamente.

$$\mathbf{v}_i \leftarrow \omega \mathbf{v}_i + \varphi_p r_p (\mathbf{b}_i - \mathbf{x}_i) + \varphi_g r_g (\mathbf{g} - \mathbf{x}_i) \quad (9.3)$$

$$\mathbf{x}_i \leftarrow \mathbf{x}_i + \mathbf{v}_i \quad (9.4)$$

Em que ω , φ_p e φ_g são parâmetros do algoritmo, e r_p e r_g são número reais aleatórios entre 0 e 1. O método prossegue até que algum critério de parada seja atingido (número máximo de iterações, tempo máximo, limite de processamento, etc.). Um pseudocódigo para **PSO!** é apresentado no Algoritmo 2.

O **PSO!** tem vantagens por não impor requisitos sobre o problema a ser otimizado além do conhecimento do espaço de busca e de uma medida de desempenho. Entretanto, seu comportamento não é bem compreendido e não há garantia de convergência para solução ótima. Além disso, o método sofre de tendência a convergir para máximos locais.

Algoritmo 2: Pseudocódigo do *Particle Swarm Optimization*.

```

begin
  for  $i \leftarrow 1, \dots, P$  do
    for  $d \leftarrow 1, \dots, D$  do
       $\mathbf{x}_i(d) \leftarrow \text{random}(\mathbf{l}(d), \mathbf{u}(d));$ 
       $\Delta \leftarrow |\mathbf{u}(d) - \mathbf{l}(d)|;$ 
       $\mathbf{v}_i(d) \leftarrow \text{random}(-\Delta, \Delta);$ 
    end
     $\mathbf{b}_i \leftarrow \mathbf{x}_i;$ 
    if  $f(\mathbf{b}_i) > f(\mathbf{g})$  then
       $\mathbf{g} \leftarrow \mathbf{b}_i;$ 
    end
  end

  while critério de parada não satisfeito do
    for  $i \leftarrow 1, \dots, P$  do
      for  $d \leftarrow 1, \dots, D$  do
         $r_p \leftarrow \text{random}(0, 1);$ 
         $r_g \leftarrow \text{random}(0, 1);$ 
         $\mathbf{v}_i(d) \leftarrow \omega \mathbf{v}_i(d) + \varphi_p r_p (\mathbf{b}_i(d) - \mathbf{x}_i(d)) + \varphi_g r_g (\mathbf{g}(d) - \mathbf{x}_i(d));$ 
      end
       $\mathbf{x}_i \leftarrow \mathbf{x}_i + \mathbf{v}_i;$ 
      if  $f(\mathbf{x}_i) > f(\mathbf{b}_i)$  then
         $\mathbf{b}_i \leftarrow \mathbf{x}_i;$ 
        if  $f(\mathbf{b}_i) > f(\mathbf{g})$  then
           $\mathbf{g} \leftarrow \mathbf{b}_i;$ 
        end
      end
    end
  end
end

```

10 Tecnologias Utilizadas

10.1 USARSim

USARSim! é um simulador de Robótica de alta fidelidade. A versão atual é baseada no **UDK!** (**UDK!**) (14), kit de desenvolvimento da *engine* de jogos Unreal. A Unreal usa como engine de Física a Nvidia PhysX (25), uma das mais avançadas engines de Física de tempo real. Com isso, é possível simular interações mecânicas, tais como colisão e atrito, com boa precisão. Inclusive, consegue-se modelar com boa fidelidade o comportamento de robôs humanóides com grande número de graus de liberdade, como demonstra (40).

O simulador já possui diversos modelos de robôs, sensores e atuadores. Além disso, a implementação de novos modelos é muito facilitada pelas ferramentas providas pelo **UDK!**, em especial uma ferramenta de edição chamada **UDK!** Editor e uma linguagem de *script* de alto nível denominada UnrealScript. A seguir, são apresentados os conceitos da **UDK!** e do **USARSim!** relevantes para o entendimento deste trabalho.

10.1.1 Nvidia PhysX

A simulação de Física da PhysX mantém uma cena em que os objetos são atualizados iterativamente, em que a cada iteração injeta-se um passo de simulação (no caso de tempo real, o intervalo de tempo desde a última atualização). Este comportamento discreto introduz erros de Física quando comparado ao que seria uma simulação contínua, logo deseja-se que o passo de simulação seja o menor possível para permitir uma maior fidelidade.

Em simulações em que a Física é crítica, como a simulação de um robô humanoíde, a qualidade da simulação degrada muito com a redução da taxa de atualização da Física, como mostra (40). Observe que a simulação na Unreal ocorre

em tempo real, o que torna o passo limitado pela capacidade de processamento disponível.

Uma cena de PhysX contém três importantes aspectos: *actors* (atores), *materials* (materiais) e *joints* (juntas). *Actors* definem objetos físicos capazes de interagir com o mundo e com outros objetos. *Actors* podem ser estáticos (fixos no mundo; geralmente usados para partes do cenário) ou corpos rígidos dinâmicos (usados para objetos móveis).

A cada *actor* pode estar associado um formato (modelo) físico. Note que este é desvinculado do modelo gráfico que é renderizado pela *engine* gráfica. Na realidade, para um dado objeto, em geral convém utilizar um modelo físico mais simples que o gráfico, pois cálculos de Física consomem bastante processamento; usar o modelo gráfico para Física é impraticável na maioria dos casos. Ademais, um *actor* também possui um tensor de inércia I_{body} e uma massa M localizada em seu centro de massa C_M .

Materials descrevem as propriedades de uma superfície (e.g. coeficiente de atrito) de um *actor*. Essas propriedades ditam o que ocorre quando dois *actors* colidem. *Joints* conectam dois corpos rígidos e limitam o movimento entre estes. PhysX possui diversos tipos de juntas (classificadas conforme as restrições aplicados aos corpos que unem). Neste trabalho, a única junta utilizada é a *revolute joint* (junta de revolução), que conecta dois corpos por um eixo como mostra a Figura 18.

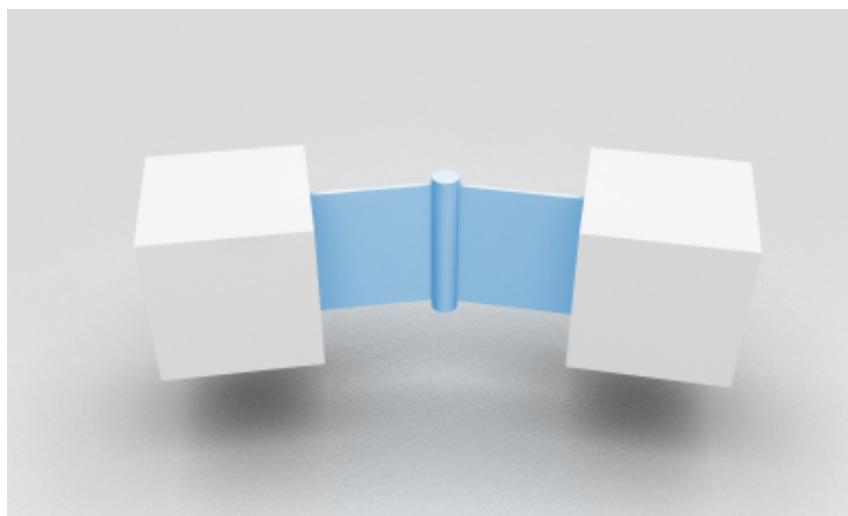


Figura 18: Junta de revolução.

Uma das tarefas mais importantes de uma engine Física é detectar quais colisões

sões ocorrem em um dado momento eficientemente. Há dois desafios principais a serem superados nisso: detecção de colisão polígono por polígono (extremamente custosa) e dado n objetos presentes em uma cena, precisa-se, a princípio, testar colisão entre $\binom{n}{2}$ pares de objetos.

Para resolver o primeiro problema, a *engine* mantém uma caixa delimitadora (*bounding box*) para cada modelo físico. Essa caixa é formada pelos limites mínimos e máximos do modelo em cada uma das coordenadas. Assim, para verificar se dois modelos colidem, o algoritmo verifica primeiro se as caixas delimitadoras se sobrepõem; se isso não ocorre, pode-se afirmar que os modelos certamente não colidem e evita-se o custoso teste polígono por polígono.

Para evitar testar colisão entre todos os pares de modelos de uma cena, PhysX divide o espaço em partições, de modo que há necessidade de verificar colisões apenas com outros objetos presente na mesma partição ou no máximo em partições vizinhas.

10.1.2 UDK Editor

O **UDK!** Editor é a ferramenta principal de edição do **UDK!**. Por ser uma ferramenta do UDK, ela é voltada à criação de jogos. Assim, possui diversas funcionalidades para este fim, como manipulação de modelos 3D, criação de cenários etc.

Para esse trabalho, a funcionalidade mais importante é a auto-geração de modelos físicos a partir de modelos gráficos 3D. Para isso, o editor provê diversos métodos. Um dos mais convenientes é o K-DOF. O algoritmo do K-DOF basicamente toma K planos alinhados com K eixos passando pelo centro da malha gráfica e aproxima esses planos o máximo possível da malha sem que ocorra intersecção com esta. Pode-se escolher K dentre as seguintes opções:

- 6: caixa alinhada com os eixos principais (X, Y e Z);
- 10: caixa com 4 arestas chanfradas – pode-se escolher dentre arestas alinhadas com os eixos X, Y ou Z;
- 18: caixa com todas as arestas chanfradas;
- 26: caixa com todas as arestas e cantos chanfrados.

A Figura 19 exibe as diferenças entre as opções de K-DOF para a peça do peito do Robonova.

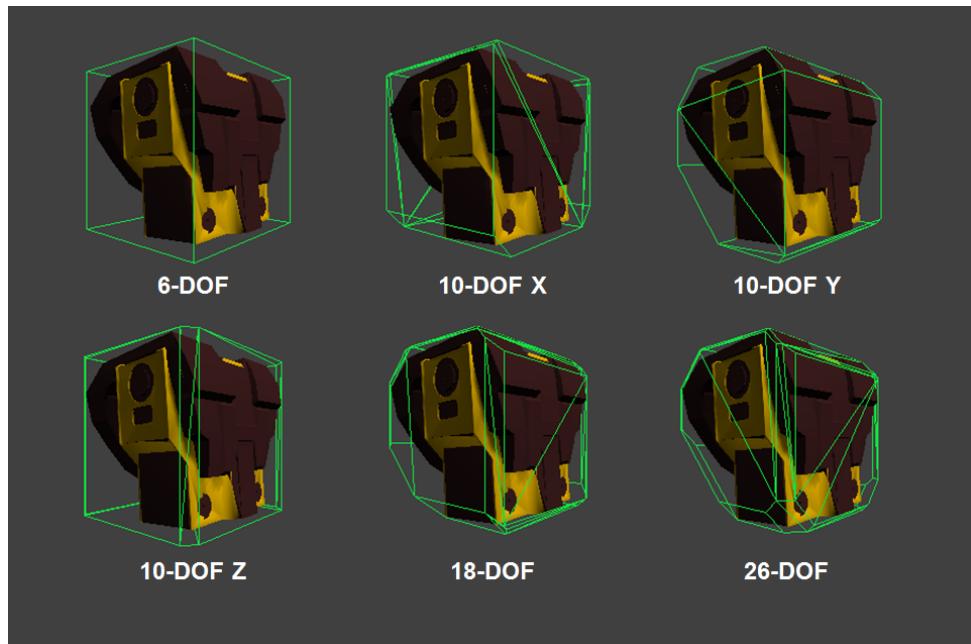


Figura 19: Diferenças entre modelos físicos gerados com K-DOF (os modelos físicos são apresentados em *wireframe*).

10.1.3 UnrealScript

A UnrealScript é uma linguagem de *script* proprietária da *engine* Unreal. Foi projetada por Tim Sweeney especificamente para desenvolvimento de jogos. As principais características da UnrealScript são:

- Orientada a objetos;
- Não há suporte a herança múltipla, ou seja, uma classe só poder herdar de no máximo uma outra classe;
- Não existe o conceito de ponteiro. Trabalha-se com referências, assim como em Java;
- Programador não precisa se preocupar com desalocação de memória dinâmica, pois há um *garbage collector*;
- Forte detecção de erros durante tempo de compilação;
- Estilo de sintaxe similar a C/C++/Java;

- Suporte a sobrecarga de operadores;
- Não há suporte a sobrecarga de métodos;
- Suporte nativo a conceitos importantes para desenvolvimento de jogos: tempo, estados, eventos, propriedades, rede etc.

Como pode-se perceber pelas características listadas, muitas das decisões de projeto da UnrealScript foram inspiradas pela linguagem Java. Inclusive, Tim Sweeney experimentou usar Java para a Unreal antes de decidir criar uma linguagem própria. Por fim, destaca-se que a UnrealScript é usada apenas para programar a parte de alto nível. O baixo nível, como as partes de renderização gráfica e de simulação de Física, que exigem mais desempenho, é programado em C++.

10.1.4 Implementação de Robôs em USARSim

A implementação de modelos novos de robôs em USARSim envolve basicamente os passos:

1. Construção de modelos **CAD!** que representam o robô;
2. Geração dos modelos físicos a partir dos modelos **CAD!**;
3. Programação do modelo do robô em UnrealScript;
4. Definição de partes extras, como sensores e atuadores.

10.1.5 Comunicação entre Agentes e USARSim

A comunicação entre agentes e o simulador é feita através de trocas de mensagens **TCP/IP!** seguindo protocolo próprio do **USARSim!**. Todas as mensagens trocadas contêm um tipo e uma lista de segmentos seguindo o formato “TIPO segmento1 segmento2...”, em que:

- TIPO: refere-se ao tipo da mensagem e deve ser escrito em letras maiúsculas. O protocolo define 5 tipos de mensagens: INIT, STA, SEN, DRIVE e CONF;
- Segmentos: são pares nome-valor escritos da forma “nome valor” que representam os dados da mensagem em si. Por exemplo, no caso do segmento “Orientation 0.0,0.0,0.0”, “Orientation” é o nome e “0.0,0.0,0.0” é o valor.

Note que o tipo e a lista de segmentos são separados por um espaço. Os segmentos são também separados entre si por um espaço. Dentro de um segmento, o nome e valor também são separados por um espaço, assim espaços dentro do nome ou do valor não são permitidos. Com isso, o segmento “Orientation 0.0, 0.0, 0.0” é inválido. Para indicar fim de mensagem, deve-se adicionar “\r\n” no final da cadeia de caracteres.

10.2 Robonova-I

O Robonova-I é um modelo de robô humanoide de baixo custo desenvolvido pela empresa japonesa Hitec Robotics (29). A Figura 20 exibe o robô visto de costas e de frente. O Robonova-I é dotado de 16 graus de liberdade, distribuídos da seguinte forma: 3 em cada braço (2 no ombro e 1 no cotovelo) e 5 em cada perna (2 na coxa, 1 no joelho e 2 no pé). A Figura 21 mostra a disposição das juntas, assim como o eixo de rotação de cada uma.



Figura 20: Robonova-I. Extraído de (29).

Cada junta é implementada por um servomotor Hitec HSR-8498HB, apresentado na Figura 22. Tratam-se de servomotores especificamente desenvolvidos para o Robonova-I e são relativamente baratos, o que garante o baixo custo do robô. A Tabela 2 apresenta as principais características do HSR-8498HB.

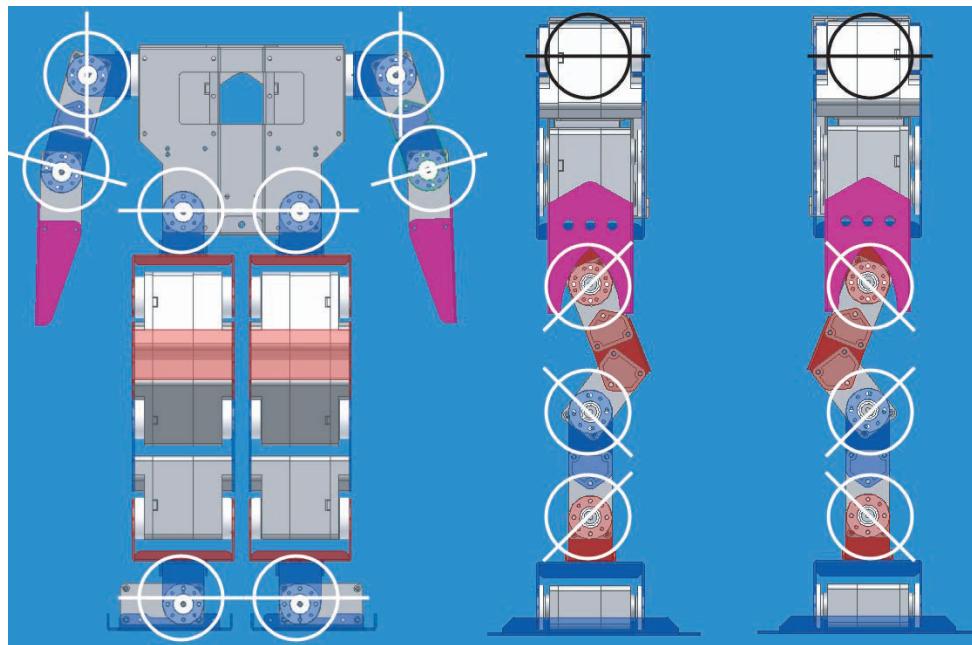


Figura 21: Juntas do Robonova-I. Extraído de (29).



Figura 22: Servomotores Hitec HSR-8498HB. Extraído de (29).

Interface	Protocolo HMI!, PWM!
Voltagem	6,0 V
Velocidade Máxima	60° em 0,20 s @ 6,0 V
Torque	10 kg·cm
Ângulo de Operação	Máximo de 180°
Peso	55 g
Dimensão	40 x 20 x 47 mm

Tabela 2: Especificação dos servomotores Hitec HSR-8498HB. Extraído de (29).

O único sensor que vem juntamente com o kit é um sensor infravermelho, que é instalado na cabeça do robô, para receber comandos de um controle remoto, que também faz parte do kit. Porém, o fabricante produzia alguns tipos de sensores compatíveis, como sensor de toque, girômetro e sensor de luz.

O controle do robô é feito por uma placa MR-C3024, que fica instalada nas costas do robô, conforme mostra a Figura 23. A CPU da placa é um Atmel ATMEGA128, o que é uma limitação caso se deseje ter um robô humanóide completamente autônomo. O ponto forte da MR-C3024 é ter uma capacidade de **E/S!** razoável, principalmente suporte a 24 **PWM!**s, o que é suficiente para controlar todos os 16 servomotores do kit e ainda permite a adição de mais 8. A Tabela 3 resume as características da MR-C3024.

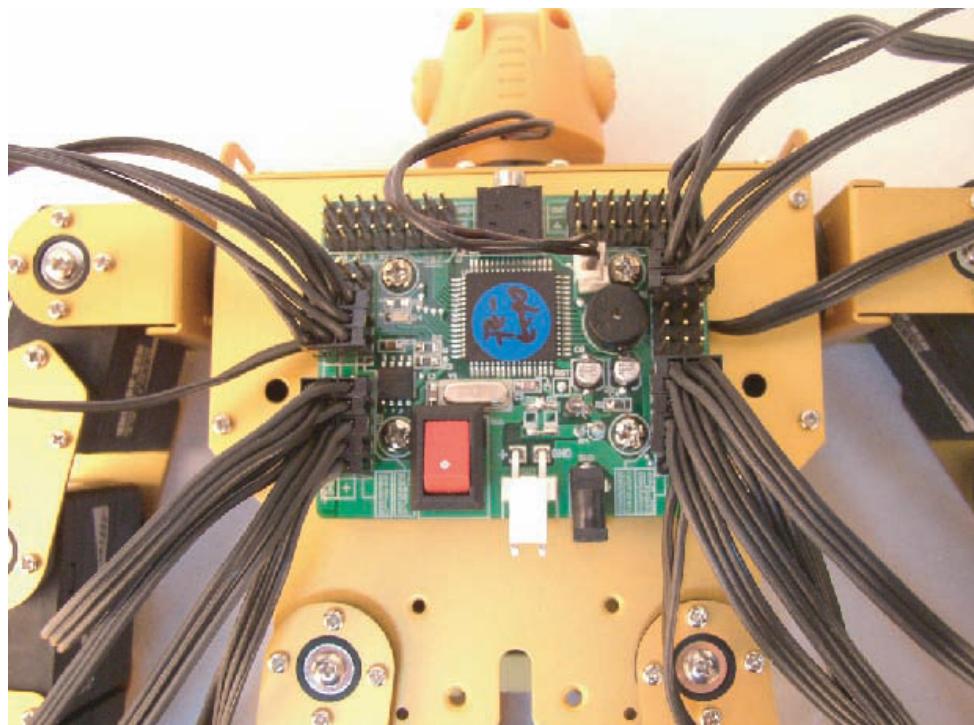


Figura 23: Detalhe das costas do Robonova-I mostrando a placa MR-C3024 instalada. Extraído de (29).

CPU	Atmel ATMEGA128 8bit RISC
Máx Servos	24
Conversores A/D	8
Memória de Programa	32 Kbytes
Peso	0,2 kg
Dimensão	55 x 50 x 15 mm

Tabela 3: Especificação da placa MR-C3024. Extraído de (7).

A programação é feita com uma linguagem proprietária chamada RoboBASIC, especificamente criada para o Robonova-I. A linguagem tem a vantagem de possuir primitivas específicas para utilizar os recursos do Robonova-I e da MR-C3024. A programação feita é passada do PC para a MR-C3024 por comunicação serial RS-232 com uso de um cabo próprio. Outra opção de controle é mandar comandos

via RS-232 para mover diretamente os servomotores seguindo protocolo próprio da MR-C3204 (1).

11 Modelo de Simulação

11.1 Modelos CAD

Os modelos **CAD!** foram confeccionados em um trabalho anterior (22). Os modelos foram construídos com uso do software Autodesk AutoCAD (3) a partir de medidas das peças de do Robonova-I real tomadas com um paquímetro. Cada peça foi feita como um modelo **CAD!** separado.

Em seguida, as peças foram importados no software Autodesk 3D Studio Max (2), onde materiais (gráficos) com padrões de cores simples foram criados e assinalados conforme as cores correspondentes no robô real. As Figuras 24 e 25 apresentam o modelo final montado e o explodido, respectivamente. Como pode-se verificar, teve-se o cuidado de confeccionar o modelo com boa precisão, para que se consiga um comportamento em simulação o mais fiel possível ao robô real.

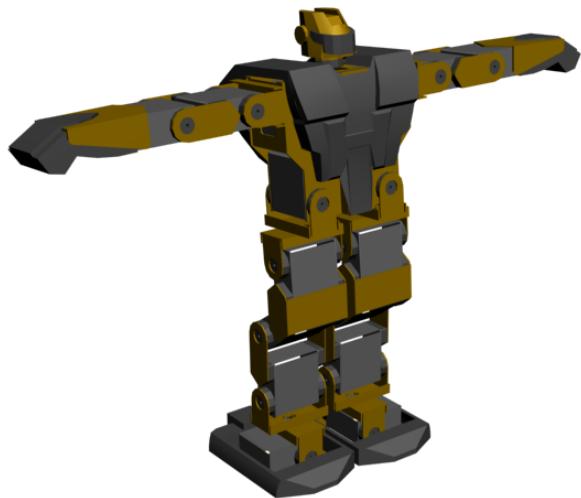


Figura 24: Modelo completo montado do Robonova-I.

Finalmente, cada modelo foi exportado como um arquivo FBX (4) separado, porque esse formato permite importação direta no **UDK!** Editor.

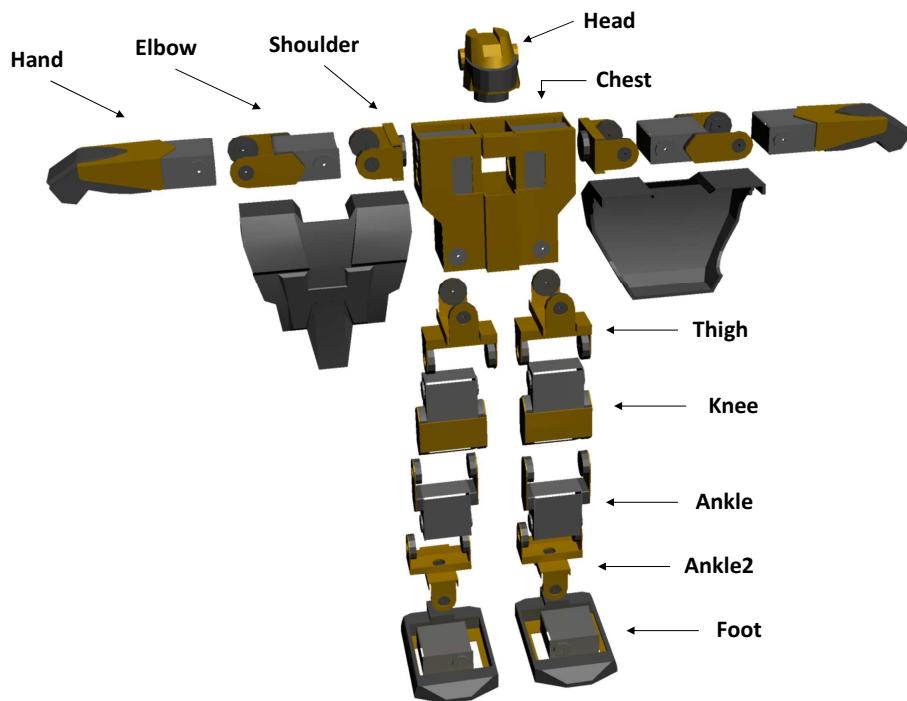


Figura 25: Modelo completo explodido do Robonova-I.

11.2 Configuração no UDK Editor

Para ter-se um modelo de simulação o mais fiel possível à realidade, optou-se pelo método *26-DOF simplified collision* para auto-gerar os modelos físicos a partir dos gráficos.

Embora os materiais já tivessem sido associados às peças anteriormente, foi necessário repetir esse processo dentro do **UDK!** Editor. Após a configuração de todos as peças, exportou-se o conjunto de peças como um pacote UPK (Unreal Package).

11.2.1 Implementação no USARSim

Para concluir a implementação do robô em **USARSim!**, faltava ainda criar a classe do robô em UnrealScript e configurar os sensores. A classe em UnrealScript do Robonova-I foi inspirada na implementação em **USARSim!** do robô Albebaran Nao (40).

As peças foram implementadas como objetos do tipo “Part”, que permite definir o modelo (gráfico e físico), massa e uma posição em relação à origem do robô (ou

Peça (Part)	Massa (g)
Head	27
Chest	337
LeftShoulder	6
LeftElbow	65
LeftHand	65
RightShoulder	6
RightElbow	65
RightHand	65
LeftThigh	23
LeftKnee	135
LeftAnkle	44
LeftAnkle2	23
LeftFoot	83
RightThigh	23
RightKnee	135
RightAnkle	44
RightAnkle2	23
RightFoot	83

Tabela 4: Peças implementadas como objetos do tipo “Part”.

um deslocamento em relação a uma outra Part tomada como “pai”). A Tabela 4 apresenta todas as peças implementadas.

Em seguida, as juntas foram implementadas como juntas de revolução (objetos do tipo “RevoluteJoint”). Um objeto do tipo RevoluteJoint une dois objetos do tipo Part por um eixo de rotação. A Figura 26 mostra os nomes dados às juntas implementadas.

Devido a imprecisões dos modelos físicos, foi necessário desabilitar colisão entre peças adjacentes (considera-se que duas peças são adjacentes se são ligadas por uma junta). As demais colisões foram mantidas ativas.

Para percepção, colocou-se uma câmera na cabeça e sensores de toque nos pés. O **USARSim!** já possui esses sensores implementados, logo foi necessário apenas configurá-los. Além disso, acoplou-se um sensor especial do **USARSim!** chamado “GroundTruth” no tronco do robô. Esse sensor provê posição e orientação globais livres de ruído. Embora essas informações sejam impossíveis de se obter em um robô real, elas são muito úteis em processos de Aprendizado ou Otimização.

A Figura 27 apresenta o Robonova-I dentro do **USARSim!**; os modelos físicos

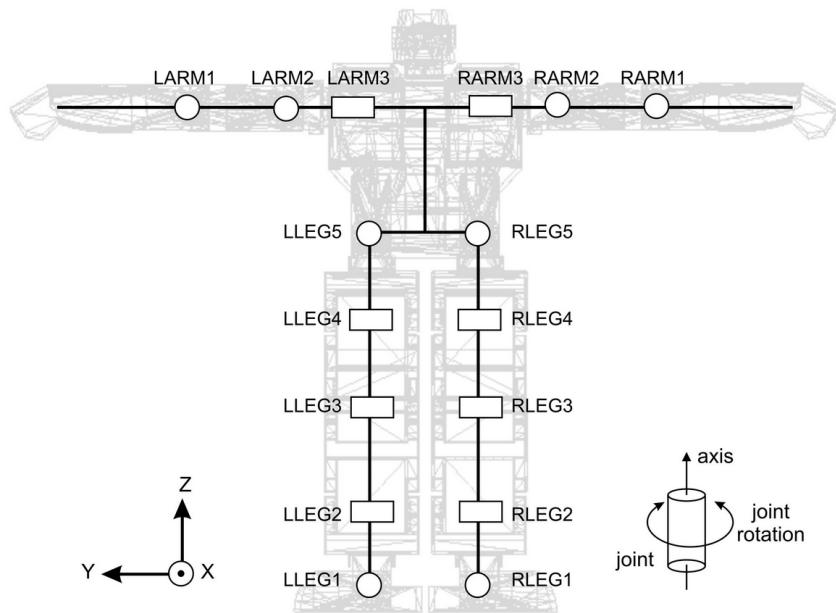


Figura 26: Juntas implementadas no modelo de simulação.

são mostrados em wireframe por linhas rosas. No canto superior esquerdo é mostrada a visualização a partir da câmera do robô.



Figura 27: Robonova-I simulado dentro do **USARSim!**.

12 Programa do Agente

O agente foi implementado em C++ usando a biblioteca Qt (24). Essas tecnologias foram escolhidas pois permitem implementação *cross-platform* e um alto desempenho em tempo de execução. Para permitir que boa parte do código fosse comum entre simulação e robô real, dividiu-se o programa do agente em três camadas (vide Figura 28):

- **Comunicação:** implementa a comunicação de baixo nível com sensores e atuadores. Interface e implementação são diferentes entre simulação e robô real;
- **Interface:** provê uma abstração para sensores e atuadores. Mesma interface na simulação e no robô real, mas implementações diferentes;
- **Controlador:** determina quais posições devem ser enviadas para as juntas do robô a cada momento. Interface e implementação iguais entre simulação e robô real.

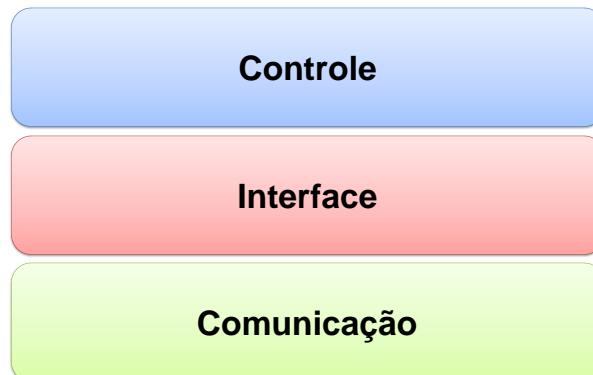


Figura 28: Camadas do programa do agente.

É importante observar que a camada de Interface provê uma abstração para a camada superior (Controle), de modo que, a princípio, pode-se usar o mesmo controlador para o robô simulado e para o real. Já as camadas de Comunicação e de Interface devem ser implementadas em cada plataforma.

Tal arquitetura é suficiente para os propósitos desse trabalho. Todavia, caso deseje-se que o robô realize tarefas mais complexas, como jogar futebol, as seguintes alterações são interessantes:

- Adição de um componente de **Modelo** à camada de Controle. Esse componente seria responsável por processar as percepções e gerar modelos mais elaborados sobre o mundo e sobre o agente, de modo a prover informações importantes, como posições globais do agente, de outros agentes e de objetos. Com isso, seria adequado passar a chamar essa nova camada de **Modelo e Controle**;
- Adição de uma camada de **Cognição**, que deveria ficar acima das demais. Tal camada trataria de, a partir dos modelos providos pelo componente de Modelo, determinar o melhor movimento (andar, girar o corpo, levantar-se etc.) a ser executado e notificar a camada de Controle disto.

A seguir, cada camada efetivamente implementada é detalhada. Nisso, deve-se destacar um fato: fazia parte do plano inicial utilizar o mesmo programa de agente no robô simulado e no real, tanto que a arquitetura explicada foi idealizada de modo a permitir isso. Entretanto, o único *hardware* de processamento disponibilizado foi a placa original do Robonova-I (MR-C3204) que é muito limitada e permite programação apenas em linguagem RoboBASIC. Com isso, implementou-se o programa de agente aqui descrito apenas na simulação.

Embora isto torne a separação do programa em camadas irrelevante para a proposta deste trabalho, esta arquitetura ainda é interessante para servir como base para futuros trabalhos em que se possua o *hardware* de processamento necessário.

12.1 Comunicação

A camada de comunicação implementa a comunicação direta de baixo nível com sensores e atuadores. Como essa comunicação difere muito entre robô simulado e

real, é difícil estabelecer padrões para essa camada, portanto considerou-se interface e implementação diferentes entre as duas plataformas.

Para a simulação, essa camada deve consistir de um socket **TCP/IP!** para comunicação com o servidor e de um *parser* para transformar as mensagens brutas recebidas em uma estrutura mais fácil de lidar. Desse modo, a implementação é composta por duas classes:

- USARSocket: implementa um socket **TCP/IP!** para comunicação com o servidor do **USARSim!**. Faz a separação dos dados recebidos na comunicação em mensagens usando a indicação de fim de mensagem “\r\n”, como especificado no protocolo. A funcionalidade de socket propriamente dita é herdada de QTcpSocket, que a implementa de modo *cross-platform*;
- USARMessage: representa uma mensagem que segue o protocolo do USAR-Sim. A classe possui dois construtores: um que faz o *parsing* de uma mensagem bruta recebida do servidor e a separada em seus constituintes (tipo e segmentos) e outro que recebe os constituintes e gera uma mensagem no protocolo esperado pelo servidor.

12.2 Interface

Esta camada trata as estruturas intermediárias recebidas da camada de Comunicação e provê uma abstração para sensores e atuadores independente de se o programa está sendo executado no robô simulado ou no real. Como a camada lida com estruturas da camada de Comunicação, a implementação tem de ser diferente entre as duas plataformas. Porém, como a intenção é prover uma abstração independente de plataforma para a camada de Controle, a interface deve ser a mesma entre robô simulado e real.

Para conseguir esse efeito, o mecanismo usado em Orientação a Objetos é criar classes abstratas para representar a interface e então criar classes concretas que herdam destas classes abstratas e que implementam as funcionalidades desejadas em cada caso. Portanto, criou-se as seguintes classes abstratas:

- RobotPerceptor: funciona como uma espécie de sensor especial que contém informações do corpo do robô, como nível da bateria e posições das juntas;

- Sensor: representa um sensor genérico. Sensores devem ser implementados através de especialização desta classe, com exceção do RobotPerceptor;
- Perception: provê uma interface única para toda a percepção;
- Action: representa uma ação genérica. Não inclui comandos para as juntas;
- ActionHandler: provê uma interface única para toda a atuação (incluindo as juntas).

No robô simulado, essa camada tem basicamente duas responsabilidades. No lado da percepção, deve interpretar as estruturas do tipo USARMessage da camada de Comunicação e atualizar o estado interno do agente. Em relação à atuação, deve receber uma requisição para movimentação de junta e criar uma estrutura do tipo USARMessage que será passada para a camada de Comunicação. Para isso, as principais classes criadas foram:

- GroundTruth: implementa sensor GroundTruth. Sensor exclusivo do robô simulado;
- USARPerception: implementação concreta de Perception. Interpreta uma USARMessage recebida da camada de Comunicação e atualiza o estado interno do robô;
- InitAction: inicia um modelo de robô na simulação;
- GetStartPosesAction: requisita ao servidor as localizações padrões em que o robô pode ser iniciado no mapa em questão;
- ReconnectAction: reconecta o agente ao simulador;
- USARActionHandler: implementação concreta de ActionHandler. Recebe ações (incluindo movimentação de junta), cria uma USARMessage correspondente e a envia para a camada de Comunicação.

12.3 Controle

O objetivo desta camada é implementar os movimentos do robô humanóide a partir do controle de suas juntas. Como a camada de Interface provê uma abstração

para sensores e atuadores, o código desta camada pode ser o mesmo tanto no robô simulado quanto no simulado (considerando que o comportamento físico do robô simulado seja próximo o suficiente do real).

Dado o escopo do trabalho, implementou-se apenas um controlador para a caminhada do robô. Porém, a implementação feita já provê uma estrutura para implementações futuras de novos movimentos, como girar o corpo, levanta-se, chutar uma bola etc. As principais classes criadas foram:

- TFSGaitController: controlador para caminhada baseada em **SFT!** (**SFT!**);
- TFSGaitGenerator: classe abstrata que representa um gerador de caminhada baseada em **SFT!**. Dado o instante de tempo atual, gera as posições das juntas a partir das equações do modelo de caminhada.

13 Processo de Otimização

13.1 Modelos de Caminhada

Para verificar os efeitos da adição de movimento de braços e movimento no plano coronal, decidiu-se por implementar geradores para os 3 modelos propostos por Shafii (32, 33, 34), conforme explicitado no Capítulo ??.

Entretanto, após alguns testes, optou-se por modificar a função proposta por Shafii para os ombros. A modificação proposta envolve considerar que as amplitudes no sentido positivo e negativo podem ser diferentes para o movimento do braço, assim como é feito para a perna no sentido frente-trás. Desse modo, $\theta_o(t)$ passa a ser descrita pela equação (13.1).

$$\theta_o(t) = \begin{cases} -D_- \sin\left(\frac{2\pi t}{T}\right), & t \in \left[kT, \frac{T}{2} + kT\right), k \in \mathbb{Z} \\ -D_+ \sin\left(\frac{2\pi t}{T}\right), & t \in \left[\frac{T}{2} + kT, (k+1)T\right), k \in \mathbb{Z} \end{cases} \quad (13.1)$$

Note que essa modificação aumenta em 1 o número de constantes a serem determinadas para os modelos que possuem movimento de braços. Portanto, os modelos de caminhada implementados são os seguintes:

- Modelo Simples (MS): usa apenas as juntas na direção frente-trás das pernas;
- Modelo com Movimento de Braços (MB): além das juntas do “Modelo Simples”, utiliza as juntas do ombro (com trajetória para o ombro esquerdo definida pela equação (13.1));
- Modelo Complexo (MC): além das juntas do Modelo com “Movimento de Braços”, adiciona as juntas da coxa no sentido lateral (plano coronal).

Junta nos Modelos Teóricos	Junta no Robonova
Coxa Frente-trás Esquerda	LLEG4
Joelho Esquerdo	LLEG3
Pé Frente-trás Esquerdo	LLEG2
Ombro Esquerdo	LARM3
Coxa Lateral Esquerda	LLEG5
Pé Lateral Esquerdo	LLEG1
Coxa Frente-trás Direita	RLEG4
Joelho Direito	RLEG3
Pé Frente-trás Direito	RLEG2
Ombro Direito	RARM3
Coxa Lateral Direita	RLEG5
Pé Lateral Direito	RLEG1

Tabela 5: Mapeamento das juntas dos modelos teóricos para as do Robonova (veja a Figura 26 para nomenclatura utilizada para as juntas do Robonova).

Observe que o Robonova possui os graus de liberdade necessários para implementar os 3 modelos. A Tabela 5 apresenta o mapeamento feito das juntas do modelo teórico para as do Robonova (veja a Figura 26 para nomenclatura utilizada para as juntas do Robonova).

13.2 Configuração dos Algoritmos de Otimização

Um algoritmo de Otimização fornece um *framework* para resolução de problemas de otimização, mas deve-se definir o que significa certos elemento do algoritmo para o problema em específico.

O problema de Otimização em questão envolve a determinação de constantes reais relacionada ao modelo de caminhada. É interessante definir um domínio para cada uma das constantes a fim de evitar valores sem sentido para o problema (que resultem em ângulos ou velocidades além do domínio de operação dos servomotores ou que certamente levem à queda do robô). Após testes manuais, determinou-se os limites para as constantes do modelo apresentados na Tabela 6 (as equações (??), (??), (13.1) e (??) apresentam detalhes sobre as constantes mencionadas).

Constante	Mínimo	Máximo
O_c	-1,5	0
A	0,01	1,0
B	0,01	1,0
O_j	0	2,0
C	0	1,0
$\tau = t_2/T$	0,1	0,9
T	0,1	0,7
D_+	0	0,6
D_-	0	0,6
E	0	0,5

Tabela 6: Limites para os valores das constantes dos modelos de caminhada.

13.2.1 Configuração do Algoritmo Genético

A seguir, são apresentados como os conceitos de **AG!** são definidos no problema em específico:

- Cromossomo: a escolha mais óbvia para a definição de cromossomo é um vetor com as constantes, em que cada gene representa uma constante;
- Função de *fitness*: explicitada a seguir, na Seção 13.3;
- Mutação: altera um gene (no caso, uma das constantes) por um valor real aleatório dentro dos limites da Tabela 6.

Os demais conceitos de AG (seleção, crossover e sobrevivência dos mais aptos) saem naturalmente da definição de cromossomo.

Por fim, a Tabela 7 apresenta os valores dos parâmetros usados nas execuções de **AG!**.

Parâmetro	Valor
S_i	20
S_m	20
R	10
p_m	0,05

Tabela 7: Valores dos parâmetros usados nas execuções de **AG!**.

13.2.2 Configuração do Particle Swarm Optimization

A escolha natural é considerar que cada partícula em um espaço n -dimensional, em que n é o número de constantes a serem determinadas. Assim, cada posição de partículas é um vetor de constantes. O espaço de busca é dado pelos limites da Tabela 6. Já a função de medida de qualidade é apresentada na Seção 13.3.

No **PSO!** pode ocorrer das partículas atingirem velocidades muito altas e saírem do espaço de busca. Para evitar esses problemas, fez-se modificações no **PSO!** apresentado na Seção 9.2. Primeiramente, logo após a atualização de velocidade de uma partícula, limita-se sua velocidade com uso da equação (13.2).

$$\mathbf{v}_i(d) \leftarrow \min(\mathbf{u}(d) - \mathbf{l}(d), \max(\mathbf{l}(d) - \mathbf{u}(d), \mathbf{v}_i(d))), d = 1, \dots, D \quad (13.2)$$

A outra modificação busca forçar as partículas a permanecerem sempre dentro do espaço de busca. Para tal, considera-se que as partículas sofrem “choques mecânicos inelásticos” ao tentarem cruzar os limites do espaço de busca. A partir desta inspiração da Mecânica, criou-se a subrotina apresentada no Algoritmo 3, que é executada logo após ser aplicada a limitação de velocidade. Note que o uso dessa subrotina introduz o parâmetro ε , ao qual deu-se a denominação de “coeficiente de

restituição” para seguir a analogia mecânica.

Algoritmo 3: Subrotina que simula “choques” das partículas com os limites do espaço de busca.

```

begin
  for  $i \leftarrow 1, \dots, P$  do
    for  $d \leftarrow 1, \dots, D$  do
      if  $x_i(d) > u(d)$  then
         $\delta \leftarrow x_i(d) - u(d);$ 
         $x_i(d) \leftarrow \varepsilon(u(d) - \delta);$ 
         $v_i(d) \leftarrow -\varepsilon v_i(d);$ 
      end
      if  $x_i(d) < l(d)$  then
         $\delta \leftarrow l(d) - x_i(d);$ 
         $x_i(d) \leftarrow \varepsilon(l(d) + \delta);$ 
         $v_i(d) \leftarrow -\varepsilon v_i(d);$ 
      end
    end
  end
end

```

Por fim, a Tabela 8 apresenta os valores dos parâmetros usados nas execuções de **PSO!**.

Parâmetro	Valor
P	20
ω	0,9
φ_p	0,6
φ_g	0,8
ε	0,7

Tabela 8: Valores dos parâmetros usados nas execuções de **PSO!**.

13.3 Montagem do Experimento Simulado

Para utilizar um algoritmo de Otimização para o “aprendizado” das melhores constantes para os modelos de caminhada, é necessário montar um experimento em que seja dado ao robô um período de tempo para tentar andar e depois seja

aplicada uma métrica para avaliação do desempenho da caminhada com o dado conjunto de constantes.

O mapa do simulador escolhido para os experimentos foi o “ExampleMap” (vide Figura 29), porque possui uma grande área com terreno plano e sem presença de obstáculos. A localização escolhida para iniciar o robô no mapa foi a “RobotStart1”, que é onde o robô se encontra na Figura 29.

Como o robô inicia com as juntas em posições diferentes das posições neutras da caminhada (quando os senos valem zero), adicionou-se um tempo de preparação em que os ângulos das juntas são interpolados linearmente das posições iniciais para as neutras da caminhada. Experimentalmente, verificou-se que 1,5 segundo era adequado para esse tempo de ajuste.

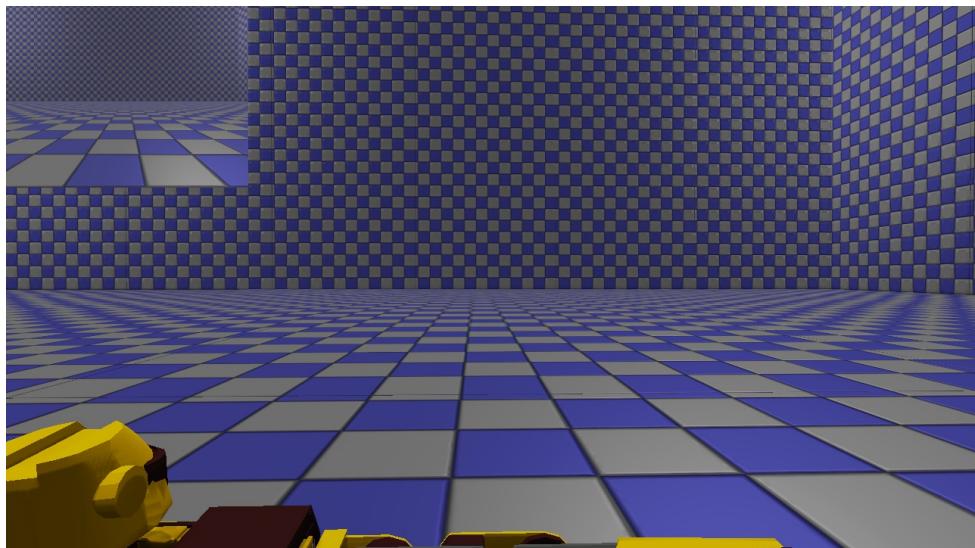


Figura 29: ExampleMap.

Depois, deixava-se o robô andar por 20 segundos, o que podia ser interrompido prematuramente caso o robô caísse. Considera-se queda se a orientação do robô passar de 0,6 radianos em relação aos eixos X ou Y (vide Figura 30). Por fim, media-se o desempenho do robô. Em resumo, cada experimento de simulação segue os passos:

1. Iniciar o Robonova na localização “RobotStart1”;
2. Esperar 1,5 segundo para preparação;
3. Esperar 20 segundos ou o robô cair, o que ocorrer primeiro;
4. Calcular desempenho com a equação (13.3).

$$D = (x - x_o) - |y - y_o| + 0,1 \times \Delta t - \sum P_i \quad (13.3)$$

Na equação (13.3), (x_o, y_o) e (x, y) são respectivamente as posições inicial e final do robô no plano do mapa; o sistema de coordenadas usado é o mostrado na Figura 30. Δt é a quantidade tempo (em segundos) que o robô permaneceu sem cair. $\sum P_i$ representa o somatório das possíveis punições (mostradas na Tabela 9). O objetivo das punições é tratar casos muito indesejados.

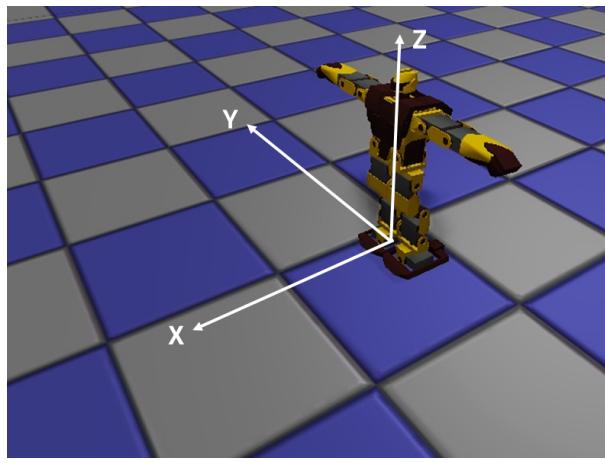


Figura 30: Sistema de coordenadas no USARSim.

Punição	Significado	Valor
P_1	Queda	50
P_2	Posição inicial instável	80
P_3	Praticamente não se moveu	60

Tabela 9: Limites para os valores das constantes dos modelos de caminhada.

Após algumas execuções dos experimentos simulados, verificou-se o seguinte:

- Percebeu-se que havia uma dificuldade grande do robô romper a transição brusca de quando ele estava parado para o primeiro passo. Ocorria com frequência de uma caminhada que se tornava bem estável quando o robô entrava em regime cair no primeiro passo;
- Às vezes, ocorria de uma caminhada pouco estável, mas muito rápida, ter a sorte de se manter em pé durante os 20 segundos do teste e receber uma avaliação muito boa. Isto era problemático principalmente para o **PSO!**, que é fortemente guiado pelo melhor desempenho encontrado.

Para resolver estes dois problemas, implementou-se duas heurísticas propostas em (34):

- Ao invés de começar o movimento já com as amplitudes no máximo, no começo do movimento reduz-se todas as amplitudes dos movimentos por um fator que aumenta linearmente de 0 a 1. Após alguns testes, determinou-se que uma duração de 3 períodos (3 primeiros passos) era adequada para este tempo. Ou seja, o robô começa dando passos curtos e vai aumentando o tamanho do passo gradativamente até atingir o valor de regime;
- Ao invés de usar o desempenho de uma única execução do experimento para alimentar a otimização, passou-se a utilizar uma média de 3 execuções.

13.4 Resultados e Discussões

A Tabela 10 apresenta os resultados dos experimentos. Como **AG!** e **PSO!** envolvem aleatoriedade, o mais justo para comparação seria realizar diversas execuções de cada algoritmo para cada modelo de caminhada e tirar uma média. Entretanto, isso exigiria uma disponibilidade de poder de processamento bem superior à que o autor tinha disponível. Assim, cada linha da Tabela 10 se refere a uma única instância de execução. Apesar disso, acredita-se que os resultados apresentados permitem fazer as seguintes considerações qualitativas:

- A adição de movimento de braços provoca melhora na qualidade da caminhada (se os parâmetros estiverem ajustados corretamente);
- A adição de movimento no plano coronal provoca melhora ainda maior na qualidade da caminhada (novamente, se os parâmetros estiverem ajustados corretamente);
- Quanto mais parâmetros são adicionados ao modelo, mais difícil é a convergência dos algoritmos, como esperado.

As Figuras 31, 32 e 33 apresentam como varia o melhor *fitness* até então pelo número de testes para experimentos com AG. As Figuras 34, 35 e 36 fazem o mesmo para o PSO. A Tabela 11 exibem os melhores conjuntos de parâmetros encontrados para cada caso.

Algoritmo de Otimização	Modelo de Caminhada	Melhor Desempenho	Número de Testes
AG	Simples	6,16	1585
AG	Com Movimento de Braços	8,3	1678
AG	Complexo	5,77	1636
PSO	Simples	5,58	860
PSO	Com Movimento de Braços	7,2	1449
PSO	Complexo	7,99	1493

Tabela 10: Resultados dos Experimentos.

Constante	MS+AG	MB+AG	MC+AG	MS+PSO	MB+PSO	MC+PSO
O_c	-0,69	-1,2	-0,96	-0,64	-0,66	-0,87
A	0,23	0,33	0,37	0,27	0,5	0,51
B	0,43	0,37	0,68	0,35	0,56	0,7
O_j	0,98	1,6	0,99	0,85	0,83	1,23
C	0,4	0,51	0,76	0,3	0,6	0,46
$\tau = t_2/T$	0,38	0,25	0,22	0,39	0,38	0,34
T	0,34	0,1	0,4	0,44	0,39	0,38
D_+	-	0,58	0,58	-	0,17	0,54
D_-	-	0,14	0,55	-	0,57	0,39
E	-	-	0,04	-	-	0,05

Tabela 11: Limites para os valores das contantes dos modelos de caminhada.

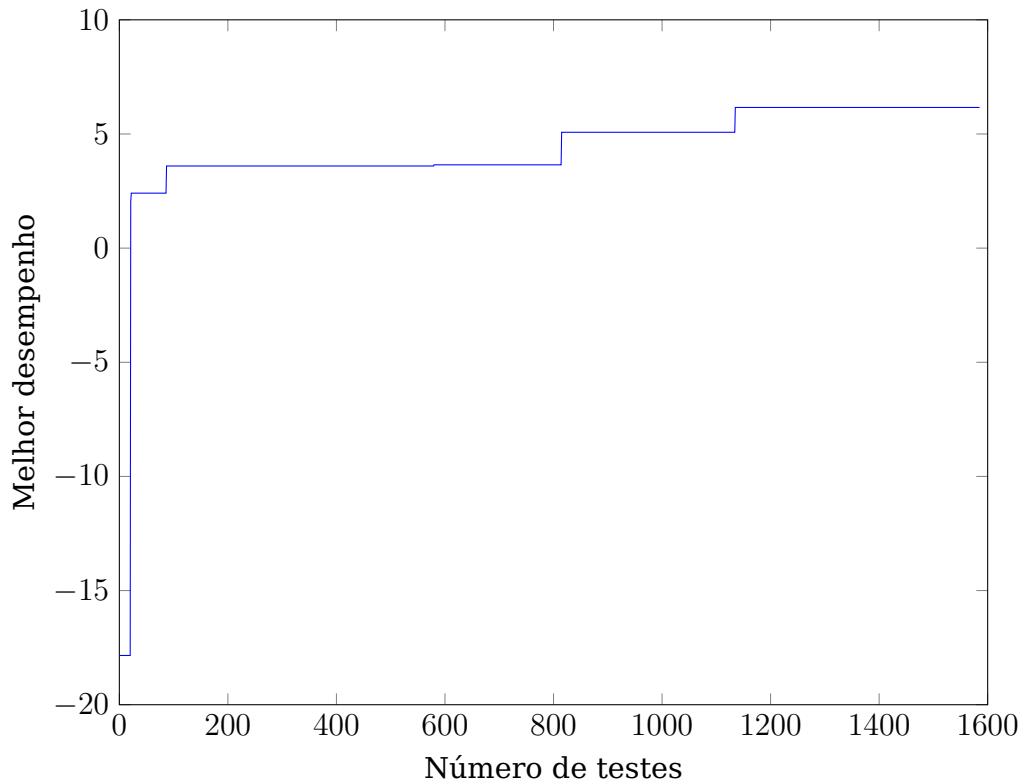


Figura 31: Resultados da otimização com Modelo Simples e **AG!**.

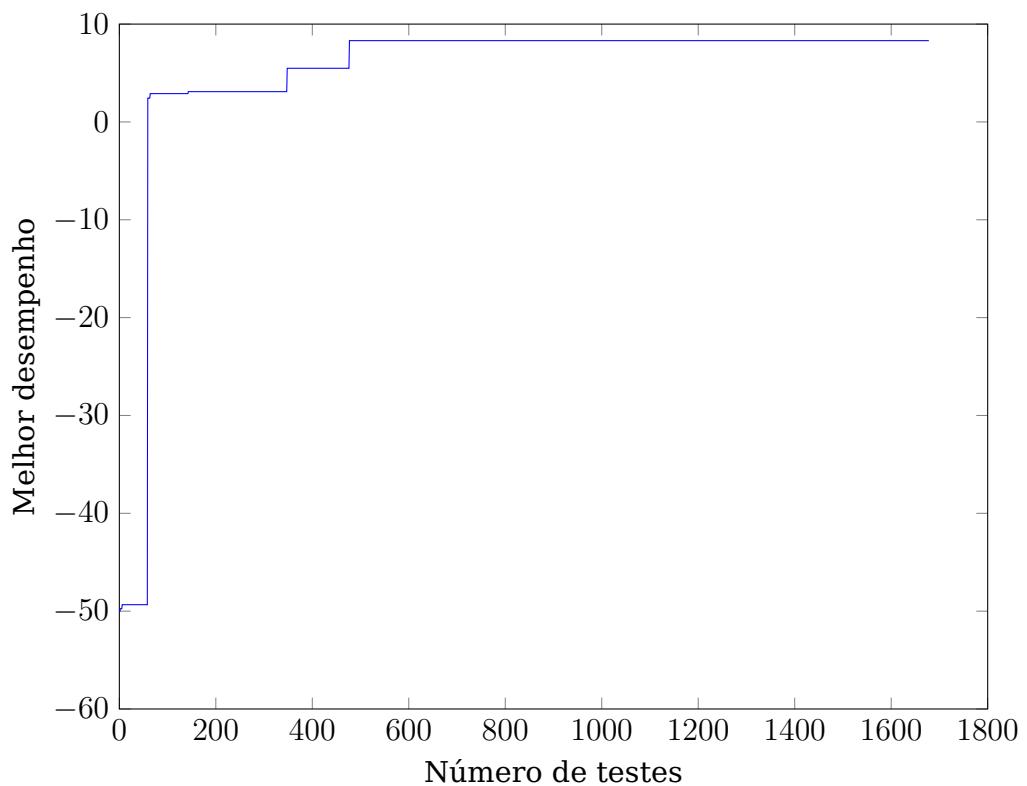


Figura 32: Resultados da otimização com Modelo com Movimento de Braços e **AG!**.

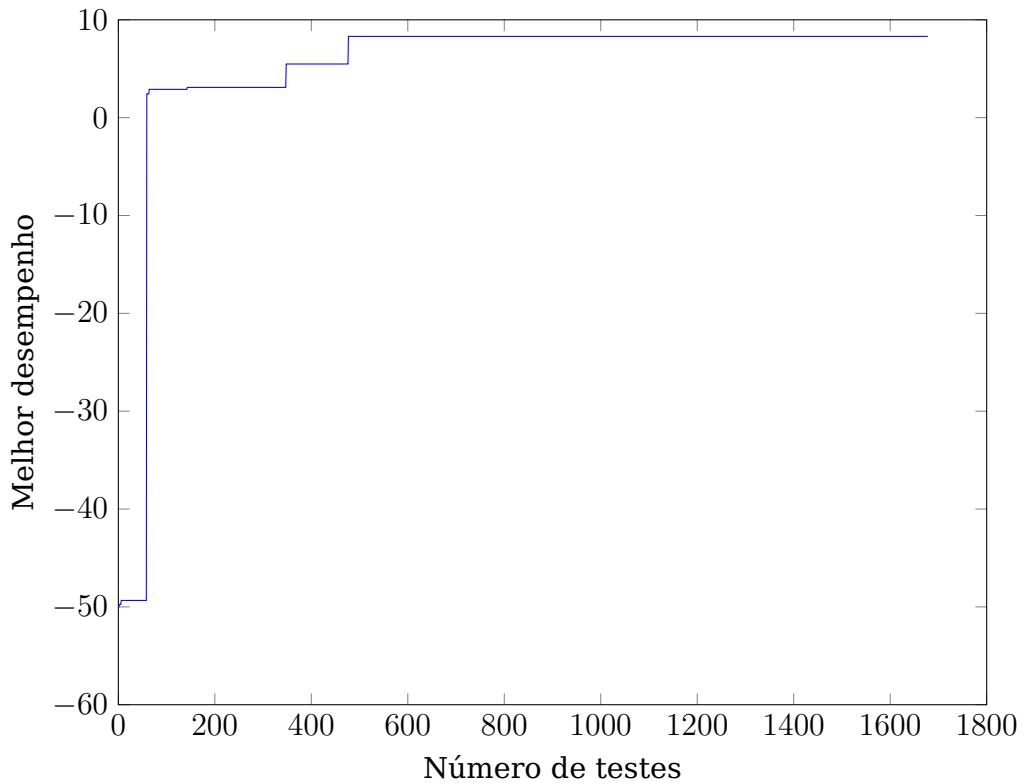


Figura 33: Resultados da otimização com Modelo Complexo e **AG!**.

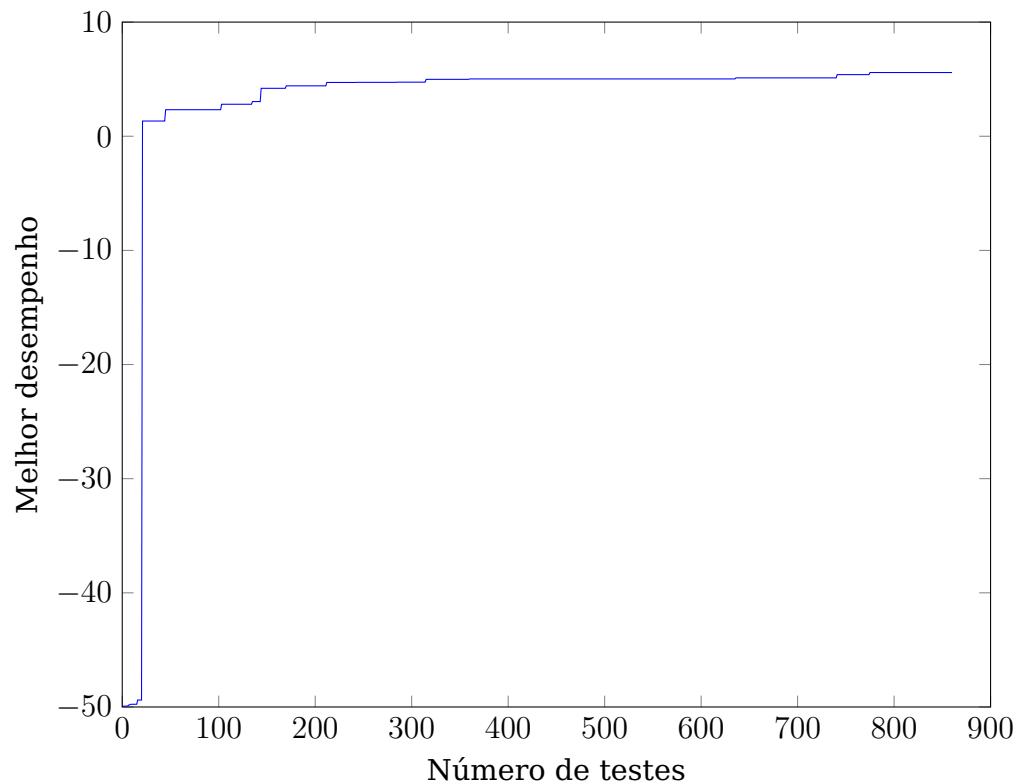


Figura 34: Resultados da otimização com Modelo Simples e **PSO!**.

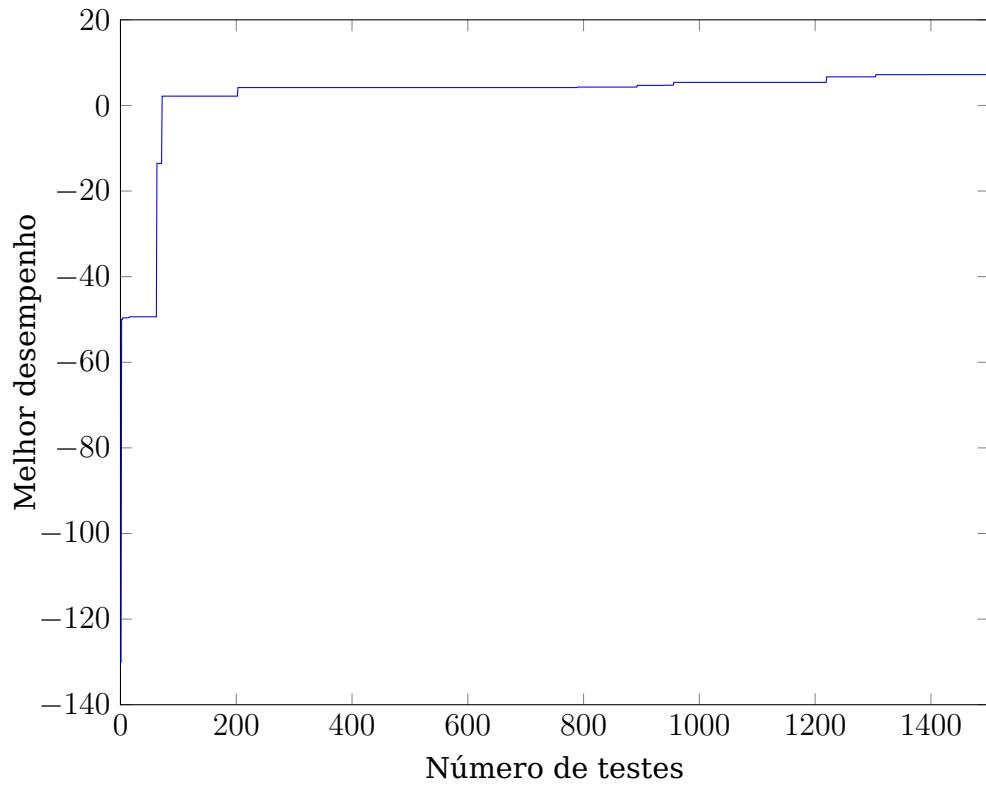


Figura 35: Resultados da otimização com Modelo com Movimento de Braços e **PSO!**.

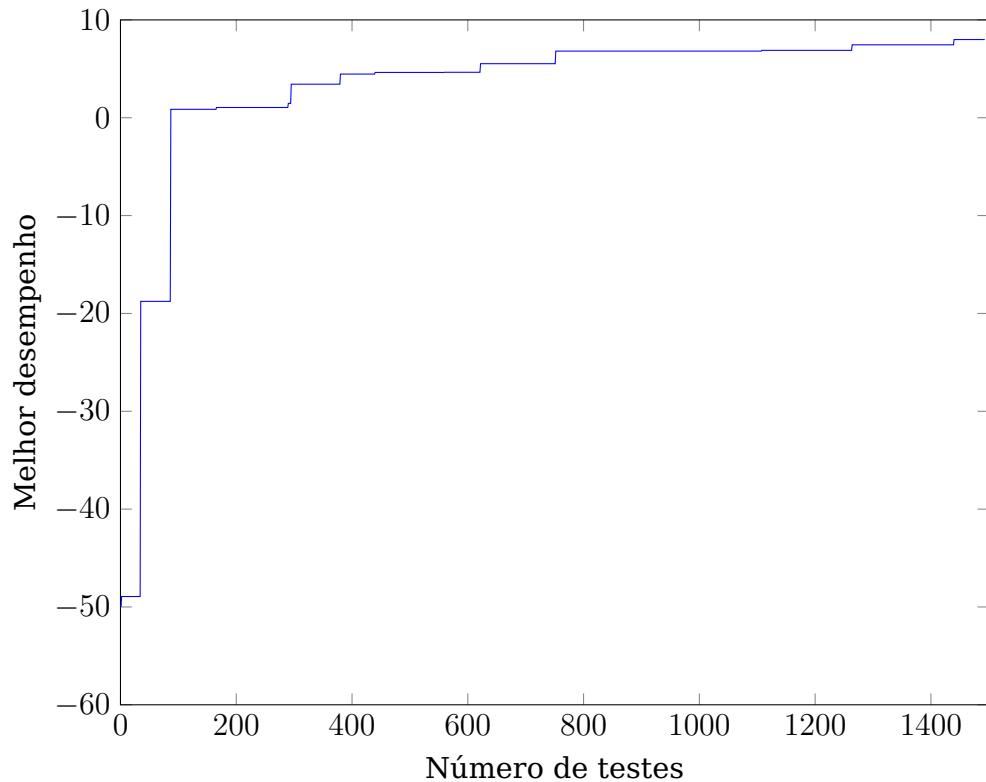


Figura 36: Resultados da otimização com Modelo Complexo e **PSO!**.

Por fim, as Figuras 37, 38 e 39 apresentam sequências de imagens para ilustrar a visualização das caminhadas aprendidas com **PSO!** para cada modelo. A taxa de quadros utilizada para a gravação foi de 15 quadros por segundo.

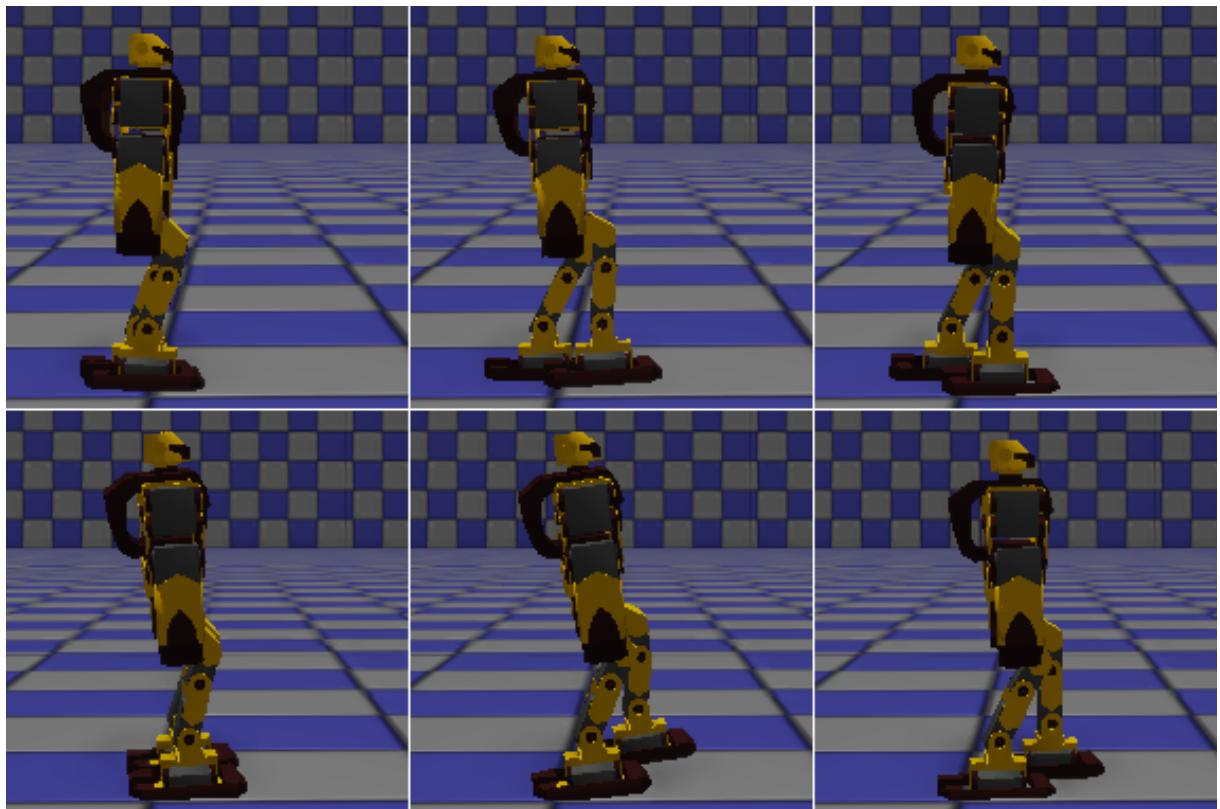


Figura 37: Sequência de imagens para ilustrar a caminhada aprendida com Modelo Simples e **PSO!**.



Figura 38: Sequência de imagens para ilustrar a caminhada aprendida com Modelo com Movimento de Braços e **PSO!**.

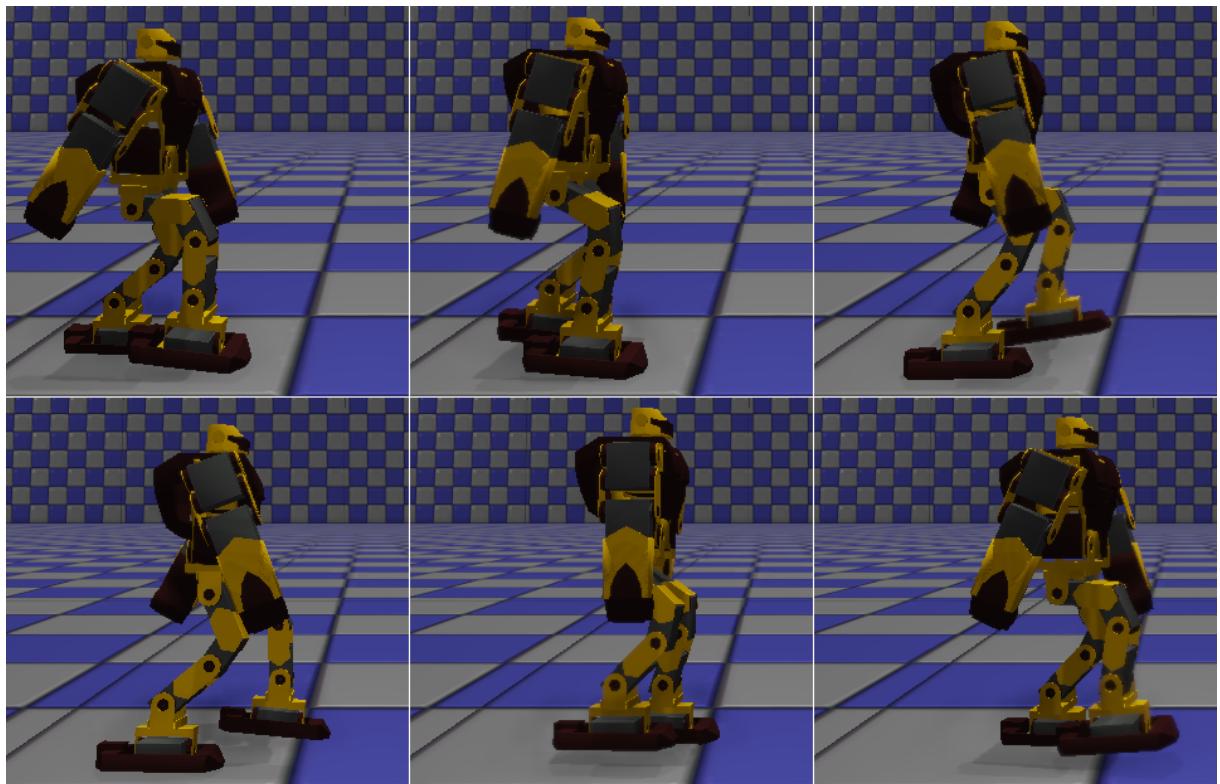


Figura 39: Sequência de imagens para ilustrar a caminhada aprendida com Modelo Complexo e **PSO!**.

14 Transferência para o Robô Real

14.1 Desafios Envolvidos

Apesar do cuidado tomado em fazer um modelo físico o mais próximo possível do real e da PhysX ser uma das melhores engines de Física da atualidade, há diversas limitações na modelagem que não foram tratadas:

- Modelos físicos são aproximações dos modelos CAD;
- O coeficiente de atrito do solo usado para otimização no simulador não é necessariamente o mesmo que um solo em que o robô real caminhará;
- Embora sejam todos do mesmo modelo, os servomotores do robô real possuem pequenas diferenças de torque e velocidade devido a questões de construção;
- No robô real, existem folgas mecânicas que não são modeladas na simulação.

Locomoção humanóide é um problema complexo em que pequenas variações nas condições como as citadas acima podem tornar o comportamento muito diferente. Assim, espera-se que a caminhada com os parâmetros aprendidos em simulação não tenha um desempenho tão bom no robô real, mas que, após alguns ajustes manuais, obtenha-se uma boa solução para o problema.

14.2 Processo de Transferência

Como comentado na Seção ??, o plano inicial era utilizar o mesmo código C++ tanto em simulação quanto no robô real. Para isso, esperava-se substituir a placa original do Robonova (MR-C3024) por uma placa Gumstix (16). Esta placa roda uma versão embarcada do sistema operacional Linux, o que permitiria compilar e executar a maior parte do código do controlador construído para o robô simulado.

Infelizmente, não foi possível obter esse hardware. Desse modo, alterou-se o plano para programação na MR-C3024.

A programação para a MR-C3024 deve ser feita em RoboBASIC, conforme comentado na Seção 10.2. O recursos dessa linguagem são bem limitados e ela não possui suporte ao uso direto da função seno, que é necessária para a implementação das equações que descrevem as trajetórias angulares das juntas.

Portanto, decidiu-se criar um programa em linguagem C# que, a partir das equações do modelo de caminhada e um passo de tempo, gera código em RoboBASIC com os valores numéricos para as posições das juntas já calculados. O código gerado é formado basicamente por dois comandos da RoboBASIC: o MOVE, que envia novas posições para todos os servomotores, e DELAY, que bloqueia a execução por um tempo em milisegundos. A Listagem 14.1 mostra o código gerado para a caminhada com Modelo com Movimento de Braços.

Listagem 14.1: Código em RoboBASIC para a caminhada de Modelo com Movimento de Braços.

```
' 3 PASSOS INICIAIS

MOVE24 ,79,140,90, , ,100, , , , ,100, , , , , ,82,137,90, ,
DELAY 20
MOVE24 ,81,140,87, , ,101, , , , ,96, , , , , ,80,137,92, ,
DELAY 20
MOVE24 ,82,137,90, , ,100, , , , ,100, , , , , ,79,140,90, ,
DELAY 20
MOVE24 ,80,137,92, , ,96, , , , ,101, , , , , ,81,140,87, ,
DELAY 20
MOVE24 ,79,140,90, , ,100, , , , ,100, , , , , ,86,133,90, ,
DELAY 20
MOVE24 ,84,140,85, , ,102, , , , ,92, , , , , ,81,134,93, ,
DELAY 20
MOVE24 ,86,133,90, , ,100, , , , ,100, , , , , ,79,140,90, ,
DELAY 20
MOVE24 ,81,134,93, , ,92, , , , ,102, , , , , ,84,140,85, ,
DELAY 20
MOVE24 ,79,140,90, , ,100, , , , ,100, , , , , ,89,130,90, ,
DELAY 20
MOVE24 ,86,140,82, , ,103, , , , ,88, , , , , ,83,131,95, ,
```

```

DELAY 20
MOVE24 ,89,130,90, ,100, , , , ,100, , , , , ,79,140,90, ,
DELAY 20
MOVE24 ,83,131,95, ,88, , , , ,103, , , , , ,86,140,82, ,
DELAY 20

' MOVIMENTO PERIÓDICO

walk_loop:

MOVE24 ,79,140,90, ,100, , , , ,100, , , , , ,89,130,90, ,
DELAY 20
MOVE24 ,89,140,80, ,103, , , , ,84, , , , , ,84,127,97, ,
DELAY 20
MOVE24 ,92,127,90, ,100, , , , ,100, , , , , ,79,140,90, ,
DELAY 20
MOVE24 ,84,127,97, ,84, , , , ,103, , , , , ,89,140,80, ,
DELAY 20

GOTO walk_loop

```

Testes foram feitos para avaliar a velocidade de resposta do microcontrolador e dos servomotores na prática. Com os servomotores em velocidade máxima, determinou-se 20 milisegundos como um bom passo de tempo. Passos menores faziam os servomotores vibrarem excessivamente durante a operação.

Com isso, a primeira tentativa foi tentar a caminhada com “Modelo Simples” com os parâmetros aprendidos em simulação. A caminhada funcionou, mas o desempenho foi bem inferior ao da simulação: a caminhada ficou lenta, pouco estável (robô caia com frequência) e curvava excessivamente para a direita.

Através de alguns testes foi possível perceber que apenas a redução do período já melhorava a qualidade da caminhada. Empiricamente, chegou-se ao valor de 0,08 segundos como adequado para o período. A caminhada assim obtida mostrou-se bem estável, de modo que quedas se tornaram raras quando em solo plano.

Entretanto, ainda verificou-se que ela curvava muito. Atribui-se isso principalmente ao deslizamento no solo devido a uma amplitude muito grande dos passos. Desse modo, testes foram realizados reduzindo-se os valores das amplitudes de to-

das as juntas percentualmente até encontrar um percentual de 60% de redução como adequado. A velocidade da caminhada assim obtida foi de 18,08 cm/s.

Então, implementou-se movimento de braços e verificou-se uma melhora de desempenho, com a velocidade passando a 21,49 cm/s. Também, a trajetória do robô passou a curvar menos.

A Tabela 12 resume as velocidades as velocidades da caminhada com os diferentes modelos. Para efeitos de comparação, mostra-se também as velocidades das caminhadas originais do kit Robonova e de uma versão melhorada disponível em (30). Observe que a caminhada final gerada nesse trabalho supera em velocidade todas as outras testadas. A Figura 40 apresenta uma sequência de imagens que ilustra a caminhada após todas as modificações feitas.



Figura 40: Sequência de imagens para ilustrar a caminhada final do Robonova real. A taxa de quadros usada para gravação foi de 30 quadros por segundo.

As medidas das velocidades das caminhadas foram feitas a partir de quanto o robô conseguia caminhar em 5 segundos. 10 testes foram feitos para cada tipo de caminhada. As medidas de distância foram feitas com uso de uma trena no chão e as de tempo com uso de um cronômetro digital. A Figura 41 mostra o ambiente do experimento montado.

Caminhada	Média da Velocidade (cm/s)	Desvio Padrão da Velocidade (cm/s)	Número de Quedas (em 10 testes)
Modelo Simples	18,08	1,05	0
Modelo com Movimento de Braços	21,49	0,9	0
Forward Walk (fabricante)	2,7	0,25	0
Fast Walk (fabricante)	6,35	3,12	5
New Fast Walk (30)	19,2	1,3	0

Tabela 12: Comparação entre diversas caminhadas para o Robonova-I.



Figura 41: Ambiente do experimento de medida de velocidade do robô real.

15 Validação com Outro Robô

Para verificar a validade das técnicas utilizadas neste trabalho em outro modelo de robô, foi feito um procedimento análogo com o robô Nao simulado do domínio da RoboCup 3D Soccer Simulation League.

15.1 RoboCup 3D Soccer Simulation League

A **Soccer 3D!** é uma das categorias da competição RoboCup (11). Na **Soccer 3D!**, 22 agentes (11 em cada time) jogam futebol em um ambiente simulado, seguindo regras semelhantes às do futebol humano.

O simulador de Robótica utilizado é o **SimSpark!** (26). Esse simulador utiliza a **ODE! (ODE!)** (36) como sua *engine* de Física, que permite uma simulação precisa de interações mecânicas, como atrito e colisão. Isso permite modelar robôs humanoides complexos, como o Albebaran Nao (28), que possui 22 graus de liberdade. A Figura 42 mostra o robô Nao simulado dentro do **SimSpark!**.



Figura 42: Robô Nao simulado chutando uma bola no **SimSpark!**.

Diferentemente do USARSim, em que a simulação ocorre em tempo real, sendo

o passo de tempo limitado pelo poder de processamento da máquina, a simulação no **SimSpark!** ocorre a um passo fixo de 20 milisegundos. A comunicação entre agentes e servidor é por **TCP/IP!** (**TCP/IP!**) de acordo com um protocolo específico.

Um dos objetivos da competição é fomentar pesquisas em controle de humanoides, assim a atuação é feita a partir do envio de comandos de velocidade para as juntas. Note que a implementação de controle de posição para as juntas fica a cargo do agente. A Figura 43 apresenta um esquema das juntas do Nao simulado.

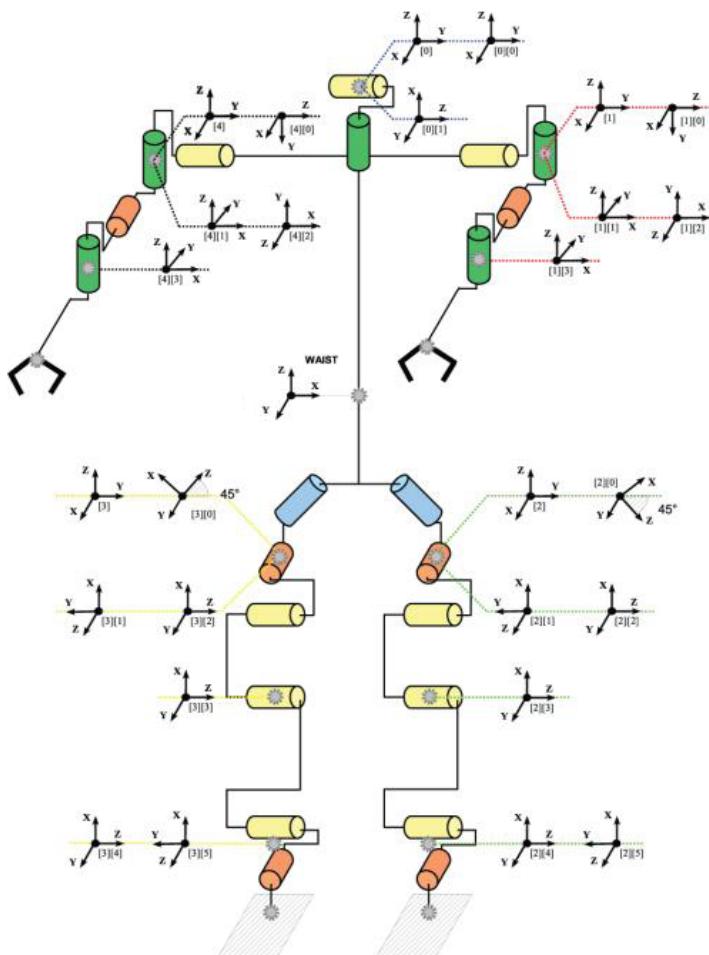


Figura 43: Esquema das juntas do Nao simulado do **SimSpark!**.

Já a visão é simplificada e não é necessário fazer processamento de imagem, pois o servidor envia medidas de distância e ângulo para cada objeto dentro do campo de visão do agente (que abrange 120° na horizontal). Outros sensores (acelerômetro, girômetro, sensores de pressão nos pés etc.) presentes no Nao real estão também presentes nessa versão simulada. Note que ruído é adicionado às medidas dos sensores para simular o que ocorre no caso de sensores reais. Ademais, para se comunicarem entre si, os agentes podem “falar” e “ouvir” mensagens

limitadas a 20 bytes.

15.2 Implementação

Como trata-se de uma competição, a **Soccer 3D!** possui uma comunidade de tamanho razoável. Alguns times mais experientes liberam códigos de agentes base para servir de exemplo e facilitar a entrada de novos times.

Como o objetivo era apenas usar a **Soccer 3D!** para validação das técnicas utilizadas e não construir um novo programa de agente, optou-se pelo uso de um time base. Após a análise de alguns dos códigos provados em (35), escolheu-se o **magma-AF!** (**magma-AF!**), que é desenvolvido pelo time magmaOffenburg da Hochschule Offenburg University of Applied Sciences. O código do **magma-AF!** é escrito em Java com o uso de boas práticas de Engenharia de Software.

O **magma-AF!** é um agente funcional que joga futebol de modo autônomo com uma estratégia bem simples. Assim, várias das questões de baixo nível necessárias foram aproveitadas: comunicação com o servidor, controlador de posição, verificação de se o robô caiu etc.

Entretanto, no **SimSpark!**, o Nao não possui um sensor que dê a localização global do agente, assim como faz o GroundTruth do USARSim. Desse modo, o agente deve inferir sua posição a partir das medidas dos sensores que possui, principalmente da câmera. Considerando que o problema de Localização é um dos mais complexos da Robótica Móvel e que o **magma-AF!** usa um método muito simples de localização, as estimativas de posição feitas pelo agente certamente não seriam adequadas para o processo de treinamento.

A solução para isso foi implementar o que geralmente é chamado na liga de “treinador”. Esse treinador se conecta ao servidor como se fosse um monitor (um programa para visualização do jogo), logo recebe posições e orientações globais de todos os objetos. Com isso, pode-se obter a posição do agente desejado. O treinador implementado foi inspirado no código provido em (39). Para facilitar a troca de informações, optou-se por implementar o treinador no mesmo processo Java do agente, mas sendo executado em uma *thread* própria.

Depois disso, a caminhada com Modelo Complexo foi implementada conforme as estruturas providas pelo **magma-AF!**.

15.3 Processo de Otimização

O processo de otimização foi montado de modo semelhante ao explicado no Capítulo 13, inclusive a função de medida de qualidade utilizada foi a mesma. No caso, executou-se otimização apenas para o Modelo Complexo e com **PSO!**. Os parâmetros usados para o **PSO!** foram os apresentados na Tabela 13. Os limites para do espaço de busca são mostrados na Tabela 14.

Parâmetro	Valor
P	50
ω	0,7
φ_p	0,5
φ_g	0,8
ε	0,8

Tabela 13: Valores dos parâmetros da execução de **PSO!** para otimização dentro do domínio da **Soccer 3D!**.

Constante	Mínimo	Máximo
O_c	-1,0	0
A	0,01	1,0
B	0,01	1,0
O_j	0	1,5
C	0	1,5
$\tau = t_2/T$	0,1	0,9
T	0,1	2,0
D_+	0	1
D_-	0	1
E	0	0,5

Tabela 14: Limites do espaço de busca para no caso da otimização realizada dentro da domínio da **Soccer 3D!**.

A Figura 44 apresenta como o melhor desempenho até então varia com o número de testes. A Tabela 15 mostra os valores da melhor partícula encontrada, que foi avaliada com qualidade igual a 9,39. Por fim, a Figura 45 mostra uma sequência de imagens apresentando a caminhada aprendida.

Para avaliar o desempenho da caminhada aprendida, decidiu-se compará-la com a caminhada provida no **magma-AF!**. Assim, executou-se 10 experimentos simulados de 15 segundos para cada caminhada. Ao fim dos 15 segundos, a distância percorrida pelo robô no sentido positivo do eixo X era medida. A Tabela 16 resume

Constante	Valor
O_c	-0,36
A	0,51
B	0,21
O_j	0,81
C	0,72
$\tau = t_2/T$	0,36
T	0,27
D_+	0,23
D_-	0,31
E	0,12

Tabela 15: Parâmetros aprendidos para o Modelo Complexo executado no Nao simulado do **SimSpark!**.

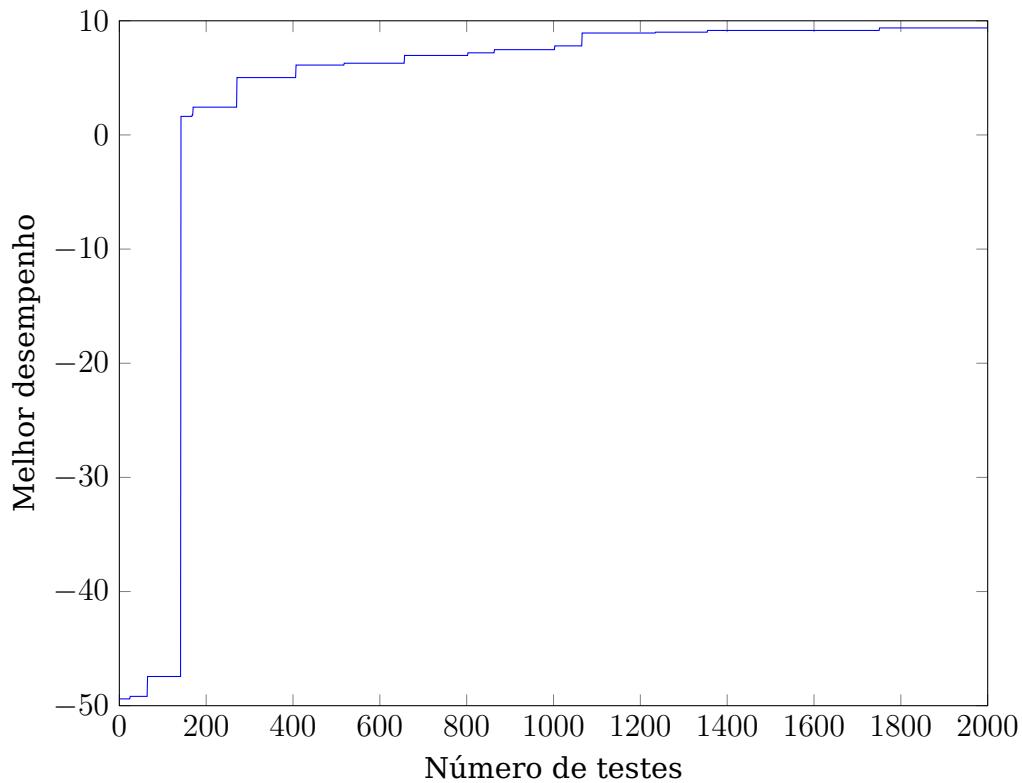


Figura 44: Resultados da otimização com **PSO!** realizada no ambiente da **Soccer 3D!**.

os resultados obtidos. Observe que a caminhada aprendida é bem superior à do time base, sendo 89% mais rápida.

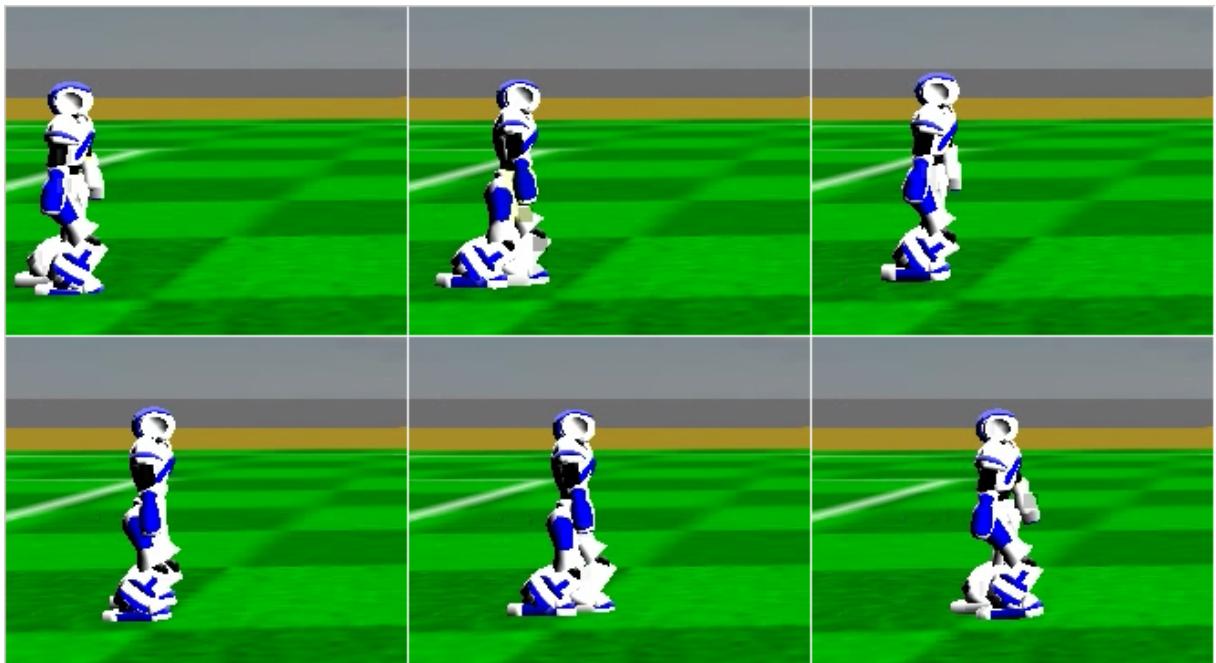


Figura 45: Sequência de imagens para ilustrar a caminhada aprendida para o Nao simulado do **SimSpark!**. Há uma diferença de tempo de 0,1 segundo entre uma imagem e a posterior.

	Caminhada	Média	Desvio Padrão
Modelo Complexo	7,41	0,55	
magma-AF	3,93	0,4	

Tabela 16: Resultados de medidas de distâncias percorridas no sentido positivo do eixo X. Realizou-se 10 experimentos de 15 segundos para cada caminhada.

16 Conclusões e Trabalhos Futuros

16.1 Conclusão

Nesse trabalho, caminhadas rápidas e estáveis foram confeccionadas para um robô Hitec Robonova-I. Para isso, usou-se um modelos parametrizados baseados em **SFT!** (**SFT!**) propostos em (33, 32, 34). Na abordagem seguida, parâmetros adequados para os modelos foram aprendidos com uso de 2 algoritmos de otimização: **AG!** (**AG!**) e **PSO!** (**PSO!**). Como aprendizado de locomoção diretamente no robô seria inconveniente e poderia provocar danos ao *hardware*, construiu-se um modelo do Robonova-I no **USARSim!** (**USARSim!**) e realizou-se o processo de aprendizado em simulação. Então, adaptou-se as caminhadas aprendidas para o robô real por ajustes manuais. Testes realizados com a melhor caminhada obtida mostraram que seu desempenho é bem superior à caminhada original do fabricante.

Posteriormente, uma validação adicional foi feita no domínio da **Soccer 3D!** (**Soccer 3D!**), que é uma categoria de futebol de robôs humanóides simulado da competição RoboCup. A **Soccer 3D!** é baseada no **SimSpark!** (**SimSpark!**) e atualmente usa um modelo simulado do robô Aldebaran Nao. Para evitar o desenvolvimento de uma interface com o **SimSpark!**, como foi feito no caso do **USARSim!**, utilizou-se o código base **magma-AF!** (**magma-AF!**). Assim, o processo de aprendizado foi executado e a melhor caminhada obtida se mostrou rápida e estável, inclusive superando significativamente o desempenho da caminhada provida no código base.

16.2 Trabalhos Futuros

Desde seu início, a intenção desse trabalho era criar uma estrutura para diversos outros trabalhos de pesquisa em robôs humanóides na instituição. Exatamente por isso, houve um cuidado especial em deixar os desenvolvimentos feitos bem documentados e em se fazer uma boa estrutura de programa de agente, embora essas questões não fossem tão importantes dentro do escopo desse trabalho.

Em relação ao controle de humanóides especificamente, são propostas as seguintes frentes de trabalho futuro:

- Implementação de outros movimentos, como levantar-se, girar o corpo etc.;
- Idealização e execução de experimentos e métricas que avaliem o quanto o comportamento do robô simulado difere do real. A partir disso, seria interessante a realização de ajustes finos no modelo de simulação a fim de se obter um comportamento o mais próximo possível do robô real;
- Em otimização heurística, é difícil determinar de antemão qual o melhor método para um determinado problema. Assim, seria interessante tentar utilizar outros métodos além de **AG!** e **PSO!**;
- Estudo, desenvolvimento e implementação de novos modelos de caminhada. Em especial, caminhadas omnidirecionais, por serem mais flexíveis;
- Estudo, desenvolvimento e implementação de estratégias de balanço com base em sensores para “fechar a malha” da caminhada e torná-la mais estável e menos suscetível a pertubações como irregularidades no solo. Para isso, seria necessário antes a adição de sensores julgados interessantes, como acelerômetro, girômetro e sensores de pressão nos pés.

Em relação a outras linhas ligadas a humanóides, o autor tem interesse especial em continuar este trabalho em uma pós-graduação no sentido de construir robôs autônomos jogadores de futebol para a liga Humanoid KidSize da RoboCup, o que na realidade era objetivo implícito desde o início. Inclusive, um grupo de alunos de já está formado dentro da ITAndroids, grupo para competições de Robótica do ITA, para este projeto.

Referências

- 1 Hitec MR-C3024 to PC Protocol for RoboNova.
- 2 Autodesk. Autodesk 3D Studio Max. <http://usa.autodesk.com/3ds-max/>, 2012. [Online; acessado em 1 de novembro de 2012].
- 3 Autodesk. Autodesk Autocad. <http://usa.autodesk.com/autocad/>, 2012. [Online; acessado em 1 de novembro de 2012].
- 4 Autodesk. Autodesk FBX. <http://usa.autodesk.com/fbx/>, 2012. [Online; acessado em 1 de novembro de 2012].
- 5 R. Auvray, B. Fabre, and P.-Y. Lagrée. Harmonics generation in flute-like instruments. In *Proceedings of the International Symposium on Musical Acoustics*, pages 40–43, 2014.
- 6 Gianmario Bollano, Donato Ettorre, and Antonio Esiliato. Method and system to improve automated emotional recognition, January 31 2007. US Patent App. 12/449,298.
- 7 David Buckley. MR-C3024 ROBOT CONTROLLER.
- 8 Juan Carlos Fernández Caballero, Francisco José Martínez, César Hervás, and Pedro Antonio Gutiérrez. Sensitivity versus accuracy in multiclass problems using memetic pareto evolutionary neural networks. *Neural Networks, IEEE Transactions on*, 21(5):750–770, 2010.
- 9 Edwin Chen. What are the advantages of different classification algorithms? <https://www.quora.com/What-are-the-advantages-of-different-classification-algorithms>. [Online; acessado em 08 de novembro de 2015].
- 10 G. F. Cooper. In *The computational complexity of probabilistic inference using Bayesian belief networks*, 1990.
- 11 RoboCup Federation. RoboCup. <http://www.robocup.org/>, 2012. [Online; acessado em 25 de outubro de 2012].
- 12 N. H. Fletcher. Acoustical correlates of flute performance technique. *Journal of the Acoustical Society of America*, pages 233–237, 1975.
- 13 N. H. Fletcher. Air flow and sound generation in musical wind instruments. *Annual Review of Fluid Mechanics*, pages 123–146, 1979.
- 14 Epic Games. Unreal Development Kit. <http://www.unrealengine.com/udk/>, 2008–2012. [Online; acessado em 25 de outubro de 2012].

- 15 Google. Chrome extensions - overview. <https://developer.chrome.com/extensions/overview>. [Online; acessado em 11 de novembro de 2015].
- 16 Gumstix. Gumstix. <http://www.gumstix.com/>, 2012. [Online; acessado em 25 de outubro de 2012].
- 17 J. H. Holland. *Adaptation in Natural and Artificial Systems*. The University of Michigan Press, 1975.
- 18 Dan Jurafsky and Christopher Manning. Practical Issues in Text Classification. <https://class.coursera.org/nlp/lecture>. [Online; acessado em 22 de setembro de 2015].
- 19 Dan Jurafsky and Christopher Manning. What is Text Classification? <https://class.coursera.org/nlp/lecture>. [Online; acessado em 20 de setembro de 2015].
- 20 Daphne Koller. Bayesian Network Fundamentals - Semantics And Factorization. <https://class.coursera.org/pgm/lecture>. [Online; acessado em 10 de outubro de 2015].
- 21 Chang-Hwan Lee, Fernando Gutierrez, and Dejing Dou. Calculating Feature Weights in Naive Bayes with Kullback-Leibler Measure. In *Data Mining (ICDM), 2011 IEEE International Conference on Data Mining*, pages 1146–1151. IEEE, 2011.
- 22 Jackson Paul Matsuura, Esther Luna Colombini, and Alexandre da Silva Simões. Desenvolvimento de Robô Humanóide Autônomo de Baixo Custo. In *Simpósio Brasileiro de Automação Inteligente (SBAI) 2007*, 2007.
- 23 P. Kevin Murphyk. A Brief Introduction to Graphical Models and Bayesian Networks. <http://www.cs.berkeley.edu/~murphyk/Bayes/bayes.html>, 1998. [Online; acessado em 04 de novembro de 2015].
- 24 Nokia. Qt. <http://qt.nokia.com/>, 2012. [Online; acessado em 28 de outubro de 2012].
- 25 Nvidia. Physx. <http://www.geforce.com/hardware/technology/physx>, 2012. [Online; acessado em 28 de outubro de 2012].
- 26 Oliver Obst and Markus Rollmann. SPARK - A Generic Simulator for Physical Multiagent Simulations. *Computer Systems Science and Engineering* 20, pages 347–356, 2005.
- 27 rbx. Kappa statistic in plain english. <http://stats.stackexchange.com/questions/82162/kappa-statistic-in-plain-english>, 2013. [Online; acessado em 10 de novembro de 2015].
- 28 Aldebaran Robotics. Nao H25: Humanoid Robot Platform. <http://www.aldebaran-robotics.com/en/Discover-NAO/nao-datasheet-h25.html>, 2012. [Online; acessado em 25 de outubro de 2012].
- 29 Hitec Robotics. Robonova-I English Instruction Manual.

- 30 Hitec Robotics. New source code with fast walk and fast turn. http://www.robonova.de/store/support/index.php?_m=downloads&_a=viewdownload&downloaditemid=93&nav=0,5,7, 2006.
- 31 Stuart Russell and Peter Norvig. *Artificial Intelligence: A Modern Approach*. Prentice Hall, 2009.
- 32 Nima Shafii, Siavash Aslani, Omid Mohamad Nezami, and Saeed Shiry. Evolution of Biped Walking Using Truncated Fourier Series and Particle Swarm Optimization. In *Baltes, J., Lagoudakis, M.G., Naruse, T.; Ghidary, S.S. (eds.) RoboCup 2009*, pages 344–354, 2010.
- 33 Nima Shafii, Ali Khorsandian, Abbas Abdolmaleki, and Bahram Jozi. An Optimized Gait Generator Based on Fourier Series Toward Fast and Robust Biped Locomotion Involving Arms Swing. In *Proceedings of the IEEE International Conference on Automation and Logistics*, 2009.
- 34 Nima Shafii, Luís Paulo Reis, and Nuno Lau. Biped Walking Using Coronal and Sagittal Movements Based on Truncated Fourier Series. In *RoboCup 2010: Robot Soccer World Cup XIV, Lecture Notes in Computer Science*, pages 324–335, 2010.
- 35 SimSpark. SimSpark Agents. <http://simspark.sourceforge.net/wiki/index.php/Agents>, 2012. [Online; acessado em 25 de outubro de 2012].
- 36 Russell Smith. Open Dynamics Engine. <http://www.ode.org/>, 2012. [Online; acessado em 25 de outubro de 2012].
- 37 Marina Sokolova and Guy Lapalme. A systematic analysis of performance measures for classification tasks. *Information Processing & Management*, 45(4):427–437, 2009.
- 38 Pang-Ning Tan, Michael Steinbach, and Vipin Kumar. Introduction to Data Mining. In *Introduction to Data Mining*, pages 145–146, 2006.
- 39 TinMan. TinMan. <http://code.google.com/p/tin-man/>, 2012. [Online; acessado em 25 de outubro de 2012].
- 40 Sander van Noort and Arnoud Visser. Validation of the dynamics of an humanoid robot in USARSim. In *Proceedings of the Performance Metrics for Intelligent Systems Workshop (PerMIS'12)*, March 2012.
- 41 Anthony J Viera, Joanne M Garrett, et al. Understanding interobserver agreement: the kappa statistic. *Fam Med*, 37(5):360–363, 2005.

FOLHA DE REGISTRO DO DOCUMENTO

1. CLASSIFICAÇÃO/TIPO TC	2. DATA	3. REGISTRO N°	4. N° DE PÁGINAS N PAGINAS
5. TÍTULO E SUBTÍTULO: Desenvolvimento de um classificador de postagens em rede social utilizando Processamento de Linguagem Natural			
6. AUTOR(ES): Luiz Filipe Martins Ramos Bernardo Monteiro Rufino			
7. INSTITUIÇÃO(ES)/ÓRGÃO(S) INTERNO(S)/DIVISÃO(ES): Instituto Tecnológico de Aeronáutica - ITA			
8. PALAVRAS-CHAVE SUGERIDAS PELO AUTOR: Inteligência Artificial, Processamento de Linguagem Natural, Redes Bayesianas			
9. PALAVRAS-CHAVE RESULTANTES DE INDEXAÇÃO: Solicite preenchimento dos campos 2, 3 e 9 – envie este formulário para doc.pt@ita.br			
10. APRESENTAÇÃO:		<input checked="" type="checkbox"/> Nacional	<input type="checkbox"/> Internacional
ITA, São José dos Campos. Curso de Graduação em Engenharia de Computação. Orientador(es): Prof. Dr. Paulo André Lima de Castro. Publicado em 2015			
11. RESUMO:			
12. GRAU DE SIGILO: <input checked="" type="checkbox"/> OSTENSIVO <input type="checkbox"/> RESERVADO <input type="checkbox"/> SECRETO			